

Relatório de Experimentos

Estudo Comparativo: LSSVM Esperso vs. Transformers Tabulares
Dissertação de Mestrado — Experimentos (atualizado em junho de 2026)

Paulo Bernardo

Junho de 2026

Sumário

1	Introdução	3
2	Auditoria da Implementação do Nyström-SVM	4
2.1	As três versões	4
2.2	Verificação experimental	5
2.3	Esparsidade reportada	5
3	Experimento Tier 1: Benchmarks Reais	6
3.1	Resultados por Dataset	6
3.2	Comparação Geral	7
3.3	Análise estatística: Friedman e ranks médios (Tier 1)	8
3.4	Ranking nos datasets reais (sem sintéticos)	8
4	Arquitetura dos FT-Transformers e Tipos de Atenção	9
4.1	Atenção inter-features (intra-instância)	9
4.2	Atenção inter-instâncias (entre amostras)	10
5	Análise de Esparsidade	10
5.1	Esparsidade amostral — LSSVMs	11
5.2	Esparsidade de atenção inter-features — FT-Transformers baselines	12
5.3	Esparsidade nos Transformers — Tier 2 ($N = 5000$)	13
6	Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)	14
7	Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)	15
8	Ablação C: Dados Sintéticos Multifeature (MK5)	16
9	Análise das Variantes Investigadas e Modelos Propostos	18
9.1	Mecanismos de esparsidade	18
9.2	Desempenho consolidado	18
9.3	Síntese comparativa	19

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$)	20
10.1 Protocolo	20
10.2 Resultados por Dataset (todos os 18 modelos)	20
10.3 Análise estatística: Friedman e ranks médios	21
10.4 Esparsidade consolidada no Tier 2	22
10.5 Colapso dos métodos primais com ℓ_1 em escala	23
10.6 FT-CUR/SAINT e a correção metodológica da H2	23
10.7 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia	25
11 Benchmark de Eficiência Computacional em <i>Full-Data</i>	26
11.1 Análise Comparativa: SAINT vs. FT-CUR em Mini-batch e Full-batch . .	27
11.2 Benchmark de Predição: LSSVMs Esparsos no Tier 2	29
12 Sumário e Próximos Passos	32
A Infraestrutura e Reprodutibilidade	33
B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)	34

1 Introdução

Este relatório consolida os resultados dos experimentos conduzidos na dissertação, que compara métodos de *Least-Squares Support Vector Machine* (LSSVM) com ênfase em esparsidade contra variantes de *FT-Transformer* com atenção esparsa em tarefas de classificação binária tabular.

O trabalho estende o algoritmo LSSVM-ADMM-Nesterov proposto por Marinho et al. com dois novos mecanismos de esparsidade: (i) **DualFISTA**, formulação dual do LSSVM como LASSO com otimização via ISTA acelerado; e (ii) **Nyström-SVM**, aproximação da matriz kernel por seleção de landmarks via norma de coluna. Como comparativo do lado dos Transformers, avalia-se o **FT-CUR**, que aplica decomposição CUR com colnorm à matriz de atenção.

Auditoria do Nyström-SVM — três versões

A implementação do Nyström-SVM passou por três versões. A versão final, auditada matematicamente (Seção 2), é a apresentada neste relatório.

Versão	Predição	F1 Tier 1
Bug original	$f(x)=K(x, X_{\text{treino}})\alpha + b$ (kernel completo)	0,8427 (inflado)
“Fix” errado	$f(x)=K(x, Z)\alpha[\text{lm_idx}] + b$ (subset ingênuo de α)	0,6678 (colapsado)
Correta	$f(x)=K(x, Z)(W^{-1}C^T\alpha) + b$ (Nyström)	0,8342

A versão correta usa a fórmula matemática da aproximação Nyström ($\tilde{K} = CW^{-1}C^T$), com custo $O(n_{\text{test}} \cdot m)$ e **sem dependência de X_{treino} na predição** (verificado experimentalmente). A perda de F1 em relação ao bug original é de apenas 0,0085, mas agora com $\approx 78\%$ de esparsidade amostral genuína (Grid+CV, Tier 1).

Modelos avaliados

Ao todo, 18 modelos foram avaliados, organizados em cinco grupos por origem na literatura:

- **Baseline geral tabular (1): XGBoost** (Chen & Guestrin, 2016) — padrão-ouro para dados tabulares, serve como referência externa às famílias LSSVM e Transformer.
- **LSSVMs baselines (7):** LSSVM-Std (sem esparsidade), LSSVM-PCP, LSSVM-FSA, LSSVM-IP, LSSVM-Pruning, LSSVM-OppMaps, e **FISTA-Nesterov** (LSSVM primal com FISTA — método clássico de Beck & Teboulle, 2009, amplamente documentado).
- **FT-Transformers baselines (5):** variantes com atenção softmax, top- k , entmax e sparsemax — mais **SAINT** (Somepalli et al., 2021; atenção inter-instâncias densa).
- **Paper-base estendido: LSSVM-ADMM-Nesterov** de Marinho et al. — método sobre o qual esta dissertação constrói.
- **Variantes investigadas e modelos propostos (4):**
 - **ADMM-ElasticNet^o**: variante do paper-base com penalidade Elastic Net (combinação ADMM-Nesterov + Elastic Net + LSSVM não localizada explicitamente na literatura como método publicado).

- **DualFISTA**[◦]: formulação dual do LSSVM como LASSO ($\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \|\alpha\|_1$), otimizada via FISTA. Ponto de investigação — não localizada na literatura nesta forma exata; pode ser uma reformulação convergente com métodos análogos em SVM ou regressão Lasso.
- **Nyström-SVM (colnorm)**^{*}: aproxima $K \in \mathbb{R}^{n \times n}$ via $m \ll n$ landmarks selecionados por norma de coluna (em vez de amostragem uniforme/leverage tradicional); predição restrita aos landmarks ($O(n_{\text{test}} \cdot m)$, auditada).
- **FT-CUR (Nyströmformer)**^{*}: aplicação de Nyströmformer (Xiong et al., 2021) à atenção inter-instâncias do FT-Transformer em dados tabulares; seleção de landmarks via colnorm (combinação não localizada como método publicado).

[◦] = variante/ponto de investigação; ^{*} = aplicação/combinação proposta.

Protocolo experimental

- 30 sementes aleatórias, partição estratificada 70/30.
- Métrica principal: F1-macro (média aritmética do F1 por classe).
- Hiperparâmetros otimizados via **Grid Search exaustivo + 5-fold CV** estratificado (**GridSearchCV**, scikit-learn) para todos os 18 modelos no Tier 1 (Transformers re-executados com `epochs=40`, `patience=6` em GPU T4). Todos os modelos Tier 2 utilizam Optuna TPE (20 trials, 3-fold CV).
- Normalização por **StandardScaler** ajustado apenas no treino.

2 Auditoria da Implementação do Nyström-SVM

2.1 As três versões

O Nyström-SVM aproxima a matriz kernel completa $K \in \mathbb{R}^{n \times n}$ a partir de m landmarks $\{z_1, \dots, z_m\}$ selecionados antes do treino:

$$K \approx C W^{-1} C^{\top}, \quad C = K(X, Z) \in \mathbb{R}^{n \times m}, \quad W = K(Z, Z) \in \mathbb{R}^{m \times m}.$$

O treinamento, via identidade de Woodbury, é correto em todas as versões. A diferença está apenas na predição:

V1 — Bug original. Predizia com o kernel completo:

$$f(x) = K(x, X_{\text{treino}}) \alpha + b.$$

Não tinha esparsidade real (todo X_{treino} era usado em inferência) e produzia $F_1 = 0,8427$ no Tier 1.

V2 — “Fix” ingênuo. Tentativa de restringir aos landmarks pegando apenas o subset de α nos índices dos landmarks:

$$f(x) = K(x, Z) \alpha[\text{lm_idx}] + b.$$

Está **matematicamente errado**: os pesos $\alpha \in \mathbb{R}^n$ foram ajustados para o sistema KKT completo n -dimensional, e simplesmente subetá-los nos índices dos landmarks não recupera a aproximação Nyström. F1 colapsou para 0,6678.

V3 — Correta (atual). A aproximação Nyström verdadeira é $\tilde{K}(x, X) = K(x, Z) W^{-1} C^\top$. Substituindo em $f(x) = \tilde{K}(x, X) \alpha + b$:

$$f(x) = K(x, Z) (W^{-1} C^\top \alpha) + b = K(x, Z) w_\alpha + b, \quad w_\alpha = W^{-1} C^\top \alpha \in \mathbb{R}^m.$$

O vetor w_α é calculado uma vez ao final do fit e cacheado. Em inferência, só $K(x, Z) \in \mathbb{R}^{n_{\text{test}} \times m}$ é computado — não há mais nenhuma dependência de X_{treino} . F1 = 0,8342.

2.2 Verificação experimental

A implementação V3 foi auditada matematicamente (`scripts/audit_nystrom_lssvm.py`) confirmando três propriedades:

1. **Equivalência matemática.** $\|f_{\text{cache}}(x) - f_{\text{Nyström}}(x)\|_2 = 0$ exatamente, onde $f_{\text{Nyström}}$ usa a fórmula expandida $K(x, Z) W^{-1} C^\top \alpha + b$.
2. **Sem dependência de X_{treino} .** Após o fit, ao apagar X_{treino} do modelo, as predições continuam idênticas ($\|\Delta f\|_2 = 0$). Confirma que apenas Z é usado na inferência.
3. **Custo $O(n_{\text{test}} \cdot m)$.** Mantendo m fixo e variando n_{treino} de 1000 a 6000, o tempo de predição permanece em ≈ 5 ms (não escala com n).

Tabela 1: Comparação direta no BCW (10 sementes, mesmos hiperparâmetros).

Versão	F1 BCW	Diagnóstico
V1 (kernel completo)	0,974	0% de esparsidade real
V2 (α subsetado)	0,360	matematicamente inválida
V3 ($W^{-1} C^\top \alpha$, atual)	0,968	$\approx 80\%$ esparsidade real

A V3 perde apenas 0,006 em relação ao kernel completo no BCW, mostrando que a aproximação Nyström com seleção colnorm é *genuinamente* boa quando bem tunada — a esparsidade não custa quase nada de F1.

2.3 Esparsidade reportada

Com a predição V3, a esparsidade do Nyström-SVM é semanticamente consistente com os demais LSSVMs:

- **ADMM/FISTA:** esparsidade = fração de $\alpha_i = 0$.
- **Nyström:** esparsidade = $1 - m/n$, fração de pontos de treino *não* usados como landmark-key.

A razão m/n é tunada por Grid+CV por dataset; a esparsidade resultante varia entre 50% (TWC) e 92% (PID), com média 78% no Tier 1.

3 Experimento Tier 1: Benchmarks Reais

Nove conjuntos de dados foram utilizados (Tabela 2). Os três últimos (TWS, TWM, TWC) são sintéticos bidimensionais incluídos como controle com fronteiras de decisão conhecidas.

Tabela 2: Conjuntos de dados — Tier 1.

ID	Nome	N	Features	Domínio
BCW	Breast Cancer Wisconsin	569	30	Diagnóstico médico
PID	Pima Indians Diabetes	768	8	Diagnóstico médico
HAB	Haberman Survival	306	3	Sobrevivência
VCP	Vehicle Coupon Purchase	1584	7	Marketing
GCR	German Credit Risk	1000	20	Crédito
AUS	Australian Credit	690	14	Crédito
TWS	Two Spirals (sintético)	400	2	Controle
TWM	Two Moons (sintético)	400	2	Controle
TWC	Checkerboard (sintético)	400	2	Controle

3.1 Resultados por Dataset

A Tabela 3 apresenta o F1-macro médio (30 sementes) para *todos* os modelos, usando Grid Search exaustivo + 5-fold CV (GridSearchCV, scikit-learn) para todos os modelos incluindo Transformers (re-executados em GPU T4 no Kaggle). Os melhores valores por coluna estão em negrito.

Tabela 3: F1-macro médio (30 sementes, Grid+CV). **Negrito**: melhor por coluna. ◦ = variante investigada; ★ = proposta.

Modelo	BCW	PID	HAB	VCP	GCR	AUS	TWS	TWM	TWC	Média
<i>Baseline geral tabular</i>										
XGBoost	0,958	0,724	0,559	0,804	0,691	0,862	0,944	0,984	0,912	0,826
<i>Baselines LSSVM</i>										
LSSVM-Std	0,973	0,732	0,566	0,827	0,691	0,861	0,994	0,997	0,898	0,838
LSSVM-FSA	0,966	0,732	0,550	0,811	0,680	0,855	0,987	0,997	0,879	0,829
LSSVM-IP	0,969	0,718	0,546	0,828	0,681	0,857	0,992	0,996	0,897	0,832
LSSVM-PCP	0,916	0,717	0,627	0,783	0,684	0,849	0,990	0,993	0,880	0,827
FISTA-Nesterov	0,823	0,682	0,609	0,755	0,552	0,829	0,971	0,989	0,877	0,787
LSSVM-Prun	0,969	0,642	0,493	0,816	0,628	0,851	0,989	0,997	0,891	0,808
LSSVM-OppM	0,951	0,463	0,454	0,715	0,550	0,815	0,986	0,991	0,907	0,759
<i>Baselines FT-Transformer</i>										
FT-Sparsemax	0,950	0,696	0,560	0,794	0,653	0,857	0,632	0,962	0,474	0,731
SAINT	0,945	0,712	0,534	0,815	0,669	0,857	0,641	0,942	0,460	0,731
FT-Entmax	0,959	0,698	0,554	0,800	0,667	0,861	0,625	0,960	0,482	0,734
FT-Softmax	0,954	0,688	0,553	0,803	0,675	0,855	0,625	0,946	0,471	0,730
FT-TopK	0,951	0,668	0,537	0,756	0,648	0,855	0,630	0,884	0,476	0,712
<i>Paper-base estendido</i>										
LSSVM-ADMM-Nesterov	0,872	0,688	0,623	0,765	0,592	0,840	0,971	0,988	0,881	0,802
<i>Variantes investigadas / propostos</i>										
DualFISTA◦	0,964	0,726	0,574	0,831	0,642	0,851	0,993	0,997	0,901	0,831
Nyström-SVM★	0,970	0,728	0,579	0,825	0,691	0,863	0,992	0,999	0,898	0,838
ADMM-ElasticNet◦	0,872	0,687	0,623	0,764	0,592	0,840	0,971	0,988	0,881	0,802
FT-CUR★ (Nyströmformer)	0,949	0,704	0,559	0,815	0,672	0,856	0,624	0,974	0,487	0,738

3.2 Comparação Geral

A Figura 1 mostra o F1-macro médio ($\pm$ dp) agregado sobre todos os datasets e sementes para cada modelo.




Figura 1: F1-macro médio $\pm$ dp (30 sementes $\times$ 9 datasets). ★ indica modelos propostos; vermelho = DualFISTA, verde = Nyström-SVM, laranja = FT-CUR.

Observações principais (Grid+CV):

- **Nyström-SVM** (0,838) é o modelo com melhor F1-macro médio, empatado estatisticamente com LSSVM-Std (0,838). DualFISTA segue próximo (0,831) e LSSVM-IP (0,832). Com $\approx 78\%$ de esparsidade amostral, o Nyström-SVM valida o trade-off F1/esparsidade como o melhor entre modelos de alta compressão.
- **DualFISTA** (0,831) alcança F1-macro médio próximo ao LSSVM-Std completo (0,838, diferença 0,007) com $\approx 10\%$ de esparsidade. É o único modelo esparsa da família dual que se aproxima do baseline sem esparsidade.
- **XGBoost** (baseline tabular) atinge 0,826 no Tier 1 — agora competitivo com os LSSVMs esparsos (IP 0,832, PCP 0,827). Destaque para TWC (0,912, melhor por coluna): o Grid+CV encontrou parâmetros que capturam a fronteira xadrez, eliminando o colapso observado no protocolo Optuna anterior (0,476). Perde em AUS e nos dados sintéticos TWS/TWM para os LSSVMs com kernel RBF.
- O **LSSVM-ADMM** e ADMM-ElasticNet ficam ≈ 4 pp abaixo do LSSVM-Std (0,802 ambos). **FISTA-Nesterov** (0,787) cai mais acentuadamente (≈ 5 pp) após reexecução com grade estendida de λ — resultado do CV selecionar λ menores que maximizam F1 com baixa regularização.
- **LSSVM-Pruning** (0,808) recuperou-se significativamente com a correção do grid (adição de pruning_rate= 0,05 e sigma= 15): era 0,782 no protocolo Optuna.
- **Transformers** (Grid+CV, 40 épocas, GPU T4) ficam em 0,712–0,738 de F1 médio — 10–13 pp abaixo do bloco líder LSSVM. O colapso concentra-se nos datasets sintéticos:

TWC melhor transformer (0,487, FT-CUR) contra Nyström-SVM 0,898; TWS 0,641 vs 0,994. Nos datasets reais os Transformers são competitivos (ver Seção 3.4).

- **FT-CUR** (0,738) é o melhor Transformer, empatado em rank com FT-Entmax (0,734). FT-CUR comprime $\approx 85\%$ da atenção inter-instâncias mantendo F1 superior ao SAINT denso (0,731): **a compressão não custa F1** também no protocolo rigoroso.

3.3 Análise estatística: Friedman e ranks médios (Tier 1)

O teste não-paramétrico de Friedman aplicado às 18 variantes (12 LSSVM+XGBoost + 6 Transformers) sobre os 9 datasets confirma diferença estatisticamente significativa entre os modelos: $\chi^2 = 66,20$, $p \approx 0$. A diferença crítica de Nemenyi para $\alpha = 0,05$ é $CD = 8,78$.

Tabela 4: Ranks médios de Friedman (menor = melhor).

Rank	Model	Avg. rank
1	XGBoost	1.000
2	LSSVM (Standard)	2.833
3	LSSVM-Nystrom	3.333
4	LSSVM-IP	4.333
5	LSSVM-PCP	5.333
6	LSSVM-DualFISTA	6.333
7	LSSVM-FSA	6.833
8	ADMMNystromLSSVM	6.833
9	FISTANystrom	8.167

Leitura dos ranks: Nyström-SVM (rank 2,8) e LSSVM-Std (3,3) formam o topo do ranking. DualFISTA desceu para rank 5,6 (era 3,4 antes da reexecução com grade de λ corrigida) mas permanece próximo de LSSVM-IP (5,7) e dentro da diferença crítica. XGBoost (rank 6,7) é o melhor modelo não-kernel e não-Transformer. Os Transformers ficam na metade inferior do ranking (ranks 10,9–14,1): FT-Entmax (rank 10,9) é o melhor Transformer, seguido de FT-CUR (11,0), FT-Sparsemax (11,6) e SAINT (12,0). LSSVM-ADMM (11,7) e LSSVM-ADMM-EN (11,9) intercalam-se entre os Transformers. LSSVM-FISTA (13,3) e FT-TopK (14,1) são os piores modelos. O colapso dos Transformers nos datasets sintéticos TWS/TWM/TWC — onde a fronteira de decisão exige inductive bias geométrico que a atenção não possui — é o principal responsável pelos ranks baixos.

3.4 Ranking nos datasets reais (sem sintéticos)

Para isolar o efeito do inductive bias geométrico, repetiu-se a análise de Friedman excluindo os três datasets sintéticos (TWS, TWM, TWC) e considerando apenas os seis datasets reais (BCW, PID, HAB, VCP, GCR, AUS).

Resultado: $\chi^2 = 87,40$, $p \approx 0$, $CD \approx 10,8$ (18 modelos $\times$ 6 datasets; CD maior que no caso de 9 datasets por menor número de blocos).

Rank	Modelo	Avg. rank	F1 médio
1	LSSVM-Nyström	2,667	0,776
2	LSSVM-Std	3,333	0,775
3	XGBoost	5,833	0,766
3	LSSVM-IP	5,833	0,766
5	LSSVM-DualFISTA	7,167	0,765
6	LSSVM-FSA	7,333	0,766
7	FT-Entmax	8,667	0,757
8	LSSVM-PCP	9,000	0,763
9	FT-CUR	9,167	0,759
10	FT-Sparsemax	10,000	0,752
10	SAINT	10,000	0,755
10	FT-Softmax	10,000	0,755
13	LSSVM-Pruning	11,500	0,733
14	LSSVM-ADMM-EN	12,833	0,730
15	LSSVM-ADMM	13,000	0,730
16	FT-TopK	13,167	0,736
17	LSSVM-FISTA	14,667	0,708
18	LSSVM-OppMaps	16,833	0,658

Interpretação: sem os datasets sintéticos, os Transformers sobem significativamente no ranking. FT-Entmax (rank 8,7) e FT-CUR (rank 9,2) superam LSSVM-PCP, LSSVM-Pruning, LSSVM-ADMM e LSSVM-FISTA. A diferença entre o melhor LSSVM (Nyström, rank 2,7) e o melhor Transformer (FT-Entmax, rank 8,7) é $6,0 < CD \approx 10,8$, portanto **não é estatisticamente significativa** para $\alpha = 0,05$. DualFISTA desce para rank 7,2 (era 3,8 antes do rerun), mas permanece acima dos Transformers.

Conclui-se que o fraco desempenho global dos Transformers no Tier 1 é *quase inteiramente explicado pelo colapso nos datasets sintéticos*. Em dados tabulares reais, Transformers e LSSVMs com kernel são estatisticamente equivalentes no topo. A escolha entre as duas famílias deve ser guiada pelo tipo de dado: para dados com estrutura geométrica não-linear e N pequeno, kernel methods dominam; para dados tabulares heterogêneos reais, Transformers são alternativas viáveis.

4 Arquitetura dos FT-Transformers e Tipos de Atenção

Esta seção esclarece a distinção entre os dois mecanismos de atenção presentes nos modelos baseados em Transformer avaliados, terminologia necessária para interpretar corretamente as medidas de esparsidade.

4.1 Atenção inter-features (intra-instância)

Os FT-Transformers baselines (softmax, top- k , entmax, sparsemax) implementam **atenção entre features de uma mesma instância**. Dado um batch de n amostras com d features, cada instância $x_i \in \mathbb{R}^d$ é representada como uma sequência de d tokens após embedding. A atenção opera na dimensão dos tokens:

$$A^{(i)} = \text{softmax}\left(\frac{Q^{(i)}(K^{(i)})^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{d \times d},$$

onde $A^{(i)}$ indica quanta atenção a feature j dá à feature k dentro da instância i . As variantes esparsas (sparsemax, top- k) fazem $A^{(i)}$ ter entradas exatamente zero. Esta esparsidade *não* envolve comparação entre amostras distintas — é **intra-instância**.

4.2 Atenção inter-instâncias (entre amostras)

SAINT e **FT-CUR** acrescentam (ou substituem) um mecanismo de atenção entre instâncias distintas. Todas as n amostras do contexto são comparadas entre si:

$$A = f\left(\frac{QK^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{n \times n},$$

onde cada entrada A_{ij} mede a influência da amostra j sobre a amostra i .

SAINT vs. FT-CUR: atenção inter-instâncias densa vs. comprimida

- **SAINT** usa $f = \text{softmax}$ completo: $A \in \mathbb{R}^{n \times n}$ é materializada integralmente. Custo: $O(n^2d)$ por cabeça. Sem zeros exatos $\Rightarrow$ esparsidade de compressão = 0%. Serve como **baseline denso** para a comparação com FT-CUR.
- **FT-CUR (Nyströmformer)** evita materializar A ao todo: seleciona $m \ll n$ landmarks por norma de coluna e computa três produtos menores com softmax separado:

$$C = \text{softmax}\left(\frac{QK_m^\top}{\sqrt{d_h}}\right)[n \times m], \quad R = \text{softmax}\left(\frac{Q_mK^\top}{\sqrt{d_h}}\right)[m \times n], \quad W = \text{softmax}\left(\frac{Q_mK_m^\top}{\sqrt{d_h}}\right)[m \times m]$$

Saída: $\text{out} = C(W^+(RV))$ da direita para a esquerda — custo $O(nmd)$, nunca $O(n^2d)$. Compressão inter-instâncias: $1 - m/n$.

A atenção inter-features (softmax/topk/entmax/sparsemax) e a atenção inter-instâncias (SAINT/FT-CUR) são **ortogonais**: SAINT e FT-CUR incluem ambas (bloco inter-features padrão + bloco inter-instâncias), enquanto os FT-Transformers baselines têm apenas a inter-features.

5 Análise de Esparsidade

Os modelos avaliados produzem três tipos qualitativamente distintos de esparsidade:

- **Esparsidade amostral** (LSSVMs): fração de amostras de treino *não* utilizadas na predição. Para ADMM/FISTA, é a fração de $\alpha_i = 0$; para Nyström-SVM, é $1 - m/n$. Mede compressão do modelo em vetores de suporte.
- **Esparsidade de atenção inter-features**: fração de pesos da atenção *intra-instância* exatamente zero (sparsemax, top- k). Mede seletividade de features, não compressão de amostras.
- **Compressão inter-instâncias** (FT-CUR): fração $1 - m/n$ de amostras não usadas como landmark-key na atenção Nyströmformer. Análogo ao Nyström-SVM, mas na dimensão de atenção em vez da predição kernel.

5.1 Esparsidade amostral — LSSVMs

Tabela 5: Trade-off esparsidade amostral $\times$ desempenho (LSSVMs, Tier 1). Ordenado por F1-macro decrescente.

Modelo	F1-macro	Spar. amostral	Mecanismo
Nyström-SVM*	0,838	78,1%	colnorm landmarks (m/n tunado por dataset)
LSSVM-Std	0,838	0,0%	— (baseline denso)
LSSVM-IP	0,832	46,1%	iterative pruning
DualFISTA*	0,831	10,3%	ℓ_1 dual via FISTA
LSSVM-FSA	0,829	54,6%	seleção forward
LSSVM-PCP	0,827	0,0%	cone projection
LSSVM-Prun	0,808	62,9%	pruning iterativo $c/$ <i>early stop</i>
LSSVM-ADMM*	0,802	24,4%	ℓ_1 primal (ADMM-Nesterov)
ADMM-ElasticNet*	0,802	24,5%	$\ell_1 + \ell_2$ (Elastic Net)
FISTA-Nesterov*	0,787	18,0%	ℓ_1 primal via FISTA
LSSVM-OppM	0,759	78,9%	opposite maps




Figura 2: Trade-off esparsidade amostral $\times$ F1-macro (LSSVMs). ★ = modelos propostos.

Análise (Grid+CV):

- **Nyström-SVM** (78% de esparsidade, F1= 0,838) é o melhor resultado geral: mais esparsa que no protocolo Optuna (era 69%, agora 78% — o grid expandido de m_ratio descobriu razões mais baixas) sem custo preditivo em relação ao LSSVM-Std denso.

- **DualFISTA** atinge 10,3% de esparsidade (era 20% com Optuna) porque o Grid+CV seleciona λ menores que maximizam F1 com pouca regularização. A perda em F1 é 0,007 — pequena mas perceptível.
- Os métodos ADMM/FISTA (primal) apresentam esparsidade 18–24% no novo protocolo: ADMM-N e ADMM-EN com 24,4–24,5%, FISTA-Nesterov com 18%. A queda em F1 em relação ao LSSVM-Std é ≈ 4 –5 pp.
- **LSSVM-Prun** (62,9%, F1= 0,808) recuperou-se significativamente com a correção do grid (`pruning_rate`= 0,05, $\sigma = 15$): era 0,782 (71,6%) no protocolo Optuna. A poda agressiva só é sustentável com grid que cubra taxas baixas de poda.
- **LSSVM-OppM** (78,9%) mantém o maior nível de esparsidade mas paga ≈ 8 pp em F1 relativo ao LSSVM-Std: sem *early stopping*, a heurística de mapas opostos não recupera a fronteira de decisão.

5.2 Esparsidade de atenção inter-features — FT-Transformers baselines

Nota: esparsidade inter-features vs. compressão inter-instâncias

Os FT-Transformers baselines (softmax, topk, entmax, sparsemax) têm atenção *intra-instância* — fração de pesos zerados mede seletividade de features. **SAINT** adiciona atenção inter-instâncias com softmax completo ($n \times n$): sem zeros exatos, compressão = 0% (baseline denso). **FT-CUR** substitui o softmax $n \times n$ pelo Nyströmformer (m landmarks, colnorm): nunca materializa $A^{n \times n}$, compressão = $1 - m/n \approx 80\%$.

Tabela 6: Esparsidade de atenção inter-features (baselines FT) e compressão inter-instâncias (SAINT/FT-CUR). Tier 1, média sobre 9 datasets e 30 sementes.

Modelo	F1-macro	Spar. feat.	Compr. inst.	Mecanismo
<i>Atenção inter-features (intra-instância)</i>				
FT-TopK	0,712	79,8%	—	top- k fixo ($k=2$ de $d+1$ tokens)
FT-Sparsemax	0,731	41,4%	—	sparsemax (zeros exatos)
FT-Entmax	0,734	1,1%	—	entmax (poucos zeros exatos)
FT-Softmax	0,730	0,0%	—	softmax (nunca exatamente zero)
<i>Atenção inter-instâncias</i>				
SAINT	0,731	—	0%	softmax $n \times n$ completo (baseline denso)
FT-CUR*	0,738	—	85,2%	Nyströmformer, $m/n \approx 0,15$, $O(nmd)$

Análise:

- **FT-TopK** (76,8%) e **FT-Sparsemax** (39,1%) produzem esparsidade de atenção inter-features genuína, mas ela não se traduz em ganho de F1 — ambos ficam abaixo ou muito próximos do FT-Softmax denso em média.

- **FT-Entmax** (1,4%) produz poucos zeros na prática: apesar de ser conceitualmente esparsos, a entmax com $\alpha=1,5$ raramente satura em zero para os datasets avaliados.
- **SAINT** (0,731, denso) e **FT-CUR** (0,738, 85,2% de compressão) atingem F1 essencialmente idêntico — diferença de apenas 0,007. Isso valida empiricamente o Nyströmformer: **comprimir $\approx 85\%$ da atenção inter-instâncias não custa F1**. A aproximação $\tilde{A} = C(W^+ R) V$ via softmax separado é fiel à atenção completa $A = \text{softmax}(QK^\top / \sqrt{d}) V$ na prática.
- Comparado aos FT-Transformers baselines (sem atenção inter-instâncias), SAINT e FT-CUR ficam ligeiramente acima de FT-Softmax/Entmax/TopK e abaixo do FT-Sparsemax. A atenção inter-instâncias não é, isoladamente, suficiente para superar as variantes esparsas no nível feature.

5.3 Esparsidade nos Transformers — Tier 2 ($N = 5000$)

A transição para o Tier 2 ($N = 5000$) permitiu analisar o comportamento de esparsidade dos Transformers em um regime de dados mais desafiador. A Tabela 7 detalha a fração média de zeros na atenção inter-features (`mean_zero_fraction`) e a compressão de instâncias do FT-CUR.

Tabela 7: Esparsidade de atenção e compressão nos Transformers (Tier 2). Valores agregados dos experimentos $N=5000$ com `val_loss`.

Modelo	F1-macro	Métrica de Esparsidade	Valor
FT-TopK	0,720	Atenção inter-features (zeros)	89,2%
FT-Sparsemax	0,723	Atenção inter-features (zeros)	75,2%
FT-Entmax	0,723	Atenção inter-features (zeros)	18,5%
FT-Softmax	0,724	Atenção inter-features (zeros)	2,5%
SAINT	0,722	Compressão inter-instâncias	0,0% (Dense)
FT-CUR*	0,713	Compressão inter-instâncias	89,4%

Análise:

- A métrica `mean_zero_fraction` revela que as variantes com indução de esparsidade (TopK e Sparsemax) conseguem zerar agressivamente os pesos de atenção para features não-informativas (89,2% e 75,2%, respectivamente), atuando como um forte seletor de features nativo sem degradar a performance preditiva ($F_1 \approx 0,72$).
- O **FT-CUR** demonstra que a aproximação de Nyström na dimensão de instâncias atinge **89,4% de compressão** da matriz de atenção, entregando um F_1 de 0,713 (superior ao baseline do LSSVM denso). Isso consolida a eficácia do Nyström tanto para a família SVM (Nyström-LSSVM) quanto para a família Deep Learning (FT-CUR).

6 Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)

Motivação: Investigar se os Transformers melhoram com mais dados (são conhecidamente *data-hungry*) e se os modelos baseados em kernel mantêm a vantagem estrutural.

Configuração: Os três sintéticos (TWS, TWM, TWC) foram re-gerados com $N = 2000$. Os hiperparâmetros tuned para Tier 1 ($N = 400$) foram reutilizados.

Nota: ADMM-ElasticNet excluído desta ablação

O ADMM-ElasticNet não foi incluído na Ablação A por duas razões complementares: (i) a análise da distribuição de λ_2 no Tier 1 mostra que 73,3% das combinações ótimas selecionaram o menor valor da grade ($\lambda_2 = 0,001$), indicando que o regularizador ℓ_2 adicional raramente é ativo; e (ii) resultados parciais com $N = 2000$ confirmam desempenho virtualmente idêntico ao LSSVM-ADMM (F1: 0,9955 vs. 0,9953). Adicionalmente, o grid aumentado ($\sigma \times \tau \times \lambda \times \lambda_2 = 5 \times 5 \times 4 \times 3 = 300$ combinações vs. 100 do ADMM) tornaria o custo computacional $3\times$ maior sem ganho preditivo. Os resultados do Tier 1 para ADMM-ElasticNet são mantidos nas tabelas comparativas gerais (Seção ??).




Figura 3: F1-macro com $N = 400$ (barras translúcidas) vs. $N = 2000$ (sólidas).

Observações:

- **LSSVMs e XGBoost** apresentam eficiência amostral elevada: $\bar{\Delta}$ varia de +0,010 (LSSVM-FSA) a +0,037 (XGBoost), indicando que o kernel RBF já saturou na geometria sintética com $N = 400$.
- **Transformers são fortemente *data-hungry*:** FT-Sparsemax ($\bar{\Delta} = +0,145$) é o mais beneficiado, com ganho de +0,262 em TWS (de 0,632 para 0,894). FT-TopK (+0,094), FT-Softmax (+0,089) e FT-Entmax (+0,090) também se beneficiam fortemente. FT-CUR (+0,044) e SAINT (+0,034) são moderadamente *data-hungry*.
- Mesmo com $N = 2000$, os Transformers ainda ficam claramente abaixo dos LSSVMs em TWC: FT-Sparsemax atinge 0,613 vs. Nyström-SVM 0,943, indicando que o *inductive bias* geométrico do kernel RBF é a causa dominante, não a limitação de dados.

Tabela 8: Ablação A — Escalabilidade amostral: F1-macro médio em $N = 400$ vs $N = 2000$. $\Delta = F1(N_{2k}) - F1(N_{400})$; $\bar{\Delta}$ = média dos três datasets. LSSVMs e XGBoost: 30 sementes; Transformers: 20 sementes.

Modelo	TWS			TWM			TWC			$\bar{\Delta}$
	N_{400}	N_{2k}	Δ	N_{400}	N_{2k}	Δ	N_{400}	N_{2k}	Δ	
LSSVM-Nyström	0.992	0.996	+0.004	0.999	0.998	-0.001	0.898	0.943	+0.046	+0.016
LSSVM (Std)	0.994	0.996	+0.003	0.997	0.998	+0.002	0.898	0.944	+0.046	+0.017
LSSVM-DualFISTA	0.993	0.996	+0.003	0.997	0.998	+0.001	0.901	0.943	+0.043	+0.016
LSSVM-IP	0.992	0.996	+0.004	0.996	0.998	+0.002	0.897	0.940	+0.042	+0.016
LSSVM-FSA	0.987	0.987	0.000	0.997	0.997	0.000	0.879	0.911	+0.032	+0.010
LSSVM-PCP	0.990	0.994	+0.004	0.993	0.997	+0.004	0.880	0.938	+0.058	+0.022
XGBoost	0.944	0.983	+0.038	0.984	0.996	+0.012	0.912	0.973	+0.061	+0.037
LSSVM-Pruning	0.989	0.996	+0.007	0.997	0.998	+0.001	0.891	0.946	+0.055	+0.021
LSSVM-FISTA	0.971	0.996	+0.025	0.989	0.998	+0.010	0.877	0.936	+0.059	+0.031
LSSVM-ADMM	0.971	0.996	+0.025	0.988	0.998	+0.010	0.881	0.939	+0.058	+0.031
LSSVM-ADMM-EN	0.971	0.996	+0.025	0.988	0.998	+0.010	0.881	0.939	+0.058	+0.031
LSSVM-OppMaps	0.986	0.992	+0.006	0.991	0.958	-0.032	0.907	0.940	+0.033	+0.002
FT-CUR	0.624	0.666	+0.041	0.974	0.994	+0.020	0.487	0.558	+0.071	+0.044
SAINT	0.641	0.655	+0.014	0.942	0.990	+0.048	0.460	0.499	+0.039	+0.034
FT-entmax	0.625	0.849	+0.223	0.960	0.997	+0.037	0.482	0.492	+0.010	+0.090
FT-sparsemax	0.632	0.894	+0.262	0.962	0.996	+0.035	0.474	0.613	+0.139	+0.145
FT-softmax	0.625	0.815	+0.190	0.946	0.996	+0.050	0.471	0.499	+0.028	+0.089
FT-topk (k=10%)	0.630	0.723	+0.093	0.884	0.994	+0.109	0.476	0.556	+0.080	+0.094

7 Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)

Motivação: Avaliar a sensibilidade à presença de dimensões irrelevantes, cenário comum em dados tabulares reais.

Configuração: Três features gaussianas de ruído ($\sigma_{\text{ruído}} = 1,0$) foram adicionadas às coordenadas x_1, x_2 originais ($N = 400$). Grid+CV completo (30 sementes) nos 12 modelos LSSVM+XGBoost e nos 6 Transformers (GPU T4 Kaggle) sobre os datasets 5D (TWS_5f, TWM_5f, TWC_5f).

Análise mecânica: A adição de 3 features de ruído expande a distância euclidiana quadrática média em $\approx 3\sigma_{\text{ruído}}^2$, colapsando os valores do kernel RBF para próximo de zero e destruindo a estrutura da matriz kernel. O reajuste do σ (valores maiores) recupera parcialmente o sinal, mas não restitui a resolução espacial original em fronteiras de alta frequência.

Padrões observados:

- **XGBoost** é o mais robusto de todos: queda média de apenas $-0,048$, praticamente nula em TWM ($-0,000$) e moderada em TWC ($-0,131$). Árvores de decisão com feature importance natural ignoram dimensões irrelevantes, o que constitui vantagem estrutural sobre métodos kernel neste cenário.
- Todos os **LSSVMs** sofrem quedas severas em TWS e TWC (Δ de $-0,26$ a $-0,39$): o kernel RBF isotrópico trata todas as dimensões igualmente, portanto as 3 novas dimensões de ruído distorcem as distâncias e destroem a estrutura aprendida.

Tabela 9: Ablação B — Robustez ao ruído: F1-macro médio (30 sementes) com 2 vs 5 features de ruído. $\Delta = F1(5D) - F1(2D)$; $\bar{\Delta}$ = média dos três datasets.

Modelo	TWS			TWM			TWC			$\bar{\Delta}$
	2D	5D	Δ	2D	5D	Δ	2D	5D	Δ	
LSSVM-Nyström	0.992	0.585	-0.408	0.999	0.944	-0.055	0.898	0.509	-0.389	-0.284
LSSVM (Std)	0.994	0.605	-0.389	0.997	0.958	-0.038	0.898	0.518	-0.380	-0.269
LSSVM-DualFISTA	0.992	0.622	-0.371	1.000	0.951	-0.049	0.905	0.529	-0.375	-0.265
LSSVM-IP	0.992	0.583	-0.410	0.996	0.947	-0.049	0.897	0.517	-0.381	-0.280
LSSVM-FSA	0.987	0.603	-0.383	0.997	0.941	-0.056	0.879	0.521	-0.359	-0.266
LSSVM-PCP	0.990	0.600	-0.390	0.993	0.920	-0.073	0.880	0.521	-0.359	-0.274
XGBoost	0.944	0.930	-0.014	0.984	0.984	0.000	0.912	0.781	-0.131	-0.048
LSSVM-Pruning	0.989	0.501	-0.489	0.997	0.951	-0.046	0.891	0.466	-0.425	-0.320
LSSVM-FISTA	0.989	0.612	-0.377	0.996	0.928	-0.068	0.875	0.517	-0.358	-0.268
LSSVM-ADMM	0.974	0.612	-0.361	0.988	0.926	-0.062	0.883	0.522	-0.360	-0.261
LSSVM-ADMM-EN	0.974	0.610	-0.364	0.988	0.927	-0.061	0.879	0.520	-0.358	-0.261
LSSVM-OppMaps	0.986	0.483	-0.503	0.991	0.758	-0.232	0.907	0.472	-0.435	-0.390
FT-CUR	0.624	0.622	-0.003	0.974	0.871	-0.103	0.487	0.490	+0.003	-0.034
SAINT	0.641	0.615	-0.026	0.942	0.864	-0.077	0.460	0.472	+0.012	-0.031
FT-entmax	0.625	0.620	-0.006	0.960	0.866	-0.094	0.482	0.461	-0.021	-0.040
FT-sparsemax	0.632	0.600	-0.032	0.962	0.873	-0.089	0.474	0.463	-0.011	-0.044
FT-softmax	0.625	0.609	-0.017	0.946	0.832	-0.114	0.471	0.476	+0.004	-0.042
FT-topk (k=10%)	0.630	0.609	-0.021	0.884	0.815	-0.070	0.476	0.481	+0.005	-0.029

- **DualFISTA** e **ADMM** são os LSSVMs mais robustos ($\bar{\Delta} \approx -0,26$); **Opposite-Maps** é o mais sensível (-0,39), seguido de **Pruning** (-0,32).
- **TWM** é consistentemente mais resistente ao ruído que TWS e TWC em todos os modelos: sua fronteira de decisão linear/simples é menos afetada pela distorção das distâncias.
- **Transformers são muito mais robustos ao ruído** que os LSSVMs: $\bar{\Delta}$ varia de -0,029 (FT-TopK, mais robusto) a -0,044 (FT-Sparsemax), muito abaixo das quedas dos LSSVMs (-0,261 a -0,390). A ausência de um kernel isotrópico RBF — que amplifica a distorção das dimensões ruidosas — explica a resiliência estrutural dos Transformers neste cenário.

8 Ablação C: Dados Sintéticos Multifeature (MK5)

Motivação: Os datasets sintéticos anteriores (TWS/TWM/TWC) são bidimensionais, favorecendo o kernel RBF. O MK5 usa dados gerados por `make_classification` (scikit-learn) com 5 features verdadeiramente informativas em 3 níveis de dificuldade: MKE (fácil), MKM (médio), MKH (difícil). Grid+CV completo, 30 sementes, 12 modelos LSSVM+XGBoost e 6 Transformers (GPU T4 Kaggle).

Destaques:

- **LSSVM-Std** lidera com 0,851 de F1 médio, seguido de **Nyström-SVM** (0,841), **DualFISTA** (0,838) e **LSSVM-IP** (0,840) — o mesmo bloco líder do Tier 1. O ranking é essencialmente preservado quando se passa de 2 para 5 features informativas.

Tabela 10: Ablação C — Sintético multifeature (MK5): F1-macro médio (30 sementes). MKE = fácil, MKM = médio, MKH = difícil.

Modelo	MKE	MKM	MKH	Média
LSSVM-Nyström	0.985	0.840	0.697	0.841
LSSVM (Std)	0.987	0.858	0.709	0.851
LSSVM-DualFISTA	0.982	0.837	0.696	0.838
LSSVM-IP	0.985	0.834	0.700	0.840
LSSVM-FSA	0.986	0.831	0.686	0.834
LSSVM-PCP	0.984	0.821	0.672	0.826
XGBoost	0.974	0.810	0.698	0.827
LSSVM-Pruning	0.985	0.809	0.633	0.809
LSSVM-FISTA	0.984	0.816	0.670	0.823
LSSVM-ADMM	0.983	0.811	0.668	0.821
LSSVM-ADMM-EN	0.983	0.812	0.663	0.819
LSSVM-OppMaps	0.903	0.622	0.519	0.681
SAINT	0.978	0.785	0.659	0.807
FT-CUR	0.977	0.787	0.654	0.806
FT-sparsemax	0.972	0.778	0.649	0.799
FT-entmax	0.973	0.782	0.637	0.797
FT-softmax	0.972	0.773	0.638	0.794
FT-topk (k=10%)	0.967	0.757	0.621	0.782

- **XGBoost** (0,827) permanece competitivo, agora próximo do LSSVM-PCP (0,826). Com 5 features informativas (sem ruído), as árvores exploram bem o espaço de features.
- **MKH** é o nível mais difícil para todos: F1 médio cai para 0,63–0,71 (vs 0,97–0,99 em MKE), indicando fronteiras de decisão mais complexas que excedem a capacidade dos modelos com $N = 400$.
- **LSSVM-Pruning** (0,809) e **OppMaps** (0,681) ficam claramente abaixo dos demais, padrão consistente com o Tier 1 e com a ablação de escalabilidade.
- **Transformers** ficam abaixo de todos os LSSVMs exceto OppMaps: SAINT (0,807) e FT-CUR (0,806) são os melhores Transformers, ainda abaixo de LSSVM-Pruning (0,809) e LSSVM-ADMM (0,821). O *inductive bias* geométrico do kernel RBF confere vantagem estrutural clara em dados tabulares sintéticos com 5 features informativas.

9 Análise das Variantes Investigadas e Modelos Propostos

9.1 Mecanismos de esparsidade

Tabela 11: Caracterização dos mecanismos de esparsidade dos modelos investigados e propostos. LSSVM-ADMM-Nesterov é o paper-base (Marinho et al.); demais são variantes ou aplicações propostas/investigadas.

Modelo	Mecanismo	Esparsidade
LSSVM-ADMM-Nesterov (Marinho et al.)	Otimização ADMM com penalidade ℓ_1 (primal); aceleração de Nesterov.	Emerge da otimização; heterogênea entre datasets. Média: 30%.
ADMM-ElasticNet ^o	Variante do paper-base com penalidade Elastic Net ($\ell_1 + \ell_2$); combinação não localizada em literatura.	Similar ao paper-base, ligeiramente mais homogênea. Média: $\approx 24\%$ (Tier 1, Grid+CV).
DualFISTA ^o	Formulação dual: $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \ \alpha\ _1$, otimizado via FISTA. Não localizada na literatura nesta forma exata.	Mais uniforme que ADMM (dual bem condicionado). Média: $\approx 10\%$ (Tier 1, Grid+CV).
Nyström-SVM [*]	Aproximação Nyström com seleção <i>colnorm</i> (norma de coluna em vez de uniforme/leverage); predição honesta restrita aos m landmarks.	Controlada por m/n tunado por dataset; varia 50–92%. Média: $\approx 78\%$ (Tier 1, Grid+CV).
FT-CUR (Nyströmformer) [*]	Aplicação de Nyströmformer (Xiong et al. 2021) à atenção inter-instâncias do FT-Transformer com seleção <i>colnorm</i> .	Compressão inter-instâncias: $1 - m/n \approx 80\%$.

9.2 Desempenho consolidado

A Tabela 12 consolida os resultados dos modelos propostos nos quatro experimentos realizados.

Tabela 12: Modelos investigados / propostos e paper-base — F1-macro médio em todos os experimentos. Spar.A = esparsidade amostral (LSSVMs); Spar.At = compressão interinstâncias (FT-CUR/SAINT).

Modelo	Tier 1			Ablação A ($N=2k$)		Ablação B (5D)		MK5
	F1	Spar.A	Spar.At	F1	Δ	F1	Δ	
DualFISTA ^o	0,831	10%	—	0,979	+0,016	0,701	−0,265	0,838
LSSVM-ADMM (paper-base)	0,802	24%	—	0,978	+0,031	0,687	−0,261	0,821
ADMM-ElasticNet ^o	0,802	24%	—	—	—	—	—	—
Nyström-SVM*	0,838	78%	—	0,979	+0,016	0,679	−0,284	0,841
FT-CUR (Nyströmformer)*	0,738	—	85,2%	0,739	+0,044	0,661	−0,034	0,806
SAINT (baseline FT)	0,731	—	0%	0,715	+0,034	0,650	−0,030	0,807

9.3 Síntese comparativa

Tabela 13: Perfis dos modelos investigados e propostos.

Modelo	Ponto forte	Ponto fraco	Característica distintiva
DualFISTA ^o	F1 quase idêntico ao LSSVM-Std; convergência estável	Sensível a features de ruído (kernel RBF); esparsidade baixa ($\approx 10\%$ no Tier 1)	Formulação dual bem condicionada; melhor trade-off esparsidade/acurácia em baixa esparsidade
ADMM-ElasticNet ^o	Esparsidade mais uniforme que ADMM- ℓ_1 puro	F1 ≈ 3 pp abaixo do LSSVM-Std; ganho marginal sobre o paper-base	Variante do paper-base com ElasticNet (combinação não localizada em literatura)
Nyström-SVM*	F1 competitivo (0,838, equivalente ao LSSVM-Std) com 78% de esparsidade; melhor trade-off em alta esparsidade	Sensível a features de ruído (kernel RBF); m/n ideal varia muito entre datasets (8–50%)	Único modelo com compressão de memória real: $O(nm)$ vs. $O(n^2)$; auditoria matemática confirma honestidade
FT-CUR (Nyströmformer)*	Robusto a features irrelevantes; beneficia-se de mais dados; compressão interinstâncias com Nyströmformer ($O(nmd)$)	Fraco em fronteiras não-lineares complexas (TWS, TWC); transductivo (requer X_{train} na inferência)	Aplicação do Nyströmformer a dados tabulares; comparado ao SAINT, valida empiricamente que 80% de compressão custa $\approx 0,003$ de F1

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$)

Esta seção apresenta os resultados *consolidados* do experimento Tier 2, que estende a comparação a seis datasets reais de larga escala (**ADULT**, **CREDIT**, **BANK**, **TELCO**, **SHOPPERS**, **HIGGS50K**) com subamostragem estratificada para $N_{\text{treino}} = 5000$ por seed. Os **18 modelos** (baselines, paper-base e variantes/propostos) completaram as 30 sementes, totalizando **3.240 execuções**. Os resultados de FT-CUR e SAINT incorporam a correção metodológica da ablação H2 (Seção 10.6): `early_stop_metric = val_loss` em vez de `val_acc`.

10.1 Protocolo

- **Subamostragem por seed:** cada (modelo, dataset, seed) usa uma amostra estratificada de $N=7143$ amostras, determinística pela seed. O split 70/30 resulta em $N_{\text{treino}}=5000 + N_{\text{teste}}=2143$. Cada seed gera um subsample diferente, permitindo estimar variância amostral sobre N pequeno.
- **Tuning Optuna:** 20 trials $\times$ 3-fold CV sobre cada subsample, separado por (modelo, dataset). Cada um dos 18 modelos teve espaço de busca próprio.
- **Métricas:** 30 seeds por (modelo, dataset), F1-macro como métrica primária para lidar com o desbalanceamento inerente aos dados.
- **Análise estatística:** teste de Friedman seguido de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni (Tabelas 16 e 30).

Tabela 14: Datasets Tier 2 com respectiva taxa de positivos.

ID	Nome	N original	% positivos	Domínio
ADULT	UCI Adult Income	45 222	24%	Renda
CREDIT	Default of Credit Card Clients	30 000	22%	Crédito
BANK	UCI Bank Marketing	45 211	11%	Marketing direto
TELCO	IBM Telco Customer Churn	7 032	27%	Churn
SHOPPERS	Online Shoppers Purchasing	12 330	15%	E-commerce
HIGGS50K	Higgs Boson (subset 50k)	50 000	53%	Física de partículas

10.2 Resultados por Dataset (todos os 18 modelos)

A Tabela 15 apresenta o F1-macro médio ($\pm$ desvio padrão) dos 18 modelos nos 6 datasets reais Tier 2; o melhor por coluna está em negrito.

Observações por grupo de modelos:

- **Baseline geral tabular (XGBoost)** domina o ranking consolidado: lidera ADULT (0,802), HIGGS50K (0,693) e SHOPPERS (0,795), e fica empatado em CREDIT/BANK/TELCO com o bloco de Transformers. Média agregada $\approx 0,735$, melhor rank Friedman (2,67).

Tabela 15: Média $\pm$ desvio padrão de F1-macro (30 sementes, 6 conjuntos de dados TIER2).

Model	ADULT	BANK	CREDIT	HIGGS50K	SHOPPERS	TELCO
ADMM-Nystrom	0.747 $\pm$ 0.018	0.667 $\pm$ 0.020	0.646 $\pm$ 0.026	0.594 $\pm$ 0.019	0.733 $\pm$ 0.022	0.697 $\pm$ 0.021
FISTA-Nystrom	0.740 $\pm$ 0.020	0.661 $\pm$ 0.023	0.637 $\pm$ 0.022	0.594 $\pm$ 0.019	0.719 $\pm$ 0.026	0.691 $\pm$ 0.023
LSSVM (Standard)	0.757 $\pm$ 0.019	0.677 $\pm$ 0.025	0.660 $\pm$ 0.025	0.629 $\pm$ 0.016	0.757 $\pm$ 0.022	0.717 $\pm$ 0.017
LSSVM-DualFISTA	0.749 $\pm$ 0.017	0.673 $\pm$ 0.025	0.645 $\pm$ 0.026	0.606 $\pm$ 0.015	0.739 $\pm$ 0.022	0.693 $\pm$ 0.022
LSSVM-FSA	0.712 $\pm$ 0.023	0.678 $\pm$ 0.027	0.651 $\pm$ 0.032	0.589 $\pm$ 0.018	0.713 $\pm$ 0.027	0.715 $\pm$ 0.017
LSSVM-IP	0.738 $\pm$ 0.022	0.679 $\pm$ 0.023	0.664 $\pm$ 0.027	0.619 $\pm$ 0.018	0.754 $\pm$ 0.024	0.711 $\pm$ 0.019
LSSVM-Nystrom	0.759 $\pm$ 0.020	0.678 $\pm$ 0.023	0.658 $\pm$ 0.026	0.626 $\pm$ 0.016	0.757 $\pm$ 0.023	0.715 $\pm$ 0.020
LSSVM-PCP	0.748 $\pm$ 0.022	0.659 $\pm$ 0.023	0.652 $\pm$ 0.021	0.618 $\pm$ 0.018	0.742 $\pm$ 0.022	0.716 $\pm$ 0.017
XGBoost	0.784 $\pm$ 0.020	0.702 $\pm$ 0.023	0.670 $\pm$ 0.025	0.671 $\pm$ 0.014	0.790 $\pm$ 0.016	0.722 $\pm$ 0.016

- **Baselines FT-Transformer** (Softmax, TopK, Entmax, Sparsemax) ocupam o segundo patamar, confinados ao intervalo 0,720–0,725 na média. A esparsidade de atenção inter-features (sparsemax 75%; topk 89%) não traz vantagem mensurável: a diferença máxima entre o mais esperso (TopK) e o mais denso (Softmax) é 0,005 em média.
- **SAINT** (denso, inter-instâncias) atinge média 0,722, empatando com os FT baselines. Confirma que *a atenção inter-instâncias não é, isoladamente, suficiente para superar a atenção inter-features* em datasets reais.
- **FT-CUR (proposto)** alcança média 0,713 com a correção `val_loss`. Permanece dentro de 0,012 do bloco FT baseline em média, recuperando a maior parte do colapso aparente do protocolo original com `val_acc` (ver Seção 10.6).
- **LSSVMs duais bem condicionados** (LSSVM-Std, DualFISTA, Nyström-LSSVM) caem para $\approx 0,706$ – $0,709$ — $\approx 0,13$ *pp* abaixo do Tier 1. O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em features tabulares mistas (categóricas codificadas + numéricas) com ruído estrutural.
- **LSSVM-PCP, LSSVM-IP, LSSVM-FSA** ficam entre 0,68 e 0,69, um degrau abaixo do LSSVM-Std, com esparsidades amostrais entre 60% (IP) e 92% (FSA).
- **Métodos primais com ℓ_1** (ADMM-Nesterov, FISTA-Nesterov, ADMM-ElasticNet) colapsam para $F_1 \approx 0,58$ — $\Delta \approx -0,13$ vs. LSSVM-Std denso. Analisado em Seção 10.5.
- **LSSVM-Pruning** (após correção com *early stopping* guiado por F1 de treino com tolerância de 5%, código `src/models/lssvm/dual/p_lssvm.py`) sobe para 0,594 com 52% de esparsidade. Recupera a maior parte da degradação antes observada (versão pré-correção: 0,462 com 96% de esparsidade), embora ainda fique abaixo dos LSSVMs duais bem comportados.
- **LSSVM-OppMaps** é o pior modelo do estudo (0,478): a seleção *opposite maps* com esparsidade fixa em 94% não possui mecanismo de *early stopping*, e destrói a fronteira de decisão em escala $N = 5000$.

10.3 Análise estatística: Friedman e ranks médios

A Tabela 16 apresenta os ranks médios obtidos pelo teste não-paramétrico de Friedman ($\chi^2 = 84,96$, $p < 10^{-10}$), confirmando que existe diferença estatisticamente significativa

entre os modelos no conjunto agregado dos seis datasets.

Tabela 16: Ranks médios de Friedman — TIER2 (menor = melhor).

Rank	Model	Avg. rank
1	XGBoost	1.000
2	LSSVM (Standard)	2.833
3	LSSVM-Nystrom	3.333
4	LSSVM-IP	4.333
5	LSSVM-PCP	5.333
6	LSSVM-DualFISTA	6.333
7	LSSVM-FSA	6.833
8	ADMM-Nystrom	6.833
9	FISTA-Nystrom	8.167

A Tabela 30 (apêndice) reporta o pós-teste de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni ($n_{\text{comp}} = 153$). Com $K = 6$ datasets e correção conservadora, comparações par-a-par individuais não atingem $\alpha = 0,05$, mas a hierarquia de ranks de Friedman é robusta: XGBoost (2,67), SAINT (3,67) e o bloco FT baseline + FT-CUR (4,3–6,5) dominam claramente os métodos primais com ℓ_1 (≥ 14) e heurísticas cegas (≥ 17).

10.4 Esparsidade consolidada no Tier 2

Tabela 17: Taxa de esparsidade média por modelo (TIER2, todos os datasets e sementes).

Model	Sparsity ratio
ADMM-Nystrom	0.209 ± 0.155
FISTA-Nystrom	0.145 ± 0.205
LSSVM (Standard)	0.000 ± 0.000
LSSVM-DualFISTA	0.045 ± 0.072
LSSVM-FSA	0.920 ± 0.029
LSSVM-IP	0.386 ± 0.138
LSSVM-Nystrom	0.700 ± 0.000
LSSVM-PCP	0.907 ± 0.018

Leitura cruzada com a Tabela 15:

- **Nyström-LSSVM** mantém o trade-off observado no Tier 1: 81,5% de esparsidade amostral com $F_1 = 0,707$, apenas 0,002 abaixo do LSSVM-Std denso (0,709). *Compressão substancial sem custo preditivo*, agora confirmado em dados reais $N = 5000$.
- **FT-CUR** obtém 89,4% de compressão inter-instâncias com $F_1 = 0,713$, equivalente ao SAINT denso (0,722, gap 0,009). Repete o padrão Tier 1: *a compressão Nyströmformer é fiel também em larga escala*.
- **DualFISTA** fica em 2,1% de esparsidade no Tier 2 — muito abaixo dos 5% do Tier 1 (Grid+CV). O Optuna passou a preferir λ pequenos para preservar margem em datasets imbalanceados, evidenciando que o método se ajusta dinamicamente ao regime de dados.

- **LSSVM-Pruning** agora opera em 52% de esparsidade média no Tier 2 (era 96% antes da correção do *early stopping*), recuperando $F_1 = 0,594$. O modelo passou a parar antes de destruir a fronteira de decisão, ao custo de menos compressão.
- **LSSVM-OppMaps** mantém 94% de esparsidade fixa e permanece em colapso ($F_1 = 0,478$): sem mecanismo análogo de *early stopping*, a heurística cega não escala em $N = 5000$.
- **FT-Sparsemax (75%) e FT-TopK (89%)** mantêm a esparsidade inter-features observada no Tier 1; FT-Entmax (19%) permanece pouco saturada na prática.

10.5 Colapso dos métodos primais com ℓ_1 em escala

O achado mais expressivo da migração Tier 1 $\rightarrow$ Tier 2 é o colapso dos métodos baseados em formulação primal com penalidade ℓ_1 :

Tabela 18: Métodos primais com ℓ_1 no Tier 2 (média sobre 6 datasets).

Modelo	F1 Tier 1	F1 Tier 2	Δ	Esparsidade Tier 2
LSSVM-ADMM (paper-base)	0,802	0,580	-0,222	75,2%
ADMM-ElasticNet ^o	0,802	0,576	-0,226	73,7%
FISTA-Nesterov	0,787	0,577	-0,210	49,1%
<i>Referência: LSSVM-Std denso</i>		0,709	—	0,0%

Mecânica do colapso (ADMM/ADMM-EN). Para a matriz kernel densa 5000×5000 (25 milhões de entradas), o Optuna convergiu para valores de λ grandes o suficiente para zerar $\approx 75\%$ dos coeficientes α_i . O hiperplano resultante torna-se rígido e, na ausência de uma atualização proporcional do *bias* via problema de projeção, falha em capturar a classe minoritária nos datasets desbalanceados (BANK 11%, SHOPPERS 15%, CREDIT 22%) — o F_1 macro $\approx 0,58$ é exatamente o valor de uma predição quase-majoritária. A variante **ADMM-ElasticNet** ($\ell_1 + \ell_2$) reduz o tempo de fit de ≈ 160 s para ≈ 54 s por seed (convexidade forte da penalidade ℓ_2 melhora o condicionamento), mas preserva a mesma barreira de expressividade.

Mecânica do colapso (FISTA-Nesterov). Após a correção da escala do λ via `lambda_ratio` (`commit b83243e`), o FISTA-Nesterov no Tier 2 fica em 49,1% de esparsidade média e ainda assim colapsa, indicando que o problema não é apenas a magnitude do λ mas a própria formulação primal: a função objetivo penaliza a magnitude de α no espaço primal, deslocando o hiperplano para regiões que não respeitam a estrutura do problema KKT original. A reformulação dual do **DualFISTA** — $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \|\alpha\|_1$ — elimina exatamente este problema, mantendo $F_1 = 0,706$ no Tier 2.

10.6 FT-CUR/SAINT e a correção metodológica da H2

Os primeiros runs do Tier 2 (parciais, com 6/18 modelos completos) sugeriram um colapso estrutural do FT-CUR em datasets imbalanceados: $F_1 = 0,444$ em CREDIT, 0,548 em BANK — valores compatíveis com predição quase exclusiva da classe majoritária. Três hipóteses foram formuladas para explicar o efeito (Tabela 19).

Tabela 19: Hipóteses sobre o colapso aparente do FT-CUR no Tier 2 parcial.

H	Causa proposta	Teste experimental	Status
H1	Seleção colnorm geométrica sub-representa a classe minoritária nos m landmarks	Tier 2 balanceado: under-sample da majoritária só no treino	A rodar
H2	<code>val_acc</code> em early stopping favorece a classe majoritária	Rerun com <code>val_loss/val_f1_macro</code> e re-tuning Optuna independente por métrica	Confirmada
H3	Limitação fundamental da decomposição CUR	Confirmação por exclusão	Enfraquecida

Ablação H2 (concluída). 360 runs ($2 \text{ modelos} \times 2 \text{ datasets} \times 3 \text{ métricas} \times 30 \text{ seeds}$):

Tabela 20: Efeito do critério de early stopping em FT-CUR e SAINT nos datasets desbalanceados CREDIT e BANK (30 seeds, retuning Optuna por métrica).

Modelo	Dataset	<code>val_acc</code>	<code>val_loss</code>	<code>val_f1</code>	$\Delta(\text{loss-acc})$	Melhor FT baseline
FT-CUR	CREDIT	0,438	0,657	0,610	+0,219	0,682 (FT-Entmax)
FT-CUR	BANK	0,507	0,714	0,473	+0,207	0,720 (FT-Softmax)
SAINT	CREDIT	0,439	0,684	0,467	+0,245	0,682 (FT-Entmax)
SAINT	BANK	0,473	0,710	0,498	+0,237	0,720 (FT-Softmax)

Validação estatística (Wilcoxon pareado, H_a : `val_loss` > `val_acc`): FT-CUR/CREDIT $p = 1,3 \times 10^{-6}$; FT-CUR/BANK $p = 1,9 \times 10^{-9}$; SAINT/CREDIT $p = 9,3 \times 10^{-10}$; SAINT/BANK $p = 9,3 \times 10^{-10}$.

Conclusão da ablação. O uso de `val_acc` como critério de early stopping era um *erro metodológico* no protocolo original. `val_loss` foi superior nos quatro cenários, com magnitude (+0,21 a +0,25) incompatível com ruído. Em BANK, a correção elimina sozinha o colapso aparente; em CREDIT, ela explica a maior parte. A hipótese H3 (limitação fundamental do CUR) fica enfraquecida mas não completamente descartada para um pequeno resíduo em CREDIT.

Rerun completo do Tier 2 com `val_loss`. Os números da Tabela 15 para FT-CUR e SAINT já refletem este protocolo corrigido. A Tabela 21 compara explicitamente os dois protocolos para FT-CUR para quantificar a magnitude da correção.

Tabela 21: FT-CUR no Tier 2: protocolo histórico (`val_acc`) vs. protocolo corrigido (`val_loss`).

Modelo	ADULT	CREDIT	BANK	TELCO	SHOPPERS	HIGGS50K	Média
FT-CUR (<code>val_acc</code> , histórico)	0,770	0,444	0,548	0,714	0,751	0,648	0,646
FT-CUR (<code>val_loss</code> , atual)	0,774	0,683	0,695	0,724	0,763	0,639	0,713

10.7 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia

A Tabela 22 sumariza o deslocamento de F1-macro de cada família ao migrar do regime sintético/pequeno (Tier 1) para o regime real grande (Tier 2).

Tabela 22: F1-macro médio: Tier 1 (sintéticos + pequenos reais, $N \in [400, 1584]$) vs. Tier 2 ($N_{\text{treino}} = 5000$ em datasets reais grandes). Δ negativo = perda ao migrar.

Modelo	Tier 1	Tier 2	Δ	Família
LSSVM-Std	0,838	0,709	−0,129	kernel denso
DualFISTA ^o	0,831	0,706	−0,125	dual ℓ_1 via FISTA
Nyström-LSSVM [*]	0,838	0,707	−0,131	kernel esparso (81% esp.)
LSSVM-IP	0,832	0,694	−0,138	iterative pruning
LSSVM-PCP	0,827	0,685	−0,142	cone projection
LSSVM-FSA	0,829	0,679	−0,150	forward selection
XGBoost	0,826	0,735	−0,091	gradient boosting
FT-Softmax [†]	0,730	0,725	−0,005	atenção feature densa
FT-Sparsemax [†]	0,731	0,723	−0,008	atenção feature esparsa
FT-Entmax [†]	0,734	0,723	−0,011	atenção feature esparsa
FT-TopK [†]	0,712	0,720	+0,008	atenção feature top- k
SAINT [†]	0,731	0,722	−0,009	atenção inter-inst. densa
FT-CUR ^{*†}	0,738	0,713	−0,025	atenção inter-inst. comprimida
LSSVM-ADMM (paper-base)	0,802	0,580	−0,222	primal ℓ_1 (ADMM)
ADMM-ElasticNet ^o	0,802	0,576	−0,226	primal $\ell_1 + \ell_2$
FISTA-Nesterov	0,787	0,577	−0,210	primal ℓ_1 (FISTA)
LSSVM-Pruning [†]	0,808	0,594	−0,214	pruning iterativo $c/$ <i>early stop</i>
LSSVM-OppMaps	0,759	0,478	−0,281	opposite maps

Três regimes de deslocamento:

1. **LSSVMs duais bem-comportados** ($\Delta \approx -0,13$ a $-0,15$). O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em dados reais com features categóricas codificadas, redundância e ruído estrutural. *Nyström-LSSVM* e *DualFISTA* mantêm-se virtualmente empatados com *LSSVM-Std* denso no Tier 2 (gap $\leq 0,003$), confirmando que os mecanismos de esparsidade propostos são *neutros* em relação à formulação dual em escala.
2. **Transformers e XGBoost**. FT-Transformers ([†], protocolo Optuna no Tier 2) absorvem a transição com baixa perda ($\Delta \approx -0,025$ a $+0,008$, com FT-TopK ligeiramente melhor no Tier 2 que no Tier 1 com Grid+CV). As variantes esparsas convergem para o mesmo patamar do softmax denso (0,720–0,725): a esparsidade na atenção inter-features não traz vantagem mensurável. **XGBoost**, com o novo Grid+CV, passa de 0,776 (Optuna) para 0,826 no Tier 1, resultando em $\Delta = -0,091$ — maior que os Transformers, mas ainda muito inferior ao colapso dos métodos primais.
3. **Métodos primais com ℓ_1 e heurísticas cegas** ($\Delta \approx -0,21$ a $-0,28$). Os métodos que dependem de regularização agressiva sobre o espaço primal ou de poda

heurística sofrem o maior colapso. É a contribuição central do Tier 2: revelar que o paper-base LSSVM-ADMM-Nesterov possui um teto de escalabilidade não evidente em $N \leq 1000$. O **LSSVM-Pruning**, após adquirir *early stopping* guiado por F1 de treino e correção do grid, sobe para 0,808 no Tier 1 e reduz a queda a $-0,214$.

Reordenação: no Tier 1, o ranking é Nyström/LSSVM-Std (0,838) > IP (0,832) > DualFISTA (0,831) > FSA/PCP/XGBoost (0,826–0,829) > primais ℓ_1 > OppMaps; no Tier 2, é XGBoost $\geq$ FT-Transformers + SAINT + FT-CUR > LSSVMs duais (Std, Nyström, DualFISTA, IP, PCP, FSA) > primais com ℓ_1 > heurísticas. A vantagem do paradigma Transformer cresce *em proporção à complexidade tabular dos dados*, e não à escolha de função de ativação da atenção.

11 Benchmark de Eficiência Computacional em *Full-Data*

Em complemento ao estudo de F1-macro, executou-se um benchmark *end-to-end* em GPU T4 (Colab) com **uma única seed**, medindo o custo de uma execução real: carregamento do dataset, subamostragem para um N alvo, split 70/30, préprocessamento, treinamento e inferência. O objetivo **não** é comparar desempenho preditivo com rigor estatístico, mas caracterizar o **trade-off computacional** entre as variantes Transformer em regime *full-data*. Os valores de F_1 aqui devem ser lidos como *sanity check* operacional.

Tabela 23: Benchmark de eficiência em *full-data*. Para cada dataset, reporta-se o maior N concluído por modelo. Para SAINT, indica-se o maior N atingido antes de OOM.

Dataset	Modelo	N	Fit (s)	Pred. (s)	VRAM pico (MB)
ADULT	FT-Softmax	45 222	100,2	0,11	364
ADULT	FT-Sparsemax	45 222	124,2	0,41	628
ADULT	FT-TopK	45 222	195,8	0,23	387
ADULT	FT-CUR	45 222	231,6	5,87	3 288
ADULT	FT-Entmax	45 222	425,5	0,59	394
ADULT	SAINT	20 000	25,8	0,85	12 271
CREDIT	FT-Sparsemax	30 000	29,3	0,33	718
CREDIT	FT-TopK	30 000	29,4	0,22	718
CREDIT	FT-Softmax	30 000	38,6	0,18	718
CREDIT	FT-Entmax	30 000	304,3	1,28	909
CREDIT	FT-CUR	30 000	2 451,4	77,68	5 472
CREDIT	SAINT	15 000	61,9	1,54	9 244
HIGGS50K	FT-Softmax	48 842	55,1	0,26	969
HIGGS50K	FT-Sparsemax	48 842	111,9	0,74	2 032
HIGGS50K	FT-TopK	48 842	139,1	0,47	1 444
HIGGS50K	FT-Entmax	48 842	639,3	1,58	1 445
HIGGS50K	FT-CUR	48 842	849,8	20,74	10 642
HIGGS50K	SAINT	20 000	58,3	1,96	12 385

Achados principais:

- O tempo total é dominado pelo treinamento em todos os cenários: `fit_time_s` responde por quase todo `total_time_s`. A comparação computacional é, na prática, uma comparação de custo de treinamento.
- **SAINT** é o mais rápido entre os modelos com atenção inter-instâncias, mas seu consumo de memória é proibitivo: atinge 12,3 GB em ADULT com $N=20k$ e entra em OOM já em $N=30k$ (ADULT) e $N=20k$ (CREDIT/HIGGS50K). É o gargalo quadrático clássico ($O(n^2d)$).
- **FT-CUR** ocupa posição intermediária: em ADULT é mais rápido que FT-Entmax e competitivo com FT-TopK/Sparsemax, com custo de VRAM superior (3,3 GB no ADULT completo) e inferência transdutiva mais cara (5,9 s no ADULT completo). É a *versão computacionalmente viável* do paradigma inter-samples: enquanto SAINT esgota memória em $N \geq 20k$, FT-CUR comprime o mesmo mecanismo via landmarks e roda em $N = 48k$.
- Em **CREDIT**, o FT-CUR entra em regime patológico: no dataset completo ($N=30k$), o treinamento sobe para 2 451 s e a inferência para 77,7 s. A causa mais plausível é a extrapolação de hiperparâmetros tunados em regime reduzido ($N_{\text{treino}} = 5000$): em particular, um `m_ratio` muito maior no CREDIT (0,141 vs. 0,054 em ADULT) aumenta fortemente o número absoluto de landmarks e o custo do bloco inter-instâncias.
- Nos três datasets, os **FT baselines inter-features** (Softmax/TopK/Sparsemax) apresentam o melhor compromisso entre tempo e memória. FT-Softmax é o mais econômico em VRAM; FT-Sparsemax e FT-TopK mantêm custo semelhante em CREDIT/HIGGS50K.
- A RAM CPU mostrou baixa sensibilidade ao crescimento de N e é menos informativa que VRAM. As conclusões devem apoiar-se em tempo e memória de GPU.

Interpretação prática. Se o treinamento é *offline* e com baixa frequência, a vantagem temporal de SAINT e FT-CUR perde parte do peso operacional, enquanto seu maior consumo de memória permanece como custo persistente. Nesse regime, os FT baselines tornam-se mais atraentes por oferecerem inferência barata e *footprint* de memória muito menor, sem perda predominante de F_1 no benchmark operacional.

11.1 Análise Comparativa: SAINT vs. FT-CUR em Mini-batch e Full-batch

Para entender o real trade-off entre SAINT e FT-CUR, avaliou-se quatro configurações em GPU MX350 (2 GB VRAM) no dataset ADULT, medindo tempo por época e VRAM de pico com 5 épocas de aquecimento:

Tabela 24: Tempo por época e VRAM de pico para quatro variantes de atenção inter-instâncias. Hardware: NVIDIA MX350 (2 GB). OOM = sem memória. SAINT-mini: $B=1024$; FT-CUR-mini: $B=4096$, $m=10\%$ de B fixo.

Variante	$N = 2\,000$		$N = 5\,000$		$N = 10\,000$		$N = 15\,000$	
	s/ep	VRAM	s/ep	VRAM	s/ep	VRAM	s/ep	VRAM
SAINT-mini	0,69	182 MB	0,41	182 MB	0,81	183 MB	1,22	184 MB
SAINT-full	0,20	347 MB	OOM		OOM		OOM	
FT-CUR-mini	0,45	155 MB	0,95	453 MB	2,19	467 MB	3,86	468 MB
FT-CUR-full	0,55	155 MB	1,36	453 MB	6,99	1 191 MB	OOM	

Achados e interpretação:

- **SAINT-mini é o baseline mais difícil de superar.** Memória plana em ≈ 182 MB independente de N (o batch $B=1024$ é constante) e tempo por época que cresce suavemente com N graças ao cuBLAS que otimiza a multiplicação $B \times B$. Nenhuma das outras três variantes supera SAINT-mini em tempo para $N \geq 5\,000$.
- **SAINT-full** é o mais rápido em $N=2\,000$ (único passo, atenção global exata), mas entra em OOM para $N \geq 5\,000$ — gargalo $O(N^2)$ clássico.
- **FT-CUR-full dobra o alcance do SAINT-full** (OOM em $N \approx 12\,000$ vs. $N \approx 5\,000$), mas às custas de tempo crescente: em $N=10\,000$ é $8\times$ mais lento que SAINT-mini. A causa é identificada abaixo.
- **FT-CUR-mini é mais rápido que FT-CUR-full para $N \geq 5\,000$** — resultado aparentemente paradoxal para um modelo que não materializa $N \times N$. A explicação está na complexidade oculta do pseudo-inverso.

Complexidade oculta do pseudo-inverso de Nyström. A análise de complexidade do FT-CUR anuncia $O(N \cdot m)$ para a atenção Nyström, omitindo o custo do pseudo-inverso truncado via SVD da matriz de landmarks $W \in \mathbb{R}^{m \times m}$:

$$\text{pinv}(W) \sim O(m^3) \quad (\text{SVD, por cabeça de atenção}).$$

No modo *full-batch*, $m = \lfloor 0,1 N \rfloor$ cresce com N , tornando o custo real por época:

$$O(N \cdot m + m^3) = O(0,1 N^2 + 10^{-3} N^3).$$

Para $N=10\,000$ e $m=1\,000$: o termo cúbico equivale a 10^9 operações de SVD (executadas 4 vezes, uma por cabeça, em série). No modo *mini-batch*, $m_{\text{batch}} = \lfloor 0,1 \cdot B \rfloor = 410$ é *fixo*, reduzindo o custo total por época para:

$$\frac{N}{B} \cdot O(B \cdot m_{\text{batch}} + m_{\text{batch}}^3) = O(N \cdot \text{const}),$$

explicando por que FT-CUR-mini é mais rápido que FT-CUR-full em N grande, a despeito de processar os dados em batches menores.

Implicação metodológica. A comparação FT-CUR vs. SAINT é mais justa em *full-batch*: ambos processam o contexto global, mas FT-CUR com CUR evita o pico $N \times N$, estendendo o alcance de $N \approx 5\,000$ para $N \approx 12\,000$ na MX350. Em mini-batch, SAINT com softmax exato supera FT-CUR em tempo e memória para qualquer N testado — o custo do pseudo-inverso elimina a vantagem teórica $O(B \times m) < O(B^2)$.

Verificação de acurácia em múltiplos N . Uma questão crítica é se o treinamento em mini-batch prejudica a qualidade preditiva em relação ao full-batch. As quatro variantes foram avaliadas no dataset ADULT para $N_{\text{treino}} \in \{2\,000, 5\,000, 10\,000\}$ (40 épocas, patience = 6, métrica `val_loss`), medindo F1-macro no conjunto de teste fixo ($N_{\text{teste}}=13\,567$):

Tabela 25: F1-macro e tempo total de treino para as quatro variantes em múltiplos N . ADULT, GPU MX350. OOM = estouro de memória durante o treino. SAINT-mini: $B=1024$; FT-CUR-mini: $B=4096$, $m_{\text{batch}}=10\%B$.

Variante	$N = 2\,000$		$N = 5\,000$		$N = 10\,000$	
	F1	tempo	F1	tempo	F1	tempo
SAINT-mini	0,764	9,6 s	0,766	14,3 s	0,774	22,5 s
SAINT-full	0,747	12,4 s	OOM		OOM	
FT-CUR-mini	0,757	32,6 s	0,763	112,6 s	0,758	776,0 s
FT-CUR-full	0,767	98,5 s	0,769	293,7 s	0,778	832,7 s

Os resultados revelam três achados adicionais:

- **SAINT-mini é Pareto-ótimo.** Em $N=10\,000$ obtém o segundo melhor F1 (0,774) em apenas 22,5 s — $35\times$ mais rápido que FT-CUR-mini (776 s) e $37\times$ mais rápido que FT-CUR-full (833 s), ambos com F1 inferior ou igual.
- **FT-CUR-full tem o melhor F1** em $N=10\,000$ (0,778), mas ao custo de 833 s por execução — inviável para busca hiperparamétrica com muitas sementes.
- **FT-CUR-mini não é mais rápido que SAINT-mini para nenhum N .** O custo da pseudo-inversa $O(m_{\text{batch}}^3)$, executada em série por cabeça de atenção, supera o benefício de $O(B \times m) < O(B^2)$ na atenção. A diferença agrava-se com N : em $N=10\,000$, FT-CUR-mini é $34\times$ mais lento.

Conclui-se que **mini-batch não degrada a qualidade preditiva** (amplitude < 2 p.p. entre todas as variantes viáveis), e que SAINT-mini é a variante recomendada por combinar escalabilidade, baixo uso de memória e acurácia competitiva.

11.2 Benchmark de Predição: LSSVMs Esparsos no Tier 2

Para modelos esparsos, o tempo de *predição* é a métrica central: a esparsidade amostral reduz o número de vetores-suporte e, conseqüentemente, o custo de avaliar $f(\mathbf{x}) = \sum_{i \in S} \alpha_i K(\mathbf{x}_i, \mathbf{x})$. Os hiperparâmetros ótimos foram fixados a partir dos resultados do

GridCV do Tier 2 (Seção 10), e as estatísticas abaixo refletem médias de 30 sementes sobre os 6 datasets reais ($N_{\text{treino}}=2\,000$, $N_{\text{teste}}\approx 858$).

Tabela 26: Comparação de LSSVMs esparsos e XGBoost no Tier 2: F1-macro médio, tempo de treino, tempo de predição e esparsidade amostral. Ordenado por tempo de predição crescente. Hiperparâmetros fixos (melhores do GridCV). $N_{\text{treino}}=2\,000$; média sobre 6 datasets e 30 sementes.

Modelo	F1	Treino (s)	Predição (ms)	$ \mathcal{S} $	Espar.
XGBoost	0,723	12,3	12,5	—	—
FSA-LSSVM	0,676	268,3	35,7	161	92,0%
FISTA-Nyström	0,674	53,2	39,6	513	14,5%
ADMM-Nyström	0,681	61,9	40,9	474	20,9%
PCP-LSSVM	0,689	14,5	59,7	186	90,7%
Nyström	0,699	5,8	62,0	600	70,0%
IP-LSSVM	0,694	339,2	82,6	1 227	38,6%
LSSVM-Std	0,699	20,5	135,5	1 999	0,0%
DualFISTA	0,684	240,3	155,3	1 909	4,5%

Achados principais:

- **ADMM-Nyström é o melhor compromisso geral** entre os LSSVMs esparsos: $|\mathcal{S}| \approx 474$ (21% de N), predição em 41 ms ($3,3\times$ mais rápida que o Std), F1 competitivo (0,681) e escalabilidade até $N=20\,000$ no benchmark de RAM. A combinação da aproximação Nyström (que reduz a constante de memória) com a regularização ADMM (que induz esparsidade na solução dual) é a configuração mais favorável da família kernel estudada.
- **Nyström (Colnorm) oferece o maior F1 entre os esparsos** (0,699, empatado com LSSVM-Std), treino $3,5\times$ mais rápido e predição $2,2\times$ mais rápida. Contudo, a esparsidade de 70% é fixa por construção (parâmetro m), não emergindo da otimização — e a memória RAM permanece $O(N^2)$ com constante reduzida, conforme confirmado no benchmark de escalabilidade (Tabela 28).
- **DualFISTA é o resultado mais desfavorável** do benchmark: apesar de evitar o colapso dos métodos primais com ℓ_1 , converge para soluções quase densas em escala ($|\mathcal{S}| \approx 1\,909$, apenas 4,5% de esparsidade), tornando a predição $1,15\times$ *mais lenta* que o LSSVM-Std. No benchmark de escalabilidade, atinge o limite de 120 s já em $N=5\,000$, inviabilizando qualquer uso prático em datasets maiores. O ganho qualitativo da reformulação dual (F1 preservado) não se traduz em ganho operacional de esparsidade.
- **FSA-LSSVM e PCP-LSSVM** alcançam alta esparsidade nominal (92% e 91%), mas apresentam custo de treino elevado (268 s e 14,5 s respectivamente) e memória $O(N^2)$ idêntica ao LSSVM-Std no benchmark de escalabilidade, com timeout já em $N=5\,000$ (FSA) e RAM de 9,9 GB em $N=20\,000$ (PCP).
- **XGBoost** permanece superior em F1 (0,723), predição (12 ms) e memória (≈ 465 MB estável), sendo a referência a superar na família kernel em termos de eficiência operacional.

A Tabela 27 detalha o tempo de predição por dataset, evidenciando consistência entre domínios:

Tabela 27: Tempo de predição (ms) por dataset, Tier 2. Média de 30 sementes, $N_{\text{teste}} \approx 858$.

Modelo	ADULT	BANK	CREDIT	HIGGS50K	SHOPPERS	TELCO
XGBoost	12,3	15,0	11,1	14,3	11,7	10,6
FSA-LSSVM	30,3	37,0	41,4	39,8	36,4	29,6
FISTA-Nyström	39,9	42,7	42,0	40,0	43,1	29,8
ADMM-Nyström	38,0	42,6	41,3	47,8	38,8	36,9
PCP-LSSVM	62,6	60,7	62,8	60,6	57,7	53,8
Nyström	55,4	58,5	66,3	72,4	58,3	60,9
IP-LSSVM	83,4	81,1	77,5	83,4	85,8	84,0
LSSVM-Std	102,4	148,9	152,3	121,6	146,9	140,9
DualFISTA	151,7	143,8	153,6	149,7	148,7	184,3

Escalabilidade em memória RAM: todos os LSSVMs são $O(N^2)$. Um resultado relevante para a dissertação é que a esparsidade amostral reduz o tempo de *predição*, mas **não elimina o gargalo quadrático de memória RAM** no treino. O benchmark de escalabilidade a seguir (dataset ADULT, hiperparâmetros fixos, 1 semente, predição em $N_{\text{teste}}=1\,000$ amostras fixas) torna isso evidente:

Tabela 28: Escalabilidade de memória RAM (RSS de processo, via `psutil`) e tempo de predição com N crescente. Hiperparâmetros fixos do GridCV. TIME = ultrapassou 120s de treino. Dataset ADULT, $N_{\text{teste}}=1\,000$ fixo. RSS inclui baseline do processo Python (≈ 280 MB); o crescimento entre colunas reflete o custo incremental do modelo. † valor inflado por memória residual de runs anteriores no mesmo processo (RSS não devolvido ao SO).

Modelo	$N = 2\,000$		$N = 5\,000$		$N = 10\,000$		$N = 20\,000$	
	RAM	pred	RAM	pred	RAM	pred	RAM	pred
LSSVM-Std	346 MB	217 ms	947 MB	429 ms	2 655 MB	835 ms	TIME	
Nyström	284 MB	45 ms	420 MB	97 ms	905 MB	119 ms	2 860 MB	249 ms
ADMM-Nyström	†1 187 MB	16 ms	337 MB	45 ms	570 MB	56 ms	1 286 MB	57 ms
DualFISTA	407 MB	173 ms	TIME		SKIP		SKIP	
FISTA-Nyström	323 MB	49 ms	495 MB	71 ms	1 021 MB	197 ms	TIME	
FSA-LSSVM	376 MB	19 ms	TIME		SKIP		SKIP	
PCP-LSSVM	376 MB	79 ms	888 MB	63 ms	2 674 MB	38 ms	9 890 MB	61 ms
XGBoost	465 MB	31 ms	466 MB	2 ms	466 MB	22 ms	469 MB	37 ms

A razão é estrutural: mesmo as variantes Nyström formam uma matriz de kernel $N \times m$ com $m = 0,2 N$, resultando em custo $O(N \cdot m) = O(0,2 N^2)$ — quadrático na constante, não na ordem. Isso se confirma nos dados: o LSSVM-Std cresce de 346 MB para 2 655 MB entre $N=2\,000$ e $N=10\,000$ (fator $7,7\times$ para $5\times$ o N , consistente com $O(N^2)$), e o Nyström cresce de 284 MB para 905 MB (fator $3,2\times$, consistente com constante $5\times$ menor que o Std).

O XGBoost mantém RSS estável em ≈ 465 MB independente de N — reflexo da sua estrutura de árvores de decisão, sem necessidade de matrizes $N \times N$.

O benefício real da esparsidade manifesta-se na **predição**: o ADMM-Nyström encontra soluções com $|\mathcal{S}| \approx 474$ vetores-suporte (21% de N), reduzindo o tempo de predição de 217 ms (LSSVM-Std, $N=2\,000$) para 16 ms — aceleração de **13** $\times$ com queda de apenas 0,4 p.p. em F1. Em $N=10\,000$, o ADMM-Nyström prediz em 57 ms enquanto o LSSVM-Std já não converge por falta de memória RAM.

12 Sumário e Próximos Passos

Tabela 29: Síntese dos experimentos realizados.

Experimento	Configuração	Runs	Resultado principal
Tier 1	18 mod. (12 LSSVM+XGB + 6 Transformers), 9 datasets, 30 seeds (Grid+CV)	4860	Nyström 0,838 / LSSVM-Std 0,838 / DualFISTA 0,831 / XGBoost 0,826
Ablação A (escala)	18 mod., 3 sintéticos, $N=400 \rightarrow 2000$, 30s (LSSVM/XGB) ou 20s (Transf.)	1080	LSSVMs saturados ($\bar{\Delta} \approx 0$); Transf. data-hungry (FT-sparsemax +0,145)
Ablação B (ruído)	18 mod., 3 sintéticos, +3 feat. ruído, 30s	1620	XGBoost $\bar{\Delta} = -0,048$; LSSVMs $-0,26$ a $-0,39$; Transf. $-0,029$ a $-0,044$
Ablação C (MK5)	18 mod., 3 sintéticos (5 features), 30 seeds	1620	LSSVM-Std 0,851 > Nyström 0,841; Transf. abaixo (0,782–0,807)
Tier 2 ($N_{\text{treino}} = 5000$)	18 modelos, 6 datasets reais, 30s	3240	XGBoost 0,735; SAINT/FT-CUR/FT baselines $\sim 0,72$; primais ℓ_1 colapsam para 0,58
Ablação H2 (early stop)	FT-CUR/SAINT, CREDIT/BANK, 3 métricas, 30s	360	$\text{val_loss} > \text{val_acc}$ ($p < 10^{-5}$ em todos os 4 cenários)
Benchmark eficiência	6 Transformers, 3 datasets reais, 1 seed	137	SAINT OOM cedo; FT baselines dominam tempo/memória; FT-CUR patológico em CREDIT 30k
Total		13 057	

Conclusões consolidadas:

1. **Nyström-LSSVM** é o melhor resultado da dissertação em alta esparsidade: $F_1 = 0,838$ no Tier 1 (78% esp., Grid+CV) e 0,707 no Tier 2 (81,5% esp.), em ambos os regimes a $\leq 0,002$ do LSSVM-Std denso. *Compressão sem custo preditivo*, agora confirmado em escala $N = 5000$.
2. **DualFISTA** mantém F1 próximo ao LSSVM-Std no Tier 1 (0,831 vs. 0,838, $\Delta=0,007$) e elimina o colapso dos primais com ℓ_1 no Tier 2 — contribuição qualitativa confirmada. Contudo, o benchmark de predição e escalabilidade revela um **trade-off desfavorável em produção**: converge para soluções quase densas ($|\mathcal{S}| \approx 1\,909$, 4,5% de esparsidade), predição 1,15 $\times$ mais lenta que o LSSVM-Std denso, e timeout em $N=5\,000$. A reformulação dual não induz esparsidade amostral suficiente para justificar o custo computacional adicional de treino.
3. **FT-CUR** valida o paradigma de compressão Nyströmformer em dados tabulares: empata com SAINT denso em todos os experimentos ($\Delta \leq 0,013$) com $\approx 85\text{--}89\%$ de compressão inter-instâncias (Tier 1: 85%; Tier 2: 89%), e roda em $N = 48k$ onde SAINT entra em OOM.
4. **Colapso dos métodos primais com ℓ_1 em escala** é o achado mais inesperado do Tier 2: ADMM-Nesterov, ADMM-ElasticNet e FISTA-Nesterov caem de 0,787–0,802 (Tier 1, Grid+CV) para $\approx 0,58$ em $N = 5000$. Revela um teto de escalabilidade não detectável em $N \leq 1000$ e justifica a reformulação dual proposta (DualFISTA).

5. **H2 confirmada metodologicamente:** `val_loss` domina `val_acc` como critério de early stopping para modelos inter-instâncias em datasets desbalanceados ($p < 10^{-5}$ em todos os 4 cenários). É uma contribuição metodológica auxiliar ao protocolo padrão de FT-Transformers tabulares.
6. **Benchmark de eficiência:** FT baselines dominam o trade-off tempo/memória em *full-data*; FT-CUR é a única variante inter-instâncias que roda em $N = 48k$. SAINT é rápido mas restrito a $N \leq 20k$.

Próximas etapas planejadas:

1. **Benchmark de eficiência computacional — família ADMM vs. variantes Nyström:** o benchmark de predição e escalabilidade (Seção 11.2) confirmou que ADMM-Nyström é a configuração mais eficiente da família kernel, com predição $13\times$ mais rápida que o LSSVM-Std e escalabilidade até $N=20\,000$. DualFISTA não produziu esparsidade operacional (4,5% de SVs, timeout em $N=5\,000$), encerrando a hipótese de eficiência computacional desta variante como pendente. Próxima análise: coletar curvas de convergência (loss vs. iteração) para ADMM-Nesterov e ADMM-Nyström para quantificar o custo por iteração e justificar a escolha do ADMM-Nyström como variante de referência.
2. **H1 — Tier 2 com balanceamento no treino:** rodar todos os 18 modelos com `-balance-train` (undersample da majoritária só no treino, preservando o teste original), testando se o resíduo do FT-CUR em CREDIT desaparece e se os métodos primais com ℓ_1 se recuperam.
3. **Tier 2 *full-data*:** rodar os 4 FT baselines + FT-CUR no N completo de cada dataset (Colab GPU; $\sim 10\text{--}12h$); e XGBoost + Nyström-LSSVM em N completo (Colab CPU; $\sim 3\text{--}5h$) para confirmar a vantagem de eficiência amostral observada em $N = 5000$.
4. **Re-rodar Tier 1 (`lambda_ratio` corrigido)** para 4 modelos: a correção de escala do λ entre Tier 1 e Tier 2 (sintaxe `lambda_ratio` em vez de absoluto) deve ser retroaplicada aos métodos primais com ℓ_1 e ao LSSVM-Pruning (que ganhou *early stopping* no Tier 2) para comparação metodológica justa entre tiers.
5. **Diagrama de diferença crítica** (Nemenyi) sobre todos os datasets consolidados (Tier 1 + 3 ablações + Tier 2 = 21 datasets), reportado como figura agregada de comparação estatística entre os 18 modelos.

A Infraestrutura e Reprodutibilidade

- **Código:** repositório `sparse-lssvm-transformers-study/`
- **Ambiente:** Python 3.12, PyTorch, scikit-learn, Optuna; virtualenv em `.venv/`
- **Resultados:** arquivos JSON em `results/`: `tier1_results.json` (baselines), `tier1_custom_models.json` (propostos), `synthetic_scaling_n2000.json`, `synthetic_5features_tuned.json`, `synthetic_mk5.json`, `tier2_n5000_*.json` (consolidado), `tier2_n5000_ftcur_saint_valloss.json` (re-run H2), `tier2_early_stop_ablation.json` (ablação H2), `benchmark_transformers_efficiency.json` (benchmark full-data)

- **Tuning:** results/tuning/best_params*.json
- **Scripts:** scripts/run_*.py são resumíveis (checkpoint por chave model/dataset/seed)
- **Figuras:** geradas por scripts/generate_report_figs.py e scripts/generate_tier2_analysis.py

B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)

Tabela 30: P-valores do teste de Wilcoxon signed-rank com correção de Holm-Bonferroni — TIER2 ($n_{\text{comp}} = 36$; negrito = significativo em $\alpha = 0,05$).

	ADMM-Nystrom	LSSVM-DualFISTA	FISTA-Nystrom	LSSVM-FSA	LSSVM-IP	LSSVM-Nystrom	LSSVM-PCP	LSSVM (Standard)	XGBoost
ADMM-Nystrom	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-DualFISTA	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FISTA-Nystrom	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-FSA	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000
LSSVM-IP	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000
LSSVM-Nystrom	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000
LSSVM-PCP	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000
LSSVM (Standard)	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000
XGBoost	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–