

Relatório de Experimentos

Estudo Comparativo: LSSVM Esperso vs. Transformers Tabulares
Dissertação de Mestrado — Experimentos (atualizado em junho de 2026)

Paulo Bernardo

Junho de 2026

Sumário

1	Introdução	3
2	Auditoria da Implementação do Nyström-SVM	4
2.1	As três versões	4
2.2	Verificação experimental	5
2.3	Esparsidade reportada	5
3	Experimento Tier 1: Benchmarks Reais	6
3.1	Resultados por Dataset	6
3.2	Comparação Geral	7
3.3	Análise estatística: Friedman e ranks médios (Tier 1)	8
3.4	Ranking nos datasets reais (sem sintéticos)	8
4	Arquitetura dos FT-Transformers e Tipos de Atenção	9
4.1	Atenção inter-features (intra-instância)	9
4.2	Atenção inter-instâncias (entre amostras)	10
5	Análise de Esparsidade	11
5.1	Esparsidade amostral — LSSVMs	11
5.2	Esparsidade de atenção inter-features — FT-Transformers baselines	13
5.3	Esparsidade nos Transformers — Tier 2 ($N_{\text{treino}} = 2000$)	13
6	Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)	14
7	Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)	16
8	Ablação C: Dados Sintéticos Multifeature (MK5)	17
9	Análise das Variantes Investigadas e Modelos Propostos	19
9.1	Mecanismos de esparsidade	19
9.2	Desempenho consolidado	19
9.3	Síntese comparativa	20

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 2000$)	21
10.1 Protocolo	21
10.2 Resultados por Dataset (todos os 18 modelos)	21
10.3 Análise estatística: Friedman e ranks médios	23
10.4 Esparsidade consolidada no Tier 2	23
10.5 Colapso dos métodos primais com ℓ_1 em escala	24
10.6 Ablação de Escalabilidade Amostral no Tier 2 ($N = 2000 \rightarrow N = 5000$) . .	25
10.7 FT-CUR/SAINT e a correção metodológica da H2	28
10.8 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia	29
10.9 Comparação entre variantes de FT-Transformer no Tier 2	31
11 Benchmark de Eficiência Computacional em <i>Full-Data</i>	32
11.1 Análise Comparativa: SAINT vs. FT-CUR em Mini-batch e Full-batch . .	34
11.2 Benchmark de Predição: LSSVMs Esparsos no Tier 2	36
12 Sumário e Próximos Passos	38
A Infraestrutura e Reprodutibilidade	40
B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)	40

1 Introdução

Este relatório consolida os resultados dos experimentos conduzidos na dissertação, que compara métodos de *Least-Squares Support Vector Machine* (LSSVM) com ênfase em esparsidade contra variantes de *FT-Transformer* com atenção esparsa em tarefas de classificação binária tabular.

O trabalho estende o algoritmo LSSVM-ADMM-Nesterov proposto por Marinho et al. com dois novos mecanismos de esparsidade: (i) **DualFISTA**, formulação dual do LSSVM como LASSO com otimização via ISTA acelerado; e (ii) **Nyström-SVM**, aproximação da matriz kernel por seleção de landmarks via norma de coluna. Como comparativo do lado dos Transformers, avalia-se o **FT-CUR**, que aplica decomposição CUR com colnorm à matriz de atenção.

Auditoria do Nyström-SVM — três versões

A implementação do Nyström-SVM passou por três versões. A versão final, auditada matematicamente (Seção 2), é a apresentada neste relatório.

Versão	Predição	F1 Tier 1
Bug original	$f(x)=K(x, X_{\text{treino}})\alpha + b$ (kernel completo)	0,8427 (inflado)
“Fix” errado	$f(x)=K(x, Z)\alpha[\text{lm_idx}] + b$ (subset ingênuo de α)	0,6678 (colapsado)
Correta	$f(x)=K(x, Z)(W^{-1}C^T\alpha) + b$ (Nyström)	0,8342

A versão correta usa a fórmula matemática da aproximação Nyström ($\tilde{K} = CW^{-1}C^T$), com custo $O(n_{\text{test}} \cdot m)$ e **sem dependência de X_{treino} na predição** (verificado experimentalmente). A perda de F1 em relação ao bug original é de apenas 0,0085, mas agora com $\approx 78\%$ de esparsidade amostral genuína (Grid+CV, Tier 1).

Modelos avaliados

Ao todo, 18 modelos foram avaliados, organizados em cinco grupos por origem na literatura:

- **Baseline geral tabular (1): XGBoost** (Chen & Guestrin, 2016) — padrão-ouro para dados tabulares, serve como referência externa às famílias LSSVM e Transformer.
- **LSSVMs baselines (7):** LSSVM-Std (sem esparsidade), LSSVM-PCP, LSSVM-FSA, LSSVM-IP, LSSVM-Pruning, LSSVM-OppMaps, e **FISTA-Nesterov** (LSSVM primal com FISTA — método clássico de Beck & Teboulle, 2009, amplamente documentado).
- **FT-Transformers baselines (5):** variantes com atenção softmax, top- k , entmax e sparsemax — mais **SAINT** (Somepalli et al., 2021; atenção inter-instâncias densa).
- **Paper-base estendido: LSSVM-ADMM-Nesterov** de Marinho et al. — método sobre o qual esta dissertação constrói.
- **Variantes investigadas e modelos propostos (4):**
 - **ADMM-ElasticNet^o**: variante do paper-base com penalidade Elastic Net (combinação ADMM-Nesterov + Elastic Net + LSSVM não localizada explicitamente na literatura como método publicado).

- **DualFISTA**[◦]: formulação dual do LSSVM como LASSO ($\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \|\alpha\|_1$), otimizada via FISTA. Ponto de investigação — não localizada na literatura nesta forma exata; pode ser uma reformulação convergente com métodos análogos em SVM ou regressão Lasso.
- **Nyström-SVM (colnorm)**^{*}: aproxima $K \in \mathbb{R}^{n \times n}$ via $m \ll n$ landmarks selecionados por norma de coluna (em vez de amostragem uniforme/leverage tradicional); predição restrita aos landmarks ($O(n_{\text{test}} \cdot m)$, auditada).
- **FT-CUR (Nyströformer)**^{*}: aplicação de Nyströformer (Xiong et al., 2021) à atenção inter-instâncias do FT-Transformer em dados tabulares; seleção de landmarks via colnorm (combinação não localizada como método publicado).

◦ = variante/ponto de investigação; * = aplicação/combinação proposta.

Protocolo experimental

- 30 sementes aleatórias, partição estratificada 70/30.
- Métrica principal: F1-macro (média aritmética do F1 por classe).
- Hiperparâmetros otimizados via **Grid Search exaustivo + 5-fold CV** estratificado (**GridSearchCV**, scikit-learn) para todos os modelos em ambos os tiers (Transformers re-executados com **epochs=40, patience=6** em GPU T4).
- Normalização por **StandardScaler** ajustado apenas no treino.

2 Auditoria da Implementação do Nyström-SVM

2.1 As três versões

O Nyström-SVM aproxima a matriz kernel completa $K \in \mathbb{R}^{n \times n}$ a partir de m landmarks $\{z_1, \dots, z_m\}$ selecionados antes do treino:

$$K \approx C W^{-1} C^{\top}, \quad C = K(X, Z) \in \mathbb{R}^{n \times m}, \quad W = K(Z, Z) \in \mathbb{R}^{m \times m}.$$

O treinamento, via identidade de Woodbury, é correto em todas as versões. A diferença está apenas na predição:

V1 — Bug original. Predizia com o kernel completo:

$$f(x) = K(x, X_{\text{treino}}) \alpha + b.$$

Não tinha esparsidade real (todo X_{treino} era usado em inferência) e produzia $F_1 = 0,8427$ no Tier 1.

V2 — “Fix” ingênuo. Tentativa de restringir aos landmarks pegando apenas o subset de α nos índices dos landmarks:

$$f(x) = K(x, Z) \alpha[\text{lm_idx}] + b.$$

Está **matematicamente errado**: os pesos $\alpha \in \mathbb{R}^n$ foram ajustados para o sistema KKT completo n -dimensional, e simplesmente subsetá-los nos índices dos landmarks não recupera a aproximação Nyström. F1 colapsou para 0,6678.

V3 — Correta (atual). A aproximação Nyström verdadeira é $\tilde{K}(x, X) = K(x, Z) W^{-1} C^\top$. Substituindo em $f(x) = \tilde{K}(x, X) \alpha + b$:

$$f(x) = K(x, Z) (W^{-1} C^\top \alpha) + b = K(x, Z) w_\alpha + b, \quad w_\alpha = W^{-1} C^\top \alpha \in \mathbb{R}^m.$$

O vetor w_α é calculado uma vez ao final do fit e cacheado. Em inferência, só $K(x, Z) \in \mathbb{R}^{n_{\text{test}} \times m}$ é computado — não há mais nenhuma dependência de X_{treino} . F1 = 0,8342.

2.2 Verificação experimental

A implementação V3 foi auditada matematicamente (`scripts/audit_nystrom_lssvm.py`) confirmando três propriedades:

1. **Equivalência matemática.** $\|f_{\text{cache}}(x) - f_{\text{Nyström}}(x)\|_2 = 0$ exatamente, onde $f_{\text{Nyström}}$ usa a fórmula expandida $K(x, Z) W^{-1} C^\top \alpha + b$.
2. **Sem dependência de X_{treino} .** Após o fit, ao apagar X_{treino} do modelo, as predições continuam idênticas ($\|\Delta f\|_2 = 0$). Confirma que apenas Z é usado na inferência.
3. **Custo $O(n_{\text{test}} \cdot m)$.** Mantendo m fixo e variando n_{treino} de 1000 a 6000, o tempo de predição permanece em ≈ 5 ms (não escala com n).

Tabela 1: Comparação direta no BCW (10 sementes, mesmos hiperparâmetros).

Versão	F1 BCW	Diagnóstico
V1 (kernel completo)	0,974	0% de esparsidade real
V2 (α subsetado)	0,360	matematicamente inválida
V3 ($W^{-1} C^\top \alpha$, atual)	0,968	$\approx 80\%$ esparsidade real

A V3 perde apenas 0,006 em relação ao kernel completo no BCW, mostrando que a aproximação Nyström com seleção colnorm é *genuinamente* boa quando bem tunada — a esparsidade não custa quase nada de F1.

2.3 Esparsidade reportada

Com a predição V3, a esparsidade do Nyström-SVM é semanticamente consistente com os demais LSSVMs:

- **ADMM/FISTA:** esparsidade = fração de $\alpha_i = 0$.
- **Nyström:** esparsidade = $1 - m/n$, fração de pontos de treino *não* usados como landmark-key.

A razão m/n é tunada por Grid+CV por dataset; a esparsidade resultante varia entre 50% (TWC) e 92% (PID), com média 78% no Tier 1.

3 Experimento Tier 1: Benchmarks Reais

Nove conjuntos de dados foram utilizados (Tabela 2). Os três últimos (TWS, TWM, TWC) são sintéticos bidimensionais incluídos como controle com fronteiras de decisão conhecidas.

Tabela 2: Conjuntos de dados — Tier 1.

ID	Nome	N	Features	Domínio
BCW	Breast Cancer Wisconsin	569	30	Diagnóstico médico
PID	Pima Indians Diabetes	768	8	Diagnóstico médico
HAB	Haberman Survival	306	3	Sobrevivência
VCP	Vehicle Coupon Purchase	1584	7	Marketing
GCR	German Credit Risk	1000	20	Crédito
AUS	Australian Credit	690	14	Crédito
TWS	Two Spirals (sintético)	400	2	Controle
TWM	Two Moons (sintético)	400	2	Controle
TWC	Checkerboard (sintético)	400	2	Controle

3.1 Resultados por Dataset

A Tabela 3 apresenta o F1-macro médio (30 sementes) para *todos* os modelos, usando Grid Search exaustivo + 5-fold CV (GridSearchCV, scikit-learn) para todos os modelos incluindo Transformers (re-executados em GPU T4 no Kaggle). Os melhores valores por coluna estão em negrito.

Tabela 3: F1-macro médio (30 sementes, Grid+CV). **Negrito**: melhor por coluna. ◦ = variante investigada; ★ = proposta.

Modelo	BCW	PID	HAB	VCP	GCR	AUS	TWS	TWM	TWC	Média
<i>Baseline geral tabular</i>										
XGBoost	0,958	0,724	0,559	0,804	0,691	0,862	0,944	0,984	0,912	0,826
<i>Baselines LSSVM</i>										
LSSVM-Std	0,973	0,732	0,566	0,827	0,691	0,861	0,994	0,997	0,898	0,838
LSSVM-FSA	0,966	0,732	0,550	0,811	0,680	0,855	0,987	0,997	0,879	0,829
LSSVM-IP	0,969	0,718	0,546	0,828	0,681	0,857	0,992	0,996	0,897	0,832
LSSVM-PCP	0,975	0,731	0,563	0,827	0,687	0,862	0,991	1,000	0,905	0,838
FISTA-Nesterov	0,823	0,682	0,609	0,755	0,552	0,829	0,971	0,989	0,877	0,787
LSSVM-Prun	0,969	0,642	0,493	0,816	0,628	0,851	0,989	0,997	0,891	0,808
LSSVM-OppM	0,951	0,463	0,454	0,715	0,550	0,815	0,986	0,991	0,907	0,759
<i>Baselines FT-Transformer</i>										
FT-Sparsemax	0,950	0,696	0,560	0,794	0,653	0,857	0,632	0,962	0,474	0,731
SAINT	0,945	0,712	0,534	0,815	0,669	0,857	0,641	0,942	0,460	0,731
FT-Entmax	0,959	0,698	0,554	0,800	0,667	0,861	0,625	0,960	0,482	0,734
FT-Softmax	0,954	0,688	0,553	0,803	0,675	0,855	0,625	0,946	0,471	0,730
FT-TopK	0,951	0,668	0,537	0,756	0,648	0,855	0,630	0,884	0,476	0,712
<i>Paper-base estendido</i>										
LSSVM-ADMM-Nesterov	0,872	0,688	0,623	0,765	0,592	0,840	0,971	0,988	0,881	0,802
<i>Variantes investigadas / propostos</i>										
DualFISTA◦	0,964	0,726	0,574	0,831	0,642	0,851	0,993	0,997	0,901	0,831
Nyström-SVM★	0,970	0,728	0,579	0,825	0,691	0,863	0,992	0,999	0,898	0,838
ADMM-ElasticNet◦	0,872	0,687	0,623	0,764	0,592	0,840	0,971	0,988	0,881	0,802
FT-CUR★ (Nyströmformer)	0,949	0,704	0,559	0,815	0,672	0,856	0,624	0,974	0,487	0,738

3.2 Comparação Geral

A Figura 1 mostra o F1-macro médio ($\pm$ dp) agregado sobre todos os datasets e sementes para cada modelo.




Figura 1: F1-macro médio $\pm$ dp (30 sementes $\times$ 9 datasets). ★ indica modelos propostos; vermelho = DualFISTA, verde = Nyström-SVM, laranja = FT-CUR.

Observações principais (Grid+CV):

- **Nyström-SVM** (0,838) é o modelo com melhor F1-macro médio, empatado estatisticamente com LSSVM-Std (0,838). DualFISTA segue próximo (0,831) e LSSVM-IP (0,832). Com $\approx 78\%$ de esparsidade amostral, o Nyström-SVM valida o trade-off F1/esparsidade como o melhor entre modelos de alta compressão.
- **DualFISTA** (0,831) alcança F1-macro médio próximo ao LSSVM-Std completo (0,838, diferença 0,007) com $\approx 10\%$ de esparsidade. É o único modelo esparsa da família dual que se aproxima do baseline sem esparsidade.
- **XGBoost** (baseline tabular) atinge 0,826 no Tier 1 — agora competitivo com os LSSVMs esparsos (IP 0,832, PCP 0,838). Destaque para TWC (0,912, melhor por coluna): o Grid+CV encontrou parâmetros que capturam a fronteira xadrez, eliminando o colapso observado no protocolo Optuna anterior (0,476). Perde em AUS e nos dados sintéticos TWS/TWM para os LSSVMs com kernel RBF.
- O **LSSVM-ADMM** e ADMM-ElasticNet ficam ≈ 4 pp abaixo do LSSVM-Std (0,802 ambos). **FISTA-Nesterov** (0,787) cai mais acentuadamente (≈ 5 pp) após reexecução com grade estendida de λ — resultado do CV selecionar λ menores que maximizam F1 com baixa regularização.
- **LSSVM-Pruning** (0,808) recuperou-se significativamente com a correção do grid (adição de pruning_rate= 0,05 e sigma= 15): era 0,782 no protocolo Optuna.
- **Transformers** (Grid+CV, 40 épocas, GPU T4) ficam em 0,712–0,738 de F1 médio — 10–13 pp abaixo do bloco líder LSSVM. O colapso concentra-se nos datasets sintéticos:

TWC melhor transformer (0,487, FT-CUR) contra Nyström-SVM 0,898; TWS 0,641 vs 0,994. Nos datasets reais os Transformers são competitivos (ver Seção 3.4).

- **FT-CUR** (0,738) é o melhor Transformer, empatado em rank com FT-Entmax (0,734). FT-CUR comprime $\approx 85\%$ da atenção inter-instâncias mantendo F1 superior ao SAINT denso (0,731): **a compressão não custa F1** também no protocolo rigoroso.

3.3 Análise estatística: Friedman e ranks médios (Tier 1)

O teste não-paramétrico de Friedman aplicado às 18 variantes (12 LSSVM+XGBoost + 6 Transformers) sobre os 9 datasets confirma diferença estatisticamente significativa entre os modelos: $\chi^2 = 66,20$, $p \approx 0$. A diferença crítica de Nemenyi para $\alpha = 0,05$ é $CD = 8,78$.

Tabela 4: Ranks médios de Friedman (menor = melhor).

Rank	Model	Avg. rank
1	XGBoost	1.000
2	LSSVM (Standard)	2.833
3	LSSVM-Nystrom	3.333
4	LSSVM-IP	4.333
5	LSSVM-PCP	5.333
6	LSSVM-DualFISTA	6.333
7	LSSVM-FSA	6.833
8	ADMMNystromLSSVM	6.833
9	FISTANystrom	8.167

Leitura dos ranks: Nyström-SVM (rank 2,8) e LSSVM-Std (3,3) formam o topo do ranking. DualFISTA desceu para rank 5,6 (era 3,4 antes da reexecução com grade de λ corrigida) mas permanece próximo de LSSVM-IP (5,7) e dentro da diferença crítica. XGBoost (rank 6,7) é o melhor modelo não-kernel e não-Transformer. Os Transformers ficam na metade inferior do ranking (ranks 10,9–14,1): FT-Entmax (rank 10,9) é o melhor Transformer, seguido de FT-CUR (11,0), FT-Sparsemax (11,6) e SAINT (12,0). LSSVM-ADMM (11,7) e LSSVM-ADMM-EN (11,9) intercalam-se entre os Transformers. LSSVM-FISTA (13,3) e FT-TopK (14,1) são os piores modelos. O colapso dos Transformers nos datasets sintéticos TWS/TWM/TWC — onde a fronteira de decisão exige inductive bias geométrico que a atenção não possui — é o principal responsável pelos ranks baixos.

3.4 Ranking nos datasets reais (sem sintéticos)

Para isolar o efeito do inductive bias geométrico, repetiu-se a análise de Friedman excluindo os três datasets sintéticos (TWS, TWM, TWC) e considerando apenas os seis datasets reais (BCW, PID, HAB, VCP, GCR, AUS).

Resultado: $\chi^2 = 87,40$, $p \approx 0$, $CD \approx 10,8$ (18 modelos $\times$ 6 datasets; CD maior que no caso de 9 datasets por menor número de blocos).

Rank	Modelo	Avg. rank	F1 médio
1	LSSVM-Nyström	2,667	0,776
2	LSSVM-Std	3,333	0,775
3	XGBoost	5,833	0,766
3	LSSVM-IP	5,833	0,766
5	LSSVM-DualFISTA	7,167	0,765
6	LSSVM-FSA	7,333	0,766
7	FT-Entmax	8,667	0,757
8	LSSVM-PCP	9,000	0,763
9	FT-CUR	9,167	0,759
10	FT-Sparsemax	10,000	0,752
10	SAINT	10,000	0,755
10	FT-Softmax	10,000	0,755
13	LSSVM-Pruning	11,500	0,733
14	LSSVM-ADMM-EN	12,833	0,730
15	LSSVM-ADMM	13,000	0,730
16	FT-TopK	13,167	0,736
17	LSSVM-FISTA	14,667	0,708
18	LSSVM-OppMaps	16,833	0,658

Interpretação: sem os datasets sintéticos, os Transformers sobem significativamente no ranking. FT-Entmax (rank 8,7) e FT-CUR (rank 9,2) superam LSSVM-PCP, LSSVM-Pruning, LSSVM-ADMM e LSSVM-FISTA. A diferença entre o melhor LSSVM (Nyström, rank 2,7) e o melhor Transformer (FT-Entmax, rank 8,7) é $6,0 < CD \approx 10,8$, portanto **não é estatisticamente significativa** para $\alpha = 0,05$. DualFISTA desce para rank 7,2 (era 3,8 antes do rerun), mas permanece acima dos Transformers.

Conclui-se que o fraco desempenho global dos Transformers no Tier 1 é *quase inteiramente explicado pelo colapso nos datasets sintéticos*. Em dados tabulares reais, Transformers e LSSVMs com kernel são estatisticamente equivalentes no topo. A escolha entre as duas famílias deve ser guiada pelo tipo de dado: para dados com estrutura geométrica não-linear e N pequeno, kernel methods dominam; para dados tabulares heterogêneos reais, Transformers são alternativas viáveis.

4 Arquitetura dos FT-Transformers e Tipos de Atenção

Esta seção esclarece a distinção entre os dois mecanismos de atenção presentes nos modelos baseados em Transformer avaliados, terminologia necessária para interpretar corretamente as medidas de esparsidade.

4.1 Atenção inter-features (intra-instância)

Os FT-Transformers baselines (softmax, top- k , entmax, sparsemax) implementam **atenção entre features de uma mesma instância**. Dado um batch de n amostras com d features, cada instância $x_i \in \mathbb{R}^d$ é representada como uma sequência de d tokens após embedding. A atenção opera na dimensão dos tokens:

$$A^{(i)} = \text{softmax}\left(\frac{Q^{(i)}(K^{(i)})^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{d \times d},$$

onde $A^{(i)}$ indica quanta atenção a feature j dá à feature k dentro da instância i . As variantes esparsas (sparsemax, top- k) fazem $A^{(i)}$ ter entradas exatamente zero. Esta esparsidade *não* envolve comparação entre amostras distintas — é **intra-instância**.

4.2 Atenção inter-instâncias (entre amostras)

SAINT e **FT-CUR** acrescentam (ou substituem) um mecanismo de atenção entre instâncias distintas. Todas as n amostras do contexto são comparadas entre si:

$$A = f\left(\frac{QK^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{n \times n},$$

onde cada entrada A_{ij} mede a influência da amostra j sobre a amostra i .

SAINT vs. FT-CUR: atenção inter-instâncias densa vs. comprimida

- **SAINT** usa $f = \text{softmax}$ completo: $A \in \mathbb{R}^{n \times n}$ é materializada integralmente. Custo: $O(n^2d)$ por cabeça. Sem zeros exatos $\Rightarrow$ esparsidade de compressão = 0%. Serve como **baseline denso** para a comparação com FT-CUR. *Atenção:* na formulação original (Somepalli et al., 2021) esse n é o tamanho do **lote** B — a atenção inter-instâncias é *batch-level*, aplicada dentro de cada *mini-batch* no treino e na inferência. O custo é, portanto, $O(B^2d)$ constante no tamanho N do conjunto; o preço é que o contexto entre amostras fica *local*, restrito às B linhas do lote (nos experimentos, $B = 1024$).
- **FT-CUR (Nyströmformer)** evita materializar A ao todo: seleciona $m \ll n$ landmarks por norma de coluna e computa três produtos menores com softmax separado:

$$C = \text{softmax}\left(\frac{QK_m^\top}{\sqrt{d_h}}\right)[n \times m], \quad R = \text{softmax}\left(\frac{Q_mK^\top}{\sqrt{d_h}}\right)[m \times n], \quad W = \text{softmax}\left(\frac{Q_mK_m^\top}{\sqrt{d_h}}\right)[m \times m].$$

Saída: $\text{out} = C(W^+(RV))$ da direita para a esquerda — custo $O(nmd)$, nunca $O(n^2d)$. Compressão inter-instâncias: $1 - m/n$.

A atenção inter-features (softmax/topk/entmax/sparsemax) e a atenção inter-instâncias (SAINT/FT-CUR) são **ortogonais**: SAINT e FT-CUR incluem ambas (bloco inter-features padrão + bloco inter-instâncias), enquanto os FT-Transformers baselines têm apenas a inter-features.

A comparação real: alcance a custo controlado (não “denso vs. barato”)

A leitura ingênua “SAINT é $O(N^2)$ e estoura memória, FT-CUR resolve” é **incorreta**. O SAINT canônico é *batch-level*: seu custo é $O(B^2)$, *constante em N* — na medição de escalabilidade, a VRAM do SAINT em *mini-batch* fica praticamente estável ($\approx 34\text{--}43$ MB) de $N = 500$ a $N = 50\,000$. O custo $O(N^2)$ só aparece se a atenção inter-instâncias for forçada **densa e global** (todas as N amostras num único *forward*): aí a VRAM cresce de ≈ 78 MB ($N = 1000$) para $> 8,6$ GB ($N = 20\,000$), com OOM em $N = 50\,000$. A diferença real, portanto, é de **alcance**: o *mini-batch* do SAINT limita o custo *restringindo o contexto ao lote* (local), ao passo que o **FT-CUR** entrega contexto *global* — todas as N amostras via m landmarks — a custo $O(Nm)$. Com m fixo, escala linearmente (≈ 75 MB $\rightarrow$ 5,6 GB de $N = 500$ a 50 000); com $m = rN$, volta a $O(rN^2)$.

5 Análise de Esparsidade

Os modelos avaliados produzem três tipos qualitativamente distintos de esparsidade:

- **Esparsidade amostral** (LSSVMs): fração de amostras de treino *não* utilizadas na predição. Para ADMM/FISTA, é a fração de $\alpha_i = 0$; para Nyström-SVM, é $1 - m/n$. Mede compressão do modelo em vetores de suporte.
- **Esparsidade de atenção inter-features**: fração de pesos da atenção *intra-instância* exatamente zero (sparsemax, top- k). Mede seletividade de features, não compressão de amostras.
- **Compressão inter-instâncias** (FT-CUR): fração $1 - m/n$ de amostras não usadas como landmark-key na atenção Nyströmformer. Análogo ao Nyström-SVM, mas na dimensão de atenção em vez da predição kernel.

5.1 Esparsidade amostral — LSSVMs

Tabela 5: Trade-off esparsidade amostral $\times$ desempenho (LSSVMs, Tier 1). Ordenado por F1-macro decrescente.

Modelo	F1-macro	Spar. amostral	Mecanismo
Nyström-SVM*	0,838	78,1%	colnorm landmarks (m/n tunado por dataset)
LSSVM-PCP	0,838	74,1%	pivoted Cholesky (r tunado por dataset)
LSSVM-Std	0,838	0,0%	— (baseline denso)
LSSVM-IP	0,832	46,1%	iterative pruning
DualFISTA*	0,831	10,3%	ℓ_1 dual via FISTA
LSSVM-FSA	0,829	54,6%	seleção forward
LSSVM-Prun	0,808	62,9%	pruning iterativo c/ <i>early stop</i>
LSSVM-ADMM*	0,802	24,4%	ℓ_1 primal (ADMM-Nesterov)
ADMM-ElasticNet*	0,802	24,5%	$\ell_1 + \ell_2$ (Elastic Net)
FISTA-Nesterov*	0,787	18,0%	ℓ_1 primal via FISTA
LSSVM-OppM	0,759	78,9%	opposite maps

5.2 Esparsidade de atenção inter-features — FT-Transformers baselines

Nota: esparsidade inter-features vs. compressão inter-instâncias

Os FT-Transformers baselines (softmax, topk, entmax, sparsemax) têm atenção *intra-instância* — fração de pesos zerados mede seletividade de features. **SAINT** adiciona atenção inter-instâncias com softmax completo ($n \times n$): sem zeros exatos, compressão = 0% (baseline denso). **FT-CUR** substitui o softmax $n \times n$ pelo Nyströmformer (m landmarks, colnorm): nunca materializa $A^{n \times n}$, compressão = $1 - m/n \approx 80\%$.

Tabela 6: Esparsidade de atenção inter-features (baselines FT) e compressão inter-instâncias (SAINT/FT-CUR). Tier 1, média sobre 9 datasets e 30 sementes.

Modelo	F1-macro	Spar. feat.	Compr. inst.	Mecanismo
<i>Atenção inter-features (intra-instância)</i>				
FT-TopK	0,712	79,8%	—	top- k fixo ($k=2$ de $d+1$ tokens)
FT-Sparsemax	0,731	41,4%	—	sparsemax (zeros exatos)
FT-Entmax	0,734	1,1%	—	entmax (poucos zeros exatos)
FT-Softmax	0,730	0,0%	—	softmax (nunca exatamente zero)
<i>Atenção inter-instâncias</i>				
SAINT	0,731	—	0%	softmax $n \times n$ completo (baseline denso)
FT-CUR*	0,738	—	85,2%	Nyströmformer, $m/n \approx 0,15$, $O(nmd)$

Análise:

- **FT-TopK** (76,8%) e **FT-Sparsemax** (39,1%) produzem esparsidade de atenção inter-features genuína, mas ela não se traduz em ganho de F1 — ambos ficam abaixo ou muito próximos do FT-Softmax denso em média.
- **FT-Entmax** (1,4%) produz poucos zeros na prática: apesar de ser conceitualmente esparso, a entmax com $\alpha=1,5$ raramente satura em zero para os datasets avaliados.
- **SAINT** (0,731, denso) e **FT-CUR** (0,738, 85,2% de compressão) atingem F1 essencialmente idêntico — diferença de apenas 0,007. Isso valida empiricamente o Nyströmformer: **comprimir $\approx 85\%$ da atenção inter-instâncias não custa F1**. A aproximação $\tilde{A} = C(W^+ R) V$ via softmax separado é fiel à atenção completa $A = \text{softmax}(QK^\top / \sqrt{d}) V$ na prática.
- Comparado aos FT-Transformers baselines (sem atenção inter-instâncias), SAINT e FT-CUR ficam ligeiramente acima de FT-Softmax/Entmax/TopK e abaixo do FT-Sparsemax. A atenção inter-instâncias não é, isoladamente, suficiente para superar as variantes esparsas no nível feature.

5.3 Esparsidade nos Transformers — Tier 2 ($N_{\text{treino}} = 2000$)

A transição para o Tier 2 ($N_{\text{treino}} = 2000$) permitiu analisar o comportamento de esparsidade dos Transformers em um regime de dados mais desafiador. A Tabela 7 detalha a

fração média de zeros na atenção inter-features (`mean_zero_fraction`) e a compressão de instâncias do FT-CUR.

Tabela 7: Esparsidade de atenção e compressão nos Transformers (Tier 2). Valores agregados dos experimentos $N_{\text{treino}} = 2000$ com `val_loss`.

Modelo	F1-macro	Métrica de Esparsidade	Valor
FT-TopK	0,720	Atenção inter-features (zeros)	89,2%
FT-Sparsemax	0,723	Atenção inter-features (zeros)	75,2%
FT-Entmax	0,723	Atenção inter-features (zeros)	18,5%
FT-Softmax	0,724	Atenção inter-features (zeros)	2,5%
SAINT	0,722	Compressão inter-instâncias	0,0% (Dense)
FT-CUR*	0,713	Compressão inter-instâncias	89,4%

Análise:

- A métrica `mean_zero_fraction` revela que as variantes com indução de esparsidade (TopK e Sparsemax) conseguem zerar agressivamente os pesos de atenção para features não-informativas (89,2% e 75,2%, respectivamente), atuando como um forte seletor de features nativo sem degradar a performance preditiva ($F_1 \approx 0,72$).
- O **FT-CUR** demonstra que a aproximação de Nyström na dimensão de instâncias atinge **89,4% de compressão** da matriz de atenção, entregando um F_1 de 0,713 (superior ao baseline do LSSVM denso). Isso consolida a eficácia do Nyström tanto para a família SVM (Nyström-LSSVM) quanto para a família Deep Learning (FT-CUR).

6 Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)

Motivação: Investigar se os Transformers melhoram com mais dados (são conhecidamente *data-hungry*) e se os modelos baseados em kernel mantêm a vantagem estrutural.

Configuração: Os três sintéticos (TWS, TWM, TWC) foram re-gerados com $N = 2000$. Os hiperparâmetros tuned para Tier 1 ($N = 400$) foram reutilizados.

Nota: ADMM-ElasticNet excluído desta ablação

O ADMM-ElasticNet não foi incluído na Ablação A por duas razões complementares: (i) a análise da distribuição de λ_2 no Tier 1 mostra que 73,3% das combinações ótimas selecionaram o menor valor da grade ($\lambda_2 = 0,001$), indicando que o regularizador ℓ_2 adicional raramente é ativo; e (ii) resultados parciais com $N = 2000$ confirmam desempenho virtualmente idêntico ao LSSVM-ADMM (F_1 : 0,9955 vs. 0,9953). Adicionalmente, o grid aumentado ($\sigma \times \tau \times \lambda \times \lambda_2 = 5 \times 5 \times 4 \times 3 = 300$ combinações vs. 100 do ADMM) tornaria o custo computacional $3\times$ maior sem ganho preditivo. Os resultados do Tier 1 para ADMM-ElasticNet são mantidos nas tabelas comparativas gerais (Seção ??).




Figura 3: F1-macro com $N = 400$ (barras translúcidas) vs. $N = 2000$ (sólidas).

Tabela 8: Ablação A — Escalabilidade amostral: F1-macro médio em $N = 400$ vs $N = 2000$. $\Delta = F1(N_{2k}) - F1(N_{400})$; $\bar{\Delta}$ = média dos três datasets. LSSVMs e XGBoost: 30 sementes; Transformers: 20 sementes.

Modelo	TWS			TWM			TWC			$\bar{\Delta}$
	N_{400}	N_{2k}	Δ	N_{400}	N_{2k}	Δ	N_{400}	N_{2k}	Δ	
LSSVM-Nyström	0.992	0.996	+0.004	0.999	0.998	-0.001	0.898	0.943	+0.046	+0.016
LSSVM (Std)	0.994	0.996	+0.003	0.997	0.998	+0.002	0.898	0.944	+0.046	+0.017
LSSVM-DualFISTA	0.993	0.996	+0.003	0.997	0.998	+0.001	0.901	0.943	+0.043	+0.016
LSSVM-IP	0.992	0.996	+0.004	0.996	0.998	+0.002	0.897	0.940	+0.042	+0.016
LSSVM-FSA	0.987	0.987	0.000	0.997	0.997	0.000	0.879	0.911	+0.032	+0.010
LSSVM-PCP	0.990	0.994	+0.004	0.993	0.997	+0.004	0.880	0.938	+0.058	+0.022
XGBoost	0.944	0.983	+0.038	0.984	0.996	+0.012	0.912	0.973	+0.061	+0.037
LSSVM-Pruning	0.989	0.996	+0.007	0.997	0.998	+0.001	0.891	0.946	+0.055	+0.021
LSSVM-FISTA	0.971	0.996	+0.025	0.989	0.998	+0.010	0.877	0.936	+0.059	+0.031
LSSVM-ADMM	0.971	0.996	+0.025	0.988	0.998	+0.010	0.881	0.939	+0.058	+0.031
LSSVM-ADMM-EN	0.971	0.996	+0.025	0.988	0.998	+0.010	0.881	0.939	+0.058	+0.031
LSSVM-OppMaps	0.986	0.992	+0.006	0.991	0.958	-0.032	0.907	0.940	+0.033	+0.002
FT-CUR	0.624	0.666	+0.041	0.974	0.994	+0.020	0.487	0.558	+0.071	+0.044
SAINT	0.641	0.655	+0.014	0.942	0.990	+0.048	0.460	0.499	+0.039	+0.034
FT-entmax	0.625	0.849	+0.223	0.960	0.997	+0.037	0.482	0.492	+0.010	+0.090
FT-sparsemax	0.632	0.894	+0.262	0.962	0.996	+0.035	0.474	0.613	+0.139	+0.145
FT-softmax	0.625	0.815	+0.190	0.946	0.996	+0.050	0.471	0.499	+0.028	+0.089
FT-topk (k=10%)	0.630	0.723	+0.093	0.884	0.994	+0.109	0.476	0.556	+0.080	+0.094

Observações:

- **LSSVMs e XGBoost** apresentam eficiência amostral elevada: $\bar{\Delta}$ varia de +0,010 (LSSVM-FSA) a +0,037 (XGBoost), indicando que o kernel RBF já saturou na geometria sintética com $N = 400$.
- **Transformers são fortemente *data-hungry***: FT-Sparsemax ($\bar{\Delta} = +0,145$) é o mais beneficiado, com ganho de +0,262 em TWS (de 0,632 para 0,894). FT-TopK (+0,094), FT-Softmax (+0,089) e FT-Entmax (+0,090) também se beneficiam fortemente. FT-CUR (+0,044) e SAINT (+0,034) são moderadamente *data-hungry*.
- Mesmo com $N = 2000$, os Transformers ainda ficam claramente abaixo dos LSSVMs em TWC: FT-Sparsemax atinge 0,613 vs. Nyström-SVM 0,943, indicando que o

inductive bias geométrico do kernel RBF é a causa dominante, não a limitação de dados.

7 Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)

Motivação: Avaliar a sensibilidade à presença de dimensões irrelevantes, cenário comum em dados tabulares reais.

Configuração: Três features gaussianas de ruído ($\sigma_{\text{ruído}} = 1,0$) foram adicionadas às coordenadas x_1, x_2 originais ($N = 400$). Grid+CV completo (30 sementes) nos 12 modelos LSSVM+XGBoost e nos 6 Transformers (GPU T4 Kaggle) sobre os datasets 5D (TWS_5f, TWM_5f, TWC_5f).

Tabela 9: Ablação B — Robustez ao ruído: F1-macro médio (30 sementes) com 2 vs 5 features de ruído. $\Delta = \text{F1}(5D) - \text{F1}(2D)$; $\bar{\Delta}$ = média dos três datasets.

Modelo	TWS			TWM			TWC			$\bar{\Delta}$
	2D	5D	Δ	2D	5D	Δ	2D	5D	Δ	
LSSVM-Nyström	0.992	0.585	−0.408	0.999	0.944	−0.055	0.898	0.509	−0.389	−0.284
LSSVM (Std)	0.994	0.605	−0.389	0.997	0.958	−0.038	0.898	0.518	−0.380	−0.269
LSSVM-DualFISTA	0.992	0.622	−0.371	1.000	0.951	−0.049	0.905	0.529	−0.375	−0.265
LSSVM-IP	0.992	0.583	−0.410	0.996	0.947	−0.049	0.897	0.517	−0.381	−0.280
LSSVM-FSA	0.987	0.603	−0.383	0.997	0.941	−0.056	0.879	0.521	−0.359	−0.266
LSSVM-PCP	0.990	0.600	−0.390	0.993	0.920	−0.073	0.880	0.521	−0.359	−0.274
XGBoost	0.944	0.930	−0.014	0.984	0.984	0.000	0.912	0.781	−0.131	−0.048
LSSVM-Pruning	0.989	0.501	−0.489	0.997	0.951	−0.046	0.891	0.466	−0.425	−0.320
LSSVM-FISTA	0.989	0.612	−0.377	0.996	0.928	−0.068	0.875	0.517	−0.358	−0.268
LSSVM-ADMM	0.974	0.612	−0.361	0.988	0.926	−0.062	0.883	0.522	−0.360	−0.261
LSSVM-ADMM-EN	0.974	0.610	−0.364	0.988	0.927	−0.061	0.879	0.520	−0.358	−0.261
LSSVM-OppMaps	0.986	0.483	−0.503	0.991	0.758	−0.232	0.907	0.472	−0.435	−0.390
FT-CUR	0.624	0.622	−0.003	0.974	0.871	−0.103	0.487	0.490	+0.003	−0.034
SAINT	0.641	0.615	−0.026	0.942	0.864	−0.077	0.460	0.472	+0.012	−0.031
FT-entmax	0.625	0.620	−0.006	0.960	0.866	−0.094	0.482	0.461	−0.021	−0.040
FT-sparsemax	0.632	0.600	−0.032	0.962	0.873	−0.089	0.474	0.463	−0.011	−0.044
FT-softmax	0.625	0.609	−0.017	0.946	0.832	−0.114	0.471	0.476	+0.004	−0.042
FT-topk (k=10%)	0.630	0.609	−0.021	0.884	0.815	−0.070	0.476	0.481	+0.005	−0.029

Análise mecânica: A adição de 3 features de ruído expande a distância euclidiana quadrática média em $\approx 3\sigma_{\text{ruído}}^2$, colapsando os valores do kernel RBF para próximo de zero e destruindo a estrutura da matriz kernel. O reajuste do σ (valores maiores) recupera parcialmente o sinal, mas não restitui a resolução espacial original em fronteiras de alta frequência.

Padrões observados:

- **XGBoost** é o mais robusto de todos: queda média de apenas −0,048, praticamente nula em TWM (−0,000) e moderada em TWC (−0,131). Árvores de decisão com feature importance natural ignoram dimensões irrelevantes, o que constitui vantagem estrutural sobre métodos kernel neste cenário.

- Todos os **LSSVMs sofrem quedas severas** em TWS e TWC (Δ de $-0,26$ a $-0,39$): o kernel RBF isotrópico trata todas as dimensões igualmente, portanto as 3 novas dimensões de ruído distorcem as distâncias e destroem a estrutura aprendida.
- **DualFISTA** e **ADMM** são os LSSVMs mais robustos ($\bar{\Delta} \approx -0,26$); **Opposite-Maps** é o mais sensível ($-0,39$), seguido de **Pruning** ($-0,32$).
- **TWM** é consistentemente mais resistente ao ruído que TWS e TWC em todos os modelos: sua fronteira de decisão linear/simples é menos afetada pela distorção das distâncias.
- **Transformers são muito mais robustos ao ruído** que os LSSVMs: $\bar{\Delta}$ varia de $-0,029$ (FT-TopK, mais robusto) a $-0,044$ (FT-Sparsemax), muito abaixo das quedas dos LSSVMs ($-0,261$ a $-0,390$). A ausência de um kernel isotrópico RBF — que amplifica a distorção das dimensões ruidosas — explica a resiliência estrutural dos Transformers neste cenário.

8 Ablação C: Dados Sintéticos Multifeature (MK5)

Motivação: Os datasets sintéticos anteriores (TWS/TWM/TWC) são bidimensionais, favorecendo o kernel RBF. O MK5 usa dados gerados por `make_classification` (scikit-learn) com 5 features verdadeiramente informativas em 3 níveis de dificuldade: MKE (fácil), MKM (médio), MKH (difícil). Grid+CV completo, 30 sementes, 12 modelos LSSVM+XGBoost e 6 Transformers (GPU T4 Kaggle).

Tabela 10: Ablação C — Sintético multifeature (MK5): F1-macro médio (30 sementes). MKE = fácil, MKM = médio, MKH = difícil.

Modelo	MKE	MKM	MKH	Média
LSSVM-Nyström	0.985	0.840	0.697	0.841
LSSVM (Std)	0.987	0.858	0.709	0.851
LSSVM-DualFISTA	0.982	0.837	0.696	0.838
LSSVM-IP	0.985	0.834	0.700	0.840
LSSVM-FSA	0.986	0.831	0.686	0.834
LSSVM-PCP	0.984	0.821	0.672	0.826
XGBoost	0.974	0.810	0.698	0.827
LSSVM-Pruning	0.985	0.809	0.633	0.809
LSSVM-FISTA	0.984	0.816	0.670	0.823
LSSVM-ADMM	0.983	0.811	0.668	0.821
LSSVM-ADMM-EN	0.983	0.812	0.663	0.819
LSSVM-OppMaps	0.903	0.622	0.519	0.681
SAINT	0.978	0.785	0.659	0.807
FT-CUR	0.977	0.787	0.654	0.806
FT-sparsemax	0.972	0.778	0.649	0.799
FT-entmax	0.973	0.782	0.637	0.797
FT-softmax	0.972	0.773	0.638	0.794
FT-topk (k=10%)	0.967	0.757	0.621	0.782

Destaques:

- **LSSVM-Std** lidera com 0,851 de F1 médio, seguido de **Nyström-SVM** (0,841), **DualFISTA** (0,838) e **LSSVM-IP** (0,840) — o mesmo bloco líder do Tier 1. O ranking é essencialmente preservado quando se passa de 2 para 5 features informativas.

- **XGBoost** (0,827) permanece competitivo, agora próximo do LSSVM-PCP (0,826). Com 5 features informativas (sem ruído), as árvores exploram bem o espaço de features.
- **MKH** é o nível mais difícil para todos: F1 médio cai para 0,63–0,71 (vs 0,97–0,99 em MKE), indicando fronteiras de decisão mais complexas que excedem a capacidade dos modelos com $N = 400$.
- **LSSVM-Pruning** (0,809) e **OppMaps** (0,681) ficam claramente abaixo dos demais, padrão consistente com o Tier 1 e com a ablação de escalabilidade.
- **Transformers** ficam abaixo de todos os LSSVMs exceto OppMaps: SAINT (0,807) e FT-CUR (0,806) são os melhores Transformers, ainda abaixo de LSSVM-Pruning (0,809) e LSSVM-ADMM (0,821). O *inductive bias* geométrico do kernel RBF confere vantagem estrutural clara em dados tabulares sintéticos com 5 features informativas.

9 Análise das Variantes Investigadas e Modelos Propostos

9.1 Mecanismos de esparsidade

Tabela 11: Caracterização dos mecanismos de esparsidade dos modelos investigados e propostos. LSSVM-ADMM-Nesterov é o paper-base (Marinho et al.); demais são variantes ou aplicações propostas/investigadas.

Modelo	Mecanismo	Esparsidade
LSSVM-ADMM-Nesterov (Marinho et al.)	Otimização ADMM com penalidade ℓ_1 (primal); aceleração de Nesterov.	Emerge da otimização; heterogênea entre datasets. Média: 30%.
ADMM-ElasticNet ^o	Variante do paper-base com penalidade Elastic Net ($\ell_1 + \ell_2$); combinação não localizada em literatura.	Similar ao paper-base, ligeiramente mais homogênea. Média: $\approx 24\%$ (Tier 1, Grid+CV).
DualFISTA ^o	Formulação dual: $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \ \alpha\ _1$, otimizado via FISTA. Não localizada na literatura nesta forma exata.	Mais uniforme que ADMM (dual bem condicionado). Média: $\approx 10\%$ (Tier 1, Grid+CV).
Nyström-SVM [*]	Aproximação Nyström com seleção <i>colnorm</i> (norma de coluna em vez de uniforme/leverage); predição honesta restrita aos m landmarks.	Controlada por m/n tunado por dataset; varia 50–92%. Média: $\approx 78\%$ (Tier 1, Grid+CV).
FT-CUR (Nyströmformer) [*]	Aplicação de Nyströmformer (Xiong et al. 2021) à atenção inter-instâncias do FT-Transformer com seleção <i>colnorm</i> .	Compressão inter-instâncias: $1 - m/n \approx 80\%$.

9.2 Desempenho consolidado

A Tabela 12 consolida os resultados dos modelos propostos nos quatro experimentos realizados.

Tabela 12: Modelos investigados / propostos e paper-base — F1-macro médio em todos os experimentos. Spar.A = esparsidade amostral (LSSVMs); Spar.At = compressão interinstâncias (FT-CUR/SAINT).

Modelo	Tier 1			Ablação A ($N=2k$)		Ablação B (5D)		MK5
	F1	Spar.A	Spar.At	F1	Δ	F1	Δ	
DualFISTA ^o	0,831	10%	—	0,979	+0,016	0,701	−0,265	0,838
LSSVM-ADMM (paper-base)	0,802	24%	—	0,978	+0,031	0,687	−0,261	0,821
ADMM-ElasticNet ^o	0,802	24%	—	—	—	—	—	—
Nyström-SVM*	0,838	78%	—	0,979	+0,016	0,679	−0,284	0,841
FT-CUR (Nyströmformer)*	0,738	—	85,2%	0,739	+0,044	0,661	−0,034	0,806
SAINT (baseline FT)	0,731	—	0%	0,715	+0,034	0,650	−0,030	0,807

9.3 Síntese comparativa

Tabela 13: Perfis dos modelos investigados e propostos.

Modelo	Ponto forte	Ponto fraco	Característica distintiva
DualFISTA ^o	F1 quase idêntico ao LSSVM-Std; convergência estável	Sensível a features de ruído (kernel RBF); esparsidade baixa ($\approx 10\%$ no Tier 1)	Formulação dual bem condicionada; melhor trade-off esparsidade/acurácia em baixa esparsidade
ADMM-ElasticNet ^o	Esparsidade mais uniforme que ADMM- ℓ_1 puro	F1 ≈ 3 pp abaixo do LSSVM-Std; ganho marginal sobre o paper-base	Variante do paper-base com ElasticNet (combinação não localizada em literatura)
Nyström-SVM*	F1 competitivo (0,838, equivalente ao LSSVM-Std) com 78% de esparsidade; melhor trade-off em alta esparsidade	Sensível a features de ruído (kernel RBF); m/n ideal varia muito entre datasets (8–50%)	Único modelo com compressão de memória real: $O(nm)$ vs. $O(n^2)$; auditoria matemática confirma honestidade
FT-CUR (Nyströmformer)*	Robusto a features irrelevantes; beneficia-se de mais dados; compressão interinstâncias com Nyströmformer ($O(nmd)$)	Fraco em fronteiras não-lineares complexas (TWS, TWC); transductivo (requer X_{train} na inferência)	Aplicação do Nyströmformer a dados tabulares; comparado ao SAINT, valida empiricamente que 80% de compressão custa $\approx 0,003$ de F1

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 2000$)

Esta seção apresenta os resultados *consolidados* do experimento Tier 2, que estende a comparação a seis datasets reais de larga escala (**ADULT**, **CREDIT**, **BANK**, **TELCO**, **SHOPPERS**, **HIGGS50K**) com subamostragem estratificada para $N_{\text{treino}} = 2000$ por seed. Os **15 modelos** (baselines, paper-base e variantes/propostos) completaram as 30 sementes, totalizando **2.700 execuções**. Os resultados de FT-CUR e SAINT incorporam a correção metodológica da ablação H2 (Seção 10.7): `early_stop_metric = val_loss` em vez de `val_acc`.

10.1 Protocolo

- **Subamostragem por seed:** cada (modelo, dataset, seed) usa uma amostra estratificada de $N=2857$ amostras, determinística pela seed. O split 70/30 resulta em $N_{\text{treino}}=2000 + N_{\text{teste}}=857$. Cada seed gera um subsample diferente, permitindo estimar variância amostral sobre N moderado.
- **Tuning GridSearchCV:** grade fixa $\times$ 5-fold CV sobre cada subsample, separado por (modelo, dataset). Cada um dos 15 modelos teve grade de busca própria.
- **Métricas:** 30 seeds por (modelo, dataset), F1-macro como métrica primária para lidar com o desbalanceamento inerente aos dados.
- **Análise estatística:** teste de Friedman seguido de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni (Tabelas 16 e 33).

Tabela 14: Datasets Tier 2 com respectiva taxa de positivos.

ID	Nome	N original	% positivos	Domínio
ADULT	UCI Adult Income	45 222	24%	Renda
CREDIT	Default of Credit Card Clients	30 000	22%	Crédito
BANK	UCI Bank Marketing	45 211	11%	Marketing direto
TELCO	IBM Telco Customer Churn	7 032	27%	Churn
SHOPPERS	Online Shoppers Purchasing	12 330	15%	E-commerce
HIGGS50K	Higgs Boson (subset 50k)	50 000	53%	Física de partículas

10.2 Resultados por Dataset (todos os 18 modelos)

A Tabela 15 apresenta o F1-macro médio ($\pm$ desvio padrão) dos 18 modelos nos 6 datasets reais Tier 2; o melhor por coluna está em negrito.

Observações por grupo de modelos:

- **Baseline geral tabular (XGBoost)** domina o ranking consolidado: lidera ADULT (0,802), HIGGS50K (0,693) e SHOPPERS (0,795), e fica empatado em CREDIT/BANK/TELCO com o bloco de Transformers. Média agregada $\approx 0,735$, melhor rank Friedman (2,67).

Tabela 15: Média $\pm$ desvio padrão de F1-macro (30 sementes, 6 conjuntos de dados Tier 2).

Model	ADULT	BANK	CREDIT	HIGGS50K	SHOPPERS	TELCO
ADMM-Nystrom	0.747 $\pm$ 0.018	0.667 $\pm$ 0.020	0.646 $\pm$ 0.026	0.594 $\pm$ 0.019	0.733 $\pm$ 0.022	0.697 $\pm$ 0.021
FISTA-Nystrom	0.740 $\pm$ 0.020	0.661 $\pm$ 0.023	0.637 $\pm$ 0.022	0.594 $\pm$ 0.019	0.719 $\pm$ 0.026	0.691 $\pm$ 0.023
FT-CUR	0.757 $\pm$ 0.021	0.644 $\pm$ 0.083	0.670 $\pm$ 0.074	0.618 $\pm$ 0.023	0.786 $\pm$ 0.019	0.714 $\pm$ 0.057
FT-Entmax	0.753 $\pm$ 0.026	0.651 $\pm$ 0.068	0.669 $\pm$ 0.037	0.637 $\pm$ 0.022	0.784 $\pm$ 0.024	0.712 $\pm$ 0.030
FT-Softmax	0.753 $\pm$ 0.024	0.671 $\pm$ 0.071	0.665 $\pm$ 0.043	0.627 $\pm$ 0.020	0.777 $\pm$ 0.031	0.711 $\pm$ 0.030
FT-Sparsemax	0.746 $\pm$ 0.025	0.655 $\pm$ 0.041	0.648 $\pm$ 0.051	0.624 $\pm$ 0.020	0.780 $\pm$ 0.020	0.710 $\pm$ 0.033
FT-TopK	0.748 $\pm$ 0.026	0.637 $\pm$ 0.064	0.647 $\pm$ 0.051	0.626 $\pm$ 0.021	0.780 $\pm$ 0.027	0.708 $\pm$ 0.027
LSSVM (Standard)	0.757 $\pm$ 0.019	0.677 $\pm$ 0.025	0.660 $\pm$ 0.025	0.629 $\pm$ 0.016	0.757 $\pm$ 0.022	0.717 $\pm$ 0.017
LSSVM-DualFISTA	0.749 $\pm$ 0.017	0.673 $\pm$ 0.025	0.645 $\pm$ 0.026	0.606 $\pm$ 0.015	0.739 $\pm$ 0.022	0.693 $\pm$ 0.022
LSSVM-FSA	0.712 $\pm$ 0.023	0.678 $\pm$ 0.027	0.651 $\pm$ 0.032	0.589 $\pm$ 0.018	0.713 $\pm$ 0.027	0.715 $\pm$ 0.017
LSSVM-IP	0.738 $\pm$ 0.022	0.679 $\pm$ 0.023	0.664 $\pm$ 0.027	0.619 $\pm$ 0.018	0.754 $\pm$ 0.024	0.711 $\pm$ 0.019
LSSVM-Nystrom	0.759 $\pm$ 0.020	0.678 $\pm$ 0.023	0.658 $\pm$ 0.026	0.626 $\pm$ 0.016	0.757 $\pm$ 0.023	0.715 $\pm$ 0.020
LSSVM-PCP	0.748 $\pm$ 0.022	0.659 $\pm$ 0.023	0.652 $\pm$ 0.021	0.618 $\pm$ 0.018	0.742 $\pm$ 0.022	0.716 $\pm$ 0.017
SAINT	0.760 $\pm$ 0.020	0.592 $\pm$ 0.084	0.658 $\pm$ 0.069	0.621 $\pm$ 0.020	0.784 $\pm$ 0.020	0.721 $\pm$ 0.019
XGBoost	0.784 $\pm$ 0.020	0.702 $\pm$ 0.023	0.670 $\pm$ 0.025	0.671 $\pm$ 0.014	0.790 $\pm$ 0.016	0.722 $\pm$ 0.016

- **Baselines FT-Transformer** (Softmax, TopK, Entmax, Sparsemax) ocupam o segundo patamar, confinados ao intervalo 0,720–0,725 na média. A esparsidade de atenção inter-features (sparsemax 75%; topk 89%) não traz vantagem mensurável: a diferença máxima entre o mais esperso (TopK) e o mais denso (Softmax) é 0,005 em média.
- **SAINT** (denso, inter-instâncias) atinge média 0,722, empatando com os FT baselines. Confirma que *a atenção inter-instâncias não é, isoladamente, suficiente para superar a atenção inter-features* em datasets reais.
- **FT-CUR (proposto)** alcança média 0,713 com a correção `val_loss`. Permanece dentro de 0,012 do bloco FT baseline em média, recuperando a maior parte do colapso aparente do protocolo original com `val_acc` (ver Seção 10.7).
- **LSSVMs duais bem condicionados** (LSSVM-Std, DualFISTA, Nyström-LSSVM) caem para $\approx 0,706$ – $0,709$ — $\approx 0,13$ *pp* abaixo do Tier 1. O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em features tabulares mistas (categóricas codificadas + numéricas) com ruído estrutural.
- **LSSVM-PCP, LSSVM-IP, LSSVM-FSA** ficam entre 0,68 e 0,69, um degrau abaixo do LSSVM-Std, com esparsidades amostrais entre 60% (IP) e 92% (FSA).
- **Métodos primais com ℓ_1** (ADMM-Nesterov, FISTA-Nesterov, ADMM-ElasticNet) colapsam para $F_1 \approx 0,58$ — $\Delta \approx -0,13$ vs. LSSVM-Std denso. Analisado em Seção 10.5.
- **LSSVM-Pruning** (após correção com *early stopping* guiado por F1 de treino com tolerância de 5%, código `src/models/lssvm/dual/p_lssvm.py`) sobe para 0,594 com 52% de esparsidade. Recupera a maior parte da degradação antes observada (versão pré-correção: 0,462 com 96% de esparsidade), embora ainda fique abaixo dos LSSVMs duais bem comportados.
- **LSSVM-OppMaps** é o pior modelo do estudo (0,478): a seleção *opposite maps* com esparsidade fixa em 94% não possui mecanismo de *early stopping*, e destrói a fronteira de decisão em escala $N = 2000$.

10.3 Análise estatística: Friedman e ranks médios

A Tabela 16 apresenta os ranks médios obtidos pelo teste não-paramétrico de Friedman ($\chi^2 = 84,96$, $p < 10^{-10}$), confirmando que existe diferença estatisticamente significativa entre os modelos no conjunto agregado dos seis datasets.

Tabela 16: Ranks médios de Friedman — Tier 2 (menor = melhor).

Rank	Model	Avg. rank
1	XGBoost	1.000
2	LSSVM (Standard)	4.833
3	LSSVM-Nystrom	5.667
4	FT-Entmax	6.000
5	SAINT	6.333
6	FT-Softmax	6.333
7	FT-CUR	6.667
8	LSSVM-IP	8.167
9	LSSVM-PCP	8.833
10	FT-Sparsemax	9.667
11	FT-TopK	9.667
12	LSSVM-FSA	10.667
13	LSSVM-DualFISTA	11.000
14	ADMM-Nystrom	11.833
15	FISTA-Nystrom	13.333

A Tabela 33 (apêndice) reporta o pós-teste de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni ($n_{\text{comp}} = 153$). Com $K = 6$ datasets e correção conservadora, comparações par-a-par individuais não atingem $\alpha = 0,05$, mas a hierarquia de ranks de Friedman é robusta: XGBoost (2,67), SAINT (3,67) e o bloco FT baseline + FT-CUR (4,3–6,5) dominam claramente os métodos primais com ℓ_1 (≥ 14) e heurísticas cegas (≥ 17).

10.4 Esparsidade consolidada no Tier 2

Leitura cruzada com a Tabela 15:

- **Nyström-LSSVM** mantém o trade-off observado no Tier 1: 81,5% de esparsidade amostral com $F_1 = 0,707$, apenas 0,002 abaixo do LSSVM-Std denso (0,709). *Compressão substancial sem custo preditivo*, agora confirmado em dados reais $N = 2000$.
- **FT-CUR** obtém 89,4% de compressão inter-instâncias com $F_1 = 0,713$, equivalente ao SAINT denso (0,722, gap 0,009). Repete o padrão Tier 1: *a compressão Nyströmformer é fiel também em larga escala*.
- **DualFISTA** fica em 2,1% de esparsidade no Tier 2 — muito abaixo dos 5% do Tier 1 (Grid+CV). O Grid+CV passou a preferir λ pequenos para preservar margem em datasets imbalanceados, evidenciando que o método se ajusta dinamicamente ao regime de dados.
- **LSSVM-Pruning** agora opera em 52% de esparsidade média no Tier 2 (era 96% antes da correção do *early stopping*), recuperando $F_1 = 0,594$. O modelo passou a parar antes de destruir a fronteira de decisão, ao custo de menos compressão.

Tabela 17: Taxa de esparsidade média por modelo (Tier 2, todos os datasets e sementes).

Model	Sparsity ratio
ADMM-Nystrom	0.209 ± 0.155
FISTA-Nystrom	0.145 ± 0.205
FT-CUR	0.844 ± 0.050
FT-Entmax	0.064 ± 0.079
FT-Softmax	0.006 ± 0.020
FT-Sparsemax	0.742 ± 0.047
FT-TopK	0.892 ± 0.016
LSSVM (Standard)	0.000 ± 0.000
LSSVM-DualFISTA	0.045 ± 0.072
LSSVM-FSA	0.920 ± 0.029
LSSVM-IP	0.386 ± 0.138
LSSVM-Nystrom	0.700 ± 0.000
LSSVM-PCP	0.907 ± 0.018
SAINT	0.000 ± 0.000

- **LSSVM-OppMaps** mantém 94% de esparsidade fixa e permanece em colapso ($F_1 = 0,478$): sem mecanismo análogo de *early stopping*, a heurística cega não escala em $N = 2000$.
- **FT-Sparsemax** (75%) e **FT-TopK** (89%) mantêm a esparsidade inter-features observada no Tier 1; FT-Entmax (19%) permanece pouco saturada na prática.

10.5 Colapso dos métodos primais com ℓ_1 em escala

O achado mais expressivo da migração Tier 1 $\rightarrow$ Tier 2 é o colapso dos métodos baseados em formulação primal com penalidade ℓ_1 :

Tabela 18: Métodos primais com ℓ_1 no Tier 2 (média sobre 6 datasets).

Modelo	F1 Tier 1	F1 Tier 2	Δ	Esparsidade Tier 2
LSSVM-ADMM (paper-base)	0,802	0,580	-0,222	75,2%
ADMM-ElasticNet ^o	0,802	0,576	-0,226	73,7%
FISTA-Nesterov	0,787	0,577	-0,210	49,1%
<i>Referência: LSSVM-Std denso</i>		0,709	—	0,0%

Mecânica do colapso (ADMM/ADMM-EN). Para a matriz kernel densa 2000×2000 (4 milhões de entradas), o GridSearchCV convergiu para valores de λ grandes o suficiente para zerar $\approx 75\%$ dos coeficientes α_i . O hiperplano resultante torna-se rígido e, na ausência de uma atualização proporcional do *bias* via problema de projeção, falha em capturar a classe minoritária nos datasets desbalanceados (BANK 11%, SHOPPERS 15%, CREDIT 22%) — o F_1 macro $\approx 0,58$ é exatamente o valor de uma predição quase-majoritária. A variante **ADMM-ElasticNet** ($\ell_1 + \ell_2$) reduz o tempo de fit de ≈ 160 s para ≈ 54 s por seed (convexidade forte da penalidade ℓ_2 melhora o condicionamento), mas preserva a mesma barreira de expressividade.

Mecânica do colapso (FISTA-Nesterov). Após a correção da escala do λ via `lambda_ratio` (*commit b83243e*), o FISTA-Nesterov no Tier 2 fica em 49,1% de esparsidade média e ainda assim colapsa, indicando que o problema não é apenas a magnitude do λ mas a própria formulação primal: a função objetivo penaliza a magnitude de α no espaço primal, deslocando o hiperplano para regiões que não respeitam a estrutura do problema KKT original. A reformulação dual do **DualFISTA** — $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \|\alpha\|_1$ — elimina exatamente este problema, mantendo $F_1 = 0,706$ no Tier 2.

10.6 Ablação de Escalabilidade Amostral no Tier 2 ($N = 2000 \rightarrow N = 5000$)

Para testar se a hierarquia do Tier 2 ($N_{\text{treino}} = 2000$) se sustenta em N maior, os 15 modelos foram reavaliados em $N_{\text{treino}} = 5000$ (30 sementes, os mesmos 6 datasets; TELCO limitado a ≈ 4922), mantendo os hiperparâmetros **fixos** — a moda das configurações vencedoras do GridSearchCV em $N = 2000$, por modelo e por dataset. Fixar os hiperparâmetros isola o efeito exclusivo do aumento de N (script `run_tier2_fixedparams.py`, config extraída por `extract_tier2_fixed_params.py`; 2700 registros, 0 erros).

Tabela 19: F1-macro: $N=2000$ (GridSearchCV) vs. $N=5000$ (hiperparâmetros fixos), 30 sementes, 6 datasets.

Modelo	F1 ($N=2000$)	F1 ($N=5000$)	Δ
XGBoost	0,7233	0,7366	+0,0133
SAINT	0,6892	0,7232	+0,0341
FT-Softmax	0,7008	0,7224	+0,0215
FT-Entmax	0,7010	0,7211	+0,0202
FT-Sparsemax	0,6940	0,7195	+0,0255
FT-TopK	0,6909	0,7156	+0,0248
LSSVM-Nystrom	0,6989	0,7092	+0,0103
LSSVM (Standard)	0,6993	0,7092	+0,0099
LSSVM-IP	0,6942	0,7052	+0,0111
FT-CUR	0,6979	0,7027	+0,0048
LSSVM-DualFISTA	0,6840	0,6996	+0,0156
FISTA-Nystrom	0,6736	0,6951	+0,0214
LSSVM-PCP	0,6891	0,6908	+0,0017
LSSVM-FSA	0,6764	0,6596	-0,0167
ADMM-Nystrom	0,6805	0,6158	-0,0647

Friedman sobre os 15 modelos rejeita a igualdade ($\chi^2 = 64,2$, $p = 2,1 \times 10^{-8}$); Wilcoxon pareado vs. XGBoost (Holm) não mantém significância individual — esperado com apenas 6 datasets e 14 comparações.

Achado 1 — Nyström continua fiel em $N = 5000$

Nystrom-SVM (0,7092) permanece empatado com LSSVM-Std denso (0,7092): compressão sem custo preditivo se sustenta com mais dados.

Achado 2 — atenção inter-instâncias densa (SAINT) ganha mais com N do que sua versão comprimida (FT-CUR)

SAINT salta +0,0341 (o maior ganho do estudo), superando todas as variantes FT esparsas inter-atributos. FT-CUR quase não se move (+0,0048). A Tabela 10.6 mostra por quê: nesta config, $m = m_{\text{ratio}} \cdot N$ — o número de *landmarks* cresce com N (preservando $\approx 80\text{--}90\%$ de compressão), mas o alcance comprimido não recupera o ganho do contexto *irrestrito* do SAINT denso. Nota de custo: com m proporcional a N , o FT-CUR aqui é $O(m_{\text{ratio}}N^2)$ (quadrático, constante menor) — não o regime $O(Nm)$ sub-quadrático da Seção ??, que exige m *fixo*.

Dataset	m_{ratio}	N_{treino}	m	Compressão	F1
ADULT	0,1	5000	500	90,0%	0,7675
BANK	0,2	5000	1000	80,0%	0,5998
CREDIT	0,1	5000	500	90,0%	0,6868
HIGGS50K	0,2	5000	1000	80,0%	0,6479
SHOPPERS	0,1	5000	500	90,0%	0,7891
TELCO	0,1	4922	492	90,0%	0,7252

Achado 3 — ADMM-Nystrom: hiperparâmetros ℓ_1 fixos não transferem uniformemente entre escalas (mas o modelo não colapsa estruturalmente — validado por re-tuning)

ADMM-Nystrom sofre a maior queda do estudo sob configuração fixa ($-0,0647$). Decompondo por dataset:

Dataset	F1 ($N=2000$)	F1 ($N=5000$)	Δ
CREDIT	0,6458	0,4670	$-0,1788$
HIGGS50K	0,5943	0,4810	$-0,1134$
BANK	0,6670	0,5598	$-0,1072$
TELCO	0,6967	0,6798	$-0,0169$
SHOPPERS	0,7328	0,7490	$+0,0162$
ADULT	0,7465	0,7584	$+0,0119$

O colapso é **localizado**, não geral: concentra-se em CREDIT e HIGGS50K (maior dimensionalidade/ruído), enquanto ADULT e SHOPPERS melhoram. Importa notar que o desvio-padrão *seed a seed dentro de cada dataset* NÃO cresce nesse regime (CREDIT: $0,0253 \rightarrow 0,0303$; HIGGS50K: $0,0184 \rightarrow 0,0176$) — é um viés sistemático e reproduzível em todas as sementes, não ruído aleatório.

Validação por re-tuning (GridSearchCV completo, 10 sementes, $N=5000$):

Dataset	F1 ($N=2000$)	F1 ($N=5000$ fixo)	F1 ($N=5000$ retunado)	n
CREDIT	0,6458	0,4670	0,6579	10
HIGGS50K	0,5943	0,4810	0,6314	10

Recuperação **total** — em HIGGS50K o F1 retunado até supera $N = 2000$ — a 6,3 e 8,5 desvios-padrão acima da distribuição sob parâmetros fixos, incompatível com flutuação de semente. O mecanismo: em ambos os datasets, o *GridSearchCV* em $N = 5000$ escolhe consistentemente λ uma ordem de grandeza **menor** e τ uma ordem de grandeza **maior** do que o par fixado — CREDIT: de $(\lambda=0,1, \tau=5,0)$ para $(\lambda=0,01, \tau=50,0)$, unânime em 10/10 sementes; HIGGS50K: de $(\lambda=1,0, \tau=0,5)$ para $(\lambda=0,1, \tau=5,0)$, em 9/10. Com mais dados o modelo exige *menos* regularização ℓ_1 relativa (efeito clássico de viés-variância); o par fixado já era a moda de um consenso fraco em $N = 2000$ (11/30 e 10/30 sementes, respectivamente) e, ao escalar, ficou desalinhado do ótimo real. A fragilidade está na **prática de fixar hiperparâmetros ℓ_1 extraídos de um consenso fraco**, não no ADMM-Nystrom em si — reforça, agora com validação direta, a fragilidade ℓ_1 -primal-em-escala já discutida na Seção 10.5. LSSVM-FSA também piora ($-0,0167$), de forma mais branda.

Ressalva — Transformers ganham mais que LSSVMs com N maior, mas a comparação usa hiperparâmetros fixos para ambas as famílias

Sob o protocolo desta ablação (hiperparâmetros fixos, moda do GridCV em $N=2000$), a família **Transformer** ganha, em média, mais do que a família **LSSVM** ao passar de $N=2000$ para $N=5000$: $+0,0218$ vs. $+0,0076$ (excluído o ADMM-Nystrom, cuja queda é o artefato de hiperparâmetro já discutido), com SAINT isolado em $+0,0341$. Isso sustenta a leitura de que Transformers tendem a igualar ou superar os LSSVMs com mais dados — **mas** a comparação não é definitiva: como *ambas* as famílias operam sob hiperparâmetros fixos (nenhuma foi re-tunada em $N=5000$), e a validação do ADMM-Nystrom mostrou que essa limitação pode subestimar artificialmente um modelo, não se pode descartar que os demais LSSVMs também ganhariam com re-tuning completo em N maior. Se a vantagem relativa dos Transformers se mantiver mesmo com ambas as famílias re-tunadas simetricamente, o ordenamento não se inverteria — mas essa verificação exige repetir o GridSearchCV completo para os 15 modelos em cada N , o que fica como próximo passo (ver Seção 10.6).

10.7 FT-CUR/SAINT e a correção metodológica da H2

Os primeiros runs do Tier 2 (parciais, com 6/18 modelos completos) sugeriram um colapso estrutural do FT-CUR em datasets imbalanceados: $F_1 = 0,444$ em CREDIT, $0,548$ em BANK — valores compatíveis com predição quase exclusiva da classe majoritária. Três hipóteses foram formuladas para explicar o efeito (Tabela 20).

Tabela 20: Hipóteses sobre o colapso aparente do FT-CUR no Tier 2 parcial.

H	Causa proposta	Teste experimental	Status
H1	Seleção colnorm geométrica sub-representa a classe minoritária nos m landmarks	Tier 2 balanceado: under-sample da majoritária só no treino	A rodar
H2	<code>val_acc</code> em early stopping favorece a classe majoritária	Rerun com <code>val_loss/val_f1_macro</code> e re-tuning GridSearchCV independente por métrica	Confirmada
H3	Limitação fundamental da decomposição CUR	Confirmação por exclusão	Enfraquecida

Ablação H2 (concluída). 360 runs (2 modelos $\times$ 2 datasets $\times$ 3 métricas $\times$ 30 seeds):

Tabela 21: Efeito do critério de early stopping em FT-CUR e SAINT nos datasets desbalanceados CREDIT e BANK (30 seeds, retuning GridSearchCV por métrica).

Modelo	Dataset	val_acc	val_loss	val_f1	$\Delta(\text{loss-acc})$	Melhor FT baseline
FT-CUR	CREDIT	0,438	0,657	0,610	+0,219	0,682 (FT-Entmax)
FT-CUR	BANK	0,507	0,714	0,473	+0,207	0,720 (FT-Softmax)
SAINT	CREDIT	0,439	0,684	0,467	+0,245	0,682 (FT-Entmax)
SAINT	BANK	0,473	0,710	0,498	+0,237	0,720 (FT-Softmax)

Validação estatística (Wilcoxon pareado, H_a : $\text{val_loss} > \text{val_acc}$): FT-CUR/CREDIT $p = 1,3 \times 10^{-6}$; FT-CUR/BANK $p = 1,9 \times 10^{-9}$; SAINT/CREDIT $p = 9,3 \times 10^{-10}$; SAINT/BANK $p = 9,3 \times 10^{-10}$.

Conclusão da ablação. O uso de `val_acc` como critério de early stopping era um *erro metodológico* no protocolo original. `val_loss` foi superior nos quatro cenários, com magnitude (+0,21 a +0,25) incompatível com ruído. Em BANK, a correção elimina sozinho o colapso aparente; em CREDIT, ela explica a maior parte. A hipótese H3 (limitação fundamental do CUR) fica enfraquecida mas não completamente descartada para um pequeno resíduo em CREDIT.

Rerun completo do Tier 2 com `val_loss`. Os números da Tabela 15 para FT-CUR e SAINT já refletem este protocolo corrigido. A Tabela 22 compara explicitamente os dois protocolos para FT-CUR para quantificar a magnitude da correção.

Tabela 22: FT-CUR no Tier 2: protocolo histórico (`val_acc`) vs. protocolo corrigido (`val_loss`).

Modelo	ADULT	CREDIT	BANK	TELCO	SHOPPERS	HIGGS50K	Média
FT-CUR (<code>val_acc</code> , histórico)	0,770	0,444	0,548	0,714	0,751	0,648	0,646
FT-CUR (<code>val_loss</code> , atual)	0,774	0,683	0,695	0,724	0,763	0,639	0,713

10.8 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia

A Tabela 23 sumariza o deslocamento de F1-macro de cada família ao migrar do regime sintético/pequeno (Tier 1) para o regime real grande (Tier 2).

Tabela 23: F1-macro médio: Tier 1 (sintéticos + pequenos reais, $N \in [400, 1584]$) vs. Tier 2 ($N_{\text{treino}} = 2000$ em datasets reais grandes). Δ negativo = perda ao migrar.

Modelo	Tier 1	Tier 2	Δ	Família
LSSVM-Std	0,838	0,709	−0,129	kernel denso
DualFISTA ^o	0,831	0,706	−0,125	dual ℓ_1 via FISTA
Nystrom-LSSVM [*]	0,838	0,707	−0,131	kernel esparso (81% esp.)
LSSVM-IP	0,832	0,694	−0,138	iterative pruning
LSSVM-PCP	0,838	0,689	−0,149	cone projection
LSSVM-FSA	0,829	0,679	−0,150	forward selection
XGBoost	0,826	0,735	−0,091	gradient boosting
FT-Softmax [†]	0,730	0,725	−0,005	atenção feature densa
FT-Sparsemax [†]	0,731	0,723	−0,008	atenção feature esparsa
FT-Entmax [†]	0,734	0,723	−0,011	atenção feature esparsa
FT-TopK [†]	0,712	0,720	+0,008	atenção feature top- k
SAINT [†]	0,731	0,722	−0,009	atenção inter-inst. densa
FT-CUR ^{*†}	0,738	0,713	−0,025	atenção inter-inst. comprimida
LSSVM-ADMM (paper-base)	0,802	0,580	−0,222	primal ℓ_1 (ADMM)
ADMM-ElasticNet ^o	0,802	0,576	−0,226	primal $\ell_1 + \ell_2$
FISTA-Nesterov	0,787	0,577	−0,210	primal ℓ_1 (FISTA)
LSSVM-Pruning [†]	0,808	0,594	−0,214	pruning iterativo <i>c/ early stop</i>
LSSVM-OppMaps	0,759	0,478	−0,281	opposite maps

Três regimes de deslocamento:

1. **LSSVMs duais bem-comportados** ($\Delta \approx -0,13$ a $-0,15$). O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em dados reais com features categóricas codificadas, redundância e ruído estrutural. *Nystrom-LSSVM* e *DualFISTA* mantêm-se virtualmente empatados com *LSSVM-Std* denso no Tier 2 (gap $\leq 0,003$), confirmando que os mecanismos de esparsidade propostos são *neutros* em relação à formulação dual em escala.
2. **Transformers e XGBoost**. FT-Transformers ([†], protocolo GridSearchCV no Tier 2) absorvem a transição com baixa perda ($\Delta \approx -0,025$ a $+0,008$, com FT-TopK ligeiramente melhor no Tier 2 que no Tier 1 com Grid+CV). As variantes esparsas convergem para o mesmo patamar do softmax denso (0,720–0,725): a esparsidade na atenção inter-features não traz vantagem mensurável. **XGBoost**, com o novo Grid+CV, passa de 0,776 (Optuna) para 0,826 no Tier 1, resultando em $\Delta = -0,091$ — maior que os Transformers, mas ainda muito inferior ao colapso dos métodos primais.
3. **Métodos primais com ℓ_1 e heurísticas cegas** ($\Delta \approx -0,21$ a $-0,28$). Os métodos que dependem de regularização agressiva sobre o espaço primal ou de poda heurística sofrem o maior colapso. É a contribuição central do Tier 2: revelar que o paper-base LSSVM-ADMM-Nesterov possui um teto de escalabilidade não evidente em $N \leq 1000$. O **LSSVM-Pruning**, após adquirir *early stopping* guiado por F1 de treino e correção do grid, sobe para 0,808 no Tier 1 e reduz a queda a $-0,214$.

Reordenação: no Tier 1, o ranking é Nyström/LSSVM-Std/PCP (0,838) > IP (0,832) > DualFISTA (0,831) > FSA/XGBoost (0,826–0,829) > primais ℓ_1 > OppMaps; no Tier 2, é XGBoost $\geq$ FT-Transformers + SAINT + FT-CUR > LSSVMs duais (Std, Nyström, DualFISTA, IP, PCP, FSA) > primais com ℓ_1 > heurísticas. A vantagem do paradigma Transformer cresce *em proporção à complexidade tabular dos dados*, e não à escolha de função de ativação da atenção.

10.9 Comparação entre variantes de FT-Transformer no Tier 2

O experimento Tier 2 de Transformers executou **1080 runs** (6 variantes $\times$ 6 datasets $\times$ 30 sementes) com $N_{\text{treino}} = 2000$, **GridSearchCV** (grade fixa, 5-fold CV) e parada antecipada por **val_loss**. A Tabela 24 reporta o F1-macro por variante e dataset; a Tabela 25 apresenta os ranks médios de Friedman.

Tabela 24: Média $\pm$ desvio padrão de F1-macro (30 sementes, 6 conjuntos de dados TIER2 TRANSFORMERS).

Model	ADULT	BANK	CREDIT	HIGGS50K	SHOPPERS	TELCO
FT-CUR	0.757 $\pm$ 0.021	0.644 $\pm$ 0.083	0.670 $\pm$ 0.074	0.618 $\pm$ 0.023	0.786 $\pm$ 0.019	0.714 $\pm$ 0.057
FT-Entmax	0.753 $\pm$ 0.026	0.651 $\pm$ 0.068	0.669 $\pm$ 0.037	0.637 $\pm$ 0.022	0.784 $\pm$ 0.024	0.712 $\pm$ 0.030
FT-Softmax	0.753 $\pm$ 0.024	0.671 $\pm$ 0.071	0.665 $\pm$ 0.043	0.627 $\pm$ 0.020	0.777 $\pm$ 0.031	0.711 $\pm$ 0.030
FT-Sparsemax	0.746 $\pm$ 0.025	0.655 $\pm$ 0.041	0.648 $\pm$ 0.051	0.624 $\pm$ 0.020	0.780 $\pm$ 0.020	0.710 $\pm$ 0.033
FT-TopK	0.748 $\pm$ 0.026	0.637 $\pm$ 0.064	0.647 $\pm$ 0.051	0.626 $\pm$ 0.021	0.780 $\pm$ 0.027	0.708 $\pm$ 0.027
SAINT	0.760 $\pm$ 0.020	0.592 $\pm$ 0.084	0.658 $\pm$ 0.069	0.621 $\pm$ 0.020	0.784 $\pm$ 0.020	0.721 $\pm$ 0.019

Tabela 25: Ranks médios de Friedman — TIER2 TRANSFORMERS (menor = melhor).

Rank	Model	Avg. rank
1	FT-CUR	2.667
2	FT-Entmax	2.667
3	FT-Softmax	3.167
4	SAINT	3.167
5	FT-Sparsemax	4.500
6	FT-TopK	4.833

Principais achados:

1. **Diferença entre variantes não é estatisticamente significativa.** O teste de Friedman retorna $\chi^2 = 7,52$, $p = 0,185$ — sem evidência de que o tipo de atenção importa no regime Tier 2. Todos os modelos ficam entre 0,689 e 0,701 de F1-macro médio, uma faixa de apenas 0,012.
2. **FT-CUR e FT-Entmax empatam em 1º lugar** (rank médio 2,667 cada), seguidos de FT-Softmax e SAINT (rank 3,167). FT-CUR vence nos datasets CREDIT e SHOPPERS; FT-Entmax vence em HIGGS50K; SAINT vence em ADULT e TELCO.
3. **FT-CUR mantém qualidade com atenção comprimida.** Com $m = 0,2 \times N = 400$ landmarks, a aproximação Nyströmformer nunca materializa a matriz $N \times N$, mas obtém F1 idêntico às variantes densas. Isso valida a aproximação CUR como alternativa eficiente mesmo em datasets Tier 2 de maior volume.

4. **Custo de treino: FT-CUR e FT-Entmax são os mais lentos.** O tempo médio de treino por run é ≈ 29 s para FT-Softmax, FT-Sparsemax e FT-TopK; 31 s para SAINT; 145 s para FT-CUR e 185 s para FT-Entmax. FT-CUR é $5\times$ mais lento que FT-Softmax apesar de desempenho equivalente — o custo vem da construção dos landmarks e da inversão da matriz $W \in \mathbb{R}^{m \times m}$, não da atenção em si. FT-Entmax é ainda mais lento devido ao solver iterativo do operador α -entmax.
5. **SAINT apresenta maior variância.** Com desvio padrão de 0,085 (vs. 0,065–0,076 nos FT-Transformers), o SAINT mostra sensibilidade maior à inicialização, reflexo da atenção inter-instâncias densa que propaga ruído de amostragem.

Conclusão: no regime Tier 2 com $N_{\text{treino}} = 2000$, o tipo de atenção do FT-Transformer é um fator de segundo plano — a arquitetura comum domina. A compressão CUR não degrada qualidade, mas o ganho de escalabilidade só se materializa em N maiores do que os testados aqui.

11 Benchmark de Eficiência Computacional em *Full-Data*

Em complemento ao estudo de F1-macro, executou-se um benchmark *end-to-end* em GPU T4 (Colab) com **uma única seed**, medindo o custo de uma execução real: carregamento do dataset, subamostragem para um N alvo, split 70/30, pré-processamento, treinamento e inferência. O objetivo **não** é comparar desempenho preditivo com rigor estatístico, mas caracterizar o **trade-off computacional** entre as variantes Transformer em regime *full-data*. Os valores de F_1 aqui devem ser lidos como *sanity check* operacional.

Tabela 26: Benchmark de eficiência em *full-data*. Para cada dataset, reporta-se o maior N concluído por modelo. Para SAINT, indica-se o maior N atingido antes de OOM.

Dataset	Modelo	N	Fit (s)	Pred. (s)	VRAM pico (MB)
ADULT	FT-Softmax	45 222	100,2	0,11	364
ADULT	FT-Sparsemax	45 222	124,2	0,41	628
ADULT	FT-TopK	45 222	195,8	0,23	387
ADULT	FT-CUR	45 222	231,6	5,87	3 288
ADULT	FT-Entmax	45 222	425,5	0,59	394
ADULT	SAINT	20 000	25,8	0,85	12 271
CREDIT	FT-Sparsemax	30 000	29,3	0,33	718
CREDIT	FT-TopK	30 000	29,4	0,22	718
CREDIT	FT-Softmax	30 000	38,6	0,18	718
CREDIT	FT-Entmax	30 000	304,3	1,28	909
CREDIT	FT-CUR	30 000	2 451,4	77,68	5 472
CREDIT	SAINT	15 000	61,9	1,54	9 244
HIGGS50K	FT-Softmax	48 842	55,1	0,26	969
HIGGS50K	FT-Sparsemax	48 842	111,9	0,74	2 032
HIGGS50K	FT-TopK	48 842	139,1	0,47	1 444
HIGGS50K	FT-Entmax	48 842	639,3	1,58	1 445
HIGGS50K	FT-CUR	48 842	849,8	20,74	10 642
HIGGS50K	SAINT	20 000	58,3	1,96	12 385

Achados principais:

- O tempo total é dominado pelo treinamento em todos os cenários: `fit_time_s` responde por quase todo `total_time_s`. A comparação computacional é, na prática, uma comparação de custo de treinamento.
- **SAINT** é o mais rápido entre os modelos com atenção inter-instâncias, mas seu consumo de memória é proibitivo: atinge 12,3 GB em ADULT com $N=20k$ e entra em OOM já em $N=30k$ (ADULT) e $N=20k$ (CREDIT/HIGGS50K). É o gargalo quadrático clássico ($O(n^2d)$).
- **FT-CUR** ocupa posição intermediária: em ADULT é mais rápido que FT-Entmax e competitivo com FT-TopK/Sparsemax, com custo de VRAM superior (3,3 GB no ADULT completo) e inferência transdutiva mais cara (5,9s no ADULT completo). É a *versão computacionalmente viável* do paradigma inter-samples: enquanto SAINT esgota memória em $N \geq 20k$, FT-CUR comprime o mesmo mecanismo via landmarks e roda em $N = 48k$.
- Em **CREDIT**, o FT-CUR entra em regime patológico: no dataset completo ($N=30k$), o treinamento sobe para 2 451 s e a inferência para 77,7s. A causa mais plausível é a extrapolação de hiperparâmetros tunados em regime reduzido ($N_{\text{treino}} = 2000$): em particular, um `m_ratio` muito maior no CREDIT (0,141 vs. 0,054 em ADULT) aumenta fortemente o número absoluto de landmarks e o custo do bloco inter-instâncias.

- Nos três datasets, os **FT baselines inter-features** (Softmax/TopK/Sparsemax) apresentam o melhor compromisso entre tempo e memória. FT-Softmax é o mais econômico em VRAM; FT-Sparsemax e FT-TopK mantêm custo semelhante em CREDIT/HIGGS50K.
- A RAM CPU mostrou baixa sensibilidade ao crescimento de N e é menos informativa que VRAM. As conclusões devem apoiar-se em tempo e memória de GPU.

Interpretação prática. Se o treinamento é *offline* e com baixa frequência, a vantagem temporal de SAINT e FT-CUR perde parte do peso operacional, enquanto seu maior consumo de memória permanece como custo persistente. Nesse regime, os FT baselines tornam-se mais atraentes por oferecerem inferência barata e *footprint* de memória muito menor, sem perda predominante de F_1 no benchmark operacional.

11.1 Análise Comparativa: SAINT vs. FT-CUR em Mini-batch e Full-batch

Para entender o real trade-off entre SAINT e FT-CUR, avaliou-se quatro configurações em GPU MX350 (2 GB VRAM) no dataset ADULT, medindo tempo por época e VRAM de pico com 5 épocas de aquecimento:

Tabela 27: Tempo por época e VRAM de pico para quatro variantes de atenção inter-instâncias. Hardware: NVIDIA MX350 (2 GB). OOM = sem memória. SAINT-mini: $B=1024$; FT-CUR-mini: $B=4096$, $m=10\%$ de B fixo.

Variante	$N = 2\,000$		$N = 5\,000$		$N = 10\,000$		$N = 15\,000$	
	s/ep	VRAM	s/ep	VRAM	s/ep	VRAM	s/ep	VRAM
SAINT-mini	0,69	182 MB	0,41	182 MB	0,81	183 MB	1,22	184 MB
SAINT-full	0,20	347 MB	OOM		OOM		OOM	
FT-CUR-mini	0,45	155 MB	0,95	453 MB	2,19	467 MB	3,86	468 MB
FT-CUR-full	0,55	155 MB	1,36	453 MB	6,99	1 191 MB	OOM	

Achados e interpretação:

- **SAINT-mini é o baseline mais difícil de superar.** Memória plana em ≈ 182 MB independente de N (o batch $B=1024$ é constante) e tempo por época que cresce suavemente com N graças ao cuBLAS que otimiza a multiplicação $B \times B$. Nenhuma das outras três variantes supera SAINT-mini em tempo para $N \geq 5\,000$.
- **SAINT-full** é o mais rápido em $N=2\,000$ (único passo, atenção global exata), mas entra em OOM para $N \geq 5\,000$ — gargalo $O(N^2)$ clássico.
- **FT-CUR-full dobra o alcance do SAINT-full** (OOM em $N \approx 12\,000$ vs. $N \approx 5\,000$), mas às custas de tempo crescente: em $N=10\,000$ é $8\times$ mais lento que SAINT-mini. A causa é identificada abaixo.
- **FT-CUR-mini é mais rápido que FT-CUR-full para $N \geq 5\,000$** — resultado aparentemente paradoxal para um modelo que não materializa $N \times N$. A explicação está na complexidade oculta do pseudo-inverso.

Complexidade oculta do pseudo-inverso de Nyström. A análise de complexidade do FT-CUR anuncia $O(N \cdot m)$ para a atenção Nyström, omitindo o custo do pseudo-inverso truncado via SVD da matriz de landmarks $W \in \mathbb{R}^{m \times m}$:

$$\text{pinv}(W) \sim O(m^3) \quad (\text{SVD, por cabeça de atenção}).$$

No modo *full-batch*, $m = \lfloor 0,1 N \rfloor$ cresce com N , tornando o custo real por época:

$$O(N \cdot m + m^3) = O(0,1 N^2 + 10^{-3} N^3).$$

Para $N=10\,000$ e $m=1\,000$: o termo cúbico equivale a 10^9 operações de SVD (executadas 4 vezes, uma por cabeça, em série). No modo *mini-batch*, $m_{\text{batch}} = \lfloor 0,1 \cdot B \rfloor = 410$ é *fixo*, reduzindo o custo total por época para:

$$\frac{N}{B} \cdot O(B \cdot m_{\text{batch}} + m_{\text{batch}}^3) = O(N \cdot \text{const}),$$

explicando por que FT-CUR-mini é mais rápido que FT-CUR-full em N grande, a despeito de processar os dados em batches menores.

Implicação metodológica. A comparação FT-CUR vs. SAINT é mais justa em *full-batch*: ambos processam o contexto global, mas FT-CUR com CUR evita o pico $N \times N$, estendendo o alcance de $N \approx 5\,000$ para $N \approx 12\,000$ na MX350. Em mini-batch, SAINT com softmax exato supera FT-CUR em tempo e memória para qualquer N testado — o custo do pseudo-inverso elimina a vantagem teórica $O(B \times m) < O(B^2)$.

Verificação de acurácia em múltiplos N . Uma questão crítica é se o treinamento em mini-batch prejudica a qualidade preditiva em relação ao full-batch. As quatro variantes foram avaliadas no dataset ADULT para $N_{\text{treino}} \in \{2\,000, 5\,000, 10\,000\}$ (40 épocas, patience = 6, métrica `val_loss`), medindo F1-macro no conjunto de teste fixo ($N_{\text{teste}}=13\,567$):

Tabela 28: F1-macro e tempo total de treino para as quatro variantes em múltiplos N . ADULT, GPU MX350. OOM = estouro de memória durante o treino. SAINT-mini: $B=1024$; FT-CUR-mini: $B=4096$, $m_{\text{batch}}=10\%B$.

	$N = 2\,000$		$N = 5\,000$		$N = 10\,000$	
Variante	F1	tempo	F1	tempo	F1	tempo
SAINT-mini	0,764	9,6 s	0,766	14,3 s	0,774	22,5 s
SAINT-full	0,747	12,4 s	OOM		OOM	
FT-CUR-mini	0,757	32,6 s	0,763	112,6 s	0,758	776,0 s
FT-CUR-full	0,767	98,5 s	0,769	293,7 s	0,778	832,7 s

Os resultados revelam três achados adicionais:

- **SAINT-mini é Pareto-ótimo.** Em $N=10\,000$ obtém o segundo melhor F1 (0,774) em apenas 22,5 s — $35\times$ mais rápido que FT-CUR-mini (776 s) e $37\times$ mais rápido que FT-CUR-full (833 s), ambos com F1 inferior ou igual.

- **FT-CUR-full tem o melhor F1** em $N=10\,000$ (0,778), mas ao custo de 833s por execução — inviável para busca hiperparamétrica com muitas sementes.
- **FT-CUR-mini não é mais rápido que SAINT-mini para nenhum N .** O custo da pseudo-inversa $O(m_{\text{batch}}^3)$, executada em série por cabeça de atenção, supera o benefício de $O(B \times m) < O(B^2)$ na atenção. A diferença agrava-se com N : em $N=10\,000$, FT-CUR-mini é $34\times$ mais lento.

Conclui-se que **mini-batch não degrada a qualidade preditiva** (amplitude < 2 p.p. entre todas as variantes viáveis), e que SAINT-mini é a variante recomendada por combinar escalabilidade, baixo uso de memória e acurácia competitiva.

11.2 Benchmark de Predição: LSSVMs Esparsos no Tier 2

Para modelos esparsos, o tempo de *predição* é a métrica central: a esparsidade amostral reduz o número de vetores-suporte e, consequentemente, o custo de avaliar $f(\mathbf{x}) = \sum_{i \in \mathcal{S}} \alpha_i K(\mathbf{x}_i, \mathbf{x})$. Os hiperparâmetros ótimos foram fixados a partir dos resultados do GridCV do Tier 2 (Seção 10), e as estatísticas abaixo refletem médias de 30 sementes sobre os 6 datasets reais ($N_{\text{treino}}=2\,000$, $N_{\text{teste}} \approx 858$).

Tabela 29: Comparação de LSSVMs esparsos e XGBoost no Tier 2: F1-macro médio, tempo de treino, tempo de predição e esparsidade amostral. Ordenado por tempo de predição crescente. Hiperparâmetros fixos (melhores do GridCV). $N_{\text{treino}}=2\,000$; média sobre 6 datasets e 30 sementes.

Modelo	F1	Treino (s)	Predição (ms)	$ \mathcal{S} $	Espar.
XGBoost	0,723	12,3	12,5	—	—
FSA-LSSVM	0,676	268,3	35,7	161	92,0%
FISTA-Nyström	0,674	53,2	39,6	513	14,5%
ADMM-Nyström	0,681	61,9	40,9	474	20,9%
PCP-LSSVM	0,689	14,5	59,7	186	90,7%
Nyström	0,699	5,8	62,0	600	70,0%
IP-LSSVM	0,694	339,2	82,6	1 227	38,6%
LSSVM-Std	0,699	20,5	135,5	1 999	0,0%
DualFISTA	0,684	240,3	155,3	1 909	4,5%

Achados principais:

- **ADMM-Nyström é o melhor compromisso geral** entre os LSSVMs esparsos: $|\mathcal{S}| \approx 474$ (21% de N), predição em 41 ms ($3,3\times$ mais rápida que o Std), F1 competitivo (0,681) e escalabilidade até $N=20\,000$ no benchmark de RAM. A combinação da aproximação Nyström (que reduz a constante de memória) com a regularização ADMM (que induz esparsidade na solução dual) é a configuração mais favorável da família kernel estudada.
- **Nyström (Colnorm) oferece o maior F1 entre os esparsos** (0,699, empatado com LSSVM-Std), treino $3,5\times$ mais rápido e predição $2,2\times$ mais rápida. Contudo, a esparsidade de 70% é fixa por construção (parâmetro m), não emergindo da otimização — e a memória RAM permanece $O(N^2)$ com constante reduzida, conforme confirmado no benchmark de escalabilidade (Tabela 31).

- **DualFISTA é o resultado mais desfavorável** do benchmark: apesar de evitar o colapso dos métodos primais com ℓ_1 , converge para soluções quase densas em escala ($|\mathcal{S}| \approx 1\,909$, apenas 4,5% de esparsidade), tornando a predição $1,15\times$ *mais lenta* que o LSSVM-Std. No benchmark de escalabilidade, atinge o limite de 120 s já em $N=5\,000$, inviabilizando qualquer uso prático em datasets maiores. O ganho qualitativo da reformulação dual (F1 preservado) não se traduz em ganho operacional de esparsidade.
- **FSA-LSSVM e PCP-LSSVM** alcançam alta esparsidade nominal (92% e 91%), mas apresentam custo de treino elevado (268 s e 14,5 s respectivamente) e memória $O(N^2)$ idêntica ao LSSVM-Std no benchmark de escalabilidade, com timeout já em $N=5\,000$ (FSA) e RAM de 9,9 GB em $N=20\,000$ (PCP).
- **XGBoost** permanece superior em F1 (0,723), predição (12 ms) e memória (≈ 465 MB estável), sendo a referência a superar na família kernel em termos de eficiência operacional.

A Tabela 30 detalha o tempo de predição por dataset, evidenciando consistência entre domínios:

Tabela 30: Tempo de predição (ms) por dataset, Tier 2. Média de 30 sementes, $N_{\text{teste}} \approx 858$.

Modelo	ADULT	BANK	CREDIT	HIGGS50K	SHOPPERS	TELCO
XGBoost	12,3	15,0	11,1	14,3	11,7	10,6
FSA-LSSVM	30,3	37,0	41,4	39,8	36,4	29,6
FISTA-Nyström	39,9	42,7	42,0	40,0	43,1	29,8
ADMM-Nyström	38,0	42,6	41,3	47,8	38,8	36,9
PCP-LSSVM	62,6	60,7	62,8	60,6	57,7	53,8
Nyström	55,4	58,5	66,3	72,4	58,3	60,9
IP-LSSVM	83,4	81,1	77,5	83,4	85,8	84,0
LSSVM-Std	102,4	148,9	152,3	121,6	146,9	140,9
DualFISTA	151,7	143,8	153,6	149,7	148,7	184,3

Escalabilidade em memória RAM: todos os LSSVMs são $O(N^2)$. Um resultado relevante para a dissertação é que a esparsidade amostral reduz o tempo de *predição*, mas **não elimina o gargalo quadrático de memória RAM** no treino. O benchmark de escalabilidade a seguir (dataset ADULT, hiperparâmetros fixos, 1 semente, predição em $N_{\text{teste}}=1\,000$ amostras fixas) torna isso evidente:

Tabela 31: Escalabilidade de memória RAM (RSS de processo, via `psutil`) e tempo de predição com N crescente. Hiperparâmetros fixos do GridCV. TIME = ultrapassou 120s de treino. Dataset ADULT, $N_{\text{teste}}=1000$ fixo. RSS inclui baseline do processo Python (≈ 280 MB); o crescimento entre colunas reflete o custo incremental do modelo. † valor inflado por memória residual de runs anteriores no mesmo processo (RSS não devolvido ao SO).

Modelo	$N = 2\,000$		$N = 5\,000$		$N = 10\,000$		$N = 20\,000$	
	RAM	pred	RAM	pred	RAM	pred	RAM	pred
LSSVM-Std	346 MB	217 ms	947 MB	429 ms	2 655 MB	835 ms	TIME	
Nyström	284 MB	45 ms	420 MB	97 ms	905 MB	119 ms	2 860 MB	249 ms
ADMM-Nyström	† 187 MB	16 ms	337 MB	45 ms	570 MB	56 ms	1 286 MB	57 ms
DualFISTA	407 MB	173 ms	TIME		SKIP		SKIP	
FISTA-Nyström	323 MB	49 ms	495 MB	71 ms	1 021 MB	197 ms	TIME	
FSA-LSSVM	376 MB	19 ms	TIME		SKIP		SKIP	
PCP-LSSVM	376 MB	79 ms	888 MB	63 ms	2 674 MB	38 ms	9 890 MB	61 ms
XGBoost	465 MB	31 ms	466 MB	2 ms	466 MB	22 ms	469 MB	37 ms

A razão é estrutural: mesmo as variantes Nyström formam uma matriz de kernel $N \times m$ com $m = 0,2 N$, resultando em custo $O(N \cdot m) = O(0,2 N^2)$ — quadrático na constante, não na ordem. Isso se confirma nos dados: o LSSVM-Std cresce de 346 MB para 2 655 MB entre $N=2\,000$ e $N=10\,000$ (fator $7,7\times$ para $5\times$ o N , consistente com $O(N^2)$), e o Nyström cresce de 284 MB para 905 MB (fator $3,2\times$, consistente com constante $5\times$ menor que o Std).

O XGBoost mantém RSS estável em ≈ 465 MB independente de N — reflexo da sua estrutura de árvores de decisão, sem necessidade de matrizes $N \times N$.

O benefício real da esparsidade manifesta-se na **predição**: o ADMM-Nyström encontra soluções com $|\mathcal{S}| \approx 474$ vetores-suporte (21% de N), reduzindo o tempo de predição de 217 ms (LSSVM-Std, $N=2\,000$) para 16 ms — aceleração de **13** $\times$ com queda de apenas 0,4 p.p. em F1. Em $N=10\,000$, o ADMM-Nyström prediz em 57 ms enquanto o LSSVM-Std já não converge por falta de memória RAM.

12 Sumário e Próximos Passos

Tabela 32: Síntese dos experimentos realizados.

Experimento	Configuração	Runs	Resultado principal
Tier 1	18 mod. (12 LSSVM+XGB + 6 Transformers), 9 datasets, 30 seeds (Grid+CV)	4860	Nyström 0,838 / LSSVM-Std 0,838 / DualFISTA 0,831 / XGBoost 0,826
Ablação A (escala)	18 mod., 3 sintéticos, $N=400 \rightarrow 2000$, 30s (LSSVM/XGB) ou 20s (Transf.)	1080	LSSVMs saturados ($\bar{\Delta} \approx 0$); Transf. data-hungry (FT-sparsemax +0,145)
Ablação B (ruído)	18 mod., 3 sintéticos, +3 feat. ruído, 30s	1620	XGBoost $\bar{\Delta} = -0,048$; LSSVMs $-0,26$ a $-0,39$; Transf. $-0,029$ a $-0,044$
Ablação C (MK5)	18 mod., 3 sintéticos (5 features), 30 seeds	1620	LSSVM-Std 0,851 > Nyström 0,841; Transf. abaixo (0,782–0,807)
Tier 2 ($N_{\text{treino}} = 2000$)	15 modelos, 6 datasets reais, 30s	2700	XGBoost 0,735; SAINT/FT-CUR/FT baselines $\sim 0,72$; primais ℓ_1 colapsam para 0,58
Ablação H2 (early stop)	FT-CUR/SAINT, CREDIT/BANK, 3 métricas, 30s	360	$\text{val_loss} > \text{val_acc}$ ($p < 10^{-5}$ em todos os 4 cenários)
Benchmark eficiência	6 Transformers, 3 datasets reais, 1 seed	137	SAINT OOM cedo; FT baselines dominam tempo/memória; FT-CUR patológico em CREDIT 30k
Total		13 057	

Conclusões consolidadas:

1. **Nyström-LSSVM** é o melhor resultado da dissertação em alta esparsidade: $F_1 = 0,838$ no Tier 1 (78% esp., Grid+CV) e $0,707$ no Tier 2 (81,5% esp.), em ambos os regimes a $\leq 0,002$ do LSSVM-Std denso. *Compressão sem custo preditivo*, agora confirmado em escala $N = 2000$.
2. **DualFISTA** mantém $F1$ próximo ao LSSVM-Std no Tier 1 ($0,831$ vs. $0,838$, $\Delta=0,007$) e elimina o colapso dos primais com ℓ_1 no Tier 2 — contribuição qualitativa confirmada. Contudo, o benchmark de predição e escalabilidade revela um **trade-off desfavorável em produção**: converge para soluções quase densas ($|\mathcal{S}| \approx 1\,909$, 4,5% de esparsidade), predição $1,15\times$ mais lenta que o LSSVM-Std denso, e timeout em $N=5\,000$. A reformulação dual não induz esparsidade amostral suficiente para justificar o custo computacional adicional de treino.
3. **FT-CUR** valida o paradigma de compressão Nyströmformer em dados tabulares: empata com SAINT denso em todos os experimentos ($\Delta \leq 0,013$) com $\approx 85\text{--}89\%$ de compressão inter-instâncias (Tier 1: 85%; Tier 2: 89%), e roda em $N = 48k$ onde SAINT entra em OOM.
4. **Colapso dos métodos primais com ℓ_1 em escala** é o achado mais inesperado do Tier 2: ADMM-Nesterov, ADMM-ElasticNet e FISTA-Nesterov caem de $0,787\text{--}0,802$ (Tier 1, Grid+CV) para $\approx 0,58$ em $N = 2000$. Revela um teto de escalabilidade não detectável em $N \leq 1000$ e justifica a reformulação dual proposta (DualFISTA).
5. **H2 confirmada metodologicamente**: `val_loss` domina `val_acc` como critério de early stopping para modelos inter-instâncias em datasets desbalanceados ($p < 10^{-5}$ em todos os 4 cenários). É uma contribuição metodológica auxiliar ao protocolo padrão de FT-Transformers tabulares.
6. **Benchmark de eficiência**: FT baselines dominam o trade-off tempo/memória em *full-data*; FT-CUR é a única variante inter-instâncias que roda em $N = 48k$. SAINT é rápido mas restrito a $N \leq 20k$.

Próximas etapas planejadas:

1. **Benchmark de eficiência computacional — família ADMM vs. variantes Nyström**: o benchmark de predição e escalabilidade (Seção 11.2) confirmou que ADMM-Nyström é a configuração mais eficiente da família kernel, com predição $13\times$ mais rápida que o LSSVM-Std e escalabilidade até $N=20\,000$. DualFISTA não produziu esparsidade operacional (4,5% de SVs, timeout em $N=5\,000$), encerrando a hipótese de eficiência computacional desta variante como pendente. Próxima análise: coletar curvas de convergência (loss vs. iteração) para ADMM-Nesterov e ADMM-Nyström para quantificar o custo por iteração e justificar a escolha do ADMM-Nyström como variante de referência.
2. **H1 — Tier 2 com balanceamento no treino**: rodar todos os 18 modelos com `-balance-train` (undersample da majoritária só no treino, preservando o teste original), testando se o resíduo do FT-CUR em CREDIT desaparece e se os métodos primais com ℓ_1 se recuperam.

3. **Tier 2 *full-data***: rodar os 4 FT baselines + FT-CUR no N completo de cada dataset (Colab GPU; ~ 10 – 12 h); e XGBoost + Nyström-LSSVM em N completo (Colab CPU; ~ 3 – 5 h) para confirmar a vantagem de eficiência amostral observada em $N = 2000$.
4. **Re-rodar Tier 1 (`lambda_ratio` corrigido)** para 4 modelos: a correção de escala do λ entre Tier 1 e Tier 2 (sintaxe `lambda_ratio` em vez de absoluto) deve ser retroaplicada aos métodos primais com ℓ_1 e ao LSSVM-Pruning (que ganhou *early stopping* no Tier 2) para comparação metodológica justa entre tiers.
5. **Diagrama de diferença crítica** (Nemenyi) sobre todos os datasets consolidados (Tier 1 + 3 ablações + Tier 2 = 21 datasets), reportado como figura agregada de comparação estatística entre os 18 modelos.

A Infraestrutura e Reprodutibilidade

- **Código**: repositório `sparse-lssvm-transformers-study/`
- **Ambiente**: Python 3.12, PyTorch, scikit-learn, XGBoost; virtualenv em `.venv/`
- **Resultados**: arquivos JSON em `results/`: `tier1_results.json` (baselines), `tier1_custom_models.json` (propostos), `synthetic_scaling_n2000.json`, `synthetic_5features_tuned.json`, `synthetic_mk5.json`, `tier2_n5000_*.json` (consolidado), `tier2_n5000_ftcur_saint_valloss.json` (re-run H2), `tier2_early_stop_ablation.json` (ablação H2), `benchmark_transformers_efficiency.json` (benchmark full-data)
- **Tuning**: `results/tuning/best_params*.json`
- **Scripts**: `scripts/run_*.py` são resumíveis (checkpoint por chave `model/dataset/seed`)
- **Figuras**: geradas por `scripts/generate_report_figs.py` e `scripts/generate_tier2_analysis.py`

B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)

Tabela 33: P-valores do teste de Wilcoxon signed-rank com correção de Holm-Bonferroni — Tier 2 ($n_{\text{comp}} = 105$; negrito = significativo em $\alpha = 0,05$).

	ADMM-Nystrom	LSSVM-DualFISTA	FISTA-Nystrom	LSSVM-FSA	FT-CUR	FT-Entmax	FT-Softmax	FT-Sparsemax	FT-TopK	LSSVM-IP	LSSVM-Nystrom	LSSVM-PCP	SAINT	LSSVM (Standard)	XGBoost
ADMM-Nystrom		1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-DualFISTA	1.000		1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FISTA-Nystrom	1.000	1.000		1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-FSA	1.000	1.000	1.000		1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-CUR	1.000	1.000	1.000	1.000		1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Entmax	1.000	1.000	1.000	1.000	1.000		1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Softmax	1.000	1.000	1.000	1.000	1.000	1.000		1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Sparsemax	1.000	1.000	1.000	1.000	1.000	1.000	1.000		1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-TopK	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000		1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-IP	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000		1.000	1.000	1.000	1.000	1.000
LSSVM-Nystrom	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000		1.000	1.000	1.000	1.000
LSSVM-PCP	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000		1.000	1.000	1.000
SAINT	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000		1.000	1.000
LSSVM (Standard)	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000		1.000
XGBoost	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	