

Relatório de Experimentos

Estudo Comparativo: LSSVM Esperso vs. Transformers Tabulares
Dissertação de Mestrado — Experimentos (atualizado em maio de 2026)

Paulo Bernardo

Maio de 2026

Sumário

1	Introdução	2
2	Auditoria da Implementação do Nyström-SVM	3
2.1	As três versões	3
2.2	Verificação experimental	4
2.3	Esparsidade reportada	4
3	Experimento Tier 1: Benchmarks Reais	5
3.1	Resultados por Dataset	5
3.2	Comparação Geral	6
4	Arquitetura dos FT-Transformers e Tipos de Atenção	7
4.1	Atenção inter-features (intra-instância)	7
4.2	Atenção inter-instâncias (entre amostras)	7
5	Análise de Esparsidade	8
5.1	Esparsidade amostral — LSSVMs	8
5.2	Esparsidade de atenção inter-features — FT-Transformers baselines	9
6	Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)	10
7	Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)	12
8	Ablação C: Dados Sintéticos Multifeature (MK5)	14
9	Análise das Variantes Investigadas e Modelos Propostos	16
9.1	Mecanismos de esparsidade	16
9.2	Desempenho consolidado	16
9.3	Síntese comparativa	17
10	Sumário e Próximos Passos	18
A	Infraestrutura e Reprodutibilidade	19

1 Introdução

Este relatório consolida os resultados dos experimentos conduzidos na dissertação, que compara métodos de *Least-Squares Support Vector Machine* (LSSVM) com ênfase em esparsidade contra variantes de *FT-Transformer* com atenção esparsa em tarefas de classificação binária tabular.

O trabalho estende o algoritmo LSSVM-ADMM-Nesterov proposto por Marinho et al. com dois novos mecanismos de esparsidade: (i) **DualFISTA**, formulação dual do LSSVM como LASSO com otimização via ISTA acelerado; e (ii) **Nyström-SVM**, aproximação da matriz kernel por seleção de landmarks via norma de coluna. Como comparativo do lado dos Transformers, avalia-se o **FT-CUR**, que aplica decomposição CUR com colnorm à matriz de atenção.

Auditoria do Nyström-SVM — três versões

A implementação do Nyström-SVM passou por três versões. A versão final, auditada matematicamente (Seção 2), é a apresentada neste relatório.

Versão	Predição	F1 Tier 1
Bug original	$f(x)=K(x, X_{\text{treino}})\alpha + b$ (kernel completo)	0,8427 (inflado)
“Fix” errado	$f(x)=K(x, Z)\alpha[\text{lm_idx}] + b$ (subset ingênuo de α)	0,6678 (colapsado)
Correta	$f(x)=K(x, Z)(W^{-1}C^T\alpha) + b$ (Nyström)	0,8342

A versão correta usa a fórmula matemática da aproximação Nyström ($\tilde{K} = CW^{-1}C^T$), com custo $O(n_{\text{test}} \cdot m)$ e **sem dependência de X_{treino} na predição** (verificado experimentalmente). A perda de F1 em relação ao bug original é de apenas 0,0085, mas agora com $\approx 69\%$ de esparsidade amostral genuína.

Modelos avaliados

Ao todo, 19 modelos foram avaliados, organizados em cinco grupos por origem na literatura:

- **Baseline geral tabular (1): XGBoost** (Chen & Guestrin, 2016) — padrão-ouro para dados tabulares, serve como referência externa às famílias LSSVM e Transformer.
- **LSSVMs baselines (7):** LSSVM-Std (sem esparsidade), LSSVM-PCP, LSSVM-FSA, LSSVM-IP, LSSVM-Pruning, LSSVM-OppMaps, e **FISTA-Nesterov** (LSSVM primal com FISTA — método clássico de Beck & Teboulle, 2009, amplamente documentado).
- **FT-Transformers baselines (5):** variantes com atenção softmax, top- k , entmax e sparsemax — mais **SAINT** (Somepalli et al., 2021; atenção inter-instâncias densa).
- **Paper-base estendido: LSSVM-ADMM-Nesterov** de Marinho et al. — método sobre o qual esta dissertação constrói.
- **Variantes investigadas e modelos propostos (4):**
 - **ADMM-ElasticNet^o**: variante do paper-base com penalidade Elastic Net (combinação ADMM-Nesterov + Elastic Net + LSSVM não localizada explicitamente na literatura como método publicado).

- **DualFISTA[°]**: formulação dual do LSSVM como LASSO ($\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \|\alpha\|_1$), otimizada via FISTA. Ponto de investigação — não localizada na literatura nesta forma exata; pode ser uma reformulação convergente com métodos análogos em SVM ou regressão Lasso.
- **Nyström-SVM (colnorm)***: aproxima $K \in \mathbb{R}^{n \times n}$ via $m \ll n$ landmarks selecionados por norma de coluna (em vez de amostragem uniforme/leverage tradicional); predição restrita aos landmarks ($O(n_{\text{test}} \cdot m)$, auditada).
- **FT-CUR (Nyströmformer)***: aplicação de Nyströmformer (Xiong et al., 2021) à atenção inter-instâncias do FT-Transformer em dados tabulares; seleção de landmarks via colnorm (combinação não localizada como método publicado).

[°] = variante/ponto de investigação; * = aplicação/combinação proposta.

Protocolo experimental

- 30 sementes aleatórias, partição estratificada 70/30.
- Métrica principal: F1-macro (média aritmética do F1 por classe).
- Hiperparâmetros otimizados via Optuna TPE com validação cruzada estratificada de 5 folds.
- Normalização por `StandardScaler` ajustado apenas no treino.

2 Auditoria da Implementação do Nyström-SVM

2.1 As três versões

O Nyström-SVM aproxima a matriz kernel completa $K \in \mathbb{R}^{n \times n}$ a partir de m landmarks $\{z_1, \dots, z_m\}$ selecionados antes do treino:

$$K \approx CW^{-1}C^{\top}, \quad C = K(X, Z) \in \mathbb{R}^{n \times m}, \quad W = K(Z, Z) \in \mathbb{R}^{m \times m}.$$

O treinamento, via identidade de Woodbury, é correto em todas as versões. A diferença está apenas na predição:

V1 — Bug original. Predizia com o kernel completo:

$$f(x) = K(x, X_{\text{treino}}) \alpha + b.$$

Não tinha esparsidade real (todo X_{treino} era usado em inferência) e produzia $F_1 = 0,8427$ no Tier 1.

V2 — “Fix” ingênuo. Tentativa de restringir aos landmarks pegando apenas o subset de α nos índices dos landmarks:

$$f(x) = K(x, Z) \alpha[\text{lm_idx}] + b.$$

Está **matematicamente errado**: os pesos $\alpha \in \mathbb{R}^n$ foram ajustados para o sistema KKT completo n -dimensional, e simplesmente subseqüenciá-los nos índices dos landmarks não recupera a aproximação Nyström. F1 colapsou para 0,6678.

V3 — Correta (atual). A aproximação Nyström verdadeira é $\tilde{K}(x, X) = K(x, Z) W^{-1} C^\top$. Substituindo em $f(x) = \tilde{K}(x, X) \alpha + b$:

$$f(x) = K(x, Z) (W^{-1} C^\top \alpha) + b = K(x, Z) w_\alpha + b, \quad w_\alpha = W^{-1} C^\top \alpha \in \mathbb{R}^m.$$

O vetor w_α é calculado uma vez ao final do fit e cacheado. Em inferência, só $K(x, Z) \in \mathbb{R}^{n_{\text{test}} \times m}$ é computado — não há mais nenhuma dependência de X_{treino} . F1 = 0,8342.

2.2 Verificação experimental

A implementação V3 foi auditada matematicamente (`scripts/audit_nystrom_lssvm.py`) confirmando três propriedades:

1. **Equivalência matemática.** $\|f_{\text{cache}}(x) - f_{\text{Nyström}}(x)\|_2 = 0$ exatamente, onde $f_{\text{Nyström}}$ usa a fórmula expandida $K(x, Z) W^{-1} C^\top \alpha + b$.
2. **Sem dependência de X_{treino} .** Após o fit, ao apagar X_{treino} do modelo, as predições continuam idênticas ($\|\Delta f\|_2 = 0$). Confirma que apenas Z é usado na inferência.
3. **Custo $O(n_{\text{test}} \cdot m)$.** Mantendo m fixo e variando n_{treino} de 1000 a 6000, o tempo de predição permanece em ≈ 5 ms (não escala com n).

Tabela 1: Comparação direta no BCW (10 sementes, mesmos hiperparâmetros).

Versão	F1 BCW	Diagnóstico
V1 (kernel completo)	0,974	0% de esparsidade real
V2 (α subsetado)	0,360	matematicamente inválida
V3 ($W^{-1} C^\top \alpha$, atual)	0,968	$\approx 80\%$ esparsidade real

A V3 perde apenas 0,006 em relação ao kernel completo no BCW, mostrando que a aproximação Nyström com seleção colnorm é *genuinamente* boa quando bem tunada — a esparsidade não custa quase nada de F1.

2.3 Esparsidade reportada

Com a predição V3, a esparsidade do Nyström-SVM é semanticamente consistente com os demais LSSVMs:

- **ADMM/FISTA:** esparsidade = fração de $\alpha_i = 0$.
- **Nyström:** esparsidade = $1 - m/n$, fração de pontos de treino *não* usados como landmark-key.

A razão m/n é tunada pelo Optuna por dataset; a esparsidade resultante varia entre 50% (TWC) e 92% (PID), com média 69% no Tier 1.

3 Experimento Tier 1: Benchmarks Reais

Nove conjuntos de dados foram utilizados (Tabela 2). Os três últimos (TWS, TWM, TWC) são sintéticos bidimensionais incluídos como controle com fronteiras de decisão conhecidas.

Tabela 2: Conjuntos de dados — Tier 1.

ID	Nome	N	Features	Domínio
BCW	Breast Cancer Wisconsin	569	30	Diagnóstico médico
PID	Pima Indians Diabetes	768	8	Diagnóstico médico
HAB	Haberman Survival	306	3	Sobrevivência
VCP	Vehicle Coupon Purchase	1584	7	Marketing
GCR	German Credit Risk	1000	20	Crédito
AUS	Australian Credit	690	14	Crédito
TWS	Two Spirals (sintético)	400	2	Controle
TWM	Two Moons (sintético)	400	2	Controle
TWC	Checkerboard (sintético)	400	2	Controle

3.1 Resultados por Dataset

A Tabela 3 apresenta o F1-macro médio (30 sementes) para *todos* os modelos. Os melhores valores por coluna estão em negrito.

Tabela 3: F1-macro médio (30 sementes). **Negrito:** melhor por coluna. $\circ$ = variante investigada / ponto de investigação; $\star$ = aplicação/combinção proposta.

Modelo	BCW	PID	HAB	VCP	GCR	AUS	TWS	TWM	TWC	Média
<i>Baseline geral tabular</i>										
XGBoost	0,964	0,732	0,580	0,811	0,699	0,867	0,875	0,978	0,476	0,776
<i>Baselines LSSVM</i>										
LSSVM-Std	0,975	0,729	0,590	0,835	0,697	0,862	0,993	1,000	0,900	0,842
LSSVM-FSA	0,967	0,741	0,590	0,820	0,676	0,859	0,990	1,000	0,893	0,837
LSSVM-IP	0,966	0,727	0,571	0,827	0,690	0,857	0,990	1,000	0,888	0,835
LSSVM-PCP	0,923	0,726	0,629	0,789	0,689	0,857	0,989	0,995	0,872	0,830
FISTA-Nesterov	0,902	0,686	0,617	0,782	0,513	0,844	0,990	0,994	0,873	0,800
LSSVM-Prun	0,969	0,639	0,482	0,801	0,437	0,849	0,994	0,996	0,874	0,782
LSSVM-OppM	0,961	0,456	0,468	0,755	0,585	0,823	0,986	0,990	0,899	0,769
<i>Baselines FT-Transformer</i>										
FT-Sparsemax	0,950	0,691	0,596	0,808	0,662	0,855	0,690	1,000	0,710	0,774
SAINT	0,949	0,710	0,535	0,774	0,676	0,859	0,639	0,969	0,588	0,744
FT-Entmax	0,953	0,700	0,538	0,800	0,657	0,860	0,667	0,999	0,504	0,742
FT-Softmax	0,959	0,708	0,541	0,810	0,658	0,854	0,653	1,000	0,478	0,740
FT-TopK	0,950	0,692	0,501	0,808	0,669	0,857	0,640	0,974	0,468	0,729
<i>Paper-base estendido</i>										
LSSVM-ADMM-Nesterov	0,899	0,684	0,616	0,783	0,608	0,842	0,992	0,992	0,866	0,809
<i>Variantes investigadas / propostos</i>										
DualFISTA $\circ$	0,976	0,734	0,589	0,834	0,698	0,862	0,994	1,000	0,891	0,842
Nyström-SVM $\star$	0,970	0,715	0,602	0,820	0,690	0,861	0,992	1,000	0,858	0,834
ADMM-ElasticNet $\circ$	0,899	0,692	0,618	0,787	0,592	0,844	0,990	0,995	0,861	0,809
FT-CUR $\star$ (Nyströmformer)	0,946	0,715	0,523	0,824	0,665	0,851	0,654	0,981	0,564	0,747

3.2 Comparação Geral

A Figura 1 mostra o F1-macro médio ($\pm$ dp) agregado sobre todos os datasets e sementes para cada modelo.




Figura 1: F1-macro médio $\pm$ dp (30 sementes $\times$ 9 datasets). ★ indica modelos propostos; vermelho = DualFISTA, verde = Nyström-SVM, laranja = FT-CUR.

Observações principais:

- **XGBoost** (baseline geral tabular) atinge 0,776 no Tier 1 — abaixo do top 5 dos LSSVMs e abaixo do DualFISTA/Nyström. Vence em AUS (0,867) mas colapsa em TWC (0,476, fronteira xadrez não-linear que favorece kernel RBF). Mostra que para dados tabulares com estrutura geométrica, métodos kernel podem superar gradient boosting.
- **DualFISTA** alcança F1-macro médio de 0,8418 — virtualmente igual ao LSSVM-Std completo (0,8424, diferença 0,0006) com 20,1% de esparsidade. É o único modelo esperso que se aproxima do desempenho do baseline sem esparsidade.
- **Nyström-SVM** (0,834) é o segundo melhor entre os modelos propostos: fica a apenas 0,008 do LSSVM-Std completo, mas com $\approx$ 69% de esparsidade amostral (mais que o triplo do DualFISTA). É o melhor trade-off F1/esparsidade entre os modelos com alta esparsidade.
- O **LSSVM-ADMM** e suas variantes (ElasticNet, FISTA-Nesterov) ficam $\approx$ 3 pp abaixo do LSSVM-Std, com esparsidade entre 27–30%.
- Todos os FT-Transformers baselines (softmax, topk, entmax, sparsemax) ficam abaixo de 0,78, com queda acentuada nos sintéticos TWS e TWC.
- **SAINT** (0,744, atenção inter-instâncias densa) e **FT-CUR** (Nyströmformer, 0,747) atingem F1 essencialmente idêntico — diferença de 0,003. Como o FT-CUR comprime $\approx$ 79% da atenção inter-instâncias e o SAINT é denso, isso valida a aproximação Nyströmformer: **a compressão não custa F1**.

4 Arquitetura dos FT-Transformers e Tipos de Atenção

Esta seção esclarece a distinção entre os dois mecanismos de atenção presentes nos modelos baseados em Transformer avaliados, terminologia necessária para interpretar corretamente as medidas de esparsidade.

4.1 Atenção inter-features (intra-instância)

Os FT-Transformers baselines (softmax, top- k , entmax, sparsemax) implementam **atenção entre features de uma mesma instância**. Dado um batch de n amostras com d features, cada instância $x_i \in \mathbb{R}^d$ é representada como uma sequência de d tokens após embedding. A atenção opera na dimensão dos tokens:

$$A^{(i)} = \text{softmax}\left(\frac{Q^{(i)}(K^{(i)})^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{d \times d},$$

onde $A^{(i)}$ indica quanta atenção a feature j dá à feature k dentro da instância i . As variantes esparsas (sparsemax, top- k) fazem $A^{(i)}$ ter entradas exatamente zero. Esta esparsidade *não* envolve comparação entre amostras distintas — é **intra-instância**.

4.2 Atenção inter-instâncias (entre amostras)

SAINT e **FT-CUR** acrescentam (ou substituem) um mecanismo de atenção entre instâncias distintas. Todas as n amostras do contexto são comparadas entre si:

$$A = f\left(\frac{QK^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{n \times n},$$

onde cada entrada A_{ij} mede a influência da amostra j sobre a amostra i .

SAINT vs. FT-CUR: atenção inter-instâncias densa vs. comprimida

- **SAINT** usa $f = \text{softmax}$ completo: $A \in \mathbb{R}^{n \times n}$ é materializada integralmente. Custo: $O(n^2d)$ por cabeça. Sem zeros exatos $\Rightarrow$ esparsidade de compressão = 0%. Serve como **baseline denso** para a comparação com FT-CUR.
- **FT-CUR (Nyströmformer)** evita materializar A ao todo: seleciona $m \ll n$ landmarks por norma de coluna e computa três produtos menores com softmax separado:

$$C = \text{softmax}\left(\frac{QK_m^\top}{\sqrt{d_h}}\right)[n \times m], \quad R = \text{softmax}\left(\frac{Q_mK^\top}{\sqrt{d_h}}\right)[m \times n], \quad W = \text{softmax}\left(\frac{Q_mK_m^\top}{\sqrt{d_h}}\right)[m \times m]$$

Saída: $\text{out} = C(W^+(RV))$ da direita para a esquerda — custo $O(nmd)$, nunca $O(n^2d)$. Compressão inter-instâncias: $1 - m/n$.

A atenção inter-features (softmax/topk/entmax/sparsemax) e a atenção inter-instâncias (SAINT/FT-CUR) são **ortogonais**: SAINT e FT-CUR incluem ambas (bloco inter-features padrão + bloco inter-instâncias), enquanto os FT-Transformers baselines têm apenas a inter-features.

5 Análise de Esparsidade

Os modelos avaliados produzem três tipos qualitativamente distintos de esparsidade:

- **Esparsidade amostral** (LSSVMs): fração de amostras de treino *não* utilizadas na predição. Para ADMM/FISTA, é a fração de $\alpha_i = 0$; para Nyström-SVM, é $1 - m/n$. Mede compressão do modelo em vetores de suporte.
- **Esparsidade de atenção inter-features**: fração de pesos da atenção *intra-instância* exatamente zero (sparsemax, top- k). Mede seletividade de features, não compressão de amostras.
- **Compressão inter-instâncias** (FT-CUR): fração $1 - m/n$ de amostras não usadas como landmark-key na atenção Nyströmformer. Análogo ao Nyström-SVM, mas na dimensão de atenção em vez da predição kernel.

5.1 Esparsidade amostral — LSSVMs

Tabela 4: Trade-off esparsidade amostral $\times$ desempenho (LSSVMs, Tier 1). Ordenado por F1-macro decrescente.

Modelo	F1-macro	Spar. amostral	Mecanismo
LSSVM-Std	0,8424	0,0%	— (baseline denso)
DualFISTA*	0,8418	20,1%	ℓ_1 dual via FISTA
LSSVM-FSA	0,8373	45,9%	seleção forward
LSSVM-IP	0,8352	57,1%	iterative pruning
Nyström-SVM*	0,8342	69,0%	colnorm landmarks (m/n tunado por dataset)
LSSVM-PCP	0,8300	0,0%	cone projection
LSSVM-ADMM*	0,8089	30,0%	ℓ_1 primal (ADMM-Nesterov)
ADMM-ElasticNet*	0,8086	27,4%	$\ell_1 + \ell_2$ (Elastic Net)
FISTA-Nesterov*	0,8000	27,4%	ℓ_1 primal via FISTA
LSSVM-Prun	0,7825	71,6%	pruning pós-treino
LSSVM-OppM	0,7692	79,3%	opposite maps




Figura 2: Trade-off esparsidade amostral × F1-macro (LSSVMs). ★ = modelos propostos.

Análise:

- **DualFISTA** apresenta o melhor trade-off em baixa esparsidade: 20% com perda de apenas 0,0006 em F1.
- **Nyström-SVM** oferece o melhor trade-off em alta esparsidade: 69% com perda de apenas 0,008 em F1. É o único modelo que combina esparsidade > 50% com F1 dentro de 1% do LSSVM-Std.
- Os métodos ADMM/FISTA (primal) produzem esparsidades entre 27–30% com queda de 3–4 pp. A esparsidade é heterogênea entre datasets.
- Os mais agressivos em esparsidade (LSSVM-Prun, 71%; LSSVM-OppM, 79%) pagam custo de $\approx 6-8$ pp em F1, mostrando que esparsidade alta sem método estruturado (como o Nyström) degrada o desempenho.

5.2 Esparsidade de atenção inter-features — FT-Transformers baselines

Nota: esparsidade inter-features vs. compressão inter-instâncias

Os FT-Transformers baselines (softmax, topk, entmax, sparsemax) têm atenção *intra-instância* — fração de pesos zerados mede seletividade de features. **SAINT** adiciona atenção inter-instâncias com softmax completo ($n \times n$): sem zeros exatos, compressão = 0% (baseline denso). **FT-CUR** substitui o softmax $n \times n$ pelo Nyströmformer (m landmarks, colnorm): nunca materializa $A^{n \times n}$, compressão = $1 - m/n \approx 80\%$.

Tabela 5: Esparsidade de atenção inter-features (baselines FT) e compressão inter-instâncias (SAINT/FT-CUR). Tier 1, média sobre 9 datasets e 30 sementes.

Modelo	F1-macro	Spar. feat.	Compr. inst.	Mecanismo
<i>Atenção inter-features (intra-instância)</i>				
FT-TopK	0,729	76,8%	—	top- k fixo ($k=2$ de $d+1$ tokens)
FT-Sparsemax	0,774	39,1%	—	sparsemax (zeros exatos)
FT-Entmax	0,742	1,4%	—	entmax (poucos zeros exatos)
FT-Softmax	0,740	0,2%	—	softmax (nunca exatamente zero)
<i>Atenção inter-instâncias</i>				
SAINT	0,744	—	0%	softmax $n \times n$ completo (baseline denso)
FT-CUR*	0,747	—	79,3%	Nyströmformer, $m/n \approx 0,20$, $O(nmd)$

Análise:

- **FT-TopK** (76,8%) e **FT-Sparsemax** (39,1%) produzem esparsidade de atenção inter-features genuína, mas ela não se traduz em ganho de F1 — ambos ficam abaixo ou muito próximos do FT-Softmax denso em média.
- **FT-Entmax** (1,4%) produz poucos zeros na prática: apesar de ser conceitualmente esperso, a entmax com $\alpha=1,5$ raramente satura em zero para os datasets avaliados.
- **SAINT** (0,744, denso) e **FT-CUR** (0,747, 79,3% de compressão) atingem F1 essencialmente idêntico — diferença de apenas 0,003. Isso valida empiricamente o Nyströmformer: **comprimir $\approx 80\%$ da atenção inter-instâncias não custa F1**. A aproximação $\tilde{A} = C(W^+R)V$ via softmax separado é fiel à atenção completa $A = \text{softmax}(QK^\top/\sqrt{d})V$ na prática.
- Comparado aos FT-Transformers baselines (sem atenção inter-instâncias), SAINT e FT-CUR ficam ligeiramente acima de FT-Softmax/Entmax/TopK e abaixo do FT-Sparsemax. A atenção inter-instâncias não é, isoladamente, suficiente para superar as variantes esparsas no nível feature.

6 Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)

Motivação: Investigar se os Transformers melhoram com mais dados (são conhecidamente *data-hungry*) e se os modelos baseados em kernel mantêm a vantagem estrutural.

Configuração: Os três sintéticos (TWS, TWM, TWC) foram re-gerados com $N = 2000$. Os hiperparâmetros tuned para Tier 1 ($N = 400$) foram reutilizados.




Figura 3: F1-macro com $N = 400$ (barras translúcidas) vs. $N = 2000$ (sólidas).

Tabela 6: Modelos propostos: F1-macro em $N = 400$ vs. $N = 2000$.

Modelo	Dataset	N=400	N=2000	Δ
DualFISTA	TWS	0,994	0,995	+0,001
	TWM	1,000	0,998	-0,002
	TWC	0,891	0,945	+0,054
LSSVM-ADMM	TWS	0,992	0,995	+0,003
	TWM	0,992	0,998	+0,007
	TWC	0,866	0,938	+0,072
Nyström-SVM	TWS	0,992	0,995	+0,003
	TWM	1,000	0,998	-0,002
	TWC	0,858	0,941	+0,083
FT-CUR (Nyströmformer)	TWS	0,654	0,788	+0,134
	TWM	0,981	0,997	+0,016
	TWC	0,564	0,762	+0,198
SAINT	TWS	0,639	0,787	+0,148
	TWM	0,969	0,995	+0,026
	TWC	0,588	0,802	+0,214
XGBoost	TWS	0,875	0,895	+0,020
	TWM	0,978	0,997	+0,019
	TWC	0,476	0,503	+0,027

Observações:

- **DualFISTA**, **LSSVM-ADMM** e agora **Nyström-SVM** apresentam eficiência amostral elevada: ganhos pequenos com $N = 2000$ (Nyström: +0,083 em TWC; nulo em TWM), pois o kernel RBF já captura bem a geometria com $N = 400$ quando o m/n está tunado.
- **FT-CUR** e **SAINT** são fortemente *data-hungry* (+0,13 a +0,21 em TWS/TWC) — ambos têm a mesma sensibilidade a N , confirmando que o ganho vem do regime de dados, não do mecanismo de compressão.

- **FT-Sparsemax** foi o FT-Transformer mais beneficiado: de 0,710 para 0,955 em TWC, superando os LSSVMs nesse dataset com $N = 2000$.

7 Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)

Motivação: Avaliar a sensibilidade à presença de dimensões irrelevantes, cenário comum em dados tabulares reais.

Configuração: Três features gaussianas de ruído ($\sigma_{\text{ruído}} = 1,0$) foram adicionadas às coordenadas x_1, x_2 originais ($N = 400$). Avaliou-se o cenário com σ **reajustado** (novo tuning para os dados em 5D).




Figura 4: F1-macro: 2D original (translúcido) vs. 5D com σ reajustado (sólido).

Tabela 7: Modelos propostos: F1-macro em 2D vs. 5D reajustado.

Modelo	Dataset	2D	5D reaj.	Δ
DualFISTA	TWS	0,994	0,648	−0,346
	TWM	1,000	0,962	−0,038
	TWC	0,891	0,559	−0,332
LSSVM-ADMM	TWS	0,992	0,632	−0,360
	TWM	0,992	0,920	−0,072
	TWC	0,866	0,549	−0,317
Nyström-SVM	TWS	0,992	0,560	−0,432
	TWM	1,000	0,966	−0,034
	TWC	0,858	0,529	−0,329
FT-CUR (Nyströmformer)	TWS	0,654	0,607	−0,047
	TWM	0,981	0,928	−0,053
	TWC	0,564	0,495	−0,069
SAINT	TWS	0,639	0,595	−0,044
	TWM	0,969	0,930	−0,039
	TWC	0,588	0,490	−0,098
XGBoost	TWS	0,875	0,927	+0,052
	TWM	0,978	0,982	+0,004
	TWC	0,476	0,772	+0,296

Análise mecânica: A adição de 3 features de ruído expande a distância euclidiana quadrática média em $\approx 3\sigma_{\text{ruído}}^2$, colapsando os valores do kernel RBF para próximo de zero e destruindo a estrutura da matriz kernel. O reajuste do σ (valores maiores) recupera parcialmente o sinal, mas não restitui a resolução espacial original em fronteiras de alta frequência.

Padrões observados:

- **DualFISTA**, **LSSVM-ADMM** e **Nyström-SVM** sofrem quedas severas em TWS e TWC (Δ de $-0,33$ a $-0,43$), pelo mesmo motivo estrutural: o kernel RBF não distingue features informativas de ruído. O Nyström, agora com base $> 0,85$ em 2D, tem queda proporcionalmente similar aos outros LSSVMs.
- **FT-CUR** e **SAINT** são notavelmente robustos ($\Delta \approx -0,04$ a $-0,10$): a atenção opera sobre representações aprendidas dos tokens, não sobre distâncias brutas entre amostras. Features irrelevantes têm impacto marginal porque o modelo aprende a ignorá-las. Esta é a vantagem estrutural mais clara dos Transformers tabulares sobre os métodos kernel neste cenário.
- **XGBoost** *melhora* com features extras ($\Delta = +0,05$ a $+0,30$): árvores aproveitam o sinal adicional. Em TWC vai de 0,476 (2D) para 0,772 (5D retunado) — o ganho mais expressivo do estudo. Confirma a complementaridade dos paradigmas: kernel para geometria pura, árvores para feature-rich tabular.

8 Ablação C: Dados Sintéticos Multifeature (MK5)

Motivação: Os datasets sintéticos anteriores (TWS/TWM/TWC) são bidimensionais, favorecendo o kernel RBF. O MK5 usa dados gerados por `make_classification` (scikit-learn) com 5 features verdadeiramente informativas em 3 níveis de dificuldade de separação.

Tabela 8: Ablação C (MK5) — F1-macro médio (30 sementes). MKE = fácil, MKM = médio, MKH = difícil. ★ = proposto. Spar.A = esparsidade amostral; Spar.At = esparsidade de atenção.

Modelo	MKE	MKM	MKH	Média	Spar.A	Spar.At
<i>Baseline geral tabular</i>						
XGBoost	0,978	0,820	0,690	0,829	—	—
<i>Baselines LSSVM</i>						
LSSVM-Std	0,987	0,859	0,729	0,859	0,0%	—
LSSVM-FSA	0,986	0,833	0,696	0,838	45,0%	—
LSSVM-IP	0,989	0,819	0,683	0,830	58,1%	—
LSSVM-PCP	0,973	0,827	0,683	0,828	0,0%	—
LSSVM-ADMM	0,986	0,825	0,685	0,832	9,6%	—
LSSVM-Prun	0,988	0,601	0,622	0,737	75,5%	—
LSSVM-OppM	0,888	0,632	0,523	0,681	78,0%	—
<i>Baselines FT-Transformer</i>						
FT-Softmax	0,976	0,797	0,669	0,814	—	0,2%
FT-Entmax	0,976	0,801	0,657	0,811	—	1,4%
FT-Sparsemax	0,975	0,787	0,652	0,805	—	39,1%
FT-TopK	0,975	0,768	0,644	0,796	—	76,8%
<i>Modelos propostos</i>						
DualFISTA★	0,987	0,858	0,726	0,857	21,4%	—
Nyström-SVM★	0,986	0,839	0,712	0,845	64,3%	—
FT-CUR★ (Nyströmformer)	0,967	0,797	0,664	0,809	—	78,2%
SAINT	0,971	0,782	0,668	0,807	—	0%




Figura 5: Ablação C — MK5: F1-macro por nível de dificuldade.

Destaques:

- **DualFISTA** (0,857) quase empata com o LSSVM-Std (0,859) com 21% de esparsidade — padrão consistente com o Tier 1.
- **Nyström-SVM** (0,845) supera todos os FT-Transformers neste cenário multifeature, com 64% de esparsidade: a aproximação Nyström é eficaz quando há features informativas distribuídas em dimensão maior que 2D.
- **SAINT** (0,807) e **FT-CUR** (0,809) ficam novamente empatados (diferença 0,002), confirmando que a compressão Nyströmformer no FT-CUR não custa F1 também em dados multifeature.

9 Análise das Variantes Investigadas e Modelos Propostos

9.1 Mecanismos de esparsidade

Tabela 9: Caracterização dos mecanismos de esparsidade dos modelos investigados e propostos. LSSVM-ADMM-Nesterov é o paper-base (Marinho et al.); demais são variantes ou aplicações propostas/investigadas.

Modelo	Mecanismo	Esparsidade
LSSVM-ADMM-Nesterov (Marinho et al.)	Otimização ADMM com penalidade ℓ_1 (primal); aceleração de Nesterov.	Emerge da otimização; heterogênea entre datasets. Média: 30%.
ADMM-ElasticNet ^o	Variante do paper-base com penalidade Elastic Net ($\ell_1 + \ell_2$); combinação não localizada em literatura.	Similar ao paper-base, ligeiramente mais homogênea. Média: 27%.
DualFISTA ^o	Formulação dual: $\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \ \alpha\ _1$, otimizado via FISTA. Não localizada na literatura nesta forma exata.	Mais uniforme que ADMM (dual bem condicionado). Média: 20%.
Nyström-SVM [*]	Aproximação Nyström com seleção <i>colnorm</i> (norma de coluna em vez de uniforme/leverage); predição honesta restrita aos m landmarks.	Controlada por m/n tunado por dataset; varia 50–92%. Média: 69%.
FT-CUR (Nyströmformer) [*]	Aplicação de Nyströmformer (Xiong et al. 2021) à atenção inter-instâncias do FT-Transformer com seleção <i>colnorm</i> .	Compressão inter-instâncias: $1 - m/n \approx 80\%$.

9.2 Desempenho consolidado

A Tabela 10 consolida os resultados dos modelos propostos nos quatro experimentos realizados.

Tabela 10: Modelos investigados / propostos e paper-base — F1-macro médio em todos os experimentos. Spar.A = esparsidade amostral (LSSVMs); Spar.At = compressão interinstâncias (FT-CUR/SAINT).

Modelo	Tier 1			Ablação A ($N=2k$)		Ablação B (5D)		MK5
	F1	Spar.A	Spar.At	F1	Δ	F1	Δ	
DualFISTA ^o	0,842	20%	—	0,979	+0,018	0,723	−0,239	0,857
LSSVM-ADMM (paper-base)	0,809	30%	—	0,977	+0,023	0,700	−0,253	0,832
ADMM-ElasticNet ^o	0,809	27%	—	—	—	—	—	—
Nyström-SVM*	0,834	69%	—	0,978	+0,144	0,685	−0,149	0,845
FT-CUR (Nyströmformer)*	0,747	—	79,3%	0,849	+0,102	0,677	−0,070	0,809
SAINT (baseline FT)	0,744	—	0%	0,862	+0,118	0,672	−0,072	0,807

9.3 Síntese comparativa

Tabela 11: Perfis dos modelos investigados e propostos.

Modelo	Ponto forte	Ponto fraco	Característica distintiva
DualFISTA ^o	F1 quase idêntico ao LSSVM-Std; convergência estável	Sensível a features de ruído (kernel RBF); esparsidade moderada (20%)	Formulação dual bem condicionada; melhor trade-off esparsidade/acurácia em baixa esparsidade
ADMM-ElasticNet ^o	Esparsidade mais uniforme que ADMM- ℓ_1 puro	F1 $\approx$ 3 pp abaixo do LSSVM-Std; ganho marginal sobre o paper-base	Variante do paper-base com ElasticNet (combinação não localizada em literatura)
Nyström-SVM*	F1 competitivo (0,834, a 0,008 do LSSVM-Std) com 69% de esparsidade; melhor trade-off em alta esparsidade	Sensível a features de ruído (kernel RBF); m/n ideal varia muito entre datasets (8–50%)	Único modelo com compressão de memória real: $O(nm)$ vs. $O(n^2)$; auditoria matemática confirma honestidade
FT-CUR (Nyströmformer)*	Robusto a features irrelevantes; beneficia-se de mais dados; compressão interinstâncias com Nyströmformer ($O(nmd)$)	Fraco em fronteiras não-lineares complexas (TWS, TWC); transductivo (requer X_{train} na inferência)	Aplicação do Nyströmformer a dados tabulares; comparado ao SAINT, valida empiricamente que 80% de compressão custa $\approx$ 0,003 de F1

10 Sumário e Próximos Passos

Tabela 12: Síntese dos experimentos realizados.

Experimento	Configuração	Runs	Resultado principal
Tier 1	19 modelos, 9 datasets, 30 seeds	5130	DualFISTA 0,842 / Nyström 0,834 / XGBoost 0,776
Ablação A (escala)	19 modelos, 3 sintéticos, $N=2000$, 30s	1710	Nyström +0,14; FT-CUR/SAINT data-hungry
Ablação B (ruído)	19 modelos, 3 sintéticos, +3 feat. ruído, 30s	1710	XGBoost +0,30 em TWC; FT-CUR/SAINT robustos
Ablação C (MK5)	19 modelos, 3 sintéticos, 30 seeds	1710	Nyström 0,845 > XGBoost 0,829 > FT-CUR 0,809
Total		10260	
Tier 2 (pendente)	5 modelos, 3 datasets grandes	—	CREDIT (30k), ADULT (48k), HIGGS50K

Conclusões preliminares:

1. **DualFISTA** é o resultado mais significativo em baixa esparsidade: F1 quase idêntico ao LSSVM-Std completo ($\Delta = 0,0006$) com 20% de esparsidade.
2. **Nyström-SVM** (após auditoria matemática) é o melhor entre os modelos com alta esparsidade: 0,834 no Tier 1 com 69% de esparsidade, a 0,008 do LSSVM-Std. Combina compressão de memória real ($O(nm)$ vs. $O(n^2)$) com F1 competitivo.
3. A **compressão Nyströmformer no FT-CUR é validada pelo SAINT**: os dois modelos atingem F1 idêntico em todos os 4 experimentos ($\Delta \leq 0,013$), mas o FT-CUR opera com 79% de compressão inter-instâncias. Comprimir não custou F1 — a aproximação é fiel.
4. **Robustez a ruído**: FT-CUR e SAINT mantêm desempenho na ablação de features irrelevantes ($\Delta \approx -0,07$); LSSVMs/Nyström/ DualFISTA caem $-0,24$ a $-0,43$. A atenção é estruturalmente mais robusta que o kernel RBF a features ruidosas.
5. **XGBoost como referência externa**: o baseline geral tabular fica em 0,776 no Tier 1, abaixo do top 5 dos LSSVMs e do DualFISTA/Nyström. Em ablações com features extras (5D retunado: 0,894), XGBoost se beneficia mais que kernel/atenção. Resultado coerente com a literatura de *tabular learning*: kernel domina em geometria pura; gradient boosting em datasets feature-rich; atenção é robusta a ruído.

Próximas etapas:

1. **Tier 2** (em andamento): benchmarks CREDIT (30k), ADULT (48k) e HIGGS50K com os modelos escaláveis (Nyström-SVM, FT-CUR, variantes FT-Transformer), executados no Google Colab (GPU T4).
2. **Análise estatística formal**: teste de Friedman + Nemenyi / diagrama de diferença crítica sobre todos os datasets consolidados.
3. **Análise de complexidade temporal**: medição do speedup do Nyström-SVM vs. LSSVM-Std em função de n (Tier 2 fornece dados reais para essa curva).

A Infraestrutura e Reprodutibilidade

- **Código:** repositório `sparse-lssvm-transformers-study/`
- **Ambiente:** Python 3.12, PyTorch, scikit-learn, Optuna; virtualenv em `.venv/`
- **Resultados:** arquivos JSON em `results/`: `tier1_results.json` (baselines), `tier1_custom_models.json` (propostos), `synthetic_scaling_n2000.json`, `synthetic_5features_tuned.json`, `synthetic_mk5.json`
- **Tuning:** `results/tuning/best_params*.json`
- **Scripts:** `scripts/run_*.py` são resumíveis (checkpoint por chave modelo/dataset/seed)
- **Figuras:** geradas por `scripts/generate_report_figs.py`