

# Relatório de Experimentos

Estudo Comparativo: LSSVM Esperso vs. Transformers Tabulares  
Dissertação de Mestrado — Experimentos (atualizado em maio de 2026)

Paulo Bernardo

Maio de 2026

## Sumário

|           |                                                                                             |           |
|-----------|---------------------------------------------------------------------------------------------|-----------|
| <b>1</b>  | <b>Introdução</b>                                                                           | <b>3</b>  |
| <b>2</b>  | <b>Auditoria da Implementação do Nyström-SVM</b>                                            | <b>4</b>  |
| 2.1       | As três versões . . . . .                                                                   | 4         |
| 2.2       | Verificação experimental . . . . .                                                          | 5         |
| 2.3       | Esparsidade reportada . . . . .                                                             | 5         |
| <b>3</b>  | <b>Experimento Tier 1: Benchmarks Reais</b>                                                 | <b>6</b>  |
| 3.1       | Resultados por Dataset . . . . .                                                            | 6         |
| 3.2       | Comparação Geral . . . . .                                                                  | 7         |
| <b>4</b>  | <b>Arquitetura dos FT-Transformers e Tipos de Atenção</b>                                   | <b>8</b>  |
| 4.1       | Atenção inter-features (intra-instância) . . . . .                                          | 8         |
| 4.2       | Atenção inter-instâncias (entre amostras) . . . . .                                         | 8         |
| <b>5</b>  | <b>Análise de Esparsidade</b>                                                               | <b>9</b>  |
| 5.1       | Esparsidade amostral — LSSVMs . . . . .                                                     | 9         |
| 5.2       | Esparsidade de atenção inter-features — FT-Transformers baselines . . . . .                 | 10        |
| <b>6</b>  | <b>Ablação A: Escalabilidade Amostral (<math>N = 400 \rightarrow 2000</math>)</b>           | <b>11</b> |
| <b>7</b>  | <b>Ablação B: Robustez a Features de Ruído (<math>2D \rightarrow 5D</math>)</b>             | <b>13</b> |
| <b>8</b>  | <b>Ablação C: Dados Sintéticos Multifeature (MK5)</b>                                       | <b>15</b> |
| <b>9</b>  | <b>Análise das Variantes Investigadas e Modelos Propostos</b>                               | <b>17</b> |
| 9.1       | Mecanismos de esparsidade . . . . .                                                         | 17        |
| 9.2       | Desempenho consolidado . . . . .                                                            | 17        |
| 9.3       | Síntese comparativa . . . . .                                                               | 18        |
| <b>10</b> | <b>Tier 2: Datasets Reais (<math>N_{\text{treino}} = 5000</math>) — Resultados Parciais</b> | <b>19</b> |
| 10.1      | Protocolo . . . . .                                                                         | 19        |
| 10.2      | Resultados parciais (6 de 18 modelos completos) . . . . .                                   | 19        |
| 10.3      | Limitação estrutural do FT-CUR em dados imbalanceados . . . . .                             | 20        |

|                                                                                                                       |           |
|-----------------------------------------------------------------------------------------------------------------------|-----------|
| 10.4 Comparação Tier 1 vs. Tier 2: deslocamento do trade-off ( <i>rascunho —<br/>pendente confirmação</i> ) . . . . . | 23        |
| 10.5 XGBoost vs. FT-Transformers em datasets reais . . . . .                                                          | 24        |
| <b>11 Sumário e Próximos Passos</b>                                                                                   | <b>25</b> |
| <b>A Infraestrutura e Reprodutibilidade</b>                                                                           | <b>26</b> |

# 1 Introdução

Este relatório consolida os resultados dos experimentos conduzidos na dissertação, que compara métodos de *Least-Squares Support Vector Machine* (LSSVM) com ênfase em esparsidade contra variantes de *FT-Transformer* com atenção esparsa em tarefas de classificação binária tabular.

O trabalho estende o algoritmo LSSVM-ADMM-Nesterov proposto por Marinho et al. com dois novos mecanismos de esparsidade: (i) **DualFISTA**, formulação dual do LSSVM como LASSO com otimização via ISTA acelerado; e (ii) **Nyström-SVM**, aproximação da matriz kernel por seleção de landmarks via norma de coluna. Como comparativo do lado dos Transformers, avalia-se o **FT-CUR**, que aplica decomposição CUR com colnorm à matriz de atenção.

## Auditoria do Nyström-SVM — três versões

A implementação do Nyström-SVM passou por três versões. A versão final, auditada matematicamente (Seção 2), é a apresentada neste relatório.

| Versão         | Predição                                                               | F1 Tier 1          |
|----------------|------------------------------------------------------------------------|--------------------|
| Bug original   | $f(x)=K(x, X_{\text{treino}})\alpha + b$ (kernel completo)             | 0,8427 (inflado)   |
| “Fix” errado   | $f(x)=K(x, Z)\alpha[\text{lm\_idx}] + b$ (subset ingênuo de $\alpha$ ) | 0,6678 (colapsado) |
| <b>Correta</b> | $f(x)=K(x, Z)(W^{-1}C^T\alpha) + b$ (Nyström)                          | <b>0,8342</b>      |

A versão correta usa a fórmula matemática da aproximação Nyström ( $\tilde{K} = CW^{-1}C^T$ ), com custo  $O(n_{\text{test}} \cdot m)$  e **sem dependência de  $X_{\text{treino}}$  na predição** (verificado experimentalmente). A perda de F1 em relação ao bug original é de apenas 0,0085, mas agora com  $\approx 69\%$  de esparsidade amostral genuína.

## Modelos avaliados

Ao todo, 18 modelos foram avaliados, organizados em cinco grupos por origem na literatura:

- **Baseline geral tabular (1): XGBoost** (Chen & Guestrin, 2016) — padrão-ouro para dados tabulares, serve como referência externa às famílias LSSVM e Transformer.
- **LSSVMs baselines (7):** LSSVM-Std (sem esparsidade), LSSVM-PCP, LSSVM-FSA, LSSVM-IP, LSSVM-Pruning, LSSVM-OppMaps, e **FISTA-Nesterov** (LSSVM primal com FISTA — método clássico de Beck & Teboulle, 2009, amplamente documentado).
- **FT-Transformers baselines (5):** variantes com atenção softmax, top- $k$ , entmax e sparsemax — mais **SAINT** (Somepalli et al., 2021; atenção inter-instâncias densa).
- **Paper-base estendido: LSSVM-ADMM-Nesterov** de Marinho et al. — método sobre o qual esta dissertação constrói.
- **Variantes investigadas e modelos propostos (4):**
  - **ADMM-ElasticNet<sup>o</sup>**: variante do paper-base com penalidade Elastic Net (combinação ADMM-Nesterov + Elastic Net + LSSVM não localizada explicitamente na literatura como método publicado).

- **DualFISTA<sup>°</sup>**: formulação dual do LSSVM como LASSO ( $\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \|\alpha\|_1$ ), otimizada via FISTA. Ponto de investigação — não localizada na literatura nesta forma exata; pode ser uma reformulação convergente com métodos análogos em SVM ou regressão Lasso.
- **Nyström-SVM (colnorm)\***: aproxima  $K \in \mathbb{R}^{n \times n}$  via  $m \ll n$  landmarks selecionados por norma de coluna (em vez de amostragem uniforme/leverage tradicional); predição restrita aos landmarks ( $O(n_{\text{test}} \cdot m)$ , auditada).
- **FT-CUR (Nyströmformer)\***: aplicação de Nyströmformer (Xiong et al., 2021) à atenção inter-instâncias do FT-Transformer em dados tabulares; seleção de landmarks via colnorm (combinação não localizada como método publicado).

<sup>°</sup> = variante/ponto de investigação; \* = aplicação/combinação proposta.

## Protocolo experimental

- 30 sementes aleatórias, partição estratificada 70/30.
- Métrica principal: F1-macro (média aritmética do F1 por classe).
- Hiperparâmetros otimizados via Optuna TPE com validação cruzada estratificada de 5 folds.
- Normalização por StandardScaler ajustado apenas no treino.

## 2 Auditoria da Implementação do Nyström-SVM

### 2.1 As três versões

O Nyström-SVM aproxima a matriz kernel completa  $K \in \mathbb{R}^{n \times n}$  a partir de  $m$  landmarks  $\{z_1, \dots, z_m\}$  selecionados antes do treino:

$$K \approx CW^{-1}C^{\top}, \quad C = K(X, Z) \in \mathbb{R}^{n \times m}, \quad W = K(Z, Z) \in \mathbb{R}^{m \times m}.$$

O treinamento, via identidade de Woodbury, é correto em todas as versões. A diferença está apenas na predição:

**V1 — Bug original.** Predizia com o kernel completo:

$$f(x) = K(x, X_{\text{treino}}) \alpha + b.$$

Não tinha esparsidade real (todo  $X_{\text{treino}}$  era usado em inferência) e produzia  $F_1 = 0,8427$  no Tier 1.

**V2 — “Fix” ingênuo.** Tentativa de restringir aos landmarks pegando apenas o subset de  $\alpha$  nos índices dos landmarks:

$$f(x) = K(x, Z) \alpha[\text{lm\_idx}] + b.$$

Está **matematicamente errado**: os pesos  $\alpha \in \mathbb{R}^n$  foram ajustados para o sistema KKT completo  $n$ -dimensional, e simplesmente subseqüenciá-los nos índices dos landmarks não recupera a aproximação Nyström. F1 colapsou para 0,6678.

**V3 — Correta (atual).** A aproximação Nyström verdadeira é  $\tilde{K}(x, X) = K(x, Z) W^{-1} C^\top$ . Substituindo em  $f(x) = \tilde{K}(x, X) \alpha + b$ :

$$f(x) = K(x, Z) (W^{-1} C^\top \alpha) + b = K(x, Z) w_\alpha + b, \quad w_\alpha = W^{-1} C^\top \alpha \in \mathbb{R}^m.$$

O vetor  $w_\alpha$  é calculado uma vez ao final do fit e cacheado. Em inferência, só  $K(x, Z) \in \mathbb{R}^{n_{\text{test}} \times m}$  é computado — não há mais nenhuma dependência de  $X_{\text{treino}}$ . F1 = 0,8342.

## 2.2 Verificação experimental

A implementação V3 foi auditada matematicamente (`scripts/audit_nystrom_lssvm.py`) confirmando três propriedades:

1. **Equivalência matemática.**  $\|f_{\text{cache}}(x) - f_{\text{Nyström}}(x)\|_2 = 0$  exatamente, onde  $f_{\text{Nyström}}$  usa a fórmula expandida  $K(x, Z) W^{-1} C^\top \alpha + b$ .
2. **Sem dependência de  $X_{\text{treino}}$ .** Após o fit, ao apagar  $X_{\text{treino}}$  do modelo, as predições continuam idênticas ( $\|\Delta f\|_2 = 0$ ). Confirma que apenas  $Z$  é usado na inferência.
3. **Custo  $O(n_{\text{test}} \cdot m)$ .** Mantendo  $m$  fixo e variando  $n_{\text{treino}}$  de 1000 a 6000, o tempo de predição permanece em  $\approx 5$  ms (não escala com  $n$ ).

Tabela 1: Comparação direta no BCW (10 sementes, mesmos hiperparâmetros).

| Versão                               | F1 BCW | Diagnóstico                     |
|--------------------------------------|--------|---------------------------------|
| V1 (kernel completo)                 | 0,974  | 0% de esparsidade real          |
| V2 ( $\alpha$ subsetado)             | 0,360  | matematicamente inválida        |
| V3 ( $W^{-1} C^\top \alpha$ , atual) | 0,968  | $\approx 80\%$ esparsidade real |

A V3 perde apenas 0,006 em relação ao kernel completo no BCW, mostrando que a aproximação Nyström com seleção colnorm é *genuinamente* boa quando bem tunada — a esparsidade não custa quase nada de F1.

## 2.3 Esparsidade reportada

Com a predição V3, a esparsidade do Nyström-SVM é semanticamente consistente com os demais LSSVMs:

- **ADMM/FISTA:** esparsidade = fração de  $\alpha_i = 0$ .
- **Nyström:** esparsidade =  $1 - m/n$ , fração de pontos de treino *não* usados como landmark-key.

A razão  $m/n$  é tunada pelo Optuna por dataset; a esparsidade resultante varia entre 50% (TWC) e 92% (PID), com média 69% no Tier 1.

### 3 Experimento Tier 1: Benchmarks Reais

Nove conjuntos de dados foram utilizados (Tabela 2). Os três últimos (TWS, TWM, TWC) são sintéticos bidimensionais incluídos como controle com fronteiras de decisão conhecidas.

Tabela 2: Conjuntos de dados — Tier 1.

| ID  | Nome                     | N    | Features | Domínio            |
|-----|--------------------------|------|----------|--------------------|
| BCW | Breast Cancer Wisconsin  | 569  | 30       | Diagnóstico médico |
| PID | Pima Indians Diabetes    | 768  | 8        | Diagnóstico médico |
| HAB | Haberman Survival        | 306  | 3        | Sobrevivência      |
| VCP | Vehicle Coupon Purchase  | 1584 | 7        | Marketing          |
| GCR | German Credit Risk       | 1000 | 20       | Crédito            |
| AUS | Australian Credit        | 690  | 14       | Crédito            |
| TWS | Two Spirals (sintético)  | 400  | 2        | Controle           |
| TWM | Two Moons (sintético)    | 400  | 2        | Controle           |
| TWC | Checkerboard (sintético) | 400  | 2        | Controle           |

#### 3.1 Resultados por Dataset

A Tabela 3 apresenta o F1-macro médio (30 sementes) para *todos* os modelos. Os melhores valores por coluna estão em negrito.

Tabela 3: F1-macro médio (30 sementes). **Negrito**: melhor por coluna.  $\circ$  = variante investigada / ponto de investigação;  $\star$  = aplicação/combinção proposta.

| Modelo                                    | BCW          | PID          | HAB          | VCP          | GCR          | AUS          | TWS          | TWM          | TWC          | Média        |
|-------------------------------------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
| <i>Baseline geral tabular</i>             |              |              |              |              |              |              |              |              |              |              |
| XGBoost                                   | 0,964        | 0,732        | 0,580        | 0,811        | 0,699        | <b>0,867</b> | 0,875        | 0,978        | 0,476        | 0,776        |
| <i>Baselines LSSVM</i>                    |              |              |              |              |              |              |              |              |              |              |
| LSSVM-Std                                 | <b>0,975</b> | 0,729        | 0,590        | <b>0,835</b> | <b>0,697</b> | 0,862        | <b>0,993</b> | <b>1,000</b> | 0,900        | 0,842        |
| LSSVM-FSA                                 | 0,967        | <b>0,741</b> | 0,590        | 0,820        | 0,676        | 0,859        | 0,990        | <b>1,000</b> | 0,893        | 0,837        |
| LSSVM-IP                                  | 0,966        | 0,727        | 0,571        | 0,827        | 0,690        | 0,857        | 0,990        | <b>1,000</b> | 0,888        | 0,835        |
| LSSVM-PCP                                 | 0,923        | 0,726        | <b>0,629</b> | 0,789        | 0,689        | 0,857        | 0,989        | 0,995        | 0,872        | 0,830        |
| FISTA-Nesterov                            | 0,902        | 0,686        | 0,617        | 0,782        | 0,513        | 0,844        | 0,990        | 0,994        | 0,873        | 0,800        |
| LSSVM-Prun                                | 0,969        | 0,639        | 0,482        | 0,801        | 0,437        | 0,849        | 0,994        | 0,996        | 0,874        | 0,782        |
| LSSVM-OppM                                | 0,961        | 0,456        | 0,468        | 0,755        | 0,585        | 0,823        | 0,986        | 0,990        | 0,899        | 0,769        |
| <i>Baselines FT-Transformer</i>           |              |              |              |              |              |              |              |              |              |              |
| FT-Sparsemax                              | 0,950        | 0,691        | 0,596        | 0,808        | 0,662        | 0,855        | 0,690        | <b>1,000</b> | 0,710        | 0,774        |
| SAINT                                     | 0,949        | 0,710        | 0,535        | 0,774        | 0,676        | 0,859        | 0,639        | 0,969        | 0,588        | 0,744        |
| FT-Entmax                                 | 0,953        | 0,700        | 0,538        | 0,800        | 0,657        | <b>0,860</b> | 0,667        | 0,999        | 0,504        | 0,742        |
| FT-Softmax                                | 0,959        | 0,708        | 0,541        | 0,810        | 0,658        | 0,854        | 0,653        | <b>1,000</b> | 0,478        | 0,740        |
| FT-TopK                                   | 0,950        | 0,692        | 0,501        | 0,808        | 0,669        | 0,857        | 0,640        | 0,974        | 0,468        | 0,729        |
| <i>Paper-base estendido</i>               |              |              |              |              |              |              |              |              |              |              |
| LSSVM-ADMM-Nesterov                       | 0,899        | 0,684        | 0,616        | 0,783        | 0,608        | 0,842        | 0,992        | 0,992        | 0,866        | 0,809        |
| <i>Variantes investigadas / propostos</i> |              |              |              |              |              |              |              |              |              |              |
| DualFISTA $\circ$                         | 0,976        | 0,734        | 0,589        | 0,834        | 0,698        | 0,862        | 0,994        | <b>1,000</b> | <b>0,891</b> | <b>0,842</b> |
| Nyström-SVM $\star$                       | 0,970        | 0,715        | 0,602        | 0,820        | 0,690        | 0,861        | 0,992        | <b>1,000</b> | 0,858        | 0,834        |
| ADMM-ElasticNet $\circ$                   | 0,899        | 0,692        | 0,618        | 0,787        | 0,592        | 0,844        | 0,990        | 0,995        | 0,861        | 0,809        |
| FT-CUR $\star$ (Nyströmformer)            | 0,946        | 0,715        | 0,523        | 0,824        | 0,665        | 0,851        | 0,654        | 0,981        | 0,564        | 0,747        |

### 3.2 Comparação Geral

A Figura 1 mostra o F1-macro médio ( $\pm$  dp) agregado sobre todos os datasets e sementes para cada modelo.




Figura 1: F1-macro médio  $\pm$  dp (30 sementes  $\times$  9 datasets). ★ indica modelos propostos; vermelho = DualFISTA, verde = Nyström-SVM, laranja = FT-CUR.

#### Observações principais:

- **XGBoost** (baseline geral tabular) atinge 0,776 no Tier 1 — abaixo do top 5 dos LSSVMs e abaixo do DualFISTA/Nyström. Vence em AUS (0,867) mas colapsa em TWC (0,476, fronteira xadrez não-linear que favorece kernel RBF). Mostra que para dados tabulares com estrutura geométrica, métodos kernel podem superar gradient boosting.
- **DualFISTA** alcança F1-macro médio de 0,8418 — virtualmente igual ao LSSVM-Std completo (0,8424, diferença 0,0006) com 20,1% de esparsidade. É o único modelo esperso que se aproxima do desempenho do baseline sem esparsidade.
- **Nyström-SVM** (0,834) é o segundo melhor entre os modelos propostos: fica a apenas 0,008 do LSSVM-Std completo, mas com  $\approx$  69% de esparsidade amostral (mais que o triplo do DualFISTA). É o melhor trade-off F1/esparsidade entre os modelos com alta esparsidade.
- O **LSSVM-ADMM** e suas variantes (ElasticNet, FISTA-Nesterov) ficam  $\approx$  3 pp abaixo do LSSVM-Std, com esparsidade entre 27–30%.
- Todos os FT-Transformers baselines (softmax, topk, entmax, sparsemax) ficam abaixo de 0,78, com queda acentuada nos sintéticos TWS e TWC.
- **SAINT** (0,744, atenção inter-instâncias densa) e **FT-CUR** (Nyströmformer, 0,747) atingem F1 essencialmente idêntico — diferença de 0,003. Como o FT-CUR comprime  $\approx$  79% da atenção inter-instâncias e o SAINT é denso, isso valida a aproximação Nyströmformer: **a compressão não custa F1**.

## 4 Arquitetura dos FT-Transformers e Tipos de Atenção

Esta seção esclarece a distinção entre os dois mecanismos de atenção presentes nos modelos baseados em Transformer avaliados, terminologia necessária para interpretar corretamente as medidas de esparsidade.

### 4.1 Atenção inter-features (intra-instância)

Os FT-Transformers baselines (softmax, top- $k$ , entmax, sparsemax) implementam **atenção entre features de uma mesma instância**. Dado um batch de  $n$  amostras com  $d$  features, cada instância  $x_i \in \mathbb{R}^d$  é representada como uma sequência de  $d$  tokens após embedding. A atenção opera na dimensão dos tokens:

$$A^{(i)} = \text{softmax}\left(\frac{Q^{(i)}(K^{(i)})^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{d \times d},$$

onde  $A^{(i)}$  indica quanta atenção a feature  $j$  dá à feature  $k$  dentro da instância  $i$ . As variantes esparsas (sparsemax, top- $k$ ) fazem  $A^{(i)}$  ter entradas exatamente zero. Esta esparsidade *não* envolve comparação entre amostras distintas — é **intra-instância**.

### 4.2 Atenção inter-instâncias (entre amostras)

**SAINT** e **FT-CUR** acrescentam (ou substituem) um mecanismo de atenção entre instâncias distintas. Todas as  $n$  amostras do contexto são comparadas entre si:

$$A = f\left(\frac{QK^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{n \times n},$$

onde cada entrada  $A_{ij}$  mede a influência da amostra  $j$  sobre a amostra  $i$ .

#### SAINT vs. FT-CUR: atenção inter-instâncias densa vs. comprimida

- **SAINT** usa  $f = \text{softmax}$  completo:  $A \in \mathbb{R}^{n \times n}$  é materializada integralmente. Custo:  $O(n^2d)$  por cabeça. Sem zeros exatos  $\Rightarrow$  esparsidade de compressão = 0%. Serve como **baseline denso** para a comparação com FT-CUR.
- **FT-CUR (Nyströmformer)** evita materializar  $A$  ao todo: seleciona  $m \ll n$  landmarks por norma de coluna e computa três produtos menores com softmax separado:

$$C = \text{softmax}\left(\frac{QK_m^\top}{\sqrt{d_h}}\right)[n \times m], \quad R = \text{softmax}\left(\frac{Q_mK^\top}{\sqrt{d_h}}\right)[m \times n], \quad W = \text{softmax}\left(\frac{Q_mK_m^\top}{\sqrt{d_h}}\right)[m \times m]$$

Saída:  $\text{out} = C(W^+(RV))$  da direita para a esquerda — custo  $O(nmd)$ , nunca  $O(n^2d)$ . Compressão inter-instâncias:  $1 - m/n$ .

A atenção inter-features (softmax/topk/entmax/sparsemax) e a atenção inter-instâncias (SAINT/FT-CUR) são **ortogonais**: SAINT e FT-CUR incluem ambas (bloco inter-features padrão + bloco inter-instâncias), enquanto os FT-Transformers baselines têm apenas a inter-features.



## 5 Análise de Esparsidade

Os modelos avaliados produzem três tipos qualitativamente distintos de esparsidade:

- **Esparsidade amostral** (LSSVMs): fração de amostras de treino *não* utilizadas na predição. Para ADMM/FISTA, é a fração de  $\alpha_i = 0$ ; para Nyström-SVM, é  $1 - m/n$ . Mede compressão do modelo em vetores de suporte.
- **Esparsidade de atenção inter-features**: fração de pesos da atenção *intra-instância* exatamente zero (sparsemax, top- $k$ ). Mede seletividade de features, não compressão de amostras.
- **Compressão inter-instâncias** (FT-CUR): fração  $1 - m/n$  de amostras não usadas como landmark-key na atenção Nyströmformer. Análogo ao Nyström-SVM, mas na dimensão de atenção em vez da predição kernel.

### 5.1 Esparsidade amostral — LSSVMs

Tabela 4: Trade-off esparsidade amostral  $\times$  desempenho (LSSVMs, Tier 1). Ordenado por F1-macro decrescente.

| Modelo              | F1-macro      | Spar. amostral | Mecanismo                                     |
|---------------------|---------------|----------------|-----------------------------------------------|
| LSSVM-Std           | 0,8424        | 0,0%           | — (baseline denso)                            |
| DualFISTA*          | 0,8418        | 20,1%          | $\ell_1$ dual via FISTA                       |
| LSSVM-FSA           | 0,8373        | 45,9%          | seleção forward                               |
| LSSVM-IP            | 0,8352        | 57,1%          | iterative pruning                             |
| <b>Nyström-SVM*</b> | <b>0,8342</b> | <b>69,0%</b>   | colnorm landmarks ( $m/n$ tunado por dataset) |
| LSSVM-PCP           | 0,8300        | 0,0%           | cone projection                               |
| LSSVM-ADMM*         | 0,8089        | 30,0%          | $\ell_1$ primal (ADMM-Nesterov)               |
| ADMM-ElasticNet*    | 0,8086        | 27,4%          | $\ell_1 + \ell_2$ (Elastic Net)               |
| FISTA-Nesterov*     | 0,8000        | 27,4%          | $\ell_1$ primal via FISTA                     |
| LSSVM-Prun          | 0,7825        | 71,6%          | pruning pós-treino                            |
| LSSVM-OppM          | 0,7692        | 79,3%          | opposite maps                                 |




Figura 2: Trade-off esparsidade amostral × F1-macro (LSSVMs). ★ = modelos propostos.

### Análise:

- **DualFISTA** apresenta o melhor trade-off em baixa esparsidade: 20% com perda de apenas 0,0006 em F1.
- **Nyström-SVM** oferece o melhor trade-off em alta esparsidade: 69% com perda de apenas 0,008 em F1. É o único modelo que combina esparsidade > 50% com F1 dentro de 1% do LSSVM-Std.
- Os métodos ADMM/FISTA (primal) produzem esparsidades entre 27–30% com queda de 3–4 pp. A esparsidade é heterogênea entre datasets.
- Os mais agressivos em esparsidade (LSSVM-Prun, 71%; LSSVM-OppM, 79%) pagam custo de  $\approx 6-8$  pp em F1, mostrando que esparsidade alta sem método estruturado (como o Nyström) degrada o desempenho.

## 5.2 Esparsidade de atenção inter-features — FT-Transformers baselines

### Nota: esparsidade inter-features vs. compressão inter-instâncias

Os FT-Transformers baselines (softmax, topk, entmax, sparsemax) têm atenção *intra-instância* — fração de pesos zerados mede seletividade de features. **SAINT** adiciona atenção inter-instâncias com softmax completo ( $n \times n$ ): sem zeros exatos, compressão = 0% (baseline denso). **FT-CUR** substitui o softmax  $n \times n$  pelo Nyströmformer ( $m$  landmarks, colnorm): nunca materializa  $A^{n \times n}$ , compressão =  $1 - m/n \approx 80\%$ .

Tabela 5: Esparsidade de atenção inter-features (baselines FT) e compressão inter-instâncias (SAINT/FT-CUR). Tier 1, média sobre 9 datasets e 30 sementes.

| Modelo                                          | F1-macro | Spar. feat. | Compr. inst. | Mecanismo                                      |
|-------------------------------------------------|----------|-------------|--------------|------------------------------------------------|
| <i>Atenção inter-features (intra-instância)</i> |          |             |              |                                                |
| FT-TopK                                         | 0,729    | 76,8%       | —            | top- $k$ fixo ( $k=2$ de $d+1$ tokens)         |
| FT-Sparsemax                                    | 0,774    | 39,1%       | —            | sparsemax (zeros exatos)                       |
| FT-Entmax                                       | 0,742    | 1,4%        | —            | entmax (poucos zeros exatos)                   |
| FT-Softmax                                      | 0,740    | 0,2%        | —            | softmax (nunca exatamente zero)                |
| <i>Atenção inter-instâncias</i>                 |          |             |              |                                                |
| SAINT                                           | 0,744    | —           | 0%           | softmax $n \times n$ completo (baseline denso) |
| FT-CUR*                                         | 0,747    | —           | 79,3%        | Nyströmformer, $m/n \approx 0,20$ , $O(nmd)$   |

#### Análise:

- **FT-TopK** (76,8%) e **FT-Sparsemax** (39,1%) produzem esparsidade de atenção inter-features genuína, mas ela não se traduz em ganho de F1 — ambos ficam abaixo ou muito próximos do FT-Softmax denso em média.
- **FT-Entmax** (1,4%) produz poucos zeros na prática: apesar de ser conceitualmente esperso, a entmax com  $\alpha=1,5$  raramente satura em zero para os datasets avaliados.
- **SAINT** (0,744, denso) e **FT-CUR** (0,747, 79,3% de compressão) atingem F1 essencialmente idêntico — diferença de apenas 0,003. Isso valida empiricamente o Nyströmformer: **comprimir  $\approx 80\%$  da atenção inter-instâncias não custa F1**. A aproximação  $\tilde{A} = C(W^+R)V$  via softmax separado é fiel à atenção completa  $A = \text{softmax}(QK^\top/\sqrt{d})V$  na prática.
- Comparado aos FT-Transformers baselines (sem atenção inter-instâncias), SAINT e FT-CUR ficam ligeiramente acima de FT-Softmax/Entmax/TopK e abaixo do FT-Sparsemax. A atenção inter-instâncias não é, isoladamente, suficiente para superar as variantes esparsas no nível feature.

## 6 Ablação A: Escalabilidade Amostral ( $N = 400 \rightarrow 2000$ )

**Motivação:** Investigar se os Transformers melhoram com mais dados (são conhecidamente *data-hungry*) e se os modelos baseados em kernel mantêm a vantagem estrutural.

**Configuração:** Os três sintéticos (TWS, TWM, TWC) foram re-gerados com  $N = 2000$ . Os hiperparâmetros tuned para Tier 1 ( $N = 400$ ) foram reutilizados.




Figura 3: F1-macro com  $N = 400$  (barras translúcidas) vs.  $N = 2000$  (sólidas).

Tabela 6: Modelos propostos: F1-macro em  $N = 400$  vs.  $N = 2000$ .

| Modelo                 | Dataset | N=400 | N=2000 | $\Delta$ |
|------------------------|---------|-------|--------|----------|
| DualFISTA              | TWS     | 0,994 | 0,995  | +0,001   |
|                        | TWM     | 1,000 | 0,998  | -0,002   |
|                        | TWC     | 0,891 | 0,945  | +0,054   |
| LSSVM-ADMM             | TWS     | 0,992 | 0,995  | +0,003   |
|                        | TWM     | 0,992 | 0,998  | +0,007   |
|                        | TWC     | 0,866 | 0,938  | +0,072   |
| Nyström-SVM            | TWS     | 0,992 | 0,995  | +0,003   |
|                        | TWM     | 1,000 | 0,998  | -0,002   |
|                        | TWC     | 0,858 | 0,941  | +0,083   |
| FT-CUR (Nyströmformer) | TWS     | 0,654 | 0,788  | +0,134   |
|                        | TWM     | 0,981 | 0,997  | +0,016   |
|                        | TWC     | 0,564 | 0,762  | +0,198   |
| SAINT                  | TWS     | 0,639 | 0,787  | +0,148   |
|                        | TWM     | 0,969 | 0,995  | +0,026   |
|                        | TWC     | 0,588 | 0,802  | +0,214   |
| XGBoost                | TWS     | 0,875 | 0,895  | +0,020   |
|                        | TWM     | 0,978 | 0,997  | +0,019   |
|                        | TWC     | 0,476 | 0,503  | +0,027   |

#### Observações:

- **DualFISTA**, **LSSVM-ADMM** e agora **Nyström-SVM** apresentam eficiência amostral elevada: ganhos pequenos com  $N = 2000$  (Nyström: +0,083 em TWC; nulo em TWM), pois o kernel RBF já captura bem a geometria com  $N = 400$  quando o  $m/n$  está tunado.
- **FT-CUR** e **SAINT** são fortemente *data-hungry* (+0,13 a +0,21 em TWS/TWC) — ambos têm a mesma sensibilidade a  $N$ , confirmando que o ganho vem do regime de dados, não do mecanismo de compressão.

- **FT-Sparsemax** foi o FT-Transformer mais beneficiado: de 0,710 para 0,955 em TWC, superando os LSSVMs nesse dataset com  $N = 2000$ .

## 7 Ablação B: Robustez a Features de Ruído ( $2D \rightarrow 5D$ )

**Motivação:** Avaliar a sensibilidade à presença de dimensões irrelevantes, cenário comum em dados tabulares reais.

**Configuração:** Três features gaussianas de ruído ( $\sigma_{\text{ruído}} = 1,0$ ) foram adicionadas às coordenadas  $x_1, x_2$  originais ( $N = 400$ ). Avaliou-se o cenário com  $\sigma$  **reajustado** (novo tuning para os dados em 5D).




Figura 4: F1-macro: 2D original (translúcido) vs. 5D com  $\sigma$  reajustado (sólido).

Tabela 7: Modelos propostos: F1-macro em 2D vs. 5D reajustado.

| Modelo                 | Dataset | 2D    | 5D reaj. | $\Delta$ |
|------------------------|---------|-------|----------|----------|
| DualFISTA              | TWS     | 0,994 | 0,648    | −0,346   |
|                        | TWM     | 1,000 | 0,962    | −0,038   |
|                        | TWC     | 0,891 | 0,559    | −0,332   |
| LSSVM-ADMM             | TWS     | 0,992 | 0,632    | −0,360   |
|                        | TWM     | 0,992 | 0,920    | −0,072   |
|                        | TWC     | 0,866 | 0,549    | −0,317   |
| Nyström-SVM            | TWS     | 0,992 | 0,560    | −0,432   |
|                        | TWM     | 1,000 | 0,966    | −0,034   |
|                        | TWC     | 0,858 | 0,529    | −0,329   |
| FT-CUR (Nyströmformer) | TWS     | 0,654 | 0,607    | −0,047   |
|                        | TWM     | 0,981 | 0,928    | −0,053   |
|                        | TWC     | 0,564 | 0,495    | −0,069   |
| SAINT                  | TWS     | 0,639 | 0,595    | −0,044   |
|                        | TWM     | 0,969 | 0,930    | −0,039   |
|                        | TWC     | 0,588 | 0,490    | −0,098   |
| XGBoost                | TWS     | 0,875 | 0,927    | +0,052   |
|                        | TWM     | 0,978 | 0,982    | +0,004   |
|                        | TWC     | 0,476 | 0,772    | +0,296   |

**Análise mecânica:** A adição de 3 features de ruído expande a distância euclidiana quadrática média em  $\approx 3\sigma_{\text{ruído}}^2$ , colapsando os valores do kernel RBF para próximo de zero e destruindo a estrutura da matriz kernel. O reajuste do  $\sigma$  (valores maiores) recupera parcialmente o sinal, mas não restitui a resolução espacial original em fronteiras de alta frequência.

**Padrões observados:**

- **DualFISTA**, **LSSVM-ADMM** e **Nyström-SVM** sofrem quedas severas em TWS e TWC ( $\Delta$  de  $-0,33$  a  $-0,43$ ), pelo mesmo motivo estrutural: o kernel RBF não distingue features informativas de ruído. O Nyström, agora com base  $> 0,85$  em 2D, tem queda proporcionalmente similar aos outros LSSVMs.
- **FT-CUR** e **SAINT** são notavelmente robustos ( $\Delta \approx -0,04$  a  $-0,10$ ): a atenção opera sobre representações aprendidas dos tokens, não sobre distâncias brutas entre amostras. Features irrelevantes têm impacto marginal porque o modelo aprende a ignorá-las. Esta é a vantagem estrutural mais clara dos Transformers tabulares sobre os métodos kernel neste cenário.
- **XGBoost** *melhora* com features extras ( $\Delta = +0,05$  a  $+0,30$ ): árvores aproveitam o sinal adicional. Em TWC vai de 0,476 (2D) para 0,772 (5D retunado) — o ganho mais expressivo do estudo. Confirma a complementaridade dos paradigmas: kernel para geometria pura, árvores para feature-rich tabular.

## 8 Ablação C: Dados Sintéticos Multifeature (MK5)

**Motivação:** Os datasets sintéticos anteriores (TWS/TWM/TWC) são bidimensionais, favorecendo o kernel RBF. O MK5 usa dados gerados por `make_classification` (scikit-learn) com 5 features verdadeiramente informativas em 3 níveis de dificuldade de separação.

Tabela 8: Ablação C (MK5) — F1-macro médio (30 sementes). MKE = fácil, MKM = médio, MKH = difícil. ★ = proposto. Spar.A = esparsidade amostral; Spar.At = esparsidade de atenção.

| Modelo                          | MKE          | MKM          | MKH          | Média        | Spar.A | Spar.At |
|---------------------------------|--------------|--------------|--------------|--------------|--------|---------|
| <i>Baseline geral tabular</i>   |              |              |              |              |        |         |
| XGBoost                         | 0,978        | 0,820        | 0,690        | 0,829        | —      | —       |
| <i>Baselines LSSVM</i>          |              |              |              |              |        |         |
| LSSVM-Std                       | 0,987        | 0,859        | 0,729        | 0,859        | 0,0%   | —       |
| LSSVM-FSA                       | 0,986        | 0,833        | 0,696        | 0,838        | 45,0%  | —       |
| LSSVM-IP                        | 0,989        | 0,819        | 0,683        | 0,830        | 58,1%  | —       |
| LSSVM-PCP                       | 0,973        | 0,827        | 0,683        | 0,828        | 0,0%   | —       |
| LSSVM-ADMM                      | 0,986        | 0,825        | 0,685        | 0,832        | 9,6%   | —       |
| LSSVM-Prun                      | 0,988        | 0,601        | 0,622        | 0,737        | 75,5%  | —       |
| LSSVM-OppM                      | 0,888        | 0,632        | 0,523        | 0,681        | 78,0%  | —       |
| <i>Baselines FT-Transformer</i> |              |              |              |              |        |         |
| FT-Softmax                      | 0,976        | 0,797        | 0,669        | 0,814        | —      | 0,2%    |
| FT-Entmax                       | 0,976        | 0,801        | 0,657        | 0,811        | —      | 1,4%    |
| FT-Sparsemax                    | 0,975        | 0,787        | 0,652        | 0,805        | —      | 39,1%   |
| FT-TopK                         | 0,975        | 0,768        | 0,644        | 0,796        | —      | 76,8%   |
| <i>Modelos propostos</i>        |              |              |              |              |        |         |
| DualFISTA★                      | <b>0,987</b> | <b>0,858</b> | <b>0,726</b> | <b>0,857</b> | 21,4%  | —       |
| Nyström-SVM★                    | 0,986        | 0,839        | 0,712        | 0,845        | 64,3%  | —       |
| FT-CUR★ (Nyströmformer)         | 0,967        | 0,797        | 0,664        | 0,809        | —      | 78,2%   |
| SAINT                           | 0,971        | 0,782        | 0,668        | 0,807        | —      | 0%      |




Figura 5: Ablação C — MK5: F1-macro por nível de dificuldade.

**Destaques:**

- **DualFISTA** (0,857) quase empata com o LSSVM-Std (0,859) com 21% de esparsidade — padrão consistente com o Tier 1.
- **Nyström-SVM** (0,845) supera todos os FT-Transformers neste cenário multifeature, com 64% de esparsidade: a aproximação Nyström é eficaz quando há features informativas distribuídas em dimensão maior que 2D.
- **SAINT** (0,807) e **FT-CUR** (0,809) ficam novamente empatados (diferença 0,002), confirmando que a compressão Nyströmformer no FT-CUR não custa F1 também em dados multifeature.



## 9 Análise das Variantes Investigadas e Modelos Propostos

### 9.1 Mecanismos de esparsidade

Tabela 9: Caracterização dos mecanismos de esparsidade dos modelos investigados e propostos. LSSVM-ADMM-Nesterov é o paper-base (Marinho et al.); demais são variantes ou aplicações propostas/investigadas.

| Modelo                               | Mecanismo                                                                                                                                                                                         | Esparsidade                                                        |
|--------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------|
| LSSVM-ADMM-Nesterov (Marinho et al.) | Otimização ADMM com penalidade $\ell_1$ (primal); aceleração de Nesterov.                                                                                                                         | Emerge da otimização; heterogênea entre datasets. Média: 30%.      |
| ADMM-ElasticNet <sup>o</sup>         | Variante do paper-base com penalidade Elastic Net ( $\ell_1 + \ell_2$ ); combinação não localizada em literatura.                                                                                 | Similar ao paper-base, ligeiramente mais homogênea. Média: 27%.    |
| DualFISTA <sup>o</sup>               | Formulação dual: $\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \ \alpha\ _1$ , otimizado via FISTA. Não localizada na literatura nesta forma exata. | Mais uniforme que ADMM (dual bem condicionado). Média: 20%.        |
| Nyström-SVM <sup>*</sup>             | Aproximação Nyström com seleção <i>colnorm</i> (norma de coluna em vez de uniforme/leverage); predição honesta restrita aos $m$ landmarks.                                                        | Controlada por $m/n$ tunado por dataset; varia 50–92%. Média: 69%. |
| FT-CUR (Nyströmformer) <sup>*</sup>  | Aplicação de Nyströmformer (Xiong et al. 2021) à atenção inter-instâncias do FT-Transformer com seleção <i>colnorm</i> .                                                                          | Compressão inter-instâncias: $1 - m/n \approx 80\%$ .              |

### 9.2 Desempenho consolidado

A Tabela 10 consolida os resultados dos modelos propostos nos quatro experimentos realizados.

Tabela 10: Modelos investigados / propostos e paper-base — F1-macro médio em todos os experimentos. Spar.A = esparsidade amostral (LSSVMs); Spar.At = compressão interinstâncias (FT-CUR/SAINT).

| Modelo                       | Tier 1       |            |         | Ablação A ( $N=2k$ ) |          | Ablação B (5D) |          | MK5   |
|------------------------------|--------------|------------|---------|----------------------|----------|----------------|----------|-------|
|                              | F1           | Spar.A     | Spar.At | F1                   | $\Delta$ | F1             | $\Delta$ |       |
| DualFISTA <sup>o</sup>       | 0,842        | 20%        | —       | 0,979                | +0,018   | 0,723          | −0,239   | 0,857 |
| LSSVM-ADMM (paper-base)      | 0,809        | 30%        | —       | 0,977                | +0,023   | 0,700          | −0,253   | 0,832 |
| ADMM-ElasticNet <sup>o</sup> | 0,809        | 27%        | —       | —                    | —        | —              | —        | —     |
| Nyström-SVM*                 | <b>0,834</b> | <b>69%</b> | —       | <b>0,978</b>         | +0,144   | 0,685          | −0,149   | 0,845 |
| FT-CUR (Nyströmformer)*      | 0,747        | —          | 79,3%   | 0,849                | +0,102   | 0,677          | −0,070   | 0,809 |
| SAINT (baseline FT)          | 0,744        | —          | 0%      | 0,862                | +0,118   | 0,672          | −0,072   | 0,807 |

### 9.3 Síntese comparativa

Tabela 11: Perfis dos modelos investigados e propostos.

| Modelo                       | Ponto forte                                                                                                            | Ponto fraco                                                                                                   | Característica distintiva                                                                                                                |
|------------------------------|------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------|
| DualFISTA <sup>o</sup>       | F1 quase idêntico ao LSSVM-Std; convergência estável                                                                   | Sensível a features de ruído (kernel RBF); esparsidade moderada (20%)                                         | Formulação dual bem condicionada; melhor trade-off esparsidade/acurácia em baixa esparsidade                                             |
| ADMM-ElasticNet <sup>o</sup> | Esparsidade mais uniforme que ADMM- $\ell_1$ puro                                                                      | F1 $\approx$ 3 pp abaixo do LSSVM-Std; ganho marginal sobre o paper-base                                      | Variante do paper-base com ElasticNet (combinação não localizada em literatura)                                                          |
| Nyström-SVM*                 | F1 competitivo (0,834, a 0,008 do LSSVM-Std) com 69% de esparsidade; melhor trade-off em alta esparsidade              | Sensível a features de ruído (kernel RBF); $m/n$ ideal varia muito entre datasets (8–50%)                     | Único modelo com compressão de memória real: $O(nm)$ vs. $O(n^2)$ ; auditoria matemática confirma honestidade                            |
| FT-CUR (Nyströmformer)*      | Robusto a features irrelevantes; beneficia-se de mais dados; compressão interinstâncias com Nyströmformer ( $O(nmd)$ ) | Fraco em fronteiras não-lineares complexas (TWS, TWC); transductivo (requer $X_{\text{train}}$ na inferência) | Aplicação do Nyströmformer a dados tabulares; comparado ao SAINT, valida empiricamente que 80% de compressão custa $\approx$ 0,003 de F1 |

## 10 Tier 2: Datasets Reais ( $N_{\text{treino}} = 5000$ ) — Resultados Parciais

Esta seção apresenta resultados *parciais* do experimento Tier 2, que estende a comparação para seis datasets reais de larga escala (**ADULT**, **CREDIT**, **BANK**, **TELCO**, **SHOPPERS**, **HIGGS50K**) com subamostragem estratificada para  $N_{\text{treino}} = 5000$  por seed. Dos 18 modelos planejados, **6 já completaram os 180 runs** cada (XGBoost, 4 FT-Transformer baselines e FT-CUR); os 12 restantes (LSSVMs baselines, ADMM family, Nyström-SVM, SAINT) estão em execução e serão incluídos no relatório final ( $\sim 01/06/2026$ ).

### 10.1 Protocolo

- **Subamostragem por seed:** cada (modelo, dataset, seed) usa uma amostra estratificada de  $N=7143$  amostras, determinística pela seed. O split 70/30 resulta em  $N_{\text{treino}}=5000 + N_{\text{teste}}=2143$ . Cada seed gera um subsample diferente, permitindo estimar variância amostral sobre  $N$  pequeno.
- **Tuning Optuna:** 20 trials  $\times$  3-fold CV sobre cada subsample, separado por (modelo, dataset). Cada um dos 18 modelos teve espaço de busca próprio.
- **30 seeds por (modelo, dataset),** F1-macro como métrica primária.

Tabela 12: Datasets Tier 2 com respectiva taxa de positivos.

| ID       | Nome                           | $N$ original | % positivos | Domínio              |
|----------|--------------------------------|--------------|-------------|----------------------|
| ADULT    | UCI Adult Income               | 45 222       | 24%         | Renda                |
| CREDIT   | Default of Credit Card Clients | 30 000       | 22%         | Crédito              |
| BANK     | UCI Bank Marketing             | 45 211       | 11%         | Marketing direto     |
| TELCO    | IBM Telco Customer Churn       | 7 032        | 27%         | Churn                |
| SHOPPERS | Online Shoppers Purchasing     | 12 330       | 15%         | E-commerce           |
| HIGGS50K | Higgs Boson (subset 50k)       | 50 000       | 53%         | Física de partículas |

### 10.2 Resultados parciais (6 de 18 modelos completos)

Tabela 13: F1-macro médio (30 sementes) por modelo e dataset. Em negrito o melhor por coluna entre os 6 modelos com dados completos. DP = desvio padrão agregado dos 180 runs.

| Modelo                  | ADULT        | CREDIT       | BANK         | TELCO        | SHOPPERS     | HIGGS50K     | Média        | DP    |
|-------------------------|--------------|--------------|--------------|--------------|--------------|--------------|--------------|-------|
| XGBoost                 | <b>0,802</b> | 0,677        | <b>0,713</b> | <b>0,728</b> | <b>0,795</b> | <b>0,693</b> | <b>0,735</b> | 0,049 |
| FT-Softmax              | 0,771        | 0,680        | 0,720        | 0,721        | 0,783        | 0,672        | 0,724        | 0,045 |
| FT-Entmax               | 0,770        | <b>0,682</b> | 0,718        | 0,722        | 0,781        | 0,667        | 0,723        | 0,045 |
| FT-Sparsemax            | 0,771        | 0,677        | 0,712        | 0,722        | 0,782        | 0,673        | 0,723        | 0,046 |
| FT-TopK                 | 0,769        | 0,677        | 0,705        | 0,719        | 0,783        | 0,667        | 0,720        | 0,046 |
| FT-CUR* (Nyströmformer) | 0,770        | 0,444        | 0,548        | 0,714        | 0,751        | 0,648        | 0,646        | 0,129 |

Observações por dataset:

- **ADULT** (24% pos.): XGBoost lidera (0,802); FT-Transformers equivalentes entre si (0,77), incluindo FT-CUR.
- **CREDIT** (22%): empate técnico entre FT-Entmax (0,682) e XGBoost (0,677). **FT-CUR colapsa para 0,444.**
- **BANK** (11%): XGBoost lidera (0,713); FT-Transformers no intervalo 0,705–0,720. **FT-CUR cai para 0,548.**
- **TELCO** (27%): XGBoost (0,728); FT-CUR competitivo (0,714).
- **SHOPPERS** (15%): XGBoost lidera (0,795); FT-CUR baixa para 0,751.
- **HIGGS50K** (53%, balanceado): XGBoost (0,693); FT-CUR a 0,648, na faixa dos FT baselines.

### 10.3 Limitação estrutural do FT-CUR em dados imbalanceados

A queda do FT-CUR em CREDIT, BANK e SHOPPERS é o achado mais expressivo dos resultados parciais. A Tabela 14 mostra o gap em função da taxa de positivos:

Tabela 14: Gap FT-CUR vs. FT-Softmax (baseline denso inter-features) por taxa de positivos. Acima de  $\sim 24\%$ : equivalência; abaixo: colapso.

| Dataset  | % positivos | FT-Softmax | FT-CUR | $\Delta$      |
|----------|-------------|------------|--------|---------------|
| HIGGS50K | 53%         | 0,672      | 0,648  | −0,024        |
| TELCO    | 27%         | 0,721      | 0,714  | −0,007        |
| ADULT    | 24%         | 0,771      | 0,770  | −0,001        |
| CREDIT   | 22%         | 0,680      | 0,444  | <b>−0,236</b> |
| SHOPPERS | 15%         | 0,783      | 0,751  | −0,032        |
| BANK     | 11%         | 0,720      | 0,548  | <b>−0,172</b> |

**Padrão observado:** acima de 24% de positivos, FT-CUR mantém desempenho equivalente aos baselines densos (diferença  $\leq 0,024$ ). Abaixo desse limiar, há colapso significativo, com perda de até 0,24 em F1.

#### Diagnóstico do colapso

A análise dos valores absolutos do F1-macro do FT-CUR em CREDIT (0,444) e BANK (0,548) sugere predição quase exclusivamente da classe majoritária. Para CREDIT (22% positivos):

$$F_1^{\text{maj, CREDIT}} = \frac{1}{2} \left( F_1^{(+)} + F_1^{(-)} \right) = \frac{1}{2} \left( 0 + \frac{2 \cdot 0,78 \cdot 1}{0,78 + 1} \right) \approx 0,44,$$

valor virtualmente idêntico ao observado (0,444).

## Hipótese causal

A aproximação CUR seleciona  $m$  landmarks por **norma de coluna** (*colnorm*), critério *geométrico* que não considera a estrutura de classes. Em datasets imbalanceados, a classe minoritária — por definição sub-representada — também tende a ser sub-representada no conjunto de landmarks, comprometendo a fidelidade da atenção comprimida na fronteira de decisão entre as classes.

Essa hipótese será verificada quando os resultados completos de SAINT (atenção *inter-instâncias* densa, sem aproximação CUR) ficarem disponíveis. Resultados preliminares do tuning do SAINT já sugerem o padrão: F1 CV 0,524 em CREDIT vs. 0,446 do FT-CUR. Caso SAINT mantenha desempenho similar aos FT baselines em CREDIT/BANK, confirma-se que o colapso é estrutural à aproximação CUR + colnorm em dados imbalanceados, não à atenção inter-instâncias em si.

Uma hipótese metodológica adicional surgiu da inspeção dos logs de treino. Na implementação atual, **FT-CUR** e **SAINT** usam *early stopping* por `val_acc`, enquanto os FT-Transformer baselines usam `val_loss`. Em datasets desbalanceados, `val_acc` pode favorecer checkpoints que acertam majoritariamente a classe dominante, mas ainda são ruins em F1-macro. Isso fornece uma explicação alternativa, ou complementar, para o colapso observado em **CREDIT** e **BANK**: parte da queda pode decorrer do critério de seleção do checkpoint, e não apenas da seleção *colnorm* de landmarks.

**Suporte experimental adicionado.** O parâmetro `early_stop_metric` foi implementado em `fit_model`, com três opções: `val_acc` (default original), `val_loss` e `val_f1_macro` (alinhado à métrica primária do estudo). O script `scripts/run_early_stop_ablation.p` executa o rerun focal de FT-CUR e SAINT em CREDIT e BANK variando `early_stop_metric`, mantendo todos os outros hiperparâmetros tunados constantes. Isto permite isolar empiricamente o efeito do critério de checkpoint do efeito da seleção *colnorm*.

## Tabela de hipóteses testáveis

Tabela 15: Três hipóteses sobre o colapso do FT-CUR em CREDIT/BANK e como testar cada uma. Cada experimento isola uma causa específica.

| Hipótese                         | Causa proposta                                                                                                                                                | Teste experimental                                                                                                                                  |
|----------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------|
| H1: imbalanceamento              | Seleção colnorm de landmarks é geométrica; minoria sub-representada nos $m$ landmarks                                                                         | Tier 2 balanceado (CREDIT_BAL, BANK_BAL, SHOPPERS_BAL)<br>via random under-sampling. Script: <code>run_tier2_balanced.py</code>                     |
| H2: critério de early stopping   | <code>val_acc</code> favorece classe majoritária; o checkpoint escolhido tem F1-macro baixo mesmo em datasets onde o modelo aprende bem                       | Rerun focal com <code>val_loss</code> e <code>val_f1_macro</code> ; mesmos hiperparâmetros e dados. Script: <code>run_early_stop_ablation.py</code> |
| H3: limitação fundamental do CUR | Compressão de baixo posto é incompatível com fronteiras de decisão complexas em datasets imbalanceados, independentemente de seleção e critério de checkpoint | Confirmação <i>por exclusão</i> : se H1 e H2 falharem em explicar, H3 é a explicação remanescente                                                   |

## Implicações para a dissertação

Este achado representa uma contribuição analítica importante: identifica uma fronteira de aplicabilidade do FT-CUR, com hipótese causal testável e propostas concretas de trabalho futuro:

- **Landmark selection estratificada por classe** (garantir proporção mínima de cada classe entre os  $m$  landmarks);
- **Rerun metodológico em CREDIT e BANK com *early stopping*** por `val_loss` (ou idealmente `val_f1_macro`) para FT-CUR e SAINT, alinhando o checkpoint à métrica principal do estudo;
- **Class-weighted loss** (pesos inversos à frequência de classes na função de custo);
- **Métricas alternativas** (F1-weighted, Average Precision) para complementar a análise em dados imbalanceados.

## 10.4 Comparação Tier 1 vs. Tier 2: deslocamento do trade-off (*rascunho* — *pendente confirmação*)

### RASCUNHO — aguardando experimentos restantes

Esta subseção é **provisória**. Dependem do término dos experimentos para confirmação:

- **DualFISTA Tier 2:** pode replicar o padrão Tier 1 (empate com LSSVM-Std com 20% esparsidade);
- **SAINT Tier 2:** hipótese central da Seção 10.3 é que SAINT *não* colapsa em CREDIT/BANK (atenção inter-instâncias densa, sem CUR + colnorm);
- **ADMM-Nesterov / ElasticNet Tier 2:** paper-base e variante.

A redação final deverá ser revisada com os números completos.

### Tabela comparativa — queda de F1 do Tier 1 para o Tier 2

Tabela 16: F1-macro médio: Tier 1 (sintéticos + pequenos reais,  $N \in [400, 1584]$ ) vs. Tier 2 ( $N_{\text{treino}} = 5000$  sobre datasets reais grandes).  $\Delta$  negativo = perda ao migrar para o cenário realista.

| Modelo                  | Tier 1 | Tier 2 | $\Delta$ | Família                        |
|-------------------------|--------|--------|----------|--------------------------------|
| LSSVM-Std               | 0,842  | 0,709  | -0,133   | kernel denso                   |
| Nyström-SVM*            | 0,834  | 0,707  | -0,127   | kernel esparsa (81% esp.)      |
| FT-Sparsemax            | 0,774  | 0,723  | -0,051   | atenção feature esparsa        |
| XGBoost                 | 0,776  | 0,735  | -0,041   | gradient boosting              |
| FT-Entmax               | 0,742  | 0,723  | -0,019   | atenção feature esparsa        |
| FT-Softmax              | 0,740  | 0,724  | -0,016   | atenção feature densa          |
| FT-CUR* (Nyströmformer) | 0,747  | 0,646  | -0,101   | atenção inter-inst. comprimida |

### Observações empíricas

1. **LSSVMs (kernel) sofrem o maior deslocamento:** -0,13 em F1 ao migrar para o cenário realista. O kernel RBF, ótimo em geometria sintética limpa e datasets pequenos cuidados, perde eficácia em dados reais com features categóricas codificadas, redundância e ruído estrutural.
2. **FT-Transformer baselines (sem CUR) absorvem a mudança:** FT-Softmax cai apenas -0,016, FT-Entmax -0,019. Isso é consistente com a Seção ?? (Ablação B), onde os Transformers já demonstraram robustez a features de ruído ( $\Delta < 0,10$  vs. -0,35 dos kernels).
3. **XGBoost lidera em ambos os cenários grandes** (Tier 2: 0,735), confirmando a literatura de *tabular learning*.

4. **Variantes esparsas de atenção feature-level (TopK, Entmax, Sparsemax) convergem para o mesmo patamar** do Softmax denso (intervalo 0,720–0,724,  $\Delta \leq 0,005$ ): a esparsidade na atenção *inter-features* não traz vantagem em datasets reais.
5. **FT-CUR é a anomalia:** cai  $-0,10$ , mais que o Softmax denso ( $-0,016$ ) mas concentrada em 3 datasets imbalanceados (CREDIT, BANK, SHOPPERS). Mostra que *a robustez do paradigma Transformer não se preserva automaticamente quando se aplica compressão CUR à atenção inter-instâncias sem estratificação por classe*. Achado contraintuitivo importante.

## Interpretação preliminar

A migração Tier 1  $\rightarrow$  Tier 2 **reordena** a hierarquia entre paradigmas: em datasets sintéticos pequenos com fronteiras geométricas, kernels dominam ( $+0,10$  vs. Transformers); em datasets reais grandes, Transformers atingem o patamar do gradient boosting, enquanto kernels (LSSVM-Std e Nyström-SVM) perdem  $\approx 0,13$  em F1.

A vantagem do Transformer é diretamente proporcional à complexidade de features e ao ruído estrutural dos dados — não à escolha de função de ativação da atenção. Isto sugere que **o ganho real do paradigma vem do mecanismo de aprendizado de representações, não da estrutura esparsa da atenção feature-level**.

## Pendências para confirmação

- **Nyström-SVM** mantém o padrão "esparsidade sem custo":  $\Delta$  vs. LSSVM-Std é de  $-0,002$  no Tier 2 (irrelevante), confirmando o achado central da Seção 3 também em dados reais.
- **DualFISTA** ainda não rodado em Tier 2 — se replicar o empate Tier 1 com LSSVM-Std ( $\Delta \leq 0,001$ ), confirma a generalização do método dual em  $N_{\text{treino}} = 5000$ .
- **SAINT** ainda não rodado — hipótese: *não* colapsará em datasets imbalanceados (como o FT-CUR), pois usa atenção inter-instâncias densa. Se confirmado, isola a causa do colapso do FT-CUR à seleção colnorm de landmarks. Um rerun focal em CREDIT/BANK com *early stopping* por `val_loss` ou `val_f1_macro` também é prioritário para separar efeito de arquitetura de efeito do critério de checkpoint.
- **ADMM-Nesterov** (paper-base) e **ADMM-ElasticNet** (variante) ainda em tuning.

## 10.5 XGBoost vs. FT-Transformers em datasets reais

XGBoost lidera em 5 dos 6 datasets, com vantagem expressiva em ADULT ( $+0,031$  sobre FT-Softmax), TELCO ( $+0,007$ ) e HIGGS50K ( $+0,021$ ). Em CREDIT, FT-Entmax marginalmente supera ( $+0,005$ ). A média agregada coloca XGBoost a  $+0,011$  sobre o melhor FT-Transformer.

As 4 variantes esparsas de FT-Transformer (Softmax, TopK, Entmax, Sparsemax) ficam todas dentro de 0,005 entre si — esparsidade de atenção inter-features não traz vantagem mensurável em datasets reais desta escala. Achado consistente com o Tier 1 sintético, onde sparsemax foi 0,774 vs. softmax 0,740 (diferença  $+0,034$  apenas em ablação de ruído).



## 11 Sumário e Próximos Passos

Tabela 17: Síntese dos experimentos realizados.

| Experimento                      | Configuração                                  | Runs        | Resultado principal                                              |
|----------------------------------|-----------------------------------------------|-------------|------------------------------------------------------------------|
| Tier 1                           | 18 modelos, 9 datasets, 30 seeds              | 4860        | DualFISTA 0,842 / Nyström 0,834 / XGBoost 0,776                  |
| Ablação A (escala)               | 18 modelos, 3 sintéticos, $N=2000$ , 30s      | 1620        | Nyström +0,14; FT-CUR/SAINT data-hungry                          |
| Ablação B (ruído)                | 18 modelos, 3 sintéticos, +3 feat. ruído, 30s | 1620        | XGBoost +0,30 em TWC; FT-CUR/SAINT robustos                      |
| Ablação C (MK5)                  | 18 modelos, 3 sintéticos, 30 seeds            | 1620        | Nyström 0,845 > XGBoost 0,829 > FT-CUR 0,809                     |
| <b>Total</b>                     |                                               | <b>9720</b> |                                                                  |
| <b>Tier 2 parcial</b> (Seção 10) | 6/18 modelos, 6 datasets, $N=5000$ , 30s      | 1080        | XGBoost lidera (0,735); FT-CUR colapsa em datasets imbalanceados |
| <b>Tier 2 (em andamento)</b>     | restante: 12 modelos                          | 2160        | LSSVMs, ADMM family, Nyström, SAINT — conclusão ~01/06/2026      |

### Conclusões preliminares:

1. **DualFISTA** é o resultado mais significativo em baixa esparsidade: F1 quase idêntico ao LSSVM-Std completo ( $\Delta = 0,0006$ ) com 20% de esparsidade.
2. **Nyström-SVM** (após auditoria matemática) é o melhor entre os modelos com alta esparsidade: 0,834 no Tier 1 com 69% de esparsidade, a 0,008 do LSSVM-Std. Combina compressão de memória real ( $O(nm)$  vs.  $O(n^2)$ ) com F1 competitivo.
3. A **compressão Nyströmformer no FT-CUR é validada pelo SAINT**: os dois modelos atingem F1 idêntico em todos os 4 experimentos ( $\Delta \leq 0,013$ ), mas o FT-CUR opera com 79% de compressão inter-instâncias. Comprimir não custou F1 — a aproximação é fiel.
4. **Robustez a ruído**: FT-CUR e SAINT mantêm desempenho na ablação de features irrelevantes ( $\Delta \approx -0,07$ ); LSSVMs/Nyström/ DualFISTA caem  $-0,24$  a  $-0,43$ . A atenção é estruturalmente mais robusta que o kernel RBF a features ruidosas.
5. **XGBoost como referência externa**: o baseline geral tabular fica em 0,776 no Tier 1, abaixo do top 5 dos LSSVMs e do DualFISTA/Nyström. Em ablações com features extras (5D retunado: 0,894), XGBoost se beneficia mais que kernel/atenção. Resultado coerente com a literatura de *tabular learning*: kernel domina em geometria pura; gradient boosting em datasets feature-rich; atenção é robusta a ruído.
6. **Tier 2 (parcial) revela limitação do FT-CUR em dados imbalanceados**: nos seis datasets reais com  $N_{\text{treino}} = 5000$ , XGBoost lidera (0,735), seguido dos quatro FT-Transformer baselines empatados (0,720–0,724). O **FT-CUR cai para 0,646** —  $-0,079$  vs. FT-Softmax — com colapso especificamente em CREDIT (22% positivos), BANK (11%) e SHOPPERS (15%). Hipótese verificável: seleção colnorm não-estratificada sub-representa a classe minoritária nos landmarks (Seção 10.3).

### Próximas etapas:

1. **Tier 2  $N_{\text{treino}} = 5000$  — 12 modelos restantes**: execução local em andamento dos 7 LSSVMs baselines, paper-base LSSVM-ADMM, variantes (ADMM-EN), Nyström-SVM, DualFISTA e SAINT. Conclusão esperada ~01/06/2026.

2. **Tier 2 *full-data*:** benchmarks com  $N$  completo em Colab T4 GPU, restrito a modelos escaláveis (XGBoost, Nyström-SVM, 4 FT baselines, FT-CUR). Os demais (LSSVMs com  $K$  denso e SAINT com atenção  $n \times n$ ) excedem capacidade de memória para  $N \gg 10k$ .
3. **Análise estatística formal:** teste de Friedman + Nemenyi / diagrama de diferença crítica sobre todos os datasets consolidados (Tier 1 + 3 ablações + Tier 2).
4. **Análise de complexidade temporal:** medição empírica do speedup do Nyström-SVM vs. LSSVM-Std em função de  $n$ , usando os dados de tempo coletados nas execuções Tier 2.

## A Infraestrutura e Reprodutibilidade

- **Código:** repositório `sparse-lssvm-transformers-study/`
- **Ambiente:** Python 3.12, PyTorch, scikit-learn, Optuna; virtualenv em `.venv/`
- **Resultados:** arquivos JSON em `results/`: `tier1_results.json` (baselines), `tier1_custom_models.json` (propostos), `synthetic_scaling_n2000.json`, `synthetic_5features_tuned.json`, `synthetic_mk5.json`
- **Tuning:** `results/tuning/best_params*.json`
- **Scripts:** `scripts/run_*.py` são resumíveis (checkpoint por chave `model/dataset/seed`)
- **Figuras:** geradas por `scripts/generate_report_figs.py`