

Relatório de Experimentos

Estudo Comparativo: LSSVM Esperso vs. Transformers Tabulares
Dissertação de Mestrado — Experimentos (atualizado em maio de 2026)

Paulo Bernardo

Maio de 2026

Sumário

1	Introdução	3
2	Auditoria da Implementação do Nyström-SVM	4
2.1	As três versões	4
2.2	Verificação experimental	5
2.3	Esparsidade reportada	5
3	Experimento Tier 1: Benchmarks Reais	6
3.1	Resultados por Dataset	6
3.2	Comparação Geral	7
3.3	Análise estatística: Friedman e ranks médios (Tier 1)	8
3.4	Ranking nos datasets reais (sem sintéticos)	8
4	Arquitetura dos FT-Transformers e Tipos de Atenção	9
4.1	Atenção inter-features (intra-instância)	9
4.2	Atenção inter-instâncias (entre amostras)	10
5	Análise de Esparsidade	10
5.1	Esparsidade amostral — LSSVMs	11
5.2	Esparsidade de atenção inter-features — FT-Transformers baselines	12
5.3	Esparsidade nos Transformers — Tier 2 ($N = 5000$)	13
6	Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)	14
7	Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)	15
8	Ablação C: Dados Sintéticos Multifeature (MK5)	16
9	Análise das Variantes Investigadas e Modelos Propostos	17
9.1	Mecanismos de esparsidade	17
9.2	Desempenho consolidado	17
9.3	Síntese comparativa	18

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$)	19
10.1 Protocolo	19
10.2 Resultados por Dataset (todos os 18 modelos)	19
10.3 Análise estatística: Friedman e ranks médios	21
10.4 Esparsidade consolidada no Tier 2	21
10.5 Colapso dos métodos primais com ℓ_1 em escala	22
10.6 FT-CUR/SAINT e a correção metodológica da H2	23
10.7 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia	24
11 Benchmark de Eficiência Computacional em <i>Full-Data</i>	26
12 Sumário e Próximos Passos	27
A Infraestrutura e Reprodutibilidade	29
B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)	29

1 Introdução

Este relatório consolida os resultados dos experimentos conduzidos na dissertação, que compara métodos de *Least-Squares Support Vector Machine* (LSSVM) com ênfase em esparsidade contra variantes de *FT-Transformer* com atenção esparsa em tarefas de classificação binária tabular.

O trabalho estende o algoritmo LSSVM-ADMM-Nesterov proposto por Marinho et al. com dois novos mecanismos de esparsidade: (i) **DualFISTA**, formulação dual do LSSVM como LASSO com otimização via ISTA acelerado; e (ii) **Nyström-SVM**, aproximação da matriz kernel por seleção de landmarks via norma de coluna. Como comparativo do lado dos Transformers, avalia-se o **FT-CUR**, que aplica decomposição CUR com colnorm à matriz de atenção.

Auditoria do Nyström-SVM — três versões

A implementação do Nyström-SVM passou por três versões. A versão final, auditada matematicamente (Seção 2), é a apresentada neste relatório.

Versão	Predição	F1 Tier 1
Bug original	$f(x)=K(x, X_{\text{treino}})\alpha + b$ (kernel completo)	0,8427 (inflado)
“Fix” errado	$f(x)=K(x, Z)\alpha[\text{lm_idx}] + b$ (subset ingênuo de α)	0,6678 (colapsado)
Correta	$f(x)=K(x, Z)(W^{-1}C^T\alpha) + b$ (Nyström)	0,8342

A versão correta usa a fórmula matemática da aproximação Nyström ($\tilde{K} = CW^{-1}C^T$), com custo $O(n_{\text{test}} \cdot m)$ e **sem dependência de X_{treino} na predição** (verificado experimentalmente). A perda de F1 em relação ao bug original é de apenas 0,0085, mas agora com $\approx 69\%$ de esparsidade amostral genuína.

Modelos avaliados

Ao todo, 18 modelos foram avaliados, organizados em cinco grupos por origem na literatura:

- **Baseline geral tabular (1): XGBoost** (Chen & Guestrin, 2016) — padrão-ouro para dados tabulares, serve como referência externa às famílias LSSVM e Transformer.
- **LSSVMs baselines (7):** LSSVM-Std (sem esparsidade), LSSVM-PCP, LSSVM-FSA, LSSVM-IP, LSSVM-Pruning, LSSVM-OppMaps, e **FISTA-Nesterov** (LSSVM primal com FISTA — método clássico de Beck & Teboulle, 2009, amplamente documentado).
- **FT-Transformers baselines (5):** variantes com atenção softmax, top- k , entmax e sparsemax — mais **SAINT** (Somepalli et al., 2021; atenção inter-instâncias densa).
- **Paper-base estendido: LSSVM-ADMM-Nesterov** de Marinho et al. — método sobre o qual esta dissertação constrói.
- **Variantes investigadas e modelos propostos (4):**
 - **ADMM-ElasticNet^o**: variante do paper-base com penalidade Elastic Net (combinação ADMM-Nesterov + Elastic Net + LSSVM não localizada explicitamente na literatura como método publicado).

- **DualFISTA**[◦]: formulação dual do LSSVM como LASSO ($\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \|\alpha\|_1$), otimizada via FISTA. Ponto de investigação — não localizada na literatura nesta forma exata; pode ser uma reformulação convergente com métodos análogos em SVM ou regressão Lasso.
- **Nyström-SVM (colnorm)**^{*}: aproxima $K \in \mathbb{R}^{n \times n}$ via $m \ll n$ landmarks selecionados por norma de coluna (em vez de amostragem uniforme/leverage tradicional); predição restrita aos landmarks ($O(n_{\text{test}} \cdot m)$, auditada).
- **FT-CUR (Nyströmformer)**^{*}: aplicação de Nyströmformer (Xiong et al., 2021) à atenção inter-instâncias do FT-Transformer em dados tabulares; seleção de landmarks via colnorm (combinação não localizada como método publicado).

◦ = variante/ponto de investigação; * = aplicação/combinação proposta.

Protocolo experimental

- 30 sementes aleatórias, partição estratificada 70/30.
- Métrica principal: F1-macro (média aritmética do F1 por classe).
- Hiperparâmetros otimizados via **Grid Search exaustivo + 5-fold CV** estratificado (**GridSearchCV**, scikit-learn) para modelos LSSVM e XGBoost no Tier 1. Transformers Tier 1 (pendente re-execução em GPU) e todos os modelos Tier 2 utilizam Optuna TPE (20 trials, 3-fold CV).
- Normalização por **StandardScaler** ajustado apenas no treino.

2 Auditoria da Implementação do Nyström-SVM

2.1 As três versões

O Nyström-SVM aproxima a matriz kernel completa $K \in \mathbb{R}^{n \times n}$ a partir de m landmarks $\{z_1, \dots, z_m\}$ selecionados antes do treino:

$$K \approx C W^{-1} C^{\top}, \quad C = K(X, Z) \in \mathbb{R}^{n \times m}, \quad W = K(Z, Z) \in \mathbb{R}^{m \times m}.$$

O treinamento, via identidade de Woodbury, é correto em todas as versões. A diferença está apenas na predição:

V1 — Bug original. Predizia com o kernel completo:

$$f(x) = K(x, X_{\text{treino}}) \alpha + b.$$

Não tinha esparsidade real (todo X_{treino} era usado em inferência) e produzia $F_1 = 0,8427$ no Tier 1.

V2 — “Fix” ingênuo. Tentativa de restringir aos landmarks pegando apenas o subset de α nos índices dos landmarks:

$$f(x) = K(x, Z) \alpha[\text{lm_idx}] + b.$$

Está **matematicamente errado**: os pesos $\alpha \in \mathbb{R}^n$ foram ajustados para o sistema KKT completo n -dimensional, e simplesmente subetá-los nos índices dos landmarks não recupera a aproximação Nyström. F1 colapsou para 0,6678.

V3 — Correta (atual). A aproximação Nyström verdadeira é $\tilde{K}(x, X) = K(x, Z) W^{-1} C^\top$. Substituindo em $f(x) = \tilde{K}(x, X) \alpha + b$:

$$f(x) = K(x, Z) (W^{-1} C^\top \alpha) + b = K(x, Z) w_\alpha + b, \quad w_\alpha = W^{-1} C^\top \alpha \in \mathbb{R}^m.$$

O vetor w_α é calculado uma vez ao final do fit e cacheado. Em inferência, só $K(x, Z) \in \mathbb{R}^{n_{\text{test}} \times m}$ é computado — não há mais nenhuma dependência de X_{treino} . F1 = 0,8342.

2.2 Verificação experimental

A implementação V3 foi auditada matematicamente (`scripts/audit_nystrom_lssvm.py`) confirmando três propriedades:

1. **Equivalência matemática.** $\|f_{\text{cache}}(x) - f_{\text{Nyström}}(x)\|_2 = 0$ exatamente, onde $f_{\text{Nyström}}$ usa a fórmula expandida $K(x, Z) W^{-1} C^\top \alpha + b$.
2. **Sem dependência de X_{treino} .** Após o fit, ao apagar X_{treino} do modelo, as predições continuam idênticas ($\|\Delta f\|_2 = 0$). Confirma que apenas Z é usado na inferência.
3. **Custo $O(n_{\text{test}} \cdot m)$.** Mantendo m fixo e variando n_{treino} de 1000 a 6000, o tempo de predição permanece em ≈ 5 ms (não escala com n).

Tabela 1: Comparação direta no BCW (10 sementes, mesmos hiperparâmetros).

Versão	F1 BCW	Diagnóstico
V1 (kernel completo)	0,974	0% de esparsidade real
V2 (α subsetado)	0,360	matematicamente inválida
V3 ($W^{-1} C^\top \alpha$, atual)	0,968	$\approx 80\%$ esparsidade real

A V3 perde apenas 0,006 em relação ao kernel completo no BCW, mostrando que a aproximação Nyström com seleção colnorm é *genuinamente* boa quando bem tunada — a esparsidade não custa quase nada de F1.

2.3 Esparsidade reportada

Com a predição V3, a esparsidade do Nyström-SVM é semanticamente consistente com os demais LSSVMs:

- **ADMM/FISTA:** esparsidade = fração de $\alpha_i = 0$.
- **Nyström:** esparsidade = $1 - m/n$, fração de pontos de treino *não* usados como landmark-key.

A razão m/n é tunada por Grid+CV por dataset; a esparsidade resultante varia entre 50% (TWC) e 92% (PID), com média 69% no Tier 1.

3 Experimento Tier 1: Benchmarks Reais

Nove conjuntos de dados foram utilizados (Tabela 2). Os três últimos (TWS, TWM, TWC) são sintéticos bidimensionais incluídos como controle com fronteiras de decisão conhecidas.

Tabela 2: Conjuntos de dados — Tier 1.

ID	Nome	N	Features	Domínio
BCW	Breast Cancer Wisconsin	569	30	Diagnóstico médico
PID	Pima Indians Diabetes	768	8	Diagnóstico médico
HAB	Haberman Survival	306	3	Sobrevivência
VCP	Vehicle Coupon Purchase	1584	7	Marketing
GCR	German Credit Risk	1000	20	Crédito
AUS	Australian Credit	690	14	Crédito
TWS	Two Spirals (sintético)	400	2	Controle
TWM	Two Moons (sintético)	400	2	Controle
TWC	Checkerboard (sintético)	400	2	Controle

3.1 Resultados por Dataset

A Tabela 3 apresenta o F1-macro médio (30 sementes) para *todos* os modelos, usando Grid Search exaustivo + 5-fold CV (GridSearchCV, scikit-learn) para todos os modelos incluindo Transformers (re-executados em GPU T4 no Kaggle). Os melhores valores por coluna estão em negrito.

Tabela 3: F1-macro médio (30 sementes, Grid+CV). **Negrito**: melhor por coluna. ◦ = variante investigada; ★ = proposta.

Modelo	BCW	PID	HAB	VCP	GCR	AUS	TWS	TWM	TWC	Média
<i>Baseline geral tabular</i>										
XGBoost	0,958	0,724	0,559	0,804	0,691	0,862	0,944	0,984	0,912	0,826
<i>Baselines LSSVM</i>										
LSSVM-Std	0,973	0,732	0,566	0,827	0,691	0,861	0,994	0,997	0,898	0,838
LSSVM-FSA	0,966	0,732	0,550	0,811	0,680	0,855	0,987	0,997	0,879	0,829
LSSVM-IP	0,969	0,718	0,546	0,828	0,681	0,857	0,992	0,996	0,897	0,832
LSSVM-PCP	0,916	0,717	0,627	0,783	0,684	0,849	0,990	0,993	0,880	0,827
FISTA-Nesterov	0,894	0,693	0,603	0,754	0,606	0,841	0,875	0,996	0,989	0,806
LSSVM-Prun	0,969	0,642	0,493	0,816	0,628	0,851	0,989	0,997	0,891	0,808
LSSVM-OppM	0,951	0,463	0,454	0,715	0,550	0,815	0,986	0,991	0,907	0,759
<i>Baselines FT-Transformer</i>										
FT-Sparsemax	0,945	0,675	0,557	0,800	0,655	0,857	0,629	0,895	0,469	0,720
SAINT	0,945	0,709	0,530	0,813	0,598	0,863	0,632	0,833	0,446	0,708
FT-Entmax	0,946	0,681	0,553	0,803	0,651	0,860	0,625	0,851	0,462	0,715
FT-Softmax	0,953	0,681	0,560	0,812	0,664	0,852	0,622	0,847	0,456	0,716
FT-TopK	0,948	0,649	0,536	0,768	0,644	0,856	0,635	0,826	0,479	0,704
<i>Paper-base estendido</i>										
LSSVM-ADMM-Nesterov	0,901	0,690	0,620	0,762	0,592	0,842	0,974	0,988	0,883	0,806
<i>Variantes investigadas / propostos</i>										
DualFISTA◦	0,976	0,730	0,558	0,824	0,687	0,863	0,992	1,000	0,905	0,837
Nyström-SVM★	0,970	0,728	0,579	0,825	0,691	0,863	0,992	0,999	0,898	0,838
ADMM-ElasticNet◦	0,901	0,689	0,620	0,766	0,591	0,841	0,974	0,988	0,879	0,805
FT-CUR★ (Nyströmformer)	0,952	0,697	0,565	0,804	0,627	0,859	0,622	0,864	0,455	0,716

3.2 Comparação Geral

A Figura 1 mostra o F1-macro médio ($\pm$ dp) agregado sobre todos os datasets e sementes para cada modelo.




Figura 1: F1-macro médio $\pm$ dp (30 sementes $\times$ 9 datasets). ★ indica modelos propostos; vermelho = DualFISTA, verde = Nyström-SVM, laranja = FT-CUR.

Observações principais (Grid+CV):

- **Nyström-SVM** (0,838) é o modelo com melhor F1-macro médio, seguido muito de perto por LSSVM-Std (0,838) e DualFISTA (0,837) — os três empatam estatisticamente. Com $\approx 69\%$ de esparsidade amostral, o Nyström-SVM valida o trade-off F1/esparsidade como o melhor entre modelos de alta compressão.
- **DualFISTA** (0,837) alcança F1-macro médio essencialmente igual ao LSSVM-Std completo (0,838, diferença 0,001) com $\approx 20\%$ de esparsidade. É o único modelo esperso que se aproxima do baseline sem esparsidade.
- **XGBoost** (baseline tabular) atinge 0,826 no Tier 1 — agora competitivo com os LSSVMs esparsos (IP 0,832, PCP 0,827). Destaque para TWC (0,912, melhor por coluna): o Grid+CV encontrou parâmetros que capturam a fronteira xadrez, eliminando o colapso observado no protocolo Optuna anterior (0,476). Perde em AUS e nos dados sintéticos TWS/TWM para os LSSVMs com kernel RBF.
- O **LSSVM-ADMM** e variantes (ElasticNet, FISTA-Nesterov) ficam ≈ 3 pp abaixo do LSSVM-Std. FISTA-Nesterov (0,806) empata praticamente com ADMM-N (0,806) e ADMM-EN (0,805) após correção do grid de σ (adição de 0,15 e 1,5, cobrindo a escala ótima para datasets sintéticos).
- **LSSVM-Pruning** (0,808) recuperou-se significativamente com a correção do grid (adição de pruning_rate= 0,05 e sigma= 15): era 0,782 no protocolo Optuna.
- **Transformers** (Grid+CV, GPU T4) ficam em 0,704–0,720 de F1 médio — 12–13 pp abaixo do bloco líder LSSVM. O colapso concentra-se nos datasets sintéticos:

TWC melhor transformer (0,479, FT-TopK) contra Nyström-SVM 0,898; TWS 0,635 vs 0,994. Nos datasets reais (BCW, AUS, VCP) os Transformers são competitivos, com SAINT empatando em AUS (0,863) com DualFISTA e Nyström-SVM.

- **SAINT** (0,708) e **FT-CUR** (0,716) ficam próximos no Grid+CV. FT-CUR comprime $\approx 79\%$ da atenção inter-instâncias mantendo F1 equivalente ao SAINT denso: **a compressão não custa F1** também no protocolo rigoroso.

3.3 Análise estatística: Friedman e ranks médios (Tier 1)

O teste não-paramétrico de Friedman aplicado às 18 variantes (12 LSSVM+XGBoost + 6 Transformers) sobre os 9 datasets confirma diferença estatisticamente significativa entre os modelos: $\chi^2 = 69,71$, $p \approx 0$. A diferença crítica de Nemenyi para $\alpha = 0,05$ é $CD = 8,78$.

Tabela 4: Ranks médios de Friedman (menor = melhor).

Rank	Model	Avg. rank
1	LSSVM-Nystrom	3.111
2	LSSVM (Standard)	3.333
3	LSSVM-DualFISTA	3.444
4	LSSVM-IP	6.000
5	XGBoost	6.889
6	LSSVM-FSA	7.444
7	LSSVM-PCP	8.556
8	LSSVM-Pruning	9.556
9	FTTransformerCURColnorm	11.333
10	LSSVM-ADMM	11.667
11	LSSVM-FISTA	11.667
12	FTTransformer_softmax	11.778
13	SAINTColnorm	12.222
14	FTTransformer_entmax	12.333
15	FTTransformer_sparsemax	12.333
16	LSSVM-ADMM-Elastic	12.556
17	LSSVM-OppMaps	13.333
18	FTTransformer_topk	13.444

Leitura dos ranks: Nyström-SVM (rank 3,1), LSSVM-Std (3,3) e DualFISTA (3,4) formam o bloco líder, estatisticamente equivalentes entre si ($\text{gap} < CD$). XGBoost (rank 6,9) é o melhor modelo não-kernel e não-Transformer. Todos os Transformers ficam na metade inferior do ranking (ranks 11,3–13,4): FT-CUR é o melhor deles (rank 11,3), seguido de FT-Softmax (11,8) e SAINT (12,2). FT-TopK (13,4) e LSSVM-OppMaps (13,3) são os piores. O colapso dos Transformers nos datasets sintéticos TWS/TWM/TWC — onde a fronteira de decisão exige inductive bias geométrico que a atenção não possui — é o principal responsável pelos ranks baixos.

3.4 Ranking nos datasets reais (sem sintéticos)

Para isolar o efeito do inductive bias geométrico, repetiu-se a análise de Friedman excluindo os três datasets sintéticos (TWS, TWM, TWC) e considerando apenas os seis datasets

reais (BCW, PID, HAB, VCP, GCR, AUS).

Resultado: $\chi^2 = 88,38$, $p \approx 0$, $CD = 9,56$ (18 modelos $\times$ 6 datasets).

Rank	Modelo	Avg. rank	F1 médio
1	LSSVM-Nyström	3,167	0,776
2	LSSVM-Std	3,333	0,775
3	LSSVM-DualFISTA	3,833	0,773
4	XGBoost	6,167	0,766
5	LSSVM-IP	6,500	0,766
6	LSSVM-FSA	7,667	0,766
7	FT-CUR	9,000	0,751
8	LSSVM-PCP	9,167	0,763
9	FT-Softmax	9,333	0,754
10	SAINT	10,167	0,743
11	FT-Entmax	10,833	0,749
12	LSSVM-Pruning	11,500	0,733
13	FT-Sparsemax	11,500	0,748
14	LSSVM-ADMM	12,750	0,734
15	FT-TopK	12,833	0,733
16	LSSVM-FISTA	13,167	0,732
17	LSSVM-ADMM-EN	13,417	0,735
18	LSSVM-OppMaps	16,667	0,658

Interpretação: sem os datasets sintéticos, os Transformers sobem significativamente no ranking. FT-CUR (rank 7) e FT-Softmax (rank 9) superam LSSVM-PCP, LSSVM-Pruning, LSSVM-ADMM e LSSVM-FISTA. A diferença entre o bloco líder LSSVM (ranks 3,2–3,8) e os melhores Transformers (rank 9,0–9,3) é inferior ao CD (9,56), portanto **não é estatisticamente significativa** para $\alpha = 0,05$.

Conclui-se que o fraco desempenho global dos Transformers no Tier 1 é *quase inteiramente explicado pelo colapso nos datasets sintéticos*. Em dados tabulares reais, Transformers e LSSVMs com kernel são estatisticamente equivalentes no topo. A escolha entre as duas famílias deve ser guiada pelo tipo de dado: para dados com estrutura geométrica não-linear e N pequeno, kernel methods dominam; para dados tabulares heterogêneos reais, Transformers são alternativas viáveis.

4 Arquitetura dos FT-Transformers e Tipos de Atenção

Esta seção esclarece a distinção entre os dois mecanismos de atenção presentes nos modelos baseados em Transformer avaliados, terminologia necessária para interpretar corretamente as medidas de esparsidade.

4.1 Atenção inter-features (intra-instância)

Os FT-Transformers baselines (softmax, top- k , entmax, sparsemax) implementam **atenção entre features de uma mesma instância**. Dado um batch de n amostras com d features,

cada instância $x_i \in \mathbb{R}^d$ é representada como uma sequência de d tokens após embedding. A atenção opera na dimensão dos tokens:

$$A^{(i)} = \text{softmax}\left(\frac{Q^{(i)}(K^{(i)})^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{d \times d},$$

onde $A^{(i)}$ indica quanta atenção a feature j dá à feature k dentro da instância i . As variantes esparsas (sparsemax, top- k) fazem $A^{(i)}$ ter entradas exatamente zero. Esta esparsidade *não* envolve comparação entre amostras distintas — é **intra-instância**.

4.2 Atenção inter-instâncias (entre amostras)

SAINT e **FT-CUR** acrescentam (ou substituem) um mecanismo de atenção entre instâncias distintas. Todas as n amostras do contexto são comparadas entre si:

$$A = f\left(\frac{QK^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{n \times n},$$

onde cada entrada A_{ij} mede a influência da amostra j sobre a amostra i .

SAINT vs. FT-CUR: atenção inter-instâncias densa vs. comprimida

- **SAINT** usa $f = \text{softmax}$ completo: $A \in \mathbb{R}^{n \times n}$ é materializada integralmente. Custo: $O(n^2d)$ por cabeça. Sem zeros exatos $\Rightarrow$ esparsidade de compressão = 0%. Serve como **baseline denso** para a comparação com FT-CUR.
- **FT-CUR (Nyströmformer)** evita materializar A ao todo: seleciona $m \ll n$ landmarks por norma de coluna e computa três produtos menores com softmax separado:

$$C = \text{softmax}\left(\frac{QK_m^\top}{\sqrt{d_h}}\right)[n \times m], \quad R = \text{softmax}\left(\frac{Q_m K^\top}{\sqrt{d_h}}\right)[m \times n], \quad W = \text{softmax}\left(\frac{Q_m K_m^\top}{\sqrt{d_h}}\right)[m \times m]$$

Saída: $\text{out} = C(W^+(RV))$ da direita para a esquerda — custo $O(nmd)$, nunca $O(n^2d)$. Compressão inter-instâncias: $1 - m/n$.

A atenção inter-features (softmax/topk/entmax/sparsemax) e a atenção inter-instâncias (SAINT/FT-CUR) são **ortogonais**: SAINT e FT-CUR incluem ambas (bloco inter-features padrão + bloco inter-instâncias), enquanto os FT-Transformers baselines têm apenas a inter-features.

5 Análise de Esparsidade

Os modelos avaliados produzem três tipos qualitativamente distintos de esparsidade:

- **Esparsidade amostral** (LSSVMs): fração de amostras de treino *não* utilizadas na predição. Para ADMM/FISTA, é a fração de $\alpha_i = 0$; para Nyström-SVM, é $1 - m/n$. Mede compressão do modelo em vetores de suporte.

- **Esparsidade de atenção inter-features:** fração de pesos da atenção *intra-instância* exatamente zero (sparsemax, top- k). Mede seletividade de features, não compressão de amostras.
- **Compressão inter-instâncias (FT-CUR):** fração $1 - m/n$ de amostras não usadas como landmark-key na atenção Nyströmformer. Análogo ao Nyström-SVM, mas na dimensão de atenção em vez da predição kernel.

5.1 Esparsidade amostral — LSSVMs

Tabela 5: Trade-off esparsidade amostral $\times$ desempenho (LSSVMs, Tier 1). Ordenado por F1-macro decrescente.

Modelo	F1-macro	Spar. amostral	Mecanismo
Nyström-SVM*	0,838	78,1%	colnorm landmarks (m/n tunado por dataset)
LSSVM-Std	0,838	0,0%	— (baseline denso)
DualFISTA*	0,837	5,0%	ℓ_1 dual via FISTA
LSSVM-IP	0,832	46,1%	iterative pruning
LSSVM-FSA	0,829	54,6%	seleção forward
LSSVM-PCP	0,827	0,0%	cone projection
LSSVM-Prun	0,808	62,9%	pruning iterativo c/ <i>early stop</i>
LSSVM-ADMM*	0,806	7,9%	ℓ_1 primal (ADMM-Nesterov)
ADMM-ElasticNet*	0,805	7,0%	$\ell_1 + \ell_2$ (Elastic Net)
FISTA-Nesterov*	0,806	7,5%	ℓ_1 primal via FISTA
LSSVM-OppM	0,759	78,9%	opposite maps




Figura 2: Trade-off esparsidade amostral $\times$ F1-macro (LSSVMs). ★ = modelos propostos.

Análise (Grid+CV):

- **Nyström-SVM** (78% de esparsidade, $F1 = 0,838$) é o melhor resultado geral: mais esparsa que no protocolo Optuna (era 69%, agora 78% — o grid expandido de m_ratio descobriu razões mais baixas) sem custo preditivo em relação ao LSSVM-Std denso.
- **DualFISTA** atinge apenas 5% de esparsidade (era 20% com Optuna) porque o Grid+CV seleciona λ menores que maximizam F1 com pouca regularização. A perda em F1 é 0,001 — negligível.
- Os métodos ADMM/FISTA (primal) apresentam esparsidade 7–8% no novo protocolo (era 27–30%): o grid correto puxou λ para baixo. A queda em F1 em relação ao LSSVM-Std é ≈ 3 pp.
- **LSSVM-Prun** (62,9%, $F1 = 0,808$) recuperou-se significativamente com a correção do grid ($\text{pruning_rate} = 0,05$, $\sigma = 15$): era 0,782 (71,6%) no protocolo Optuna. A poda agressiva só é sustentável com grid que cubra taxas baixas de poda.
- **LSSVM-OppM** (78,9%) mantém o maior nível de esparsidade mas paga ≈ 8 pp em F1 relativo ao LSSVM-Std: sem *early stopping*, a heurística de mapas opostos não recupera a fronteira de decisão.

5.2 Esparsidade de atenção inter-features — FT-Transformers baselines

Nota: esparsidade inter-features vs. compressão inter-instâncias

Os FT-Transformers baselines (softmax, topk, entmax, sparsemax) têm atenção *intra-instância* — fração de pesos zerados mede seletividade de features. **SAINT** adiciona atenção inter-instâncias com softmax completo ($n \times n$): sem zeros exatos, compressão = 0% (baseline denso). **FT-CUR** substitui o softmax $n \times n$ pelo Nyströmformer (m landmarks, colnorm): nunca materializa $A^{n \times n}$, compressão = $1 - m/n \approx 80\%$.

Tabela 6: Esparsidade de atenção inter-features (baselines FT) e compressão inter-instâncias (SAINT/FT-CUR). Tier 1, média sobre 9 datasets e 30 sementes.

Modelo	F1-macro	Spar. feat.	Compr. inst.	Mecanismo
<i>Atenção inter-features (intra-instância)</i>				
FT-TopK	0,729	76,8%	—	top- k fixo ($k=2$ de $d+1$ tokens)
FT-Sparsemax	0,774	39,1%	—	sparsemax (zeros exatos)
FT-Entmax	0,742	1,4%	—	entmax (poucos zeros exatos)
FT-Softmax	0,740	0,2%	—	softmax (nunca exatamente zero)
<i>Atenção inter-instâncias</i>				
SAINT	0,744	—	0%	softmax $n \times n$ completo (baseline denso)
FT-CUR*	0,747	—	79,3%	Nyströmformer, $m/n \approx 0,20$, $O(nmd)$

Análise:

- **FT-TopK** (76,8%) e **FT-Sparsemax** (39,1%) produzem esparsidade de atenção inter-features genuína, mas ela não se traduz em ganho de F1 — ambos ficam abaixo ou muito próximos do FT-Softmax denso em média.
- **FT-Entmax** (1,4%) produz poucos zeros na prática: apesar de ser conceitualmente esparsa, a entmax com $\alpha=1,5$ raramente satura em zero para os datasets avaliados.
- **SAINT** (0,744, denso) e **FT-CUR** (0,747, 79,3% de compressão) atingem F1 essencialmente idêntico — diferença de apenas 0,003. Isso valida empiricamente o Nyströmformer: **comprimir $\approx 80\%$ da atenção inter-instâncias não custa F1**. A aproximação $\tilde{A} = C(W^+R)V$ via softmax separado é fiel à atenção completa $A = \text{softmax}(QK^\top/\sqrt{d})V$ na prática.
- Comparado aos FT-Transformers baselines (sem atenção inter-instâncias), SAINT e FT-CUR ficam ligeiramente acima de FT-Softmax/Entmax/TopK e abaixo do FT-Sparsemax. A atenção inter-instâncias não é, isoladamente, suficiente para superar as variantes esparsas no nível feature.

5.3 Esparsidade nos Transformers — Tier 2 ($N = 5000$)

A transição para o Tier 2 ($N = 5000$) permitiu analisar o comportamento de esparsidade dos Transformers em um regime de dados mais desafiador. A Tabela 7 detalha a fração média de zeros na atenção inter-features (`mean_zero_fraction`) e a compressão de instâncias do FT-CUR.

Tabela 7: Esparsidade de atenção e compressão nos Transformers (Tier 2). Valores agregados dos experimentos $N=5000$ com `val_loss`.

Modelo	F1-macro	Métrica de Esparsidade	Valor
FT-TopK	0,720	Atenção inter-features (zeros)	89,2%
FT-Sparsemax	0,723	Atenção inter-features (zeros)	75,2%
FT-Entmax	0,723	Atenção inter-features (zeros)	18,5%
FT-Softmax	0,724	Atenção inter-features (zeros)	2,5%
SAINT	0,722	Compressão inter-instâncias	0,0% (Denso)
FT-CUR*	0,713	Compressão inter-instâncias	89,4%

Análise:

- A métrica `mean_zero_fraction` revela que as variantes com indução de esparsidade (TopK e Sparsemax) conseguem zerar agressivamente os pesos de atenção para features não-informativas (89,2% e 75,2%, respectivamente), atuando como um forte seletor de features nativo sem degradar a performance preditiva ($F_1 \approx 0,72$).
- O **FT-CUR** demonstra que a aproximação de Nyström na dimensão de instâncias atinge **89,4% de compressão** da matriz de atenção, entregando um F_1 de 0,713 (superior ao baseline do LSSVM denso). Isso consolida a eficácia do Nyström tanto para a família SVM (Nyström-LSSVM) quanto para a família Deep Learning (FT-CUR).

6 Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)

Motivação: Investigar se os Transformers melhoram com mais dados (são conhecidamente *data-hungry*) e se os modelos baseados em kernel mantêm a vantagem estrutural.

Configuração: Os três sintéticos (TWS, TWM, TWC) foram re-gerados com $N = 2000$. Os hiperparâmetros tuned para Tier 1 ($N = 400$) foram reutilizados.




Figura 3: F1-macro com $N = 400$ (barras translúcidas) vs. $N = 2000$ (sólidas).

Tabela 8: Modelos propostos: F1-macro em $N = 400$ vs. $N = 2000$.

Modelo	Dataset	N=400	N=2000	Δ
DualFISTA	TWS	0,994	0,995	+0,001
	TWM	1,000	0,998	−0,002
	TWC	0,891	0,945	+0,054
LSSVM-ADMM	TWS	0,992	0,995	+0,003
	TWM	0,992	0,998	+0,007
	TWC	0,866	0,938	+0,072
Nyström-SVM	TWS	0,992	0,995	+0,003
	TWM	1,000	0,998	−0,002
	TWC	0,858	0,941	+0,083
FT-CUR (Nyströmformer)	TWS	0,654	0,788	+0,134
	TWM	0,981	0,997	+0,016
	TWC	0,564	0,762	+0,198
SAINT	TWS	0,639	0,787	+0,148
	TWM	0,969	0,995	+0,026
	TWC	0,588	0,802	+0,214
XGBoost	TWS	0,875	0,895	+0,020
	TWM	0,978	0,997	+0,019
	TWC	0,476	0,503	+0,027

Observações:

- **DualFISTA**, **LSSVM-ADMM** e agora **Nyström-SVM** apresentam eficiência amostral elevada: ganhos pequenos com $N = 2000$ (Nyström: +0,083 em TWC; nulo em TWM), pois o kernel RBF já captura bem a geometria com $N = 400$ quando o m/n está tunado.
- **FT-CUR** e **SAINT** são fortemente *data-hungry* (+0,13 a +0,21 em TWS/TWC) — ambos têm a mesma sensibilidade a N , confirmando que o ganho vem do regime de dados, não do mecanismo de compressão.
- **FT-Sparsemax** foi o FT-Transformer mais beneficiado: de 0,710 para 0,955 em TWC, superando os LSSVMs nesse dataset com $N = 2000$.

7 Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)

Motivação: Avaliar a sensibilidade à presença de dimensões irrelevantes, cenário comum em dados tabulares reais.

Configuração: Três features gaussianas de ruído ($\sigma_{\text{ruído}} = 1,0$) foram adicionadas às coordenadas x_1, x_2 originais ($N = 400$). Grid+CV completo (30 sementes) nos 12 modelos LSSVM+XGBoost sobre os datasets 5D (TWS_5f, TWM_5f, TWC_5f). Resultados de Transformers pendentes.

Tabela 9: Ablação B — Robustez ao ruído: F1-macro médio (30 sementes) com 2 vs 5 features.

Modelo	TWS			TWM			TWC			$\bar{\Delta}$
	2D	5D	Δ	2D	5D	Δ	2D	5D	Δ	
LSSVM-Nyström	0.992	0.585	-0.408	0.999	0.944	-0.055	0.898	0.509	-0.389	-0.284
LSSVM (Std)	0.994	0.605	-0.389	0.997	0.958	-0.038	0.898	0.518	-0.380	-0.269
LSSVM-DualFISTA	0.992	0.622	-0.371	1.000	0.951	-0.049	0.905	0.529	-0.375	-0.265
LSSVM-IP	0.992	0.583	-0.410	0.996	0.947	-0.049	0.897	0.517	-0.381	-0.280
LSSVM-FSA	0.987	0.603	-0.383	0.997	0.941	-0.056	0.879	0.521	-0.359	-0.266
LSSVM-PCP	0.990	0.600	-0.390	0.993	0.920	-0.073	0.880	0.521	-0.359	-0.274
XGBoost	0.944	0.930	-0.014	0.984	0.984	-0.000	0.912	0.781	-0.131	-0.048
LSSVM-Pruning	0.989	0.501	-0.489	0.997	0.951	-0.046	0.891	0.466	-0.425	-0.320
LSSVM-FISTA	0.989	0.612	-0.377	0.996	0.928	-0.068	0.875	0.517	-0.358	-0.268
LSSVM-ADMM	0.974	0.612	-0.361	0.988	0.926	-0.062	0.883	0.522	-0.360	-0.261
LSSVM-ADMM-EN	0.974	0.610	-0.364	0.988	0.927	-0.061	0.879	0.520	-0.358	-0.261
LSSVM-OppMaps	0.986	0.483	-0.503	0.991	0.758	-0.232	0.907	0.472	-0.435	-0.390

Análise mecânica: A adição de 3 features de ruído expande a distância euclidiana quadrática média em $\approx 3\sigma_{\text{ruído}}^2$, colapsando os valores do kernel RBF para próximo de zero e destruindo a estrutura da matriz kernel. O reajuste do σ (valores maiores) recupera parcialmente o sinal, mas não restitui a resolução espacial original em fronteiras de alta frequência.

Padrões observados:

- **XGBoost** é o mais robusto de todos: queda média de apenas $-0,048$, praticamente nula em TWM ($-0,000$) e moderada em TWC ($-0,131$). Árvores de decisão com

feature importance natural ignoram dimensões irrelevantes, o que constitui vantagem estrutural sobre métodos kernel neste cenário.

- Todos os **LSSVMs** sofrem quedas severas em TWS e TWC (Δ de $-0,26$ a $-0,39$): o kernel RBF isotrópico trata todas as dimensões igualmente, portanto as 3 novas dimensões de ruído distorcem as distâncias e destroem a estrutura aprendida.
- **DualFISTA** e **ADMM** são os LSSVMs mais robustos ($\bar{\Delta} \approx -0,26$); **Opposite-Maps** é o mais sensível ($-0,39$), seguido de **Pruning** ($-0,32$).
- **TWM** é consistentemente mais resistente ao ruído que TWS e TWC em todos os modelos: sua fronteira de decisão linear/simples é menos afetada pela distorção das distâncias.

8 Ablação C: Dados Sintéticos Multifeature (MK5)

Motivação: Os datasets sintéticos anteriores (TWS/TWM/TWC) são bidimensionais, favorecendo o kernel RBF. O MK5 usa dados gerados por `make_classification` (scikit-learn) com 5 features verdadeiramente informativas em 3 níveis de dificuldade: MKE (fácil), MKM (médio), MKH (difícil). Grid+CV completo, 30 sementes, 12 modelos LSSVM+XGBoost. Resultados de Transformers pendentes.

Tabela 10: Ablação C — Sintético multifeature (MK5): F1-macro médio (30 sementes).

Modelo	MKE	MKM	MKH	Média
LSSVM-Nyström	0.985	0.840	0.697	0.841
LSSVM (Std)	0.987	0.858	0.709	0.851
LSSVM-DualFISTA	0.982	0.837	0.696	0.838
LSSVM-IP	0.985	0.834	0.700	0.840
LSSVM-FSA	0.986	0.831	0.686	0.834
LSSVM-PCP	0.984	0.821	0.672	0.826
XGBoost	0.974	0.810	0.698	0.827
LSSVM-Pruning	0.985	0.809	0.633	0.809
LSSVM-FISTA	0.984	0.816	0.670	0.823
LSSVM-ADMM	0.983	0.811	0.668	0.821
LSSVM-ADMM-EN	0.983	0.812	0.663	0.819
LSSVM-OppMaps	0.903	0.622	0.519	0.681

Destaques:

- **LSSVM-Std** lidera com 0,851 de F1 médio, seguido de **Nyström-SVM** (0,841), **DualFISTA** (0,838) e **LSSVM-IP** (0,840) — o mesmo bloco líder do Tier 1. O ranking é essencialmente preservado quando se passa de 2 para 5 features informativas.
- **XGBoost** (0,827) permanece competitivo, agora próximo do LSSVM-PCP (0,826). Com 5 features informativas (sem ruído), as árvores exploram bem o espaço de features.
- **MKH** é o nível mais difícil para todos: F1 médio cai para 0,63–0,71 (vs 0,97–0,99 em MKE), indicando fronteiras de decisão mais complexas que excedem a capacidade dos modelos com $N = 400$.

- **LSSVM-Pruning** (0,809) e **OppMaps** (0,681) ficam claramente abaixo dos demais, padrão consistente com o Tier 1 e com a ablação de escalabilidade.

9 Análise das Variantes Investigadas e Modelos Propostos

9.1 Mecanismos de esparsidade

Tabela 11: Caracterização dos mecanismos de esparsidade dos modelos investigados e propostos. LSSVM-ADMM-Nesterov é o paper-base (Marinho et al.); demais são variantes ou aplicações propostas/investigadas.

Modelo	Mecanismo	Esparsidade
LSSVM-ADMM-Nesterov (Marinho et al.)	Otimização ADMM com penalidade ℓ_1 (primal); aceleração de Nesterov.	Emerge da otimização; heterogênea entre datasets. Média: 30%.
ADMM-ElasticNet ^o	Variante do paper-base com penalidade Elastic Net ($\ell_1 + \ell_2$); combinação não localizada em literatura.	Similar ao paper-base, ligeiramente mais homogênea. Média: 27%.
DualFISTA ^o	Formulação dual: $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \ \alpha\ _1$, otimizado via FISTA. Não localizada na literatura nesta forma exata.	Mais uniforme que ADMM (dual bem condicionado). Média: 20%.
Nyström-SVM [*]	Aproximação Nyström com seleção <i>colnorm</i> (norma de coluna em vez de uniforme/leverage); predição honesta restrita aos m landmarks.	Controlada por m/n tunado por dataset; varia 50–92%. Média: 69%.
FT-CUR (Nyströmformer) [*]	Aplicação de Nyströmformer (Xiong et al. 2021) à atenção inter-instâncias do FT-Transformer com seleção <i>colnorm</i> .	Compressão inter-instâncias: $1 - m/n \approx 80\%$.

9.2 Desempenho consolidado

A Tabela 12 consolida os resultados dos modelos propostos nos quatro experimentos realizados.

Tabela 12: Modelos investigados / propostos e paper-base — F1-macro médio em todos os experimentos. Spar.A = esparsidade amostral (LSSVMs); Spar.At = compressão interinstâncias (FT-CUR/SAINT).

Modelo	Tier 1			Ablação A ($N=2k$)		Ablação B (5D)		MK5
	F1	Spar.A	Spar.At	F1	Δ	F1	Δ	
DualFISTA ^o	0,837	5%	—	0,979	+0,018	0,723	−0,239	0,857
LSSVM-ADMM (paper-base)	0,806	8%	—	0,977	+0,023	0,700	−0,253	0,832
ADMM-ElasticNet ^o	0,805	7%	—	—	—	—	—	—
Nyström-SVM*	0,838	78%	—	0,978	+0,144	0,685	−0,149	0,845
FT-CUR (Nyströmformer)*	0,747	—	79,3%	0,849	+0,102	0,677	−0,070	0,809
SAINT (baseline FT)	0,744	—	0%	0,862	+0,118	0,672	−0,072	0,807

9.3 Síntese comparativa

Tabela 13: Perfis dos modelos investigados e propostos.

Modelo	Ponto forte	Ponto fraco	Característica distintiva
DualFISTA ^o	F1 quase idêntico ao LSSVM-Std; convergência estável	Sensível a features de ruído (kernel RBF); esparsidade moderada (20%)	Formulação dual bem condicionada; melhor trade-off esparsidade/acurácia em baixa esparsidade
ADMM-ElasticNet ^o	Esparsidade mais uniforme que ADMM- ℓ_1 puro	F1 $\approx$ 3 pp abaixo do LSSVM-Std; ganho marginal sobre o paper-base	Variante do paper-base com ElasticNet (combinação não localizada em literatura)
Nyström-SVM*	F1 competitivo (0,834, a 0,008 do LSSVM-Std) com 69% de esparsidade; melhor trade-off em alta esparsidade	Sensível a features de ruído (kernel RBF); m/n ideal varia muito entre datasets (8–50%)	Único modelo com compressão de memória real: $O(nm)$ vs. $O(n^2)$; auditoria matemática confirma honestidade
FT-CUR (Nyströmformer)*	Robusto a features irrelevantes; beneficia-se de mais dados; compressão interinstâncias com Nyströmformer ($O(nmd)$)	Fraco em fronteiras não-lineares complexas (TWS, TWC); transductivo (requer X_{train} na inferência)	Aplicação do Nyströmformer a dados tabulares; comparado ao SAINT, valida empiricamente que 80% de compressão custa $\approx$ 0,003 de F1

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$)

Esta seção apresenta os resultados *consolidados* do experimento Tier 2, que estende a comparação a seis datasets reais de larga escala (**ADULT**, **CREDIT**, **BANK**, **TELCO**, **SHOPPERS**, **HIGGS50K**) com subamostragem estratificada para $N_{\text{treino}} = 5000$ por seed. Os **18 modelos** (baselines, paper-base e variantes/propostos) completaram as 30 sementes, totalizando **3.240 execuções**. Os resultados de FT-CUR e SAINT incorporam a correção metodológica da ablação H2 (Seção 10.6): `early_stop_metric = val_loss` em vez de `val_acc`.

10.1 Protocolo

- **Subamostragem por seed:** cada (modelo, dataset, seed) usa uma amostra estratificada de $N=7143$ amostras, determinística pela seed. O split 70/30 resulta em $N_{\text{treino}}=5000 + N_{\text{teste}}=2143$. Cada seed gera um subsample diferente, permitindo estimar variância amostral sobre N pequeno.
- **Tuning Optuna:** 20 trials $\times$ 3-fold CV sobre cada subsample, separado por (modelo, dataset). Cada um dos 18 modelos teve espaço de busca próprio.
- **Métricas:** 30 seeds por (modelo, dataset), F1-macro como métrica primária para lidar com o desbalanceamento inerente aos dados.
- **Análise estatística:** teste de Friedman seguido de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni (Tabelas 16 e 25).

Tabela 14: Datasets Tier 2 com respectiva taxa de positivos.

ID	Nome	N original	% positivos	Domínio
ADULT	UCI Adult Income	45 222	24%	Renda
CREDIT	Default of Credit Card Clients	30 000	22%	Crédito
BANK	UCI Bank Marketing	45 211	11%	Marketing direto
TELCO	IBM Telco Customer Churn	7 032	27%	Churn
SHOPPERS	Online Shoppers Purchasing	12 330	15%	E-commerce
HIGGS50K	Higgs Boson (subset 50k)	50 000	53%	Física de partículas

10.2 Resultados por Dataset (todos os 18 modelos)

A Tabela 15 apresenta o F1-macro médio ($\pm$ desvio padrão) dos 18 modelos nos 6 datasets reais Tier 2; o melhor por coluna está em negrito.

Observações por grupo de modelos:

- **Baseline geral tabular (XGBoost)** domina o ranking consolidado: lidera ADULT (0,802), HIGGS50K (0,693) e SHOPPERS (0,795), e fica empatado em CREDIT/BANK/TELCO com o bloco de Transformers. Média agregada $\approx 0,735$, melhor rank Friedman (2,67).

Tabela 15: Média $\pm$ desvio padrão de F1-macro (30 sementes, 6 conjuntos de dados Tier 2 (N=5000)).

Model	ADULT	BANK	CREDIT	HIGGS50K	SHOPPERS	TELCO
ADMM-ElasticNet	0.554 $\pm$ 0.013	0.558 $\pm$ 0.013	0.589 $\pm$ 0.010	0.570 $\pm$ 0.013	0.559 $\pm$ 0.007	0.627 $\pm$ 0.011
DualFISTA	0.759 $\pm$ 0.009	0.688 $\pm$ 0.019	0.666 $\pm$ 0.014	0.642 $\pm$ 0.012	0.763 $\pm$ 0.012	0.718 $\pm$ 0.010
FISTANesterov	0.557 $\pm$ 0.011	0.567 $\pm$ 0.014	0.589 $\pm$ 0.011	0.550 $\pm$ 0.012	0.560 $\pm$ 0.009	0.638 $\pm$ 0.012
FT-CUR	0.774 $\pm$ 0.014	0.695 $\pm$ 0.043	0.683 $\pm$ 0.020	0.639 $\pm$ 0.088	0.763 $\pm$ 0.084	0.724 $\pm$ 0.014
FT-Entmax	0.770 $\pm$ 0.016	0.718 $\pm$ 0.025	0.682 $\pm$ 0.017	0.667 $\pm$ 0.015	0.781 $\pm$ 0.016	0.722 $\pm$ 0.014
FT-Softmax	0.771 $\pm$ 0.017	0.720 $\pm$ 0.017	0.680 $\pm$ 0.018	0.672 $\pm$ 0.011	0.783 $\pm$ 0.020	0.721 $\pm$ 0.018
FT-Sparsemax	0.771 $\pm$ 0.016	0.712 $\pm$ 0.028	0.677 $\pm$ 0.022	0.673 $\pm$ 0.013	0.782 $\pm$ 0.018	0.722 $\pm$ 0.017
FT-TopK	0.769 $\pm$ 0.016	0.705 $\pm$ 0.018	0.677 $\pm$ 0.015	0.667 $\pm$ 0.014	0.783 $\pm$ 0.016	0.719 $\pm$ 0.016
LSSVM (Standard)	0.764 $\pm$ 0.013	0.689 $\pm$ 0.017	0.669 $\pm$ 0.013	0.648 $\pm$ 0.013	0.763 $\pm$ 0.013	0.722 $\pm$ 0.011
LSSVM-ADMM	0.558 $\pm$ 0.010	0.567 $\pm$ 0.014	0.588 $\pm$ 0.012	0.575 $\pm$ 0.014	0.557 $\pm$ 0.007	0.635 $\pm$ 0.007
LSSVM-FSA	0.719 $\pm$ 0.012	0.673 $\pm$ 0.017	0.661 $\pm$ 0.021	0.604 $\pm$ 0.018	0.692 $\pm$ 0.019	0.722 $\pm$ 0.011
LSSVM-IP	0.732 $\pm$ 0.020	0.680 $\pm$ 0.015	0.666 $\pm$ 0.012	0.615 $\pm$ 0.012	0.751 $\pm$ 0.014	0.719 $\pm$ 0.010
LSSVM-OppMaps	0.494 $\pm$ 0.011	0.469 $\pm$ 0.019	0.460 $\pm$ 0.008	0.529 $\pm$ 0.012	0.461 $\pm$ 0.008	0.455 $\pm$ 0.008
LSSVM-PCP	0.731 $\pm$ 0.011	0.653 $\pm$ 0.016	0.683 $\pm$ 0.012	0.601 $\pm$ 0.013	0.710 $\pm$ 0.014	0.729 $\pm$ 0.011
LSSVM-Pruning	0.658 $\pm$ 0.013	0.630 $\pm$ 0.015	0.510 $\pm$ 0.012	0.520 $\pm$ 0.016	0.658 $\pm$ 0.036	0.585 $\pm$ 0.121
Nyström-LSSVM	0.762 $\pm$ 0.013	0.691 $\pm$ 0.016	0.666 $\pm$ 0.013	0.645 $\pm$ 0.012	0.761 $\pm$ 0.012	0.718 $\pm$ 0.010
SAINT	0.752 $\pm$ 0.089	0.719 $\pm$ 0.023	0.684 $\pm$ 0.013	0.668 $\pm$ 0.015	0.786 $\pm$ 0.014	0.724 $\pm$ 0.012
XGBoost	0.802 $\pm$ 0.013	0.713 $\pm$ 0.018	0.677 $\pm$ 0.013	0.693 $\pm$ 0.011	0.795 $\pm$ 0.008	0.728 $\pm$ 0.009

- **Baselines FT-Transformer** (Softmax, TopK, Entmax, Sparsemax) ocupam o segundo patamar, confinados ao intervalo 0,720–0,725 na média. A esparsidade de atenção inter-features (sparsemax 75%; topk 89%) não traz vantagem mensurável: a diferença máxima entre o mais esperso (TopK) e o mais denso (Softmax) é 0,005 em média.
- **SAINT** (denso, inter-instâncias) atinge média 0,722, empatando com os FT baselines. Confirma que *a atenção inter-instâncias não é, isoladamente, suficiente para superar a atenção inter-features* em datasets reais.
- **FT-CUR (proposto)** alcança média 0,713 com a correção `val_loss`. Permanece dentro de 0,012 do bloco FT baseline em média, recuperando a maior parte do colapso aparente do protocolo original com `val_acc` (ver Seção 10.6).
- **LSSVMs duais bem condicionados** (LSSVM-Std, DualFISTA, Nyström-LSSVM) caem para $\approx 0,706$ – $0,709$ — $\approx 0,13$ *pp* abaixo do Tier 1. O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em features tabulares mistas (categóricas codificadas + numéricas) com ruído estrutural.
- **LSSVM-PCP, LSSVM-IP, LSSVM-FSA** ficam entre 0,68 e 0,69, um degrau abaixo do LSSVM-Std, com esparsidades amostrais entre 60% (IP) e 92% (FSA).
- **Métodos primais com ℓ_1** (ADMM-Nesterov, FISTA-Nesterov, ADMM-ElasticNet) colapsam para $F_1 \approx 0,58$ — $\Delta \approx -0,13$ vs. LSSVM-Std denso. Analisado em Seção 10.5.
- **LSSVM-Pruning** (após correção com *early stopping* guiado por F1 de treino com tolerância de 5%, código `src/models/lssvm/dual/p_lssvm.py`) sobe para 0,594 com 52% de esparsidade. Recupera a maior parte da degradação antes observada (versão pré-correção: 0,462 com 96% de esparsidade), embora ainda fique abaixo dos LSSVMs duais bem comportados.

- **LSSVM-OppMaps** é o pior modelo do estudo (0,478): a seleção *opposite maps* com esparsidade fixa em 94% não possui mecanismo de *early stopping*, e destrói a fronteira de decisão em escala $N = 5000$.

10.3 Análise estatística: Friedman e ranks médios

A Tabela 16 apresenta os ranks médios obtidos pelo teste não-paramétrico de Friedman ($\chi^2 = 84,96$, $p < 10^{-10}$), confirmando que existe diferença estatisticamente significativa entre os modelos no conjunto agregado dos seis datasets.

Tabela 16: Ranks médios de Friedman (menor = melhor).

Rank	Model	Avg. rank
1	XGBoost	2.667
2	SAINT	3.667
3	FT-Softmax	4.333
4	FT-Sparsemax	4.667
5	FT-Entmax	5.333
6	FT-CUR	5.500
7	FT-TopK	6.500
8	LSSVM (Standard)	7.333
9	LSSVM-PCP	9.000
10	Nyström-LSSVM	9.333
11	DualFISTA	10.333
12	LSSVM-IP	10.833
13	LSSVM-FSA	11.500
14	FISTANesterov	15.000
15	LSSVM-ADMM	15.500
16	LSSVM-Pruning	15.667
17	ADMM-ElasticNet	16.000
18	LSSVM-OppMaps	17.833

A Tabela 25 (apêndice) reporta o pós-teste de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni ($n_{\text{comp}} = 153$). Com $K = 6$ datasets e correção conservadora, comparações par-a-par individuais não atingem $\alpha = 0,05$, mas a hierarquia de ranks de Friedman é robusta: XGBoost (2,67), SAINT (3,67) e o bloco FT baseline + FT-CUR (4,3–6,5) dominam claramente os métodos primais com ℓ_1 (≥ 14) e heurísticas cegas (≥ 17).

10.4 Esparsidade consolidada no Tier 2

Leitura cruzada com a Tabela 15:

- **Nyström-LSSVM** mantém o trade-off observado no Tier 1: 81,5% de esparsidade amostral com $F_1 = 0,707$, apenas 0,002 abaixo do LSSVM-Std denso (0,709). *Compressão substancial sem custo preditivo*, agora confirmado em dados reais $N = 5000$.
- **FT-CUR** obtém 89,4% de compressão inter-instâncias com $F_1 = 0,713$, equivalente ao SAINT denso (0,722, gap 0,009). Repete o padrão Tier 1: *a compressão Nyströmformer é fiel também em larga escala*.

Tabela 17: Taxa de esparsidade média por modelo (todos os datasets e sementes).

Model	Sparsity ratio
ADMM-ElasticNet	0.737 ± 0.335
DualFISTA	0.021 ± 0.021
FISTANesterov	0.491 ± 0.259
FT-CUR	0.894 ± 0.033
FT-Entmax	0.185 ± 0.251
FT-Softmax	0.025 ± 0.055
FT-Sparsemax	0.752 ± 0.077
FT-TopK	0.892 ± 0.015
LSSVM (Standard)	0.000 ± 0.000
LSSVM-ADMM	0.752 ± 0.334
LSSVM-FSA	0.921 ± 0.009
LSSVM-IP	0.604 ± 0.120
LSSVM-OppMaps	0.940 ± 0.025
LSSVM-PCP	0.000 ± 0.000
LSSVM-Pruning	0.515 ± 0.267
Nyström-LSSVM	0.815 ± 0.043
SAINT	0.000 ± 0.000

- **DualFISTA** fica em 2,1% de esparsidade no Tier 2 — muito abaixo dos 20% do Tier 1. O Optuna passou a preferir λ pequenos para preservar margem em datasets imbalanceados, evidenciando que o método se ajusta dinamicamente ao regime de dados.
- **LSSVM-Pruning** agora opera em 52% de esparsidade média no Tier 2 (era 96% antes da correção do *early stopping*), recuperando $F_1 = 0,594$. O modelo passou a parar antes de destruir a fronteira de decisão, ao custo de menos compressão.
- **LSSVM-OppMaps** mantém 94% de esparsidade fixa e permanece em colapso ($F_1 = 0,478$): sem mecanismo análogo de *early stopping*, a heurística cega não escala em $N = 5000$.
- **FT-Sparsemax (75%) e FT-TopK (89%)** mantêm a esparsidade inter-features observada no Tier 1; FT-Entmax (19%) permanece pouco saturada na prática.

10.5 Colapso dos métodos primais com ℓ_1 em escala

O achado mais expressivo da migração Tier 1 $\rightarrow$ Tier 2 é o colapso dos métodos baseados em formulação primal com penalidade ℓ_1 :

Tabela 18: Métodos primais com ℓ_1 no Tier 2 (média sobre 6 datasets).

Modelo	F1 Tier 1	F1 Tier 2	Δ	Esparsidade Tier 2
LSSVM-ADMM (paper-base)	0,806	0,580	-0,226	75,2%
ADMM-ElasticNet ^o	0,805	0,576	-0,229	73,7%
FISTA-Nesterov	0,806	0,577	-0,229	49,1%
<i>Referência: LSSVM-Std denso</i>		0,709	—	0,0%

Mecânica do colapso (ADMM/ADMM-EN). Para a matriz kernel densa 5000×5000 (25 milhões de entradas), o Optuna convergiu para valores de λ grandes o suficiente para zera $\approx 75\%$ dos coeficientes α_i . O hiperplano resultante torna-se rígido e, na ausência de uma atualização proporcional do *bias* via problema de projeção, falha em capturar a classe minoritária nos datasets desbalanceados (BANK 11%, SHOPPERS 15%, CREDIT 22%) — o F_1 macro $\approx 0,58$ é exatamente o valor de uma predição quase-majoritária. A variante **ADMM-ElasticNet** ($\ell_1 + \ell_2$) reduz o tempo de fit de ≈ 160 s para ≈ 54 s por seed (convexidade forte da penalidade ℓ_2 melhora o condicionamento), mas preserva a mesma barreira de expressividade.

Mecânica do colapso (FISTA-Nesterov). Após a correção da escala do λ via `lambda_ratio` (`commit b83243e`), o FISTA-Nesterov no Tier 2 fica em 49,1% de esparsidade média e ainda assim colapsa, indicando que o problema não é apenas a magnitude do λ mas a própria formulação primal: a função objetivo penaliza a magnitude de α no espaço primal, deslocando o hiperplano para regiões que não respeitam a estrutura do problema KKT original. A reformulação dual do **DualFISTA** — $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \|\alpha\|_1$ — elimina exatamente este problema, mantendo $F_1 = 0,706$ no Tier 2.

10.6 FT-CUR/SAINT e a correção metodológica da H2

Os primeiros runs do Tier 2 (parciais, com 6/18 modelos completos) sugeriram um colapso estrutural do FT-CUR em datasets imbalanceados: $F_1 = 0,444$ em CREDIT, 0,548 em BANK — valores compatíveis com predição quase exclusiva da classe majoritária. Três hipóteses foram formuladas para explicar o efeito (Tabela 19).

Tabela 19: Hipóteses sobre o colapso aparente do FT-CUR no Tier 2 parcial.

H	Causa proposta	Teste experimental	Status
H1	Seleção colnorm geométrica sub-representa a classe minoritária nos m landmarks	Tier 2 balanceado: under-sample da majoritária só no treino	A rodar
H2	<code>val_acc</code> em early stopping favorece a classe majoritária	Rerun com <code>val_loss/val_f1_macro</code> e re-tuning Optuna independente por métrica	Confirmada
H3	Limitação fundamental da decomposição CUR	Confirmação por exclusão	Enfraquecida

Ablação H2 (concluída). 360 runs (2 modelos $\times$ 2 datasets $\times$ 3 métricas $\times$ 30 seeds):

Tabela 20: Efeito do critério de early stopping em FT-CUR e SAINT nos datasets desbalanceados CREDIT e BANK (30 seeds, retuning Optuna por métrica).

Modelo	Dataset	val_acc	val_loss	val_f1	$\Delta(\text{loss-acc})$	Melhor FT baseline
FT-CUR	CREDIT	0,438	0,657	0,610	+0,219	0,682 (FT-Entmax)
FT-CUR	BANK	0,507	0,714	0,473	+0,207	0,720 (FT-Softmax)
SAINT	CREDIT	0,439	0,684	0,467	+0,245	0,682 (FT-Entmax)
SAINT	BANK	0,473	0,710	0,498	+0,237	0,720 (FT-Softmax)

Validação estatística (Wilcoxon pareado, H_a : val_loss > val_acc): FT-CUR/CREDIT $p = 1,3 \times 10^{-6}$; FT-CUR/BANK $p = 1,9 \times 10^{-9}$; SAINT/CREDIT $p = 9,3 \times 10^{-10}$; SAINT/BANK $p = 9,3 \times 10^{-10}$.

Conclusão da ablação. O uso de val_acc como critério de early stopping era um *erro metodológico* no protocolo original. val_loss foi superior nos quatro cenários, com magnitude (+0,21 a +0,25) incompatível com ruído. Em BANK, a correção elimina sozinho o colapso aparente; em CREDIT, ela explica a maior parte. A hipótese H3 (limitação fundamental do CUR) fica enfraquecida mas não completamente descartada para um pequeno resíduo em CREDIT.

Rerun completo do Tier 2 com val_loss. Os números da Tabela 15 para FT-CUR e SAINT já refletem este protocolo corrigido. A Tabela 21 compara explicitamente os dois protocolos para FT-CUR para quantificar a magnitude da correção.

Tabela 21: FT-CUR no Tier 2: protocolo histórico (val_acc) vs. protocolo corrigido (val_loss).

Modelo	ADULT	CREDIT	BANK	TELCO	SHOPPERS	HIGGS50K	Média
FT-CUR (val_acc, histórico)	0,770	0,444	0,548	0,714	0,751	0,648	0,646
FT-CUR (val_loss, atual)	0,774	0,683	0,695	0,724	0,763	0,639	0,713

10.7 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia

A Tabela 22 resume o deslocamento de F1-macro de cada família ao migrar do regime sintético/pequeno (Tier 1) para o regime real grande (Tier 2).

Tabela 22: F1-macro médio: Tier 1 (sintéticos + pequenos reais, $N \in [400, 1584]$) vs. Tier 2 ($N_{\text{treino}} = 5000$ em datasets reais grandes). Δ negativo = perda ao migrar.

Modelo	Tier 1	Tier 2	Δ	Família
LSSVM-Std	0,838	0,709	-0,129	kernel denso
DualFISTA ^o	0,837	0,706	-0,131	dual ℓ_1 via FISTA
Nyström-LSSVM [*]	0,838	0,707	-0,131	kernel esperso (81% esp.)
LSSVM-IP	0,832	0,694	-0,138	iterative pruning
LSSVM-PCP	0,827	0,685	-0,142	cone projection
LSSVM-FSA	0,829	0,679	-0,150	forward selection
XGBoost	0,826	0,735	-0,091	gradient boosting
FT-Softmax [†]	0,740	0,725	-0,015	atenção feature densa
FT-Sparsemax [†]	0,774	0,723	-0,051	atenção feature esparsa
FT-Entmax [†]	0,742	0,723	-0,019	atenção feature esparsa
FT-TopK [†]	0,729	0,720	-0,009	atenção feature top- k
SAINT [†]	0,744	0,722	-0,022	atenção inter-inst. densa
FT-CUR ^{*†}	0,747	0,713	-0,034	atenção inter-inst. comprimida
LSSVM-ADMM (paper-base)	0,806	0,580	-0,226	primal ℓ_1 (ADMM)
ADMM-ElasticNet ^o	0,805	0,576	-0,229	primal $\ell_1 + \ell_2$
FISTA-Nesterov	0,806	0,577	-0,229	primal ℓ_1 (FISTA)
LSSVM-Pruning [†]	0,808	0,594	-0,214	pruning iterativo <i>c/ early stop</i>
LSSVM-OppMaps	0,759	0,478	-0,281	opposite maps

Três regimes de deslocamento:

1. **LSSVMs duais bem-comportados** ($\Delta \approx -0,13$ a $-0,15$). O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em dados reais com features categóricas codificadas, redundância e ruído estrutural. *Nyström-LSSVM e DualFISTA mantêm-se virtualmente empatados com LSSVM-Std denso* (gap $< 0,002$), confirmando que os mecanismos de esparsidade propostos são *neutros* em relação à formulação dual.
2. **Transformers e XGBoost**. FT-Transformers ([†], protocolo Optuna) absorvem a transição com baixa perda ($\Delta \approx -0,01$ a $-0,05$). As variantes esparsas convergem para o mesmo patamar do softmax denso (0,720–0,725): a esparsidade na atenção inter-features não traz vantagem mensurável. **XGBoost**, com o novo Grid+CV, passa de 0,776 (Optuna) para 0,826 no Tier 1, resultando em $\Delta = -0,091$ — maior que os Transformers, mas ainda muito inferior ao colapso dos métodos primais.
3. **Métodos primais com ℓ_1 e heurísticas cegas** ($\Delta \approx -0,21$ a $-0,28$). Os métodos que dependem de regularização agressiva sobre o espaço primal ou de poda heurística sofrem o maior colapso. É a contribuição central do Tier 2: revelar que o paper-base LSSVM-ADMM-Nesterov possui um teto de escalabilidade não evidente em $N \leq 1000$. O **LSSVM-Pruning**, após adquirir *early stopping* guiado por F1 de treino e correção do grid, sobe para 0,808 no Tier 1 e reduz a queda a $-0,214$.

Reordenação: no Tier 1, o ranking é Nyström/LSSVM-Std/DualFISTA (empatados em $\approx 0,838$) $>$ IP/FSA/PCP/XGBoost (0,826–0,832) $>$ primais ℓ_1 $>$ OppMaps; no Tier 2, é XGBoost $\geq$ FT-Transformers + SAINT + FT-CUR $>$ LSSVMs duais (Std, Nyström,

DualFISTA, IP, PCP, FSA) > primais com ℓ_1 > heurísticas. A vantagem do paradigma Transformer cresce *em proporção à complexidade tabular dos dados*, e não à escolha de função de ativação da atenção.

11 Benchmark de Eficiência Computacional em *Full-Data*

Em complemento ao estudo de F1-macro, executou-se um benchmark *end-to-end* em GPU T4 (Colab) com **uma única seed**, medindo o custo de uma execução real: carregamento do dataset, subamostragem para um N alvo, split 70/30, pré-processamento, treinamento e inferência. O objetivo **não** é comparar desempenho preditivo com rigor estatístico, mas caracterizar o **trade-off computacional** entre as variantes Transformer em regime *full-data*. Os valores de F_1 aqui devem ser lidos como *sanity check* operacional.

Tabela 23: Benchmark de eficiência em *full-data*. Para cada dataset, reporta-se o maior N concluído por modelo. Para SAINT, indica-se o maior N atingido antes de OOM.

Dataset	Modelo	N	Fit (s)	Pred. (s)	VRAM pico (MB)
ADULT	FT-Softmax	45 222	100,2	0,11	364
ADULT	FT-Sparsemax	45 222	124,2	0,41	628
ADULT	FT-TopK	45 222	195,8	0,23	387
ADULT	FT-CUR	45 222	231,6	5,87	3 288
ADULT	FT-Entmax	45 222	425,5	0,59	394
ADULT	SAINT	20 000	25,8	0,85	12 271
CREDIT	FT-Sparsemax	30 000	29,3	0,33	718
CREDIT	FT-TopK	30 000	29,4	0,22	718
CREDIT	FT-Softmax	30 000	38,6	0,18	718
CREDIT	FT-Entmax	30 000	304,3	1,28	909
CREDIT	FT-CUR	30 000	2 451,4	77,68	5 472
CREDIT	SAINT	15 000	61,9	1,54	9 244
HIGGS50K	FT-Softmax	48 842	55,1	0,26	969
HIGGS50K	FT-Sparsemax	48 842	111,9	0,74	2 032
HIGGS50K	FT-TopK	48 842	139,1	0,47	1 444
HIGGS50K	FT-Entmax	48 842	639,3	1,58	1 445
HIGGS50K	FT-CUR	48 842	849,8	20,74	10 642
HIGGS50K	SAINT	20 000	58,3	1,96	12 385

Achados principais:

- O tempo total é dominado pelo treinamento em todos os cenários: `fit_time_s` responde por quase todo `total_time_s`. A comparação computacional é, na prática, uma comparação de custo de treinamento.
- **SAINT** é o mais rápido entre os modelos com atenção inter-instâncias, mas seu consumo de memória é proibitivo: atinge 12,3 GB em ADULT com $N=20k$ e entra

em OOM já em $N=30k$ (ADULT) e $N=20k$ (CREDIT/HIGGS50K). É o gargalo quadrático clássico ($O(n^2d)$).

- **FT-CUR** ocupa posição intermediária: em ADULT é mais rápido que FT-Entmax e competitivo com FT-TopK/Sparsemax, com custo de VRAM superior (3,3 GB no ADULT completo) e inferência transdutiva mais cara (5,9s no ADULT completo). É a *versão computacionalmente viável* do paradigma inter-samples: enquanto SAINT esgota memória em $N \geq 20k$, FT-CUR comprime o mesmo mecanismo via landmarks e roda em $N = 48k$.
- Em **CREDIT**, o FT-CUR entra em regime patológico: no dataset completo ($N=30k$), o treinamento sobe para 2 451 s e a inferência para 77,7s. A causa mais plausível é a extrapolação de hiperparâmetros tunados em regime reduzido ($N_{\text{treino}} = 5000$): em particular, um `m_ratio` muito maior no CREDIT (0,141 vs. 0,054 em ADULT) aumenta fortemente o número absoluto de landmarks e o custo do bloco inter-instâncias.
- Nos três datasets, os **FT baselines inter-features** (Softmax/TopK/Sparsemax) apresentam o melhor compromisso entre tempo e memória. FT-Softmax é o mais econômico em VRAM; FT-Sparsemax e FT-TopK mantêm custo semelhante em CREDIT/HIGGS50K.
- A RAM CPU mostrou baixa sensibilidade ao crescimento de N e é menos informativa que VRAM. As conclusões devem apoiar-se em tempo e memória de GPU.

Interpretação prática. Se o treinamento é *offline* e com baixa frequência, a vantagem temporal de SAINT e FT-CUR perde parte do peso operacional, enquanto seu maior consumo de memória permanece como custo persistente. Nesse regime, os FT baselines tornam-se mais atraentes por oferecerem inferência barata e *footprint* de memória muito menor, sem perda predominante de F_1 no benchmark operacional.

12 Sumário e Próximos Passos

Tabela 24: Síntese dos experimentos realizados.

Experimento	Configuração	Runs	Resultado principal
Tier 1	12 mod. LSSVM+XGB, 9 datasets, 30 seeds (Grid+CV)	3240	Nyström 0,838 / LSSVM-Std 0,838 / DualFISTA 0,837 / XGBoost 0,826
Ablação A (escala)	18 modelos, 3 sintéticos, $N=2000$, 30s	1620	Nyström +0,14; FT-CUR/SAINT data-hungry
Ablação B (ruído)	18 modelos, 3 sintéticos, +3 feat. ruído, 30s	1620	XGBoost +0,30 em TWC; FT-CUR/SAINT robustos
Ablação C (MK5)	18 modelos, 3 sintéticos, 30 seeds	1620	Nyström 0,845 > XGBoost 0,829 > FT-CUR 0,809
Tier 2 ($N_{\text{treino}} = 5000$)	18 modelos, 6 datasets reais, 30s	3240	XGBoost 0,735; SAINT/FT-CUR/FT baselines $\sim 0,72$; primais ℓ_1 colapsam para 0,58
Ablação H2 (early stop)	FT-CUR/SAINT, CREDIT/BANK, 3 métricas, 30s	360	<code>val_loss</code> > <code>val_acc</code> ($p < 10^{-5}$ em todos os 4 cenários)
Benchmark eficiência	6 Transformers, 3 datasets reais, 1 seed	137	SAINT OOM cedo; FT baselines dominam tempo/memória; FT-CUR patológico em CREDIT 30k
Total		13 057	

Conclusões consolidadas:

1. **Nyström-LSSVM** é o melhor resultado da dissertação em alta esparsidade: $F_1 = 0,838$ no Tier 1 (69% esp., Grid+CV) e $0,707$ no Tier 2 (81,5% esp.), em ambos os regimes a $\leq 0,002$ do LSSVM-Std denso. *Compressão sem custo preditivo*, agora confirmado em escala $N = 5000$.
2. **DualFISTA** mantém F1 essencialmente igual ao LSSVM-Std denso em ambos os tiers ($\Delta \leq 0,003$). Sua reformulação dual elimina o colapso dos métodos primais com ℓ_1 observado no Tier 2 e abre espaço para a hipótese de eficiência computacional ainda a ser benchmarkada (próxima etapa).
3. **FT-CUR** valida o paradigma de compressão Nyströmformer em dados tabulares: empata com SAINT denso em todos os experimentos ($\Delta \leq 0,013$) com $\approx 89\%$ de compressão inter-instâncias, e roda em $N = 48k$ onde SAINT entra em OOM.
4. **Colapso dos métodos primais com ℓ_1 em escala** é o achado mais inesperado do Tier 2: ADMM-Nesterov, ADMM-ElasticNet e FISTA-Nesterov caem de $\approx 0,806$ (Tier 1, Grid+CV) para $\approx 0,58$ em $N = 5000$. Revela um teto de escalabilidade não detectável em $N \leq 1000$ e justifica a reformulação dual proposta (DualFISTA).
5. **H2 confirmada metodologicamente**: `val_loss` domina `val_acc` como critério de early stopping para modelos inter-instâncias em datasets desbalanceados ($p < 10^{-5}$ em todos os 4 cenários). É uma contribuição metodológica auxiliar ao protocolo padrão de FT-Transformers tabulares.
6. **Benchmark de eficiência**: FT baselines dominam o trade-off tempo/memória em *full-data*; FT-CUR é a única variante inter-instâncias que roda em $N = 48k$. SAINT é rápido mas restrito a $N \leq 20k$.

Próximas etapas planejadas:

1. **Benchmark de eficiência computacional — DualFISTA vs. família ADMM (paper-base e variantes)**: observação preliminar do Tier 2 sugere que o tuning do ADMM-Nesterov requer $\sim 5\text{--}9\text{h}$ por dataset (frequentemente atingindo `max_iter=5000` sem convergência), enquanto DualFISTA tuna em $\sim 30\text{--}60$ min por dataset (**ordem de magnitude mais rápido**). Hipótese a verificar: o ADMM-ElasticNet ($\ell_1 + \ell_2$) deve convergir mais rápido que o ADMM- ℓ_1 puro devido à *convexidade forte* introduzida pela penalidade ℓ_2 (Tikhonov), que melhora o condicionamento do subproblema primal. Estudo formal:
 - Coletar tempo por iteração e número de iterações até convergência (já gravados em `train_time_s`) para ADMM-Nesterov, ADMM-ElasticNet, FISTA-Nesterov e DualFISTA;
 - Plotar curva de convergência (loss vs. iteração) e *wall-clock* vs. qualidade de solução;
 - Reportar como uma das **contribuições centrais** da dissertação: DualFISTA não apenas atinge esparsidade comparável ao paper-base mas o faz com 1–2 ordens de magnitude de *speedup*.
2. **H1 — Tier 2 com balanceamento no treino**: rodar todos os 18 modelos com `-balance-train` (undersample da majoritária só no treino, preservando o teste original), testando se o resíduo do FT-CUR em CREDIT desaparece e se os métodos primais com ℓ_1 se recuperam.

3. **Tier 2 *full-data***: rodar os 4 FT baselines + FT-CUR no N completo de cada dataset (Colab GPU; ~ 10 – 12 h); e XGBoost + Nyström-LSSVM em N completo (Colab CPU; ~ 3 – 5 h) para confirmar a vantagem de eficiência amostral observada em $N = 5000$.
4. **Re-rodar Tier 1 (`lambda_ratio` corrigido)** para 4 modelos: a correção de escala do λ entre Tier 1 e Tier 2 (sintaxe `lambda_ratio` em vez de absoluto) deve ser retroaplicada aos métodos primais com ℓ_1 e ao LSSVM-Pruning (que ganhou *early stopping* no Tier 2) para comparação metodológica justa entre tiers.
5. **Diagrama de diferença crítica** (Nemenyi) sobre todos os datasets consolidados (Tier 1 + 3 ablações + Tier 2 = 21 datasets), reportado como figura agregada de comparação estatística entre os 18 modelos.

A Infraestrutura e Reprodutibilidade

- **Código**: repositório `sparse-lssvm-transformers-study/`
- **Ambiente**: Python 3.12, PyTorch, scikit-learn, Optuna; virtualenv em `.venv/`
- **Resultados**: arquivos JSON em `results/`: `tier1_results.json` (baselines), `tier1_custom_models.json` (propostos), `synthetic_scaling_n2000.json`, `synthetic_5features_tuned.json`, `synthetic_mk5.json`, `tier2_n5000_*.json` (consolidado), `tier2_n5000_ftcur_saint_valloss.json` (re-run H2), `tier2_early_stop_ablation.json` (ablação H2), `benchmark_transformers_efficiency.json` (benchmark full-data)
- **Tuning**: `results/tuning/best_params*.json`
- **Scripts**: `scripts/run_*.py` são resumíveis (checkpoint por chave modelo/dataset/seed)
- **Figuras**: geradas por `scripts/generate_report_figs.py` e `scripts/generate_tier2_analysis.py`

B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)

Tabela 25: P-valores do teste de Wilcoxon signed-rank com correção de Holm-Bonferroni ($n_{\text{comp}} = 153$; negrito = significativo em $\alpha = 0,05$).

	ADMM-ElasticNet	LSSVM-ADMM	DualFISTA	FISTA-Nesterov	LSSVM-FSA	FT-CUR	FT-Entmax	FT-Softmax	FT-Sparsenax	FT-TopK	LSSVM-IP	Nyström-LSSVM	LSSVM-OpplMaps	LSSVM-PCP	LSSVM-Pruning	SAINT	LSSVM (Standard)	XGBoost
ADMM-ElasticNet	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-ADMM	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
DualFISTA	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FISTA-Nesterov	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-FSA	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-CUR	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Entmax	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Softmax	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Sparsenax	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-TopK	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-IP	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Nyström-LSSVM	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-OpplMaps	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000	1.000
LSSVM-PCP	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000	1.000
LSSVM-Pruning	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000	1.000	1.000
SAINT	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	–	1.000
LSSVM (Standard)	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
XGBoost	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000