

Relatório de Experimentos

Estudo Comparativo: LSSVM Esperso vs. Transformers Tabulares
Dissertação de Mestrado — Experimentos (atualizado em maio de 2026)

Paulo Bernardo

Maio de 2026

Sumário

1	Introdução	2
2	Auditoria da Implementação do Nyström-SVM	3
2.1	As três versões	3
2.2	Verificação experimental	4
2.3	Esparsidade reportada	4
3	Experimento Tier 1: Benchmarks Reais	5
3.1	Resultados por Dataset	5
3.2	Comparação Geral	6
4	Arquitetura dos FT-Transformers e Tipos de Atenção	7
4.1	Atenção inter-features (intra-instância)	7
4.2	Atenção inter-instâncias (entre amostras)	7
5	Análise de Esparsidade	8
5.1	Esparsidade amostral — LSSVMs	8
5.2	Esparsidade de atenção inter-features — FT-Transformers baselines	10
5.3	Esparsidade nos Transformers — Tier 2 ($N = 5000$)	10
6	Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)	11
7	Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)	12
8	Ablação C: Dados Sintéticos Multifeature (MK5)	14
9	Análise das Variantes Investigadas e Modelos Propostos	16
9.1	Mecanismos de esparsidade	16
9.2	Desempenho consolidado	16
9.3	Síntese comparativa	17

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$)	18
10.1 Protocolo	18
10.2 Resultados por Dataset (todos os 18 modelos)	18
10.3 Análise estatística: Friedman e ranks médios	20
10.4 Esparsidade consolidada no Tier 2	20
10.5 Colapso dos métodos primais com ℓ_1 em escala	21
10.6 FT-CUR/SAINT e a correção metodológica da H2	22
10.7 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia	23
11 Benchmark de Eficiência Computacional em <i>Full-Data</i>	25
12 Sumário e Próximos Passos	26
A Infraestrutura e Reprodutibilidade	28
B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)	28

1 Introdução

Este relatório consolida os resultados dos experimentos conduzidos na dissertação, que compara métodos de *Least-Squares Support Vector Machine* (LSSVM) com ênfase em esparsidade contra variantes de *FT-Transformer* com atenção esparsa em tarefas de classificação binária tabular.

O trabalho estende o algoritmo LSSVM-ADMM-Nesterov proposto por Marinho et al. com dois novos mecanismos de esparsidade: (i) **DualFISTA**, formulação dual do LSSVM como LASSO com otimização via ISTA acelerado; e (ii) **Nyström-SVM**, aproximação da matriz kernel por seleção de landmarks via norma de coluna. Como comparativo do lado dos Transformers, avalia-se o **FT-CUR**, que aplica decomposição CUR com colnorm à matriz de atenção.

Auditoria do Nyström-SVM — três versões

A implementação do Nyström-SVM passou por três versões. A versão final, auditada matematicamente (Seção 2), é a apresentada neste relatório.

Versão	Predição	F1 Tier 1
Bug original	$f(x)=K(x, X_{\text{treino}})\alpha + b$ (kernel completo)	0,8427 (inflado)
“Fix” errado	$f(x)=K(x, Z)\alpha[\text{lm_idx}] + b$ (subset ingênuo de α)	0,6678 (colapsado)
Correta	$f(x)=K(x, Z)(W^{-1}C^T\alpha) + b$ (Nyström)	0,8342

A versão correta usa a fórmula matemática da aproximação Nyström ($\tilde{K} = CW^{-1}C^T$), com custo $O(n_{\text{test}} \cdot m)$ e **sem dependência de X_{treino} na predição** (verificado experimentalmente). A perda de F1 em relação ao bug original é de apenas 0,0085, mas agora com $\approx 69\%$ de esparsidade amostral genuína.

Modelos avaliados

Ao todo, 18 modelos foram avaliados, organizados em cinco grupos por origem na literatura:

- **Baseline geral tabular (1): XGBoost** (Chen & Guestrin, 2016) — padrão-ouro para dados tabulares, serve como referência externa às famílias LSSVM e Transformer.
- **LSSVMs baselines (7):** LSSVM-Std (sem esparsidade), LSSVM-PCP, LSSVM-FSA, LSSVM-IP, LSSVM-Pruning, LSSVM-OppMaps, e **FISTA-Nesterov** (LSSVM primal com FISTA — método clássico de Beck & Teboulle, 2009, amplamente documentado).
- **FT-Transformers baselines (5):** variantes com atenção softmax, top- k , entmax e sparsemax — mais **SAINT** (Somepalli et al., 2021; atenção inter-instâncias densa).
- **Paper-base estendido: LSSVM-ADMM-Nesterov** de Marinho et al. — método sobre o qual esta dissertação constrói.
- **Variantes investigadas e modelos propostos (4):**
 - **ADMM-ElasticNet^o**: variante do paper-base com penalidade Elastic Net (combinação ADMM-Nesterov + Elastic Net + LSSVM não localizada explicitamente na literatura como método publicado).

- **DualFISTA[°]**: formulação dual do LSSVM como LASSO ($\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \|\alpha\|_1$), otimizada via FISTA. Ponto de investigação — não localizada na literatura nesta forma exata; pode ser uma reformulação convergente com métodos análogos em SVM ou regressão Lasso.
- **Nyström-SVM (colnorm)***: aproxima $K \in \mathbb{R}^{n \times n}$ via $m \ll n$ landmarks selecionados por norma de coluna (em vez de amostragem uniforme/leverage tradicional); predição restrita aos landmarks ($O(n_{\text{test}} \cdot m)$, auditada).
- **FT-CUR (Nyströmformer)***: aplicação de Nyströmformer (Xiong et al., 2021) à atenção inter-instâncias do FT-Transformer em dados tabulares; seleção de landmarks via colnorm (combinação não localizada como método publicado).

[°] = variante/ponto de investigação; * = aplicação/combinação proposta.

Protocolo experimental

- 30 sementes aleatórias, partição estratificada 70/30.
- Métrica principal: F1-macro (média aritmética do F1 por classe).
- Hiperparâmetros otimizados via Optuna TPE com validação cruzada estratificada de 5 folds.
- Normalização por StandardScaler ajustado apenas no treino.

2 Auditoria da Implementação do Nyström-SVM

2.1 As três versões

O Nyström-SVM aproxima a matriz kernel completa $K \in \mathbb{R}^{n \times n}$ a partir de m landmarks $\{z_1, \dots, z_m\}$ selecionados antes do treino:

$$K \approx CW^{-1}C^{\top}, \quad C = K(X, Z) \in \mathbb{R}^{n \times m}, \quad W = K(Z, Z) \in \mathbb{R}^{m \times m}.$$

O treinamento, via identidade de Woodbury, é correto em todas as versões. A diferença está apenas na predição:

V1 — Bug original. Predizia com o kernel completo:

$$f(x) = K(x, X_{\text{treino}}) \alpha + b.$$

Não tinha esparsidade real (todo X_{treino} era usado em inferência) e produzia $F_1 = 0,8427$ no Tier 1.

V2 — “Fix” ingênuo. Tentativa de restringir aos landmarks pegando apenas o subset de α nos índices dos landmarks:

$$f(x) = K(x, Z) \alpha[\text{lm_idx}] + b.$$

Está **matematicamente errado**: os pesos $\alpha \in \mathbb{R}^n$ foram ajustados para o sistema KKT completo n -dimensional, e simplesmente subseqüenciá-los nos índices dos landmarks não recupera a aproximação Nyström. F1 colapsou para 0,6678.

V3 — Correta (atual). A aproximação Nyström verdadeira é $\tilde{K}(x, X) = K(x, Z) W^{-1} C^\top$. Substituindo em $f(x) = \tilde{K}(x, X) \alpha + b$:

$$f(x) = K(x, Z) (W^{-1} C^\top \alpha) + b = K(x, Z) w_\alpha + b, \quad w_\alpha = W^{-1} C^\top \alpha \in \mathbb{R}^m.$$

O vetor w_α é calculado uma vez ao final do fit e cacheado. Em inferência, só $K(x, Z) \in \mathbb{R}^{n_{\text{test}} \times m}$ é computado — não há mais nenhuma dependência de X_{treino} . F1 = 0,8342.

2.2 Verificação experimental

A implementação V3 foi auditada matematicamente (`scripts/audit_nystrom_lssvm.py`) confirmando três propriedades:

1. **Equivalência matemática.** $\|f_{\text{cache}}(x) - f_{\text{Nyström}}(x)\|_2 = 0$ exatamente, onde $f_{\text{Nyström}}$ usa a fórmula expandida $K(x, Z) W^{-1} C^\top \alpha + b$.
2. **Sem dependência de X_{treino} .** Após o fit, ao apagar X_{treino} do modelo, as predições continuam idênticas ($\|\Delta f\|_2 = 0$). Confirma que apenas Z é usado na inferência.
3. **Custo $O(n_{\text{test}} \cdot m)$.** Mantendo m fixo e variando n_{treino} de 1000 a 6000, o tempo de predição permanece em ≈ 5 ms (não escala com n).

Tabela 1: Comparação direta no BCW (10 sementes, mesmos hiperparâmetros).

Versão	F1 BCW	Diagnóstico
V1 (kernel completo)	0,974	0% de esparsidade real
V2 (α subsetado)	0,360	matematicamente inválida
V3 ($W^{-1} C^\top \alpha$, atual)	0,968	$\approx 80\%$ esparsidade real

A V3 perde apenas 0,006 em relação ao kernel completo no BCW, mostrando que a aproximação Nyström com seleção colnorm é *genuinamente* boa quando bem tunada — a esparsidade não custa quase nada de F1.

2.3 Esparsidade reportada

Com a predição V3, a esparsidade do Nyström-SVM é semanticamente consistente com os demais LSSVMs:

- **ADMM/FISTA:** esparsidade = fração de $\alpha_i = 0$.
- **Nyström:** esparsidade = $1 - m/n$, fração de pontos de treino *não* usados como landmark-key.

A razão m/n é tunada pelo Optuna por dataset; a esparsidade resultante varia entre 50% (TWC) e 92% (PID), com média 69% no Tier 1.

3 Experimento Tier 1: Benchmarks Reais

Nove conjuntos de dados foram utilizados (Tabela 2). Os três últimos (TWS, TWM, TWC) são sintéticos bidimensionais incluídos como controle com fronteiras de decisão conhecidas.

Tabela 2: Conjuntos de dados — Tier 1.

ID	Nome	N	Features	Domínio
BCW	Breast Cancer Wisconsin	569	30	Diagnóstico médico
PID	Pima Indians Diabetes	768	8	Diagnóstico médico
HAB	Haberman Survival	306	3	Sobrevivência
VCP	Vehicle Coupon Purchase	1584	7	Marketing
GCR	German Credit Risk	1000	20	Crédito
AUS	Australian Credit	690	14	Crédito
TWS	Two Spirals (sintético)	400	2	Controle
TWM	Two Moons (sintético)	400	2	Controle
TWC	Checkerboard (sintético)	400	2	Controle

3.1 Resultados por Dataset

A Tabela 3 apresenta o F1-macro médio (30 sementes) para *todos* os modelos. Os melhores valores por coluna estão em negrito.

Tabela 3: F1-macro médio (30 sementes). **Negrito:** melhor por coluna. $\circ$ = variante investigada / ponto de investigação; $\star$ = aplicação/combinção proposta.

Modelo	BCW	PID	HAB	VCP	GCR	AUS	TWS	TWM	TWC	Média
<i>Baseline geral tabular</i>										
XGBoost	0,964	0,732	0,580	0,811	0,699	0,867	0,875	0,978	0,476	0,776
<i>Baselines LSSVM</i>										
LSSVM-Std	0,975	0,729	0,590	0,835	0,697	0,862	0,993	1,000	0,900	0,842
LSSVM-FSA	0,967	0,741	0,590	0,820	0,676	0,859	0,990	1,000	0,893	0,837
LSSVM-IP	0,966	0,727	0,571	0,827	0,690	0,857	0,990	1,000	0,888	0,835
LSSVM-PCP	0,923	0,726	0,629	0,789	0,689	0,857	0,989	0,995	0,872	0,830
FISTA-Nesterov	0,902	0,686	0,617	0,782	0,513	0,844	0,990	0,994	0,873	0,800
LSSVM-Prun	0,969	0,639	0,482	0,801	0,437	0,849	0,994	0,996	0,874	0,782
LSSVM-OppM	0,961	0,456	0,468	0,755	0,585	0,823	0,986	0,990	0,899	0,769
<i>Baselines FT-Transformer</i>										
FT-Sparsemax	0,950	0,691	0,596	0,808	0,662	0,855	0,690	1,000	0,710	0,774
SAINT	0,949	0,710	0,535	0,774	0,676	0,859	0,639	0,969	0,588	0,744
FT-Entmax	0,953	0,700	0,538	0,800	0,657	0,860	0,667	0,999	0,504	0,742
FT-Softmax	0,959	0,708	0,541	0,810	0,658	0,854	0,653	1,000	0,478	0,740
FT-TopK	0,950	0,692	0,501	0,808	0,669	0,857	0,640	0,974	0,468	0,729
<i>Paper-base estendido</i>										
LSSVM-ADMM-Nesterov	0,899	0,684	0,616	0,783	0,608	0,842	0,992	0,992	0,866	0,809
<i>Variantes investigadas / propostos</i>										
DualFISTA $\circ$	0,976	0,734	0,589	0,834	0,698	0,862	0,994	1,000	0,891	0,842
Nyström-SVM $\star$	0,970	0,715	0,602	0,820	0,690	0,861	0,992	1,000	0,858	0,834
ADMM-ElasticNet $\circ$	0,899	0,692	0,618	0,787	0,592	0,844	0,990	0,995	0,861	0,809
FT-CUR $\star$ (Nyströmformer)	0,946	0,715	0,523	0,824	0,665	0,851	0,654	0,981	0,564	0,747

3.2 Comparação Geral

A Figura 1 mostra o F1-macro médio ($\pm$ dp) agregado sobre todos os datasets e sementes para cada modelo.




Figura 1: F1-macro médio $\pm$ dp (30 sementes $\times$ 9 datasets). ★ indica modelos propostos; vermelho = DualFISTA, verde = Nyström-SVM, laranja = FT-CUR.

Observações principais:

- **XGBoost** (baseline geral tabular) atinge 0,776 no Tier 1 — abaixo do top 5 dos LSSVMs e abaixo do DualFISTA/Nyström. Vence em AUS (0,867) mas colapsa em TWC (0,476, fronteira xadrez não-linear que favorece kernel RBF). Mostra que para dados tabulares com estrutura geométrica, métodos kernel podem superar gradient boosting.
- **DualFISTA** alcança F1-macro médio de 0,8418 — virtualmente igual ao LSSVM-Std completo (0,8424, diferença 0,0006) com 20,1% de esparsidade. É o único modelo esperso que se aproxima do desempenho do baseline sem esparsidade.
- **Nyström-SVM** (0,834) é o segundo melhor entre os modelos propostos: fica a apenas 0,008 do LSSVM-Std completo, mas com $\approx$ 69% de esparsidade amostral (mais que o triplo do DualFISTA). É o melhor trade-off F1/esparsidade entre os modelos com alta esparsidade.
- O **LSSVM-ADMM** e suas variantes (ElasticNet, FISTA-Nesterov) ficam $\approx$ 3 pp abaixo do LSSVM-Std, com esparsidade entre 27–30%.
- Todos os FT-Transformers baselines (softmax, topk, entmax, sparsemax) ficam abaixo de 0,78, com queda acentuada nos sintéticos TWS e TWC.
- **SAINT** (0,744, atenção inter-instâncias densa) e **FT-CUR** (Nyströmformer, 0,747) atingem F1 essencialmente idêntico — diferença de 0,003. Como o FT-CUR comprime $\approx$ 79% da atenção inter-instâncias e o SAINT é denso, isso valida a aproximação Nyströmformer: **a compressão não custa F1**.

4 Arquitetura dos FT-Transformers e Tipos de Atenção

Esta seção esclarece a distinção entre os dois mecanismos de atenção presentes nos modelos baseados em Transformer avaliados, terminologia necessária para interpretar corretamente as medidas de esparsidade.

4.1 Atenção inter-features (intra-instância)

Os FT-Transformers baselines (softmax, top- k , entmax, sparsemax) implementam **atenção entre features de uma mesma instância**. Dado um batch de n amostras com d features, cada instância $x_i \in \mathbb{R}^d$ é representada como uma sequência de d tokens após embedding. A atenção opera na dimensão dos tokens:

$$A^{(i)} = \text{softmax}\left(\frac{Q^{(i)}(K^{(i)})^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{d \times d},$$

onde $A^{(i)}$ indica quanta atenção a feature j dá à feature k dentro da instância i . As variantes esparsas (sparsemax, top- k) fazem $A^{(i)}$ ter entradas exatamente zero. Esta esparsidade *não* envolve comparação entre amostras distintas — é **intra-instância**.

4.2 Atenção inter-instâncias (entre amostras)

SAINT e **FT-CUR** acrescentam (ou substituem) um mecanismo de atenção entre instâncias distintas. Todas as n amostras do contexto são comparadas entre si:

$$A = f\left(\frac{QK^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{n \times n},$$

onde cada entrada A_{ij} mede a influência da amostra j sobre a amostra i .

SAINT vs. FT-CUR: atenção inter-instâncias densa vs. comprimida

- **SAINT** usa $f = \text{softmax}$ completo: $A \in \mathbb{R}^{n \times n}$ é materializada integralmente. Custo: $O(n^2d)$ por cabeça. Sem zeros exatos $\Rightarrow$ esparsidade de compressão = 0%. Serve como **baseline denso** para a comparação com FT-CUR.
- **FT-CUR (Nyströmformer)** evita materializar A ao todo: seleciona $m \ll n$ landmarks por norma de coluna e computa três produtos menores com softmax separado:

$$C = \text{softmax}\left(\frac{QK_m^\top}{\sqrt{d_h}}\right)[n \times m], \quad R = \text{softmax}\left(\frac{Q_m K^\top}{\sqrt{d_h}}\right)[m \times n], \quad W = \text{softmax}\left(\frac{Q_m K_m^\top}{\sqrt{d_h}}\right)[m \times m]$$

Saída: $\text{out} = C(W^+(RV))$ da direita para a esquerda — custo $O(nmd)$, nunca $O(n^2d)$. Compressão inter-instâncias: $1 - m/n$.

A atenção inter-features (softmax/topk/entmax/sparsemax) e a atenção inter-instâncias (SAINT/FT-CUR) são **ortogonais**: SAINT e FT-CUR incluem ambas (bloco inter-features padrão + bloco inter-instâncias), enquanto os FT-Transformers baselines têm apenas a inter-features.

5 Análise de Esparsidade

Os modelos avaliados produzem três tipos qualitativamente distintos de esparsidade:

- **Esparsidade amostral** (LSSVMs): fração de amostras de treino *não* utilizadas na predição. Para ADMM/FISTA, é a fração de $\alpha_i = 0$; para Nyström-SVM, é $1 - m/n$. Mede compressão do modelo em vetores de suporte.
- **Esparsidade de atenção inter-features**: fração de pesos da atenção *intra-instância* exatamente zero (sparsemax, top- k). Mede seletividade de features, não compressão de amostras.
- **Compressão inter-instâncias** (FT-CUR): fração $1 - m/n$ de amostras não usadas como landmark-key na atenção Nyströmformer. Análogo ao Nyström-SVM, mas na dimensão de atenção em vez da predição kernel.

5.1 Esparsidade amostral — LSSVMs

Tabela 4: Trade-off esparsidade amostral $\times$ desempenho (LSSVMs, Tier 1). Ordenado por F1-macro decrescente.

Modelo	F1-macro	Spar. amostral	Mecanismo
LSSVM-Std	0,8424	0,0%	— (baseline denso)
DualFISTA*	0,8418	20,1%	ℓ_1 dual via FISTA
LSSVM-FSA	0,8373	45,9%	seleção forward
LSSVM-IP	0,8352	57,1%	iterative pruning
Nyström-SVM*	0,8342	69,0%	colnorm landmarks (m/n tunado por dataset)
LSSVM-PCP	0,8300	0,0%	cone projection
LSSVM-ADMM*	0,8089	30,0%	ℓ_1 primal (ADMM-Nesterov)
ADMM-ElasticNet*	0,8086	27,4%	$\ell_1 + \ell_2$ (Elastic Net)
FISTA-Nesterov*	0,8000	27,4%	ℓ_1 primal via FISTA
LSSVM-Prun	0,7825	71,6%	pruning pós-treino
LSSVM-OppM	0,7692	79,3%	opposite maps




Figura 2: Trade-off esparsidade amostral $\times$ F1-macro (LSSVMs). ★ = modelos propostos.

Análise:

- **DualFISTA** apresenta o melhor trade-off em baixa esparsidade: 20% com perda de apenas 0,0006 em F1.
- **Nyström-SVM** oferece o melhor trade-off em alta esparsidade: 69% com perda de apenas 0,008 em F1. É o único modelo que combina esparsidade $> 50\%$ com F1 dentro de 1% do LSSVM-Std.
- Os métodos ADMM/FISTA (primal) produzem esparsidades entre 27–30% com queda de 3–4 pp. A esparsidade é heterogênea entre datasets.
- Os mais agressivos em esparsidade (LSSVM-Prun, 71%; LSSVM-OppM, 79%) pagam custo de $\approx 6\text{--}8$ pp em F1. É digno de nota o caso do **LSSVM-Prun**: a implementação clássica de poda iterativa cega (que apenas aplica a *pruning rate* sem validação na curva de treinamento) causou colapso total da fronteira de decisão (poda catastrófica) em dados com alta dimensão de ruído (ex.: conjunto CREDIT), derrubando drasticamente a performance. Isso corrobora que a esparsidade agressiva só é sustentável quando guiada por esquemas de *early-stopping* ou métodos estruturados (como o Nyström ou penalizações matemáticas do ADMM/FISTA).

5.2 Esparsidade de atenção inter-features — FT-Transformers baselines

Nota: esparsidade inter-features vs. compressão inter-instâncias

Os FT-Transformers baselines (softmax, topk, entmax, sparsemax) têm atenção *intra-instância* — fração de pesos zerados mede seletividade de features. **SAINT** adiciona atenção inter-instâncias com softmax completo ($n \times n$): sem zeros exatos, compressão = 0% (baseline denso). **FT-CUR** substitui o softmax $n \times n$ pelo Nyströmformer (m landmarks, colnorm): nunca materializa $A^{n \times n}$, compressão = $1 - m/n \approx 80\%$.

Tabela 5: Esparsidade de atenção inter-features (baselines FT) e compressão inter-instâncias (SAINT/FT-CUR). Tier 1, média sobre 9 datasets e 30 sementes.

Modelo	F1-macro	Spar. feat.	Compr. inst.	Mecanismo
<i>Atenção inter-features (intra-instância)</i>				
FT-TopK	0,729	76,8%	—	top- k fixo ($k=2$ de $d+1$ tokens)
FT-Sparsemax	0,774	39,1%	—	sparsemax (zeros exatos)
FT-Entmax	0,742	1,4%	—	entmax (poucos zeros exatos)
FT-Softmax	0,740	0,2%	—	softmax (nunca exatamente zero)
<i>Atenção inter-instâncias</i>				
SAINT	0,744	—	0%	softmax $n \times n$ completo (baseline denso)
FT-CUR*	0,747	—	79,3%	Nyströmformer, $m/n \approx 0,20$, $O(nmd)$

Análise:

- **FT-TopK** (76,8%) e **FT-Sparsemax** (39,1%) produzem esparsidade de atenção inter-features genuína, mas ela não se traduz em ganho de F1 — ambos ficam abaixo ou muito próximos do FT-Softmax denso em média.
- **FT-Entmax** (1,4%) produz poucos zeros na prática: apesar de ser conceitualmente esparso, a entmax com $\alpha=1,5$ raramente satura em zero para os datasets avaliados.
- **SAINT** (0,744, denso) e **FT-CUR** (0,747, 79,3% de compressão) atingem F1 essencialmente idêntico — diferença de apenas 0,003. Isso valida empiricamente o Nyströmformer: **comprimir $\approx 80\%$ da atenção inter-instâncias não custa F1**. A aproximação $\tilde{A} = C(W^+R)V$ via softmax separado é fiel à atenção completa $A = \text{softmax}(QK^\top/\sqrt{d})V$ na prática.
- Comparado aos FT-Transformers baselines (sem atenção inter-instâncias), SAINT e FT-CUR ficam ligeiramente acima de FT-Softmax/Entmax/TopK e abaixo do FT-Sparsemax. A atenção inter-instâncias não é, isoladamente, suficiente para superar as variantes esparsas no nível feature.

5.3 Esparsidade nos Transformers — Tier 2 ($N = 5000$)

A transição para o Tier 2 ($N = 5000$) permitiu analisar o comportamento de esparsidade dos Transformers em um regime de dados mais desafiador. A Tabela 6 detalha a fração média

de zeros na atenção inter-features (`mean_zero_fraction`) e a compressão de instâncias do FT-CUR.

Tabela 6: Esparsidade de atenção e compressão nos Transformers (Tier 2). Valores agregados dos experimentos $N=5000$ com `val_loss`.

Modelo	F1-macro	Métrica de Esparsidade	Valor
FT-TopK	0,720	Atenção inter-features (zeros)	89,2%
FT-Sparsemax	0,723	Atenção inter-features (zeros)	75,2%
FT-Entmax	0,723	Atenção inter-features (zeros)	18,5%
FT-Softmax	0,724	Atenção inter-features (zeros)	2,5%
SAINT	0,722	Compressão inter-instâncias	0,0% (Dense)
FT-CUR*	0,713	Compressão inter-instâncias	89,4%

Análise:

- A métrica `mean_zero_fraction` revela que as variantes com indução de esparsidade (TopK e Sparsemax) conseguem zerar agressivamente os pesos de atenção para features não-informativas (89,2% e 75,2%, respectivamente), atuando como um forte seletor de features nativo sem degradar a performance preditiva ($F_1 \approx 0,72$).
- O **FT-CUR** demonstra que a aproximação de Nyström na dimensão de instâncias atinge **89,4% de compressão** da matriz de atenção, entregando um F_1 de 0,713 (superior ao baseline do LSSVM denso). Isso consolida a eficácia do Nyström tanto para a família SVM (Nyström-LSSVM) quanto para a família Deep Learning (FT-CUR).

6 Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)

Motivação: Investigar se os Transformers melhoram com mais dados (são conhecidamente *data-hungry*) e se os modelos baseados em kernel mantêm a vantagem estrutural.

Configuração: Os três sintéticos (TWS, TWM, TWC) foram re-gerados com $N = 2000$. Os hiperparâmetros tuned para Tier 1 ($N = 400$) foram reutilizados.




Figura 3: F1-macro com $N = 400$ (barras translúcidas) vs. $N = 2000$ (sólidas).

Tabela 7: Modelos propostos: F1-macro em $N = 400$ vs. $N = 2000$.

Modelo	Dataset	N=400	N=2000	Δ
DualFISTA	TWS	0,994	0,995	+0,001
	TWM	1,000	0,998	-0,002
	TWC	0,891	0,945	+0,054
LSSVM-ADMM	TWS	0,992	0,995	+0,003
	TWM	0,992	0,998	+0,007
	TWC	0,866	0,938	+0,072
Nyström-SVM	TWS	0,992	0,995	+0,003
	TWM	1,000	0,998	-0,002
	TWC	0,858	0,941	+0,083
FT-CUR (Nyströmformer)	TWS	0,654	0,788	+0,134
	TWM	0,981	0,997	+0,016
	TWC	0,564	0,762	+0,198
SAINT	TWS	0,639	0,787	+0,148
	TWM	0,969	0,995	+0,026
	TWC	0,588	0,802	+0,214
XGBoost	TWS	0,875	0,895	+0,020
	TWM	0,978	0,997	+0,019
	TWC	0,476	0,503	+0,027

Observações:

- **DualFISTA**, **LSSVM-ADMM** e agora **Nyström-SVM** apresentam eficiência amostral elevada: ganhos pequenos com $N = 2000$ (Nyström: +0,083 em TWC; nulo em TWM), pois o kernel RBF já captura bem a geometria com $N = 400$ quando o m/n está tunado.
- **FT-CUR** e **SAINT** são fortemente *data-hungry* (+0,13 a +0,21 em TWS/TWC) — ambos têm a mesma sensibilidade a N , confirmando que o ganho vem do regime de dados, não do mecanismo de compressão.
- **FT-Sparsemax** foi o FT-Transformer mais beneficiado: de 0,710 para 0,955 em TWC, superando os LSSVMs nesse dataset com $N = 2000$.

7 Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)

Motivação: Avaliar a sensibilidade à presença de dimensões irrelevantes, cenário comum em dados tabulares reais.

Configuração: Três features gaussianas de ruído ($\sigma_{\text{ruído}} = 1,0$) foram adicionadas às coordenadas x_1, x_2 originais ($N = 400$). Avaliou-se o cenário com σ **reajustado** (novo tuning para os dados em 5D).




Figura 4: F1-macro: 2D original (translúcido) vs. 5D com σ reajustado (sólido).

Tabela 8: Modelos propostos: F1-macro em 2D vs. 5D reajustado.

Modelo	Dataset	2D	5D reaj.	Δ
DualFISTA	TWS	0,994	0,648	−0,346
	TWM	1,000	0,962	−0,038
	TWC	0,891	0,559	−0,332
LSSVM-ADMM	TWS	0,992	0,632	−0,360
	TWM	0,992	0,920	−0,072
	TWC	0,866	0,549	−0,317
Nyström-SVM	TWS	0,992	0,560	−0,432
	TWM	1,000	0,966	−0,034
	TWC	0,858	0,529	−0,329
FT-CUR (Nyströmformer)	TWS	0,654	0,607	−0,047
	TWM	0,981	0,928	−0,053
	TWC	0,564	0,495	−0,069
SAINT	TWS	0,639	0,595	−0,044
	TWM	0,969	0,930	−0,039
	TWC	0,588	0,490	−0,098
XGBoost	TWS	0,875	0,927	+0,052
	TWM	0,978	0,982	+0,004
	TWC	0,476	0,772	+0,296

Análise mecânica: A adição de 3 features de ruído expande a distância euclidiana quadrática média em $\approx 3\sigma_{\text{ruído}}^2$, colapsando os valores do kernel RBF para próximo de zero e destruindo a estrutura da matriz kernel. O reajuste do σ (valores maiores) recupera parcialmente o sinal, mas não restitui a resolução espacial original em fronteiras de alta frequência.

Padrões observados:

- **DualFISTA, LSSVM-ADMM e Nyström-SVM** sofrem quedas severas em TWS e TWC (Δ de $-0,33$ a $-0,43$), pelo mesmo motivo estrutural: o kernel RBF não distingue features informativas de ruído. O Nyström, agora com base $> 0,85$ em 2D, tem queda proporcionalmente similar aos outros LSSVMs.

- **FT-CUR** e **SAINT** são notavelmente robustos ($\Delta \approx -0,04$ a $-0,10$): a atenção opera sobre representações aprendidas dos tokens, não sobre distâncias brutas entre amostras. Features irrelevantes têm impacto marginal porque o modelo aprende a ignorá-las. Esta é a vantagem estrutural mais clara dos Transformers tabulares sobre os métodos kernel neste cenário.
- **XGBoost** *melhora* com features extras ($\Delta = +0,05$ a $+0,30$): árvores aproveitam o sinal adicional. Em TWC vai de 0,476 (2D) para 0,772 (5D retunado) — o ganho mais expressivo do estudo. Confirma a complementaridade dos paradigmas: kernel para geometria pura, árvores para feature-rich tabular.

8 Ablação C: Dados Sintéticos Multifeature (MK5)

Motivação: Os datasets sintéticos anteriores (TWS/TWM/TWC) são bidimensionais, favorecendo o kernel RBF. O MK5 usa dados gerados por `make_classification` (scikit-learn) com 5 features verdadeiramente informativas em 3 níveis de dificuldade de separação.

Tabela 9: Ablação C (MK5) — F1-macro médio (30 sementes). MKE = fácil, MKM = médio, MKH = difícil. ★ = proposto. Spar.A = esparsidade amostral; Spar.At = esparsidade de atenção.

Modelo	MKE	MKM	MKH	Média	Spar.A	Spar.At
<i>Baseline geral tabular</i>						
XGBoost	0,978	0,820	0,690	0,829	—	—
<i>Baselines LSSVM</i>						
LSSVM-Std	0,987	0,859	0,729	0,859	0,0%	—
LSSVM-FSA	0,986	0,833	0,696	0,838	45,0%	—
LSSVM-IP	0,989	0,819	0,683	0,830	58,1%	—
LSSVM-PCP	0,973	0,827	0,683	0,828	0,0%	—
LSSVM-ADMM	0,986	0,825	0,685	0,832	9,6%	—
LSSVM-Prun	0,988	0,601	0,622	0,737	75,5%	—
LSSVM-OppM	0,888	0,632	0,523	0,681	78,0%	—
<i>Baselines FT-Transformer</i>						
FT-Softmax	0,976	0,797	0,669	0,814	—	0,2%
FT-Entmax	0,976	0,801	0,657	0,811	—	1,4%
FT-Sparsemax	0,975	0,787	0,652	0,805	—	39,1%
FT-TopK	0,975	0,768	0,644	0,796	—	76,8%
<i>Modelos propostos</i>						
DualFISTA★	0,987	0,858	0,726	0,857	21,4%	—
Nyström-SVM★	0,986	0,839	0,712	0,845	64,3%	—
FT-CUR★ (Nyströmformer)	0,967	0,797	0,664	0,809	—	78,2%
SAINT	0,971	0,782	0,668	0,807	—	0%




Figura 5: Ablação C — MK5: F1-macro por nível de dificuldade.

Destaques:

- **DualFISTA** (0,857) quase empata com o LSSVM-Std (0,859) com 21% de esparsidade — padrão consistente com o Tier 1.
- **Nyström-SVM** (0,845) supera todos os FT-Transformers neste cenário multifeature, com 64% de esparsidade: a aproximação Nyström é eficaz quando há features informativas distribuídas em dimensão maior que 2D.
- **SAINT** (0,807) e **FT-CUR** (0,809) ficam novamente empatados (diferença 0,002), confirmando que a compressão Nyströmformer no FT-CUR não custa F1 também em dados multifeature.

9 Análise das Variantes Investigadas e Modelos Propostos

9.1 Mecanismos de esparsidade

Tabela 10: Caracterização dos mecanismos de esparsidade dos modelos investigados e propostos. LSSVM-ADMM-Nesterov é o paper-base (Marinho et al.); demais são variantes ou aplicações propostas/investigadas.

Modelo	Mecanismo	Esparsidade
LSSVM-ADMM-Nesterov (Marinho et al.)	Otimização ADMM com penalidade ℓ_1 (primal); aceleração de Nesterov.	Emerge da otimização; heterogênea entre datasets. Média: 30%.
ADMM-ElasticNet ^o	Variante do paper-base com penalidade Elastic Net ($\ell_1 + \ell_2$); combinação não localizada em literatura.	Similar ao paper-base, ligeiramente mais homogênea. Média: 27%.
DualFISTA ^o	Formulação dual: $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \ \alpha\ _1$, otimizado via FISTA. Não localizada na literatura nesta forma exata.	Mais uniforme que ADMM (dual bem condicionado). Média: 20%.
Nyström-SVM [*]	Aproximação Nyström com seleção <i>colnorm</i> (norma de coluna em vez de uniforme/leverage); predição honesta restrita aos m landmarks.	Controlada por m/n tunado por dataset; varia 50–92%. Média: 69%.
FT-CUR (Nyströmformer) [*]	Aplicação de Nyströmformer (Xiong et al. 2021) à atenção inter-instâncias do FT-Transformer com seleção <i>colnorm</i> .	Compressão inter-instâncias: $1 - m/n \approx 80\%$.

9.2 Desempenho consolidado

A Tabela 11 consolida os resultados dos modelos propostos nos quatro experimentos realizados.

Tabela 11: Modelos investigados / propostos e paper-base — F1-macro médio em todos os experimentos. Spar.A = esparsidade amostral (LSSVMs); Spar.At = compressão interinstâncias (FT-CUR/SAINT).

Modelo	Tier 1			Ablação A ($N=2k$)		Ablação B (5D)		MK5
	F1	Spar.A	Spar.At	F1	Δ	F1	Δ	
DualFISTA ^o	0,842	20%	—	0,979	+0,018	0,723	−0,239	0,857
LSSVM-ADMM (paper-base)	0,809	30%	—	0,977	+0,023	0,700	−0,253	0,832
ADMM-ElasticNet ^o	0,809	27%	—	—	—	—	—	—
Nyström-SVM*	0,834	69%	—	0,978	+0,144	0,685	−0,149	0,845
FT-CUR (Nyströmformer)*	0,747	—	79,3%	0,849	+0,102	0,677	−0,070	0,809
SAINT (baseline FT)	0,744	—	0%	0,862	+0,118	0,672	−0,072	0,807

9.3 Síntese comparativa

Tabela 12: Perfis dos modelos investigados e propostos.

Modelo	Ponto forte	Ponto fraco	Característica distintiva
DualFISTA ^o	F1 quase idêntico ao LSSVM-Std; convergência estável	Sensível a features de ruído (kernel RBF); esparsidade moderada (20%)	Formulação dual bem condicionada; melhor trade-off esparsidade/acurácia em baixa esparsidade
ADMM-ElasticNet ^o	Esparsidade mais uniforme que ADMM- ℓ_1 puro	F1 $\approx$ 3 pp abaixo do LSSVM-Std; ganho marginal sobre o paper-base	Variante do paper-base com ElasticNet (combinação não localizada em literatura)
Nyström-SVM*	F1 competitivo (0,834, a 0,008 do LSSVM-Std) com 69% de esparsidade; melhor trade-off em alta esparsidade	Sensível a features de ruído (kernel RBF); m/n ideal varia muito entre datasets (8–50%)	Único modelo com compressão de memória real: $O(nm)$ vs. $O(n^2)$; auditoria matemática confirma honestidade
FT-CUR (Nyströmformer)*	Robusto a features irrelevantes; beneficia-se de mais dados; compressão interinstâncias com Nyströmformer ($O(nmd)$)	Fraco em fronteiras não-lineares complexas (TWS, TWC); transductivo (requer X_{train} na inferência)	Aplicação do Nyströmformer a dados tabulares; comparado ao SAINT, valida empiricamente que 80% de compressão custa $\approx$ 0,003 de F1

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$)

Esta seção apresenta os resultados *consolidados* do experimento Tier 2, que estende a comparação a seis datasets reais de larga escala (**ADULT**, **CREDIT**, **BANK**, **TELCO**, **SHOPPERS**, **HIGGS50K**) com subamostragem estratificada para $N_{\text{treino}} = 5000$ por seed. Os **18 modelos** (baselines, paper-base e variantes/propostos) completaram as 30 sementes, totalizando **3.240 execuções**. Os resultados de FT-CUR e SAINT incorporam a correção metodológica da ablação H2 (Seção 10.6): `early_stop_metric = val_loss` em vez de `val_acc`.

10.1 Protocolo

- **Subamostragem por seed:** cada (modelo, dataset, seed) usa uma amostra estratificada de $N=7143$ amostras, determinística pela seed. O split 70/30 resulta em $N_{\text{treino}}=5000 + N_{\text{teste}}=2143$. Cada seed gera um subsample diferente, permitindo estimar variância amostral sobre N pequeno.
- **Tuning Optuna:** 20 trials $\times$ 3-fold CV sobre cada subsample, separado por (modelo, dataset). Cada um dos 18 modelos teve espaço de busca próprio.
- **Métricas:** 30 seeds por (modelo, dataset), F1-macro como métrica primária para lidar com o desbalanceamento inerente aos dados.
- **Análise estatística:** teste de Friedman seguido de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni (Tabelas 15 e 24).

Tabela 13: Datasets Tier 2 com respectiva taxa de positivos.

ID	Nome	N original	% positivos	Domínio
ADULT	UCI Adult Income	45 222	24%	Renda
CREDIT	Default of Credit Card Clients	30 000	22%	Crédito
BANK	UCI Bank Marketing	45 211	11%	Marketing direto
TELCO	IBM Telco Customer Churn	7 032	27%	Churn
SHOPPERS	Online Shoppers Purchasing	12 330	15%	E-commerce
HIGGS50K	Higgs Boson (subset 50k)	50 000	53%	Física de partículas

10.2 Resultados por Dataset (todos os 18 modelos)

A Tabela 14 apresenta o F1-macro médio ($\pm$ desvio padrão) dos 18 modelos nos 6 datasets reais Tier 2; o melhor por coluna está em negrito.

Observações por grupo de modelos:

- **Baseline geral tabular (XGBoost)** domina o ranking consolidado: lidera ADULT (0,802), HIGGS50K (0,693) e SHOPPERS (0,795), e fica empatado em CREDIT/BANK/TELCO com o bloco de Transformers. Média agregada $\approx 0,735$, melhor rank Friedman (2,67).

Tabela 14: Média $\pm$ desvio padrão de F1-macro (30 sementes, 6 conjuntos de dados Tier 2 (N=5000)).

Model	ADULT	BANK	CREDIT	HIGGS50K	SHOPPERS	TELCO
ADMM-ElasticNet	0.554 $\pm$ 0.013	0.558 $\pm$ 0.013	0.589 $\pm$ 0.010	0.570 $\pm$ 0.013	0.559 $\pm$ 0.007	0.627 $\pm$ 0.011
DualFISTA	0.759 $\pm$ 0.009	0.688 $\pm$ 0.019	0.666 $\pm$ 0.014	0.642 $\pm$ 0.012	0.763 $\pm$ 0.012	0.718 $\pm$ 0.010
FISTANesterov	0.557 $\pm$ 0.011	0.567 $\pm$ 0.014	0.589 $\pm$ 0.011	0.550 $\pm$ 0.012	0.560 $\pm$ 0.009	0.638 $\pm$ 0.012
FT-CUR	0.774 $\pm$ 0.014	0.695 $\pm$ 0.043	0.683 $\pm$ 0.020	0.639 $\pm$ 0.088	0.763 $\pm$ 0.084	0.724 $\pm$ 0.014
FT-Entmax	0.770 $\pm$ 0.016	0.718 $\pm$ 0.025	0.682 $\pm$ 0.017	0.667 $\pm$ 0.015	0.781 $\pm$ 0.016	0.722 $\pm$ 0.014
FT-Softmax	0.771 $\pm$ 0.017	0.720 $\pm$ 0.017	0.680 $\pm$ 0.018	0.672 $\pm$ 0.011	0.783 $\pm$ 0.020	0.721 $\pm$ 0.018
FT-Sparsemax	0.771 $\pm$ 0.016	0.712 $\pm$ 0.028	0.677 $\pm$ 0.022	0.673 $\pm$ 0.013	0.782 $\pm$ 0.018	0.722 $\pm$ 0.017
FT-TopK	0.769 $\pm$ 0.016	0.705 $\pm$ 0.018	0.677 $\pm$ 0.015	0.667 $\pm$ 0.014	0.783 $\pm$ 0.016	0.719 $\pm$ 0.016
LSSVM (Standard)	0.764 $\pm$ 0.013	0.689 $\pm$ 0.017	0.669 $\pm$ 0.013	0.648 $\pm$ 0.013	0.763 $\pm$ 0.013	0.722 $\pm$ 0.011
LSSVM-ADMM	0.558 $\pm$ 0.010	0.567 $\pm$ 0.014	0.588 $\pm$ 0.012	0.575 $\pm$ 0.014	0.557 $\pm$ 0.007	0.635 $\pm$ 0.007
LSSVM-FSA	0.719 $\pm$ 0.012	0.673 $\pm$ 0.017	0.661 $\pm$ 0.021	0.604 $\pm$ 0.018	0.692 $\pm$ 0.019	0.722 $\pm$ 0.011
LSSVM-IP	0.732 $\pm$ 0.020	0.680 $\pm$ 0.015	0.666 $\pm$ 0.012	0.615 $\pm$ 0.012	0.751 $\pm$ 0.014	0.719 $\pm$ 0.010
LSSVM-OppMaps	0.494 $\pm$ 0.011	0.469 $\pm$ 0.019	0.460 $\pm$ 0.008	0.529 $\pm$ 0.012	0.461 $\pm$ 0.008	0.455 $\pm$ 0.008
LSSVM-PCP	0.731 $\pm$ 0.011	0.653 $\pm$ 0.016	0.683 $\pm$ 0.012	0.601 $\pm$ 0.013	0.710 $\pm$ 0.014	0.729 $\pm$ 0.011
LSSVM-Pruning	0.658 $\pm$ 0.013	0.630 $\pm$ 0.015	0.510 $\pm$ 0.012	0.520 $\pm$ 0.016	0.658 $\pm$ 0.036	0.585 $\pm$ 0.121
Nyström-LSSVM	0.762 $\pm$ 0.013	0.691 $\pm$ 0.016	0.666 $\pm$ 0.013	0.645 $\pm$ 0.012	0.761 $\pm$ 0.012	0.718 $\pm$ 0.010
SAINT	0.752 $\pm$ 0.089	0.719 $\pm$ 0.023	0.684 $\pm$ 0.013	0.668 $\pm$ 0.015	0.786 $\pm$ 0.014	0.724 $\pm$ 0.012
XGBoost	0.802 $\pm$ 0.013	0.713 $\pm$ 0.018	0.677 $\pm$ 0.013	0.693 $\pm$ 0.011	0.795 $\pm$ 0.008	0.728 $\pm$ 0.009

- **Baselines FT-Transformer** (Softmax, TopK, Entmax, Sparsemax) ocupam o segundo patamar, confinados ao intervalo 0,720–0,725 na média. A esparsidade de atenção inter-features (sparsemax 75%; topk 89%) não traz vantagem mensurável: a diferença máxima entre o mais esperso (TopK) e o mais denso (Softmax) é 0,005 em média.
- **SAINT** (denso, inter-instâncias) atinge média 0,722, empatando com os FT baselines. Confirma que *a atenção inter-instâncias não é, isoladamente, suficiente para superar a atenção inter-features* em datasets reais.
- **FT-CUR (proposto)** alcança média 0,713 com a correção `val_loss`. Permanece dentro de 0,012 do bloco FT baseline em média, recuperando a maior parte do colapso aparente do protocolo original com `val_acc` (ver Seção 10.6).
- **LSSVMs duais bem condicionados** (LSSVM-Std, DualFISTA, Nyström-LSSVM) caem para $\approx 0,706$ – $0,709$ — $\approx 0,13$ *pp* abaixo do Tier 1. O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em features tabulares mistas (categóricas codificadas + numéricas) com ruído estrutural.
- **LSSVM-PCP, LSSVM-IP, LSSVM-FSA** ficam entre 0,68 e 0,69, um degrau abaixo do LSSVM-Std, com esparsidades amostrais entre 60% (IP) e 92% (FSA).
- **Métodos primais com ℓ_1** (ADMM-Nesterov, FISTA-Nesterov, ADMM-ElasticNet) colapsam para $F_1 \approx 0,58$ — $\Delta \approx -0,13$ vs. LSSVM-Std denso. Analisado em Seção 10.5.
- **LSSVM-Pruning** (após correção com *early stopping* guiado por F1 de treino com tolerância de 5%, código `src/models/lssvm/dual/p_lssvm.py`) sobe para 0,594 com 52% de esparsidade. Recupera a maior parte da degradação antes observada (versão pré-correção: 0,462 com 96% de esparsidade), embora ainda fique abaixo dos LSSVMs duais bem comportados.

- **LSSVM-OppMaps** é o pior modelo do estudo (0,478): a seleção *opposite maps* com esparsidade fixa em 94% não possui mecanismo de *early stopping*, e destrói a fronteira de decisão em escala $N = 5000$.

10.3 Análise estatística: Friedman e ranks médios

A Tabela 15 apresenta os ranks médios obtidos pelo teste não-paramétrico de Friedman ($\chi^2 = 84,96$, $p < 10^{-10}$), confirmando que existe diferença estatisticamente significativa entre os modelos no conjunto agregado dos seis datasets.

Tabela 15: Ranks médios de Friedman (menor = melhor).

Rank	Model	Avg. rank
1	XGBoost	2.667
2	SAINT	3.667
3	FT-Softmax	4.333
4	FT-Sparsemax	4.667
5	FT-Entmax	5.333
6	FT-CUR	5.500
7	FT-TopK	6.500
8	LSSVM (Standard)	7.333
9	LSSVM-PCP	9.000
10	Nyström-LSSVM	9.333
11	DualFISTA	10.333
12	LSSVM-IP	10.833
13	LSSVM-FSA	11.500
14	FISTANesterov	15.000
15	LSSVM-ADMM	15.500
16	LSSVM-Pruning	15.667
17	ADMM-ElasticNet	16.000
18	LSSVM-OppMaps	17.833

A Tabela 24 (apêndice) reporta o pós-teste de Wilcoxon signed-rank pareado com correção de Holm-Bonferroni ($n_{\text{comp}} = 153$). Com $K = 6$ datasets e correção conservadora, comparações par-a-par individuais não atingem $\alpha = 0,05$, mas a hierarquia de ranks de Friedman é robusta: XGBoost (2,67), SAINT (3,67) e o bloco FT baseline + FT-CUR (4,3–6,5) dominam claramente os métodos primais com ℓ_1 (≥ 14) e heurísticas cegas (≥ 17).

10.4 Esparsidade consolidada no Tier 2

Leitura cruzada com a Tabela 14:

- **Nyström-LSSVM** mantém o trade-off observado no Tier 1: 81,5% de esparsidade amostral com $F_1 = 0,707$, apenas 0,002 abaixo do LSSVM-Std denso (0,709). *Compressão substancial sem custo preditivo*, agora confirmado em dados reais $N = 5000$.
- **FT-CUR** obtém 89,4% de compressão inter-instâncias com $F_1 = 0,713$, equivalente ao SAINT denso (0,722, gap 0,009). Repete o padrão Tier 1: *a compressão Nyströmformer é fiel também em larga escala*.

Tabela 16: Taxa de esparsidade média por modelo (todos os datasets e sementes).

Model	Sparsity ratio
ADMM-ElasticNet	0.737 ± 0.335
DualFISTA	0.021 ± 0.021
FISTANesterov	0.491 ± 0.259
FT-CUR	0.894 ± 0.033
FT-Entmax	0.185 ± 0.251
FT-Softmax	0.025 ± 0.055
FT-Sparsemax	0.752 ± 0.077
FT-TopK	0.892 ± 0.015
LSSVM (Standard)	0.000 ± 0.000
LSSVM-ADMM	0.752 ± 0.334
LSSVM-FSA	0.921 ± 0.009
LSSVM-IP	0.604 ± 0.120
LSSVM-OppMaps	0.940 ± 0.025
LSSVM-PCP	0.000 ± 0.000
LSSVM-Pruning	0.515 ± 0.267
Nyström-LSSVM	0.815 ± 0.043
SAINT	0.000 ± 0.000

- **DualFISTA** fica em 2,1% de esparsidade no Tier 2 — muito abaixo dos 20% do Tier 1. O Optuna passou a preferir λ pequenos para preservar margem em datasets imbalanceados, evidenciando que o método se ajusta dinamicamente ao regime de dados.
- **LSSVM-Pruning** agora opera em 52% de esparsidade média no Tier 2 (era 96% antes da correção do *early stopping*), recuperando $F_1 = 0,594$. O modelo passou a parar antes de destruir a fronteira de decisão, ao custo de menos compressão.
- **LSSVM-OppMaps** mantém 94% de esparsidade fixa e permanece em colapso ($F_1 = 0,478$): sem mecanismo análogo de *early stopping*, a heurística cega não escala em $N = 5000$.
- **FT-Sparsemax (75%) e FT-TopK (89%)** mantêm a esparsidade inter-features observada no Tier 1; FT-Entmax (19%) permanece pouco saturada na prática.

10.5 Colapso dos métodos primais com ℓ_1 em escala

O achado mais expressivo da migração Tier 1 $\rightarrow$ Tier 2 é o colapso dos métodos baseados em formulação primal com penalidade ℓ_1 :

Tabela 17: Métodos primais com ℓ_1 no Tier 2 (média sobre 6 datasets).

Modelo	F1 Tier 1	F1 Tier 2	Δ	Esparsidade Tier 2
LSSVM-ADMM (paper-base)	0,809	0,580	-0,229	75,2%
ADMM-ElasticNet ^o	0,809	0,576	-0,233	73,7%
FISTA-Nesterov	0,800	0,577	-0,223	49,1%
Referência: LSSVM-Std denso		0,709	—	0,0%

Mecânica do colapso (ADMM/ADMM-EN). Para a matriz kernel densa 5000×5000 (25 milhões de entradas), o Optuna convergiu para valores de λ grandes o suficiente para zera $\approx 75\%$ dos coeficientes α_i . O hiperplano resultante torna-se rígido e, na ausência de uma atualização proporcional do *bias* via problema de projeção, falha em capturar a classe minoritária nos datasets desbalanceados (BANK 11%, SHOPPERS 15%, CREDIT 22%) — o F_1 macro $\approx 0,58$ é exatamente o valor de uma predição quase-majoritária. A variante **ADMM-ElasticNet** ($\ell_1 + \ell_2$) reduz o tempo de fit de ≈ 160 s para ≈ 54 s por seed (convexidade forte da penalidade ℓ_2 melhora o condicionamento), mas preserva a mesma barreira de expressividade.

Mecânica do colapso (FISTA-Nesterov). Após a correção da escala do λ via `lambda_ratio` (`commit b83243e`), o FISTA-Nesterov no Tier 2 fica em 49,1% de esparsidade média e ainda assim colapsa, indicando que o problema não é apenas a magnitude do λ mas a própria formulação primal: a função objetivo penaliza a magnitude de α no espaço primal, deslocando o hiperplano para regiões que não respeitam a estrutura do problema KKT original. A reformulação dual do **DualFISTA** — $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \|\alpha\|_1$ — elimina exatamente este problema, mantendo $F_1 = 0,706$ no Tier 2.

10.6 FT-CUR/SAINT e a correção metodológica da H2

Os primeiros runs do Tier 2 (parciais, com 6/18 modelos completos) sugeriram um colapso estrutural do FT-CUR em datasets imbalanceados: $F_1 = 0,444$ em CREDIT, 0,548 em BANK — valores compatíveis com predição quase exclusiva da classe majoritária. Três hipóteses foram formuladas para explicar o efeito (Tabela 18).

Tabela 18: Hipóteses sobre o colapso aparente do FT-CUR no Tier 2 parcial.

H	Causa proposta	Teste experimental	Status
H1	Seleção colnorm geométrica sub-representa a classe minoritária nos m landmarks	Tier 2 balanceado: under-sample da majoritária só no treino	A rodar
H2	<code>val_acc</code> em early stopping favorece a classe majoritária	Rerun com <code>val_loss/val_f1_macro</code> e re-tuning Optuna independente por métrica	Confirmada
H3	Limitação fundamental da decomposição CUR	Confirmação por exclusão	Enfraquecida

Ablação H2 (concluída). 360 runs (2 modelos $\times$ 2 datasets $\times$ 3 métricas $\times$ 30 seeds):

Tabela 19: Efeito do critério de early stopping em FT-CUR e SAINT nos datasets desbalanceados CREDIT e BANK (30 seeds, retuning Optuna por métrica).

Modelo	Dataset	val_acc	val_loss	val_f1	$\Delta(\text{loss-acc})$	Melhor FT baseline
FT-CUR	CREDIT	0,438	0,657	0,610	+0,219	0,682 (FT-Entmax)
FT-CUR	BANK	0,507	0,714	0,473	+0,207	0,720 (FT-Softmax)
SAINT	CREDIT	0,439	0,684	0,467	+0,245	0,682 (FT-Entmax)
SAINT	BANK	0,473	0,710	0,498	+0,237	0,720 (FT-Softmax)

Validação estatística (Wilcoxon pareado, H_a : val_loss > val_acc): FT-CUR/CREDIT $p = 1,3 \times 10^{-6}$; FT-CUR/BANK $p = 1,9 \times 10^{-9}$; SAINT/CREDIT $p = 9,3 \times 10^{-10}$; SAINT/BANK $p = 9,3 \times 10^{-10}$.

Conclusão da ablação. O uso de val_acc como critério de early stopping era um *erro metodológico* no protocolo original. val_loss foi superior nos quatro cenários, com magnitude (+0,21 a +0,25) incompatível com ruído. Em BANK, a correção elimina sozinho o colapso aparente; em CREDIT, ela explica a maior parte. A hipótese H3 (limitação fundamental do CUR) fica enfraquecida mas não completamente descartada para um pequeno resíduo em CREDIT.

Rerun completo do Tier 2 com val_loss. Os números da Tabela 14 para FT-CUR e SAINT já refletem este protocolo corrigido. A Tabela 20 compara explicitamente os dois protocolos para FT-CUR para quantificar a magnitude da correção.

Tabela 20: FT-CUR no Tier 2: protocolo histórico (val_acc) vs. protocolo corrigido (val_loss).

Modelo	ADULT	CREDIT	BANK	TELCO	SHOPPERS	HIGGS50K	Média
FT-CUR (val_acc, histórico)	0,770	0,444	0,548	0,714	0,751	0,648	0,646
FT-CUR (val_loss, atual)	0,774	0,683	0,695	0,724	0,763	0,639	0,713

10.7 Comparação Tier 1 vs. Tier 2: reordenação da hierarquia

A Tabela 21 resume o deslocamento de F1-macro de cada família ao migrar do regime sintético/pequeno (Tier 1) para o regime real grande (Tier 2).

Tabela 21: F1-macro médio: Tier 1 (sintéticos + pequenos reais, $N \in [400, 1584]$) vs. Tier 2 ($N_{\text{treino}} = 5000$ em datasets reais grandes). Δ negativo = perda ao migrar.

Modelo	Tier 1	Tier 2	Δ	Família
LSSVM-Std	0,842	0,709	-0,133	kernel denso
DualFISTA ^o	0,842	0,706	-0,136	dual ℓ_1 via FISTA
Nyström-LSSVM*	0,834	0,707	-0,127	kernel esparsa (81% esp.)
LSSVM-IP	0,835	0,694	-0,141	iterative pruning
LSSVM-PCP	0,830	0,685	-0,145	cone projection
LSSVM-FSA	0,837	0,679	-0,158	forward selection
XGBoost	0,776	0,735	-0,041	gradient boosting
FT-Softmax	0,740	0,725	-0,015	atenção feature densa
FT-Sparsemax	0,774	0,723	-0,051	atenção feature esparsa
FT-Entmax	0,742	0,723	-0,019	atenção feature esparsa
FT-TopK	0,729	0,720	-0,009	atenção feature top- k
SAINT	0,744	0,722	-0,022	atenção inter-inst. densa
FT-CUR*	0,747	0,713	-0,034	atenção inter-inst. comprimida
LSSVM-ADMM (paper-base)	0,809	0,580	-0,229	primal ℓ_1 (ADMM)
ADMM-ElasticNet ^o	0,809	0,576	-0,233	primal $\ell_1 + \ell_2$
FISTA-Nesterov	0,800	0,577	-0,223	primal ℓ_1 (FISTA)
LSSVM-Pruning [†]	0,782	0,594	-0,188	pruning iterativo <i>c/ early stop</i>
LSSVM-OppMaps	0,769	0,478	-0,291	opposite maps

Três regimes de deslocamento:

1. **LSSVMs duais bem-comportados** ($\Delta \approx -0,13$ a $-0,16$). O kernel RBF, ótimo em geometria sintética limpa, perde eficácia em dados reais com features categóricas codificadas, redundância e ruído estrutural. *Nyström-LSSVM e DualFISTA mantêm-se virtualmente empatados com LSSVM-Std denso* (gap $< 0,003$), confirmando que os mecanismos de esparsidade propostos são *neutros* em relação à formulação dual.
2. **Transformers e XGBoost** ($\Delta \approx -0,01$ a $-0,05$). Absorvem a transição com baixa perda. As variantes esparsas de atenção feature-level convergem para o mesmo patamar do softmax denso (intervalo 0,720–0,725): a esparsidade na atenção inter-features não traz vantagem mensurável em datasets reais.
3. **Métodos primais com ℓ_1 e heurísticas cegas** ($\Delta \approx -0,19$ a $-0,29$). Os métodos que dependem de regularização agressiva sobre o espaço primal ou de poda heurística sofrem o maior colapso. É a contribuição central do Tier 2: revelar que o paper-base LSSVM-ADMM-Nesterov possui um teto de escalabilidade não evidente em $N \leq 1000$. O **LSSVM-Pruning**, após adquirir *early stopping* guiado por F1 de treino ([†], *commit b83243e*), reduz a queda de $-0,32$ para $-0,19$.

Reordenação: no Tier 1, o ranking era LSSVMs (kernel) $>$ propostos (esparsos) $>$ XGBoost $>$ FT-Transformers; no Tier 2, é XGBoost $\geq$ FT-Transformers + SAINT + FT-CUR $>$ LSSVMs duais (Std, Nyström, DualFISTA, IP, PCP, FSA) $>$ primais com ℓ_1 $>$ heurísticas. A vantagem do paradigma Transformer cresce *em proporção à complexidade tabular dos dados*, e não à escolha de função de ativação da atenção.

11 Benchmark de Eficiência Computacional em *Full-Data*

Em complemento ao estudo de F_1 -macro, executou-se um benchmark *end-to-end* em GPU T4 (Colab) com **uma única seed**, medindo o custo de uma execução real: carregamento do dataset, subamostragem para um N alvo, split 70/30, pré-processamento, treinamento e inferência. O objetivo **não** é comparar desempenho preditivo com rigor estatístico, mas caracterizar o **trade-off computacional** entre as variantes Transformer em regime *full-data*. Os valores de F_1 aqui devem ser lidos como *sanity check* operacional.

Tabela 22: Benchmark de eficiência em *full-data*. Para cada dataset, reporta-se o maior N concluído por modelo. Para SAINT, indica-se o maior N atingido antes de OOM.

Dataset	Modelo	N	Fit (s)	Pred. (s)	VRAM pico (MB)
ADULT	FT-Softmax	45 222	100,2	0,11	364
ADULT	FT-Sparsemax	45 222	124,2	0,41	628
ADULT	FT-TopK	45 222	195,8	0,23	387
ADULT	FT-CUR	45 222	231,6	5,87	3 288
ADULT	FT-Entmax	45 222	425,5	0,59	394
ADULT	SAINT	20 000	25,8	0,85	12 271
CREDIT	FT-Sparsemax	30 000	29,3	0,33	718
CREDIT	FT-TopK	30 000	29,4	0,22	718
CREDIT	FT-Softmax	30 000	38,6	0,18	718
CREDIT	FT-Entmax	30 000	304,3	1,28	909
CREDIT	FT-CUR	30 000	2 451,4	77,68	5 472
CREDIT	SAINT	15 000	61,9	1,54	9 244
HIGGS50K	FT-Softmax	48 842	55,1	0,26	969
HIGGS50K	FT-Sparsemax	48 842	111,9	0,74	2 032
HIGGS50K	FT-TopK	48 842	139,1	0,47	1 444
HIGGS50K	FT-Entmax	48 842	639,3	1,58	1 445
HIGGS50K	FT-CUR	48 842	849,8	20,74	10 642
HIGGS50K	SAINT	20 000	58,3	1,96	12 385

Achados principais:

- O tempo total é dominado pelo treinamento em todos os cenários: `fit_time_s` responde por quase todo `total_time_s`. A comparação computacional é, na prática, uma comparação de custo de treinamento.
- **SAINT** é o mais rápido entre os modelos com atenção inter-instâncias, mas seu consumo de memória é proibitivo: atinge 12,3 GB em ADULT com $N=20k$ e entra em OOM já em $N=30k$ (ADULT) e $N=20k$ (CREDIT/HIGGS50K). É o gargalo quadrático clássico ($O(n^2d)$).
- **FT-CUR** ocupa posição intermediária: em ADULT é mais rápido que FT-Entmax e competitivo com FT-TopK/Sparsemax, com custo de VRAM superior (3,3 GB no ADULT completo) e inferência transdutiva mais cara (5,9s no ADULT completo). É

a *versão computacionalmente viável* do paradigma inter-samples: enquanto SAINT esgota memória em $N \geq 20k$, FT-CUR comprime o mesmo mecanismo via landmarks e roda em $N = 48k$.

- Em **CREDIT**, o FT-CUR entra em regime patológico: no dataset completo ($N=30k$), o treinamento sobe para 2 451 s e a inferência para 77,7 s. A causa mais plausível é a extrapolação de hiperparâmetros tunados em regime reduzido ($N_{\text{treino}} = 5000$): em particular, um **m_ratio** muito maior no CREDIT (0,141 vs. 0,054 em ADULT) aumenta fortemente o número absoluto de landmarks e o custo do bloco inter-instâncias.
- Nos três datasets, os **FT baselines inter-features** (Softmax/TopK/Sparsemax) apresentam o melhor compromisso entre tempo e memória. FT-Softmax é o mais econômico em VRAM; FT-Sparsemax e FT-TopK mantêm custo semelhante em CREDIT/HIGGS50K.
- A RAM CPU mostrou baixa sensibilidade ao crescimento de N e é menos informativa que VRAM. As conclusões devem apoiar-se em tempo e memória de GPU.

Interpretação prática. Se o treinamento é *offline* e com baixa frequência, a vantagem temporal de SAINT e FT-CUR perde parte do peso operacional, enquanto seu maior consumo de memória permanece como custo persistente. Nesse regime, os FT baselines tornam-se mais atraentes por oferecerem inferência barata e *footprint* de memória muito menor, sem perda predominante de F_1 no benchmark operacional.

12 Sumário e Próximos Passos

Tabela 23: Síntese dos experimentos realizados.

Experimento	Configuração	Runs	Resultado principal
Tier 1	18 modelos, 9 datasets, 30 seeds	4860	DualFISTA 0,842 / Nyström 0,834 / XGBoost 0,776
Ablação A (escala)	18 modelos, 3 sintéticos, $N=2000$, 30s	1620	Nyström +0,14; FT-CUR/SAINT data-hungry
Ablação B (ruído)	18 modelos, 3 sintéticos, +3 feat. ruído, 30s	1620	XGBoost +0,30 em TWC; FT-CUR/SAINT robustos
Ablação C (MK5)	18 modelos, 3 sintéticos, 30 seeds	1620	Nyström 0,845 > XGBoost 0,829 > FT-CUR 0,809
Tier 2 ($N_{\text{treino}} = 5000$)	18 modelos, 6 datasets reais, 30s	3240	XGBoost 0,735; SAINT/FT-CUR/FT baselines $\sim 0,72$; primais ℓ_1 colapsam para 0,58
Ablação H2 (early stop)	FT-CUR/SAINT, CREDIT/BANK, 3 métricas, 30s	360	$\text{val_loss} > \text{val_acc}$ ($p < 10^{-5}$ em todos os 4 cenários)
Benchmark eficiência	6 Transformers, 3 datasets reais, 1 seed	137	SAINT OOM cedo; FT baselines dominam tempo/memória; FT-CUR patológico em CREDIT 30k
Total		13 057	

Conclusões consolidadas:

1. **Nyström-LSSVM** é o melhor resultado da dissertação em alta esparsidade: $F_1 = 0,834$ no Tier 1 (69% esp.) e $0,707$ no Tier 2 (81,5% esp.), em ambos os regimes a $\leq 0,003$ do LSSVM-Std denso. *Compressão sem custo preditivo*, agora confirmado em escala $N = 5000$.

2. **DualFISTA** mantém F1 essencialmente igual ao LSSVM-Std denso em ambos os tiers ($\Delta \leq 0,003$). Sua reformulação dual elimina o colapso dos métodos primais com ℓ_1 observado no Tier 2 e abre espaço para a hipótese de eficiência computacional ainda a ser benchmarkada (próxima etapa).
3. **FT-CUR** valida o paradigma de compressão Nyströmformer em dados tabulares: empata com SAINT denso em todos os experimentos ($\Delta \leq 0,013$) com $\approx 89\%$ de compressão inter-instâncias, e roda em $N = 48k$ onde SAINT entra em OOM.
4. **Colapso dos métodos primais com ℓ_1 em escala** é o achado mais inesperado do Tier 2: ADMM-Nesterov (paper-base), ADMM-ElasticNet e FISTA-Nesterov caem de $\approx 0,81$ para $\approx 0,58$ em $N = 5000$. Revela um teto de escalabilidade não detectável em $N \leq 1000$ e justifica a reformulação dual proposta (DualFISTA).
5. **H2 confirmada metodologicamente**: `val_loss` domina `val_acc` como critério de early stopping para modelos inter-instâncias em datasets desbalanceados ($p < 10^{-5}$ em todos os 4 cenários). É uma contribuição metodológica auxiliar ao protocolo padrão de FT-Transformers tabulares.
6. **Benchmark de eficiência**: FT baselines dominam o trade-off tempo/memória em *full-data*; FT-CUR é a única variante inter-instâncias que roda em $N = 48k$. SAINT é rápido mas restrito a $N \leq 20k$.

Próximas etapas planejadas:

1. **Benchmark de eficiência computacional — DualFISTA vs. família ADMM (paper-base e variantes)**: observação preliminar do Tier 2 sugere que o tuning do ADMM-Nesterov requer $\sim 5\text{--}9\text{h}$ por dataset (frequentemente atingindo `max_iter=5000` sem convergência), enquanto DualFISTA tuna em $\sim 30\text{--}60$ min por dataset (**ordem de magnitude mais rápido**). Hipótese a verificar: o ADMM-ElasticNet ($\ell_1 + \ell_2$) deve convergir mais rápido que o ADMM- ℓ_1 puro devido à *convexidade forte* introduzida pela penalidade ℓ_2 (Tikhonov), que melhora o condicionamento do subproblema primal. Estudo formal:
 - Coletar tempo por iteração e número de iterações até convergência (já gravados em `train_time_s`) para ADMM-Nesterov, ADMM-ElasticNet, FISTA-Nesterov e DualFISTA;
 - Plotar curva de convergência (loss vs. iteração) e *wall-clock* vs. qualidade de solução;
 - Reportar como uma das **contribuições centrais** da dissertação: DualFISTA não apenas atinge esparsidade comparável ao paper-base mas o faz com 1–2 ordens de magnitude de *speedup*.
2. **H1 — Tier 2 com balanceamento no treino**: rodar todos os 18 modelos com `-balance-train` (undersample da majoritária só no treino, preservando o teste original), testando se o resíduo do FT-CUR em CREDIT desaparece e se os métodos primais com ℓ_1 se recuperam.
3. **Tier 2 *full-data***: rodar os 4 FT baselines + FT-CUR no N completo de cada dataset (Colab GPU; $\sim 10\text{--}12\text{h}$); e XGBoost + Nyström-LSSVM em N completo (Colab CPU; $\sim 3\text{--}5\text{h}$) para confirmar a vantagem de eficiência amostral observada em $N = 5000$.

4. **Re-rodar Tier 1 (`lambda_ratio` corrigido)** para 4 modelos: a correção de escala do λ entre Tier 1 e Tier 2 (sintaxe `lambda_ratio` em vez de absoluto) deve ser retroaplicada aos métodos primais com ℓ_1 e ao LSSVM-Pruning (que ganhou *early stopping* no Tier 2) para comparação metodológica justa entre tiers.
5. **Diagrama de diferença crítica** (Nemenyi) sobre todos os datasets consolidados (Tier 1 + 3 ablações + Tier 2 = 21 datasets), reportado como figura agregada de comparação estatística entre os 18 modelos.

A Infraestrutura e Reprodutibilidade

- **Código:** repositório `sparse-lssvm-transformers-study/`
- **Ambiente:** Python 3.12, PyTorch, scikit-learn, Optuna; virtualenv em `.venv/`
- **Resultados:** arquivos JSON em `results/`: `tier1_results.json` (baselines), `tier1_custom_models.json` (propostos), `synthetic_scaling_n2000.json`, `synthetic_5features_tuned.json`, `synthetic_mk5.json`, `tier2_n5000_*.json` (consolidado), `tier2_n5000_ftcur_saint_valloss.json` (re-run H2), `tier2_early_stop_ablation.json` (ablação H2), `benchmark_transformers_efficiency.json` (benchmark full-data)
- **Tuning:** `results/tuning/best_params*.json`
- **Scripts:** `scripts/run_*.py` são resumíveis (checkpoint por chave `model/dataset/seed`)
- **Figuras:** geradas por `scripts/generate_report_figs.py` e `scripts/generate_tier2_analysis.py`

B P-valores Wilcoxon do Tier 2 (Holm-Bonferroni)

Tabela 24: P-valores do teste de Wilcoxon signed-rank com correção de Holm-Bonferroni ($n_{\text{comp}} = 153$; negrito = significativo em $\alpha = 0,05$).

	ADMM-ElasticNet	LSSVM-ADMM	DualFISTA	FISTA-Nesterov	LSSVM-FSA	FT-CUR	FT-Entmax	FT-Softmax	FT-Sparsenmax	FT-TopK	LSSVM-IP	Nystrom-LSSVM	LSSVM-OptMaps	LSSVM-PCP	LSSVM-Pruning	SAINT	LSSVM (Standard)	XGBoost
ADMM-ElasticNet	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-ADMM	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
DualFISTA	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FISTA-Nesterov	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-FSA	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-CUR	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Entmax	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Softmax	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-Sparsenmax	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
FT-TopK	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-IP	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000	1.000
Nystrom-LSSVM	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000	1.000
LSSVM-OptMaps	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000	1.000
LSSVM-PCP	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000	1.000
LSSVM-Pruning	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000	1.000
SAINT	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000	1.000
LSSVM (Standard)	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—	1.000
XGBoost	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000	—