

Relatório de Experimentos

Estudo Comparativo: LSSVM Esperso vs. Transformers Tabulares
Dissertação de Mestrado — Experimentos (atualizado em maio de 2026)

Paulo Bernardo

Maio de 2026

Sumário

1	Introdução	3
2	Auditoria da Implementação do Nyström-SVM	4
2.1	As três versões	4
2.2	Verificação experimental	5
2.3	Esparsidade reportada	5
3	Experimento Tier 1: Benchmarks Reais	6
3.1	Resultados por Dataset	6
3.2	Comparação Geral	7
4	Arquitetura dos FT-Transformers e Tipos de Atenção	8
4.1	Atenção inter-features (intra-instância)	8
4.2	Atenção inter-instâncias (entre amostras)	8
5	Análise de Esparsidade	9
5.1	Esparsidade amostral — LSSVMs	9
5.2	Esparsidade de atenção inter-features — FT-Transformers baselines	10
6	Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)	11
7	Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)	13
8	Ablação C: Dados Sintéticos Multifeature (MK5)	15
9	Análise das Variantes Investigadas e Modelos Propostos	17
9.1	Mecanismos de esparsidade	17
9.2	Desempenho consolidado	17
9.3	Síntese comparativa	18
10	Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$) — Resultados Parciais	19
10.1	Protocolo	19
10.2	Resultados parciais (6 de 18 modelos completos)	19
10.3	Limitação estrutural do FT-CUR em dados imbalanceados	20

10.4 Comparação Tier 1 vs. Tier 2: deslocamento do trade-off (<i>rascunho — pendente confirmação</i>)	24
10.5 XGBoost vs. FT-Transformers em datasets reais	26
11 Sumário e Próximos Passos	26
A Infraestrutura e Reprodutibilidade	27

1 Introdução

Este relatório consolida os resultados dos experimentos conduzidos na dissertação, que compara métodos de *Least-Squares Support Vector Machine* (LSSVM) com ênfase em esparsidade contra variantes de *FT-Transformer* com atenção esparsa em tarefas de classificação binária tabular.

O trabalho estende o algoritmo LSSVM-ADMM-Nesterov proposto por Marinho et al. com dois novos mecanismos de esparsidade: (i) **DualFISTA**, formulação dual do LSSVM como LASSO com otimização via ISTA acelerado; e (ii) **Nyström-SVM**, aproximação da matriz kernel por seleção de landmarks via norma de coluna. Como comparativo do lado dos Transformers, avalia-se o **FT-CUR**, que aplica decomposição CUR com colnorm à matriz de atenção.

Auditoria do Nyström-SVM — três versões

A implementação do Nyström-SVM passou por três versões. A versão final, auditada matematicamente (Seção 2), é a apresentada neste relatório.

Versão	Predição	F1 Tier 1
Bug original	$f(x)=K(x, X_{\text{treino}})\alpha + b$ (kernel completo)	0,8427 (inflado)
“Fix” errado	$f(x)=K(x, Z)\alpha[\text{lm_idx}] + b$ (subset ingênuo de α)	0,6678 (colapsado)
Correta	$f(x)=K(x, Z)(W^{-1}C^T\alpha) + b$ (Nyström)	0,8342

A versão correta usa a fórmula matemática da aproximação Nyström ($\tilde{K} = CW^{-1}C^T$), com custo $O(n_{\text{test}} \cdot m)$ e **sem dependência de X_{treino} na predição** (verificado experimentalmente). A perda de F1 em relação ao bug original é de apenas 0,0085, mas agora com $\approx 69\%$ de esparsidade amostral genuína.

Modelos avaliados

Ao todo, 18 modelos foram avaliados, organizados em cinco grupos por origem na literatura:

- **Baseline geral tabular (1): XGBoost** (Chen & Guestrin, 2016) — padrão-ouro para dados tabulares, serve como referência externa às famílias LSSVM e Transformer.
- **LSSVMs baselines (7):** LSSVM-Std (sem esparsidade), LSSVM-PCP, LSSVM-FSA, LSSVM-IP, LSSVM-Pruning, LSSVM-OppMaps, e **FISTA-Nesterov** (LSSVM primal com FISTA — método clássico de Beck & Teboulle, 2009, amplamente documentado).
- **FT-Transformers baselines (5):** variantes com atenção softmax, top- k , entmax e sparsemax — mais **SAINT** (Somepalli et al., 2021; atenção inter-instâncias densa).
- **Paper-base estendido: LSSVM-ADMM-Nesterov** de Marinho et al. — método sobre o qual esta dissertação constrói.
- **Variantes investigadas e modelos propostos (4):**
 - **ADMM-ElasticNet^o**: variante do paper-base com penalidade Elastic Net (combinação ADMM-Nesterov + Elastic Net + LSSVM não localizada explicitamente na literatura como método publicado).

- **DualFISTA[°]**: formulação dual do LSSVM como LASSO ($\min_{\alpha} \frac{1}{2} \alpha^{\top} \Omega \alpha - \mathbf{1}^{\top} \alpha + \lambda \|\alpha\|_1$), otimizada via FISTA. Ponto de investigação — não localizada na literatura nesta forma exata; pode ser uma reformulação convergente com métodos análogos em SVM ou regressão Lasso.
- **Nyström-SVM (colnorm)***: aproxima $K \in \mathbb{R}^{n \times n}$ via $m \ll n$ landmarks selecionados por norma de coluna (em vez de amostragem uniforme/leverage tradicional); predição restrita aos landmarks ($O(n_{\text{test}} \cdot m)$, auditada).
- **FT-CUR (Nyströmformer)***: aplicação de Nyströmformer (Xiong et al., 2021) à atenção inter-instâncias do FT-Transformer em dados tabulares; seleção de landmarks via colnorm (combinação não localizada como método publicado).

[°] = variante/ponto de investigação; * = aplicação/combinação proposta.

Protocolo experimental

- 30 sementes aleatórias, partição estratificada 70/30.
- Métrica principal: F1-macro (média aritmética do F1 por classe).
- Hiperparâmetros otimizados via Optuna TPE com validação cruzada estratificada de 5 folds.
- Normalização por StandardScaler ajustado apenas no treino.

2 Auditoria da Implementação do Nyström-SVM

2.1 As três versões

O Nyström-SVM aproxima a matriz kernel completa $K \in \mathbb{R}^{n \times n}$ a partir de m landmarks $\{z_1, \dots, z_m\}$ selecionados antes do treino:

$$K \approx CW^{-1}C^{\top}, \quad C = K(X, Z) \in \mathbb{R}^{n \times m}, \quad W = K(Z, Z) \in \mathbb{R}^{m \times m}.$$

O treinamento, via identidade de Woodbury, é correto em todas as versões. A diferença está apenas na predição:

V1 — Bug original. Predizia com o kernel completo:

$$f(x) = K(x, X_{\text{treino}}) \alpha + b.$$

Não tinha esparsidade real (todo X_{treino} era usado em inferência) e produzia $F_1 = 0,8427$ no Tier 1.

V2 — “Fix” ingênuo. Tentativa de restringir aos landmarks pegando apenas o subset de α nos índices dos landmarks:

$$f(x) = K(x, Z) \alpha[\text{lm_idx}] + b.$$

Está **matematicamente errado**: os pesos $\alpha \in \mathbb{R}^n$ foram ajustados para o sistema KKT completo n -dimensional, e simplesmente subseqüenciá-los nos índices dos landmarks não recupera a aproximação Nyström. F1 colapsou para 0,6678.

V3 — Correta (atual). A aproximação Nyström verdadeira é $\tilde{K}(x, X) = K(x, Z) W^{-1} C^\top$. Substituindo em $f(x) = \tilde{K}(x, X) \alpha + b$:

$$f(x) = K(x, Z) (W^{-1} C^\top \alpha) + b = K(x, Z) w_\alpha + b, \quad w_\alpha = W^{-1} C^\top \alpha \in \mathbb{R}^m.$$

O vetor w_α é calculado uma vez ao final do fit e cacheado. Em inferência, só $K(x, Z) \in \mathbb{R}^{n_{\text{test}} \times m}$ é computado — não há mais nenhuma dependência de X_{treino} . F1 = 0,8342.

2.2 Verificação experimental

A implementação V3 foi auditada matematicamente (`scripts/audit_nystrom_lssvm.py`) confirmando três propriedades:

1. **Equivalência matemática.** $\|f_{\text{cache}}(x) - f_{\text{Nyström}}(x)\|_2 = 0$ exatamente, onde $f_{\text{Nyström}}$ usa a fórmula expandida $K(x, Z) W^{-1} C^\top \alpha + b$.
2. **Sem dependência de X_{treino} .** Após o fit, ao apagar X_{treino} do modelo, as predições continuam idênticas ($\|\Delta f\|_2 = 0$). Confirma que apenas Z é usado na inferência.
3. **Custo $O(n_{\text{test}} \cdot m)$.** Mantendo m fixo e variando n_{treino} de 1000 a 6000, o tempo de predição permanece em ≈ 5 ms (não escala com n).

Tabela 1: Comparação direta no BCW (10 sementes, mesmos hiperparâmetros).

Versão	F1 BCW	Diagnóstico
V1 (kernel completo)	0,974	0% de esparsidade real
V2 (α subsetado)	0,360	matematicamente inválida
V3 ($W^{-1} C^\top \alpha$, atual)	0,968	$\approx 80\%$ esparsidade real

A V3 perde apenas 0,006 em relação ao kernel completo no BCW, mostrando que a aproximação Nyström com seleção colnorm é *genuinamente* boa quando bem tunada — a esparsidade não custa quase nada de F1.

2.3 Esparsidade reportada

Com a predição V3, a esparsidade do Nyström-SVM é semanticamente consistente com os demais LSSVMs:

- **ADMM/FISTA:** esparsidade = fração de $\alpha_i = 0$.
- **Nyström:** esparsidade = $1 - m/n$, fração de pontos de treino *não* usados como landmark-key.

A razão m/n é tunada pelo Optuna por dataset; a esparsidade resultante varia entre 50% (TWC) e 92% (PID), com média 69% no Tier 1.

3 Experimento Tier 1: Benchmarks Reais

Nove conjuntos de dados foram utilizados (Tabela 2). Os três últimos (TWS, TWM, TWC) são sintéticos bidimensionais incluídos como controle com fronteiras de decisão conhecidas.

Tabela 2: Conjuntos de dados — Tier 1.

ID	Nome	N	Features	Domínio
BCW	Breast Cancer Wisconsin	569	30	Diagnóstico médico
PID	Pima Indians Diabetes	768	8	Diagnóstico médico
HAB	Haberman Survival	306	3	Sobrevivência
VCP	Vehicle Coupon Purchase	1584	7	Marketing
GCR	German Credit Risk	1000	20	Crédito
AUS	Australian Credit	690	14	Crédito
TWS	Two Spirals (sintético)	400	2	Controle
TWM	Two Moons (sintético)	400	2	Controle
TWC	Checkerboard (sintético)	400	2	Controle

3.1 Resultados por Dataset

A Tabela 3 apresenta o F1-macro médio (30 sementes) para *todos* os modelos. Os melhores valores por coluna estão em negrito.

Tabela 3: F1-macro médio (30 sementes). **Negrito:** melhor por coluna. ◦ = variante investigada / ponto de investigação; ★ = aplicação/combinção proposta.

Modelo	BCW	PID	HAB	VCP	GCR	AUS	TWS	TWM	TWC	Média
<i>Baseline geral tabular</i>										
XGBoost	0,964	0,732	0,580	0,811	0,699	0,867	0,875	0,978	0,476	0,776
<i>Baselines LSSVM</i>										
LSSVM-Std	0,975	0,729	0,590	0,835	0,697	0,862	0,993	1,000	0,900	0,842
LSSVM-FSA	0,967	0,741	0,590	0,820	0,676	0,859	0,990	1,000	0,893	0,837
LSSVM-IP	0,966	0,727	0,571	0,827	0,690	0,857	0,990	1,000	0,888	0,835
LSSVM-PCP	0,923	0,726	0,629	0,789	0,689	0,857	0,989	0,995	0,872	0,830
FISTA-Nesterov	0,902	0,686	0,617	0,782	0,513	0,844	0,990	0,994	0,873	0,800
LSSVM-Prun	0,969	0,639	0,482	0,801	0,437	0,849	0,994	0,996	0,874	0,782
LSSVM-OppM	0,961	0,456	0,468	0,755	0,585	0,823	0,986	0,990	0,899	0,769
<i>Baselines FT-Transformer</i>										
FT-Sparsemax	0,950	0,691	0,596	0,808	0,662	0,855	0,690	1,000	0,710	0,774
SAINT	0,949	0,710	0,535	0,774	0,676	0,859	0,639	0,969	0,588	0,744
FT-Entmax	0,953	0,700	0,538	0,800	0,657	0,860	0,667	0,999	0,504	0,742
FT-Softmax	0,959	0,708	0,541	0,810	0,658	0,854	0,653	1,000	0,478	0,740
FT-TopK	0,950	0,692	0,501	0,808	0,669	0,857	0,640	0,974	0,468	0,729
<i>Paper-base estendido</i>										
LSSVM-ADMM-Nesterov	0,899	0,684	0,616	0,783	0,608	0,842	0,992	0,992	0,866	0,809
<i>Variantes investigadas / propostos</i>										
DualFISTA◦	0,976	0,734	0,589	0,834	0,698	0,862	0,994	1,000	0,891	0,842
Nyström-SVM★	0,970	0,715	0,602	0,820	0,690	0,861	0,992	1,000	0,858	0,834
ADMM-ElasticNet◦	0,899	0,692	0,618	0,787	0,592	0,844	0,990	0,995	0,861	0,809
FT-CUR★ (Nyströmformer)	0,946	0,715	0,523	0,824	0,665	0,851	0,654	0,981	0,564	0,747

3.2 Comparação Geral

A Figura 1 mostra o F1-macro médio ($\pm$ dp) agregado sobre todos os datasets e sementes para cada modelo.




Figura 1: F1-macro médio $\pm$ dp (30 sementes $\times$ 9 datasets). ★ indica modelos propostos; vermelho = DualFISTA, verde = Nyström-SVM, laranja = FT-CUR.

Observações principais:

- **XGBoost** (baseline geral tabular) atinge 0,776 no Tier 1 — abaixo do top 5 dos LSSVMs e abaixo do DualFISTA/Nyström. Vence em AUS (0,867) mas colapsa em TWC (0,476, fronteira xadrez não-linear que favorece kernel RBF). Mostra que para dados tabulares com estrutura geométrica, métodos kernel podem superar gradient boosting.
- **DualFISTA** alcança F1-macro médio de 0,8418 — virtualmente igual ao LSSVM-Std completo (0,8424, diferença 0,0006) com 20,1% de esparsidade. É o único modelo esperso que se aproxima do desempenho do baseline sem esparsidade.
- **Nyström-SVM** (0,834) é o segundo melhor entre os modelos propostos: fica a apenas 0,008 do LSSVM-Std completo, mas com $\approx$ 69% de esparsidade amostral (mais que o triplo do DualFISTA). É o melhor trade-off F1/esparsidade entre os modelos com alta esparsidade.
- O **LSSVM-ADMM** e suas variantes (ElasticNet, FISTA-Nesterov) ficam $\approx$ 3 pp abaixo do LSSVM-Std, com esparsidade entre 27–30%.
- Todos os FT-Transformers baselines (softmax, topk, entmax, sparsemax) ficam abaixo de 0,78, com queda acentuada nos sintéticos TWS e TWC.
- **SAINT** (0,744, atenção inter-instâncias densa) e **FT-CUR** (Nyströmformer, 0,747) atingem F1 essencialmente idêntico — diferença de 0,003. Como o FT-CUR comprime $\approx$ 79% da atenção inter-instâncias e o SAINT é denso, isso valida a aproximação Nyströmformer: **a compressão não custa F1**.

4 Arquitetura dos FT-Transformers e Tipos de Atenção

Esta seção esclarece a distinção entre os dois mecanismos de atenção presentes nos modelos baseados em Transformer avaliados, terminologia necessária para interpretar corretamente as medidas de esparsidade.

4.1 Atenção inter-features (intra-instância)

Os FT-Transformers baselines (softmax, top- k , entmax, sparsemax) implementam **atenção entre features de uma mesma instância**. Dado um batch de n amostras com d features, cada instância $x_i \in \mathbb{R}^d$ é representada como uma sequência de d tokens após embedding. A atenção opera na dimensão dos tokens:

$$A^{(i)} = \text{softmax}\left(\frac{Q^{(i)}(K^{(i)})^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{d \times d},$$

onde $A^{(i)}$ indica quanta atenção a feature j dá à feature k dentro da instância i . As variantes esparsas (sparsemax, top- k) fazem $A^{(i)}$ ter entradas exatamente zero. Esta esparsidade *não* envolve comparação entre amostras distintas — é **intra-instância**.

4.2 Atenção inter-instâncias (entre amostras)

SAINT e **FT-CUR** acrescentam (ou substituem) um mecanismo de atenção entre instâncias distintas. Todas as n amostras do contexto são comparadas entre si:

$$A = f\left(\frac{QK^\top}{\sqrt{d_h}}\right) \in \mathbb{R}^{n \times n},$$

onde cada entrada A_{ij} mede a influência da amostra j sobre a amostra i .

SAINT vs. FT-CUR: atenção inter-instâncias densa vs. comprimida

- **SAINT** usa $f = \text{softmax}$ completo: $A \in \mathbb{R}^{n \times n}$ é materializada integralmente. Custo: $O(n^2d)$ por cabeça. Sem zeros exatos $\Rightarrow$ esparsidade de compressão = 0%. Serve como **baseline denso** para a comparação com FT-CUR.
- **FT-CUR (Nyströmformer)** evita materializar A ao todo: seleciona $m \ll n$ landmarks por norma de coluna e computa três produtos menores com softmax separado:

$$C = \text{softmax}\left(\frac{QK_m^\top}{\sqrt{d_h}}\right)[n \times m], \quad R = \text{softmax}\left(\frac{Q_mK^\top}{\sqrt{d_h}}\right)[m \times n], \quad W = \text{softmax}\left(\frac{Q_mK_m^\top}{\sqrt{d_h}}\right)[m \times m]$$

Saída: $\text{out} = C(W^+(RV))$ da direita para a esquerda — custo $O(nmd)$, nunca $O(n^2d)$. Compressão inter-instâncias: $1 - m/n$.

A atenção inter-features (softmax/topk/entmax/sparsemax) e a atenção inter-instâncias (SAINT/FT-CUR) são **ortogonais**: SAINT e FT-CUR incluem ambas (bloco inter-features padrão + bloco inter-instâncias), enquanto os FT-Transformers baselines têm apenas a inter-features.

5 Análise de Esparsidade

Os modelos avaliados produzem três tipos qualitativamente distintos de esparsidade:

- **Esparsidade amostral** (LSSVMs): fração de amostras de treino *não* utilizadas na predição. Para ADMM/FISTA, é a fração de $\alpha_i = 0$; para Nyström-SVM, é $1 - m/n$. Mede compressão do modelo em vetores de suporte.
- **Esparsidade de atenção inter-features**: fração de pesos da atenção *intra-instância* exatamente zero (sparsemax, top- k). Mede seletividade de features, não compressão de amostras.
- **Compressão inter-instâncias** (FT-CUR): fração $1 - m/n$ de amostras não usadas como landmark-key na atenção Nyströmformer. Análogo ao Nyström-SVM, mas na dimensão de atenção em vez da predição kernel.

5.1 Esparsidade amostral — LSSVMs

Tabela 4: Trade-off esparsidade amostral $\times$ desempenho (LSSVMs, Tier 1). Ordenado por F1-macro decrescente.

Modelo	F1-macro	Spar. amostral	Mecanismo
LSSVM-Std	0,8424	0,0%	— (baseline denso)
DualFISTA*	0,8418	20,1%	ℓ_1 dual via FISTA
LSSVM-FSA	0,8373	45,9%	seleção forward
LSSVM-IP	0,8352	57,1%	iterative pruning
Nyström-SVM*	0,8342	69,0%	colnorm landmarks (m/n tunado por dataset)
LSSVM-PCP	0,8300	0,0%	cone projection
LSSVM-ADMM*	0,8089	30,0%	ℓ_1 primal (ADMM-Nesterov)
ADMM-ElasticNet*	0,8086	27,4%	$\ell_1 + \ell_2$ (Elastic Net)
FISTA-Nesterov*	0,8000	27,4%	ℓ_1 primal via FISTA
LSSVM-Prun	0,7825	71,6%	pruning pós-treino
LSSVM-OppM	0,7692	79,3%	opposite maps




Figura 2: Trade-off esparsidade amostral × F1-macro (LSSVMs). ★ = modelos propostos.

Análise:

- **DualFISTA** apresenta o melhor trade-off em baixa esparsidade: 20% com perda de apenas 0,0006 em F1.
- **Nyström-SVM** oferece o melhor trade-off em alta esparsidade: 69% com perda de apenas 0,008 em F1. É o único modelo que combina esparsidade > 50% com F1 dentro de 1% do LSSVM-Std.
- Os métodos ADMM/FISTA (primal) produzem esparsidades entre 27–30% com queda de 3–4 pp. A esparsidade é heterogênea entre datasets.
- Os mais agressivos em esparsidade (LSSVM-Prun, 71%; LSSVM-OppM, 79%) pagam custo de $\approx 6-8$ pp em F1, mostrando que esparsidade alta sem método estruturado (como o Nyström) degrada o desempenho.

5.2 Esparsidade de atenção inter-features — FT-Transformers baselines

Nota: esparsidade inter-features vs. compressão inter-instâncias

Os FT-Transformers baselines (softmax, topk, entmax, sparsemax) têm atenção *intra-instância* — fração de pesos zerados mede seletividade de features. **SAINT** adiciona atenção inter-instâncias com softmax completo ($n \times n$): sem zeros exatos, compressão = 0% (baseline denso). **FT-CUR** substitui o softmax $n \times n$ pelo Nyströmformer (m landmarks, colnorm): nunca materializa $A^{n \times n}$, compressão = $1 - m/n \approx 80\%$.

Tabela 5: Esparsidade de atenção inter-features (baselines FT) e compressão inter-instâncias (SAINT/FT-CUR). Tier 1, média sobre 9 datasets e 30 sementes.

Modelo	F1-macro	Spar. feat.	Compr. inst.	Mecanismo
<i>Atenção inter-features (intra-instância)</i>				
FT-TopK	0,729	76,8%	—	top- k fixo ($k=2$ de $d+1$ tokens)
FT-Sparsemax	0,774	39,1%	—	sparsemax (zeros exatos)
FT-Entmax	0,742	1,4%	—	entmax (poucos zeros exatos)
FT-Softmax	0,740	0,2%	—	softmax (nunca exatamente zero)
<i>Atenção inter-instâncias</i>				
SAINT	0,744	—	0%	softmax $n \times n$ completo (baseline denso)
FT-CUR*	0,747	—	79,3%	Nyströmformer, $m/n \approx 0,20$, $O(nmd)$

Análise:

- **FT-TopK** (76,8%) e **FT-Sparsemax** (39,1%) produzem esparsidade de atenção inter-features genuína, mas ela não se traduz em ganho de F1 — ambos ficam abaixo ou muito próximos do FT-Softmax denso em média.
- **FT-Entmax** (1,4%) produz poucos zeros na prática: apesar de ser conceitualmente esperso, a entmax com $\alpha=1,5$ raramente satura em zero para os datasets avaliados.
- **SAINT** (0,744, denso) e **FT-CUR** (0,747, 79,3% de compressão) atingem F1 essencialmente idêntico — diferença de apenas 0,003. Isso valida empiricamente o Nyströmformer: **comprimir $\approx 80\%$ da atenção inter-instâncias não custa F1**. A aproximação $\tilde{A} = C(W^+R)V$ via softmax separado é fiel à atenção completa $A = \text{softmax}(QK^\top/\sqrt{d})V$ na prática.
- Comparado aos FT-Transformers baselines (sem atenção inter-instâncias), SAINT e FT-CUR ficam ligeiramente acima de FT-Softmax/Entmax/TopK e abaixo do FT-Sparsemax. A atenção inter-instâncias não é, isoladamente, suficiente para superar as variantes esparsas no nível feature.

5.3 Esparsidade nos Transformers — Tier 2 ($N = 5000$)

A transição para o Tier 2 ($N = 5000$) permitiu analisar o comportamento de esparsidade dos Transformers em um regime de dados mais desafiador. A Tabela ?? detalha a fração média de zeros na atenção inter-features (`mean_zero_fraction`) e a compressão de instâncias do FT-CUR.

Tabela 6: Esparsidade de atenção e compressão nos Transformers (Tier 2). Valores agregados dos experimentos $N=5000$ com `val_loss`.

Modelo	F1-macro	Métrica de Esparsidade	Valor
FT-TopK	0,720	Atenção inter-features (zeros)	89,2%
FT-Sparsemax	0,723	Atenção inter-features (zeros)	75,2%
FT-Entmax	0,723	Atenção inter-features (zeros)	18,5%
FT-Softmax	0,724	Atenção inter-features (zeros)	2,5%
SAINT	0,722	Compressão inter-instâncias	0,0% (Denso)
FT-CUR*	0,713	Compressão inter-instâncias	89,4%

Análise:

- A métrica `mean_zero_fraction` revela que as variantes com indução de esparsidade (TopK e Sparsemax) conseguem zerar agressivamente os pesos de atenção para features não-informativas (89,2% e 75,2%, respectivamente), atuando como um forte seletor de features nativo sem degradar a performance preditiva ($F_1 \approx 0,72$).
- O **FT-CUR** demonstra que a aproximação de Nyström na dimensão de instâncias atinge **89,4% de compressão** da matriz de atenção, entregando um F_1 de 0,713 (superior ao baseline do LSSVM denso). Isso consolida a eficácia do Nyström tanto para a família SVM (Nyström-LSSVM) quanto para a família Deep Learning (FT-CUR).

6 Ablação A: Escalabilidade Amostral ($N = 400 \rightarrow 2000$)

Motivação: Investigar se os Transformers melhoram com mais dados (são conhecidamente *data-hungry*) e se os modelos baseados em kernel mantêm a vantagem estrutural.

Configuração: Os três sintéticos (TWS, TWM, TWC) foram re-gerados com $N = 2000$. Os hiperparâmetros tuned para Tier 1 ($N = 400$) foram reutilizados.




Figura 3: F1-macro com $N = 400$ (barras translúcidas) vs. $N = 2000$ (sólidas).

Tabela 7: Modelos propostos: F1-macro em $N = 400$ vs. $N = 2000$.

Modelo	Dataset	N=400	N=2000	Δ
DualFISTA	TWS	0,994	0,995	+0,001
	TWM	1,000	0,998	-0,002
	TWC	0,891	0,945	+0,054
LSSVM-ADMM	TWS	0,992	0,995	+0,003
	TWM	0,992	0,998	+0,007
	TWC	0,866	0,938	+0,072
Nyström-SVM	TWS	0,992	0,995	+0,003
	TWM	1,000	0,998	-0,002
	TWC	0,858	0,941	+0,083
FT-CUR (Nyströmformer)	TWS	0,654	0,788	+0,134
	TWM	0,981	0,997	+0,016
	TWC	0,564	0,762	+0,198
SAINT	TWS	0,639	0,787	+0,148
	TWM	0,969	0,995	+0,026
	TWC	0,588	0,802	+0,214
XGBoost	TWS	0,875	0,895	+0,020
	TWM	0,978	0,997	+0,019
	TWC	0,476	0,503	+0,027

Observações:

- **DualFISTA**, **LSSVM-ADMM** e agora **Nyström-SVM** apresentam eficiência amostral elevada: ganhos pequenos com $N = 2000$ (Nyström: +0,083 em TWC; nulo em TWM), pois o kernel RBF já captura bem a geometria com $N = 400$ quando o m/n está tunado.
- **FT-CUR** e **SAINT** são fortemente *data-hungry* (+0,13 a +0,21 em TWS/TWC) — ambos têm a mesma sensibilidade a N , confirmando que o ganho vem do regime de dados, não do mecanismo de compressão.
- **FT-Sparsemax** foi o FT-Transformer mais beneficiado: de 0,710 para 0,955 em TWC, superando os LSSVMs nesse dataset com $N = 2000$.

7 Ablação B: Robustez a Features de Ruído ($2D \rightarrow 5D$)

Motivação: Avaliar a sensibilidade à presença de dimensões irrelevantes, cenário comum em dados tabulares reais.

Configuração: Três features gaussianas de ruído ($\sigma_{\text{ruído}} = 1,0$) foram adicionadas às coordenadas x_1, x_2 originais ($N = 400$). Avaliou-se o cenário com σ **reajustado** (novo tuning para os dados em 5D).




Figura 4: F1-macro: 2D original (translúcido) vs. 5D com σ reajustado (sólido).

Tabela 8: Modelos propostos: F1-macro em 2D vs. 5D reajustado.

Modelo	Dataset	2D	5D reaj.	Δ
DualFISTA	TWS	0,994	0,648	−0,346
	TWM	1,000	0,962	−0,038
	TWC	0,891	0,559	−0,332
LSSVM-ADMM	TWS	0,992	0,632	−0,360
	TWM	0,992	0,920	−0,072
	TWC	0,866	0,549	−0,317
Nyström-SVM	TWS	0,992	0,560	−0,432
	TWM	1,000	0,966	−0,034
	TWC	0,858	0,529	−0,329
FT-CUR (Nyströmformer)	TWS	0,654	0,607	−0,047
	TWM	0,981	0,928	−0,053
	TWC	0,564	0,495	−0,069
SAINT	TWS	0,639	0,595	−0,044
	TWM	0,969	0,930	−0,039
	TWC	0,588	0,490	−0,098
XGBoost	TWS	0,875	0,927	+0,052
	TWM	0,978	0,982	+0,004
	TWC	0,476	0,772	+0,296

Análise mecânica: A adição de 3 features de ruído expande a distância euclidiana quadrática média em $\approx 3\sigma_{\text{ruído}}^2$, colapsando os valores do kernel RBF para próximo de zero e destruindo a estrutura da matriz kernel. O reajuste do σ (valores maiores) recupera parcialmente o sinal, mas não restitui a resolução espacial original em fronteiras de alta frequência.

Padrões observados:

- **DualFISTA, LSSVM-ADMM e Nyström-SVM** sofrem quedas severas em TWS e TWC (Δ de $-0,33$ a $-0,43$), pelo mesmo motivo estrutural: o kernel RBF não distingue features informativas de ruído. O Nyström, agora com base $> 0,85$ em 2D, tem queda proporcionalmente similar aos outros LSSVMs.

- **FT-CUR** e **SAINT** são notavelmente robustos ($\Delta \approx -0,04$ a $-0,10$): a atenção opera sobre representações aprendidas dos tokens, não sobre distâncias brutas entre amostras. Features irrelevantes têm impacto marginal porque o modelo aprende a ignorá-las. Esta é a vantagem estrutural mais clara dos Transformers tabulares sobre os métodos kernel neste cenário.
- **XGBoost** *melhora* com features extras ($\Delta = +0,05$ a $+0,30$): árvores aproveitam o sinal adicional. Em TWC vai de 0,476 (2D) para 0,772 (5D retunado) — o ganho mais expressivo do estudo. Confirma a complementaridade dos paradigmas: kernel para geometria pura, árvores para feature-rich tabular.

8 Ablação C: Dados Sintéticos Multifeature (MK5)

Motivação: Os datasets sintéticos anteriores (TWS/TWM/TWC) são bidimensionais, favorecendo o kernel RBF. O MK5 usa dados gerados por `make_classification` (scikit-learn) com 5 features verdadeiramente informativas em 3 níveis de dificuldade de separação.

Tabela 9: Ablação C (MK5) — F1-macro médio (30 sementes). MKE = fácil, MKM = médio, MKH = difícil. ★ = proposto. Spar.A = esparsidade amostral; Spar.At = esparsidade de atenção.

Modelo	MKE	MKM	MKH	Média	Spar.A	Spar.At
<i>Baseline geral tabular</i>						
XGBoost	0,978	0,820	0,690	0,829	—	—
<i>Baselines LSSVM</i>						
LSSVM-Std	0,987	0,859	0,729	0,859	0,0%	—
LSSVM-FSA	0,986	0,833	0,696	0,838	45,0%	—
LSSVM-IP	0,989	0,819	0,683	0,830	58,1%	—
LSSVM-PCP	0,973	0,827	0,683	0,828	0,0%	—
LSSVM-ADMM	0,986	0,825	0,685	0,832	9,6%	—
LSSVM-Prun	0,988	0,601	0,622	0,737	75,5%	—
LSSVM-OppM	0,888	0,632	0,523	0,681	78,0%	—
<i>Baselines FT-Transformer</i>						
FT-Softmax	0,976	0,797	0,669	0,814	—	0,2%
FT-Entmax	0,976	0,801	0,657	0,811	—	1,4%
FT-Sparsemax	0,975	0,787	0,652	0,805	—	39,1%
FT-TopK	0,975	0,768	0,644	0,796	—	76,8%
<i>Modelos propostos</i>						
DualFISTA★	0,987	0,858	0,726	0,857	21,4%	—
Nyström-SVM★	0,986	0,839	0,712	0,845	64,3%	—
FT-CUR★ (Nyströmformer)	0,967	0,797	0,664	0,809	—	78,2%
SAINT	0,971	0,782	0,668	0,807	—	0%




Figura 5: Ablação C — MK5: F1-macro por nível de dificuldade.

Destaques:

- **DualFISTA** (0,857) quase empata com o LSSVM-Std (0,859) com 21% de esparsidade — padrão consistente com o Tier 1.
- **Nyström-SVM** (0,845) supera todos os FT-Transformers neste cenário multifeature, com 64% de esparsidade: a aproximação Nyström é eficaz quando há features informativas distribuídas em dimensão maior que 2D.
- **SAINT** (0,807) e **FT-CUR** (0,809) ficam novamente empatados (diferença 0,002), confirmando que a compressão Nyströmformer no FT-CUR não custa F1 também em dados multifeature.

9 Análise das Variantes Investigadas e Modelos Propostos

9.1 Mecanismos de esparsidade

Tabela 10: Caracterização dos mecanismos de esparsidade dos modelos investigados e propostos. LSSVM-ADMM-Nesterov é o paper-base (Marinho et al.); demais são variantes ou aplicações propostas/investigadas.

Modelo	Mecanismo	Esparsidade
LSSVM-ADMM-Nesterov (Marinho et al.)	Otimização ADMM com penalidade ℓ_1 (primal); aceleração de Nesterov.	Emerge da otimização; heterogênea entre datasets. Média: 30%.
ADMM-ElasticNet ^o	Variante do paper-base com penalidade Elastic Net ($\ell_1 + \ell_2$); combinação não localizada em literatura.	Similar ao paper-base, ligeiramente mais homogênea. Média: 27%.
DualFISTA ^o	Formulação dual: $\min_{\alpha} \frac{1}{2} \alpha^\top \Omega \alpha - \mathbf{1}^\top \alpha + \lambda \ \alpha\ _1$, otimizado via FISTA. Não localizada na literatura nesta forma exata.	Mais uniforme que ADMM (dual bem condicionado). Média: 20%.
Nyström-SVM [*]	Aproximação Nyström com seleção <i>colnorm</i> (norma de coluna em vez de uniforme/leverage); predição honesta restrita aos m landmarks.	Controlada por m/n tunado por dataset; varia 50–92%. Média: 69%.
FT-CUR (Nyströmformer) [*]	Aplicação de Nyströmformer (Xiong et al. 2021) à atenção inter-instâncias do FT-Transformer com seleção <i>colnorm</i> .	Compressão inter-instâncias: $1 - m/n \approx 80\%$.

9.2 Desempenho consolidado

A Tabela 10 consolida os resultados dos modelos propostos nos quatro experimentos realizados.

Tabela 11: Modelos investigados / propostos e paper-base — F1-macro médio em todos os experimentos. Spar.A = esparsidade amostral (LSSVMs); Spar.At = compressão interinstâncias (FT-CUR/SAINT).

Modelo	Tier 1			Ablação A ($N=2k$)		Ablação B (5D)		MK5
	F1	Spar.A	Spar.At	F1	Δ	F1	Δ	
DualFISTA ^o	0,842	20%	—	0,979	+0,018	0,723	−0,239	0,857
LSSVM-ADMM (paper-base)	0,809	30%	—	0,977	+0,023	0,700	−0,253	0,832
ADMM-ElasticNet ^o	0,809	27%	—	—	—	—	—	—
Nyström-SVM*	0,834	69%	—	0,978	+0,144	0,685	−0,149	0,845
FT-CUR (Nyströmformer)*	0,747	—	79,3%	0,849	+0,102	0,677	−0,070	0,809
SAINT (baseline FT)	0,744	—	0%	0,862	+0,118	0,672	−0,072	0,807

9.3 Síntese comparativa

Tabela 12: Perfis dos modelos investigados e propostos.

Modelo	Ponto forte	Ponto fraco	Característica distintiva
DualFISTA ^o	F1 quase idêntico ao LSSVM-Std; convergência estável	Sensível a features de ruído (kernel RBF); esparsidade moderada (20%)	Formulação dual bem condicionada; melhor trade-off esparsidade/acurácia em baixa esparsidade
ADMM-ElasticNet ^o	Esparsidade mais uniforme que ADMM- ℓ_1 puro	F1 $\approx$ 3 pp abaixo do LSSVM-Std; ganho marginal sobre o paper-base	Variante do paper-base com ElasticNet (combinação não localizada em literatura)
Nyström-SVM*	F1 competitivo (0,834, a 0,008 do LSSVM-Std) com 69% de esparsidade; melhor trade-off em alta esparsidade	Sensível a features de ruído (kernel RBF); m/n ideal varia muito entre datasets (8–50%)	Único modelo com compressão de memória real: $O(nm)$ vs. $O(n^2)$; auditoria matemática confirma honestidade
FT-CUR (Nyströmformer)*	Robusto a features irrelevantes; beneficia-se de mais dados; compressão interinstâncias com Nyströmformer ($O(nmd)$)	Fraco em fronteiras não-lineares complexas (TWS, TWC); transductivo (requer X_{train} na inferência)	Aplicação do Nyströmformer a dados tabulares; comparado ao SAINT, valida empiricamente que 80% de compressão custa $\approx$ 0,003 de F1

10 Tier 2: Datasets Reais ($N_{\text{treino}} = 5000$) — Resultados Parciais

Esta seção apresenta resultados *parciais* do experimento Tier 2, que estende a comparação para seis datasets reais de larga escala (**ADULT**, **CREDIT**, **BANK**, **TELCO**, **SHOPPERS**, **HIGGS50K**) com subamostragem estratificada para $N_{\text{treino}} = 5000$ por seed. Dos 18 modelos planejados, **6 já completaram os 180 runs** cada (XGBoost, 4 FT-Transformer baselines e FT-CUR); os 12 restantes (LSSVMs baselines, ADMM family, Nyström-SVM, SAINT) estão em execução e serão incluídos no relatório final ($\sim 01/06/2026$).

10.1 Protocolo

- **Subamostragem por seed:** cada (modelo, dataset, seed) usa uma amostra estratificada de $N=7143$ amostras, determinística pela seed. O split 70/30 resulta em $N_{\text{treino}}=5000 + N_{\text{teste}}=2143$. Cada seed gera um subsample diferente, permitindo estimar variância amostral sobre N pequeno.
- **Tuning Optuna:** 20 trials $\times$ 3-fold CV sobre cada subsample, separado por (modelo, dataset). Cada um dos 18 modelos teve espaço de busca próprio.
- **30 seeds por (modelo, dataset),** F1-macro como métrica primária.

Tabela 13: Datasets Tier 2 com respectiva taxa de positivos.

ID	Nome	N original	% positivos	Domínio
ADULT	UCI Adult Income	45 222	24%	Renda
CREDIT	Default of Credit Card Clients	30 000	22%	Crédito
BANK	UCI Bank Marketing	45 211	11%	Marketing direto
TELCO	IBM Telco Customer Churn	7 032	27%	Churn
SHOPPERS	Online Shoppers Purchasing	12 330	15%	E-commerce
HIGGS50K	Higgs Boson (subset 50k)	50 000	53%	Física de partículas

10.2 Resultados parciais (6 de 18 modelos completos)

Tabela 14: F1-macro médio (30 sementes) por modelo e dataset. Em negrito o melhor por coluna entre os 6 modelos com dados completos. DP = desvio padrão agregado dos 180 runs.

Modelo	ADULT	CREDIT	BANK	TELCO	SHOPPERS	HIGGS50K	Média	DP
XGBoost	0,802	0,677	0,713	0,728	0,795	0,693	0,735	0,049
FT-Softmax	0,771	0,680	0,720	0,721	0,783	0,672	0,724	0,045
FT-Entmax	0,770	0,682	0,718	0,722	0,781	0,667	0,723	0,045
FT-Sparsemax	0,771	0,677	0,712	0,722	0,782	0,673	0,723	0,046
FT-TopK	0,769	0,677	0,705	0,719	0,783	0,667	0,720	0,046
FT-CUR* (Nyströmformer)	0,770	0,444	0,548	0,714	0,751	0,648	0,646	0,129

Observações por dataset:

- **ADULT** (24% pos.): XGBoost lidera (0,802); FT-Transformers equivalentes entre si (0,77), incluindo FT-CUR.
- **CREDIT** (22%): empate técnico entre FT-Entmax (0,682) e XGBoost (0,677). **FT-CUR colapsa para 0,444.**
- **BANK** (11%): XGBoost lidera (0,713); FT-Transformers no intervalo 0,705–0,720. **FT-CUR cai para 0,548.**
- **TELCO** (27%): XGBoost (0,728); FT-CUR competitivo (0,714).
- **SHOPPERS** (15%): XGBoost lidera (0,795); FT-CUR baixa para 0,751.
- **HIGGS50K** (53%, balanceado): XGBoost (0,693); FT-CUR a 0,648, na faixa dos FT baselines.

10.3 Limitação estrutural do FT-CUR em dados imbalanceados

A queda do FT-CUR em CREDIT, BANK e SHOPPERS é o achado mais expressivo dos resultados parciais. A Tabela 14 mostra o gap em função da taxa de positivos:

Tabela 15: Gap FT-CUR vs. FT-Softmax (baseline denso inter-features) por taxa de positivos. Acima de $\sim 24\%$: equivalência; abaixo: colapso.

Dataset	% positivos	FT-Softmax	FT-CUR	Δ
HIGGS50K	53%	0,672	0,648	−0,024
TELCO	27%	0,721	0,714	−0,007
ADULT	24%	0,771	0,770	−0,001
CREDIT	22%	0,680	0,444	−0,236
SHOPPERS	15%	0,783	0,751	−0,032
BANK	11%	0,720	0,548	−0,172

Padrão observado: acima de 24% de positivos, FT-CUR mantém desempenho equivalente aos baselines densos (diferença $\leq 0,024$). Abaixo desse limiar, há colapso significativo, com perda de até 0,24 em F1.

Diagnóstico do colapso

A análise dos valores absolutos do F1-macro do FT-CUR em CREDIT (0,444) e BANK (0,548) sugere predição quase exclusivamente da classe majoritária. Para CREDIT (22% positivos):

$$F_1^{\text{maj, CREDIT}} = \frac{1}{2} \left(F_1^{(+)} + F_1^{(-)} \right) = \frac{1}{2} \left(0 + \frac{2 \cdot 0,78 \cdot 1}{0,78 + 1} \right) \approx 0,44,$$

valor virtualmente idêntico ao observado (0,444).

Hipótese causal

A aproximação CUR seleciona m landmarks por **norma de coluna** (*colnorm*), critério *geométrico* que não considera a estrutura de classes. Em datasets imbalanceados, a classe minoritária — por definição sub-representada — também tende a ser sub-representada no conjunto de landmarks, comprometendo a fidelidade da atenção comprimida na fronteira de decisão entre as classes.

Essa hipótese será verificada quando os resultados completos de SAINT (atenção *inter-instâncias* densa, sem aproximação CUR) ficarem disponíveis. Resultados preliminares do tuning do SAINT já sugerem o padrão: F1 CV 0,524 em CREDIT vs. 0,446 do FT-CUR. Caso SAINT mantenha desempenho similar aos FT baselines em CREDIT/BANK, confirma-se que o colapso é estrutural à aproximação CUR + colnorm em dados imbalanceados, não à atenção inter-instâncias em si.

Uma hipótese metodológica adicional surgiu da inspeção dos logs de treino. Na implementação atual, **FT-CUR** e **SAINT** usam *early stopping* por `val_acc`, enquanto os FT-Transformer baselines usam `val_loss`. Em datasets desbalanceados, `val_acc` pode favorecer checkpoints que acertam majoritariamente a classe dominante, mas ainda são ruins em F1-macro. Isso fornece uma explicação alternativa, ou complementar, para o colapso observado em **CREDIT** e **BANK**: parte da queda pode decorrer do critério de seleção do checkpoint, e não apenas da seleção *colnorm* de landmarks.

Suporte experimental adicionado. O parâmetro `early_stop_metric` foi implementado em `fit_model`, com três opções: `val_acc` (default original), `val_loss` e `val_f1_macro` (alinhado à métrica primária do estudo). O script `scripts/run_early_stop_ablation.py` executa o rerun focal de FT-CUR e SAINT em CREDIT e BANK retunando *independentemente* cada combinação (modelo, dataset, `early_stop_metric`) via Optuna — isto evita o viés de comparar params otimizados para `val_acc` contra treino com `val_loss`.

Correção metodológica capturada em *code review* (29/05/2026). A versão original do `fit_model` usava o critério `landmark_idx is None` para decidir se passava o contexto completo $[X_{\text{train}} || X_{\text{val}}]$ ao modelo. Isto era *correto* para o FT-CUR (que tem `landmark_idx` definido) mas *quebrava o SAINT*, que tem atenção inter-instâncias *densa* (sem `landmark_idx`, mas que requer o contexto completo na validação, exatamente como na inferência final). A correção atualizada usa a flag arquitetural `model.use_inter_instance` (a mesma lógica do `eval_with_context`), garantindo simetria entre FT-CUR e SAINT na ablação H2.

Tabela de hipóteses testáveis

Tabela 16: Três hipóteses sobre o colapso do FT-CUR em CREDIT/BANK e como testar cada uma. Cada experimento isola uma causa específica.

Hipótese	Causa proposta	Teste experimental
H1: imbalanceamento	Seleção colnorm de landmarks é geométrica; minoria sub-representada nos m landmarks	Tier 2 balanceado: treina com undersampling da maioria <i>só no treino</i> (após split), preservando o teste original para comparabilidade direta com o Tier 2 imbalanceado. Script: <code>run_tier2_balanced.py</code> (<code>-balance-train</code> no runner)
H2: critério de early stopping	<code>val_acc</code> favorece classe majoritária; o checkpoint escolhido tem F1-macro baixo mesmo em datasets onde o modelo aprende bem	Rerun focal com <code>val_loss</code> e <code>val_f1_macro</code> ; mesmos dados, com retuning independente por métrica para comparação justa. Script: <code>run_early_stop_ablation.py</code>
H3: limitação fundamental do CUR	Compressão de baixo posto é incompatível com fronteiras de decisão complexas em datasets imbalanceados, independentemente de seleção e critério de checkpoint	Confirmação <i>por exclusão</i> : se H1 e H2 falharem em explicar, H3 é a explicação remanescente

Resultado da ablação H2: `val_loss` corrige o colapso

O experimento focal da H2 foi concluído integralmente: 360 runs (2 modelos $\times$ 2 datasets $\times$ 3 métricas $\times$ 30 seeds), todos bem-sucedidos. A Tabela 16 resume o F1-macro médio dos reruns em CREDIT e BANK, comparando o critério original `val_acc` com `val_loss` e `val_f1_macro`. Para referência, a última coluna mostra o melhor FT baseline da Tabela 13.

Tabela 17: Ablação H2: efeito do critério de early stopping em FT-CUR e SAINT nos datasets desbalanceados CREDIT e BANK (30 seeds).

Modelo	Dataset	<code>val_acc</code>	<code>val_loss</code>	<code>val_f1</code>	$\Delta(\text{loss-acc})$	Melhor FT baseline
FT-CUR	CREDIT	0,438	0,657	0,610	+0,219	0,682 (FT-Entmax)
FT-CUR	BANK	0,507	0,714	0,473	+0,207	0,720 (FT-Softmax)
SAINT	CREDIT	0,439	0,684	0,467	+0,245	0,682 (FT-Entmax)
SAINT	BANK	0,473	0,710	0,498	+0,237	0,720 (FT-Softmax)

Leitura direta do resultado:

- **val_loss** foi superior em todos os quatro cenários. Os ganhos sobre **val_acc** ficaram entre +0,207 e +0,245 em F1-macro médio, magnitude grande demais para ser atribuída a ruído experimental.
- Em **BANK**, a troca para **val_loss** elimina o “colapso” dos modelos inter-instâncias: **FT-CUR** sobe para 0,714 e **SAINT** para 0,710, ambos *dentro da faixa* dos FT baselines (0,705–0,720). Nesse dataset, os modelos ficam essencialmente **equilibrados**.
- Em **CREDIT**, a correção metodológica também é decisiva: **SAINT** com **val_loss** atinge 0,684, ligeiramente acima do melhor FT baseline (0,682, FT-Entmax), enquanto **FT-CUR** sobe para 0,657 — ainda abaixo dos baselines, mas muito distante do artefato anterior de 0,444.
- **val_f1_macro** não foi a melhor escolha prática neste experimento: embora melhore CREDIT, ela perde para **val_loss** em todos os cenários e degrada fortemente o FT-CUR em BANK.

Conclusão revisada da H2. O uso de **val_acc** como critério de early stopping era, de fato, um **erro metodológico relevante** no protocolo anterior para FT-CUR e SAINT em dados desbalanceados. Em BANK, esse erro praticamente explica sozinho o comportamento anômalo observado. Em CREDIT, ele explica **grande parte** do problema, mas não tudo: SAINT se alinha aos baselines com **val_loss**, enquanto FT-CUR ainda permanece alguns pontos abaixo. Assim, após a correção metodológica, a hipótese H3 (“limitação fundamental do CUR”) fica **enfraquecida**, mas não totalmente descartada em CREDIT.

Validação estatística (Wilcoxon pareado, H_a : **val_loss > **val_acc**):**

- FT-CUR/CREDIT: $p = 1,3 \times 10^{-6}$;
- FT-CUR/BANK: $p = 1,9 \times 10^{-9}$;
- SAINT/CREDIT: $p = 9,3 \times 10^{-10}$;
- SAINT/BANK: $p = 9,3 \times 10^{-10}$.

Todos os p -valores são muito inferiores a 0,001 — a superioridade de **val_loss** não é ruído experimental. Adicionalmente, observa-se que **val_acc** produz desvios padrão minúsculos (0,001–0,012) em CREDIT, evidência forte de que o modelo converge para o mesmo classificador trivial (classe majoritária) em todas as 30 sementes.

Rerun completo do Tier 2 com **val_loss**

O rerun completo foi concluído para **FT-CUR** e **SAINT** em todos os 6 datasets do Tier 2 com o protocolo corrigido: mesmo cap $N_{\text{total}} = 7143$, mesmo número de seeds (30), mesmo tuning Optuna (20 trials $\times$ 3-fold CV), alterando apenas o critério de early stopping de **val_acc** para **val_loss**. A Tabela ?? resume os resultados.

Tabela 18: Tier 2 $N = 5000$ revalidado para FT-CUR e SAINT com `early_stop_metric = val_loss`. Para FT-CUR, inclui-se também o resultado histórico com `val_acc` para quantificar a correção.

Modelo	ADULT	CREDIT	BANK	TELCO	SHOPPERS	HIGGS50K
FT-CUR (<code>val_acc</code> , histórico)	0,770	0,444	0,548	0,714	0,751	0,722
FT-CUR (<code>val_loss</code>)	0,774	0,683	0,695	0,724	0,763	0,722
SAINT (<code>val_loss</code>)	0,752	0,684	0,719	0,724	0,786	0,722

Comparação com os FT baselines do Tier 2 parcial:

- **CREDIT**: o rerun corrige substancialmente os dois modelos. **FT-CUR** sobe de 0,444 para 0,683, empatando na prática com o melhor FT baseline (0,682, FT-Entmax). **SAINT** atinge 0,684, ligeiramente acima do melhor baseline.
- **BANK**: **SAINT** fica essencialmente empatado com o bloco FT baseline (0,705–0,720), chegando a 0,719. O **FT-CUR** melhora fortemente (0,548 $\rightarrow$ 0,695), mas ainda permanece um degrau abaixo da faixa dos melhores FT baselines.
- **ADULT** e **TELCO**: **FT-CUR** revalidado com `val_loss` fica competitivo com os FT baselines; em TELCO, FT-CUR (0,724) e SAINT (0,724) igualam ou superam marginalmente as variantes feature-level.
- **SHOPPERS** e **HIGGS50K**: os FT baselines continuam superiores ao FT-CUR; em SHOPPERS, entretanto, o **SAINT** (0,786) alcança e ligeiramente supera o melhor baseline (0,783).

Síntese revisada. A correção metodológica via `val_loss` **não apenas explica o colapso artificial em CREDIT**, como reposiciona FT-CUR e SAINT no Tier 2:

- **SAINT** passa a integrar o mesmo patamar médio dos FT baselines (média 0,722 vs. 0,720–0,724), o que enfraquece a ideia de limitação estrutural da atenção inter-instâncias em si;
- **FT-CUR** melhora de 0,646 para 0,713 na média, removendo a maior parte do artefato metodológico, mas ainda ficando ligeiramente abaixo do bloco FT baseline agregado;
- a hipótese H3 (“limitação fundamental do CUR”) deixa de ser uma explicação geral para o colapso e passa a ser, no máximo, uma hipótese residual localizada em datasets específicos como BANK, SHOPPERS e HIGGS50K.

Implicações para a dissertação

Este achado representa uma contribuição analítica importante: identifica uma fronteira de aplicabilidade do FT-CUR, com hipótese causal testável e propostas concretas de trabalho futuro:

- **Landmark selection estratificada por classe** (garantir proporção mínima de cada classe entre os m landmarks);

- **Atualização do protocolo experimental:** para FT-CUR e SAINT em datasets desbalanceados, o critério de early stopping deve ser `val_loss`, não `val_acc`;
- **Class-weighted loss** (pesos inversos à frequência de classes na função de custo);
- **Métricas alternativas** (F1-weighted, Average Precision) para complementar a análise em dados imbalanceados.

10.4 Comparação Tier 1 vs. Tier 2: deslocamento do trade-off (*rascunho — pendente confirmação*)

RASCUNHO — aguardando experimentos restantes

Esta subseção é **provisória**. Dependem do término dos experimentos para confirmação:

- **DualFISTA Tier 2:** pode replicar o padrão Tier 1 (empate com LSSVM-Std com 20% esparsidade);
- **SAINT Tier 2:** hipótese central da Seção 10.3 é que SAINT *não* colapsa em CREDIT/BANK (atenção inter-instâncias densa, sem CUR + colnorm);
- **ADMM-Nesterov / ElasticNet Tier 2:** paper-base e variante.

A redação final deverá ser revisada com os números completos.

Tabela comparativa — queda de F1 do Tier 1 para o Tier 2

Tabela 19: F1-macro médio: Tier 1 (sintéticos + pequenos reais, $N \in [400, 1584]$) vs. Tier 2 ($N_{\text{treino}} = 5000$ sobre datasets reais grandes). Δ negativo = perda ao migrar para o cenário realista.

Modelo	Tier 1	Tier 2	Δ	Família
LSSVM-Std	0,842	0,709	-0,133	kernel denso
Nyström-SVM*	0,834	0,707	-0,127	kernel esperso (81% esp.)
FT-Sparsemax	0,774	0,723	-0,051	atenção feature esparsa
XGBoost	0,776	0,735	-0,041	gradient boosting
FT-Entmax	0,742	0,723	-0,019	atenção feature esparsa
FT-Softmax	0,740	0,724	-0,016	atenção feature densa
FT-CUR* (Nyströmformer)	0,747	0,646	-0,101	atenção inter-inst. comprimida

Observações empíricas

1. **LSSVMs (kernel) sofrem o maior deslocamento:** -0,13 em F1 ao migrar para o cenário realista. O kernel RBF, ótimo em geometria sintética limpa e datasets pequenos cuidados, perde eficácia em dados reais com features categóricas codificadas, redundância e ruído estrutural.

2. **FT-Transformer baselines (sem CUR) absorvem a mudança:** FT-Softmax cai apenas $-0,016$, FT-Entmax $-0,019$. Isso é consistente com a Seção ?? (Ablação B), onde os Transformers já demonstraram robustez a features de ruído ($\Delta < 0,10$ vs. $-0,35$ dos kernels).
3. **XGBoost lidera em ambos os cenários grandes** (Tier 2: $0,735$), confirmando a literatura de *tabular learning*.
4. **Variantes esparsas de atenção feature-level (TopK, Entmax, Sparsemax) convergem para o mesmo patamar** do Softmax denso (intervalo $0,720-0,724$, $\Delta \leq 0,005$): a esparsidade na atenção *inter-features* não traz vantagem em datasets reais.
5. **FT-CUR é a anomalia:** cai $-0,10$, mais que o Softmax denso ($-0,016$) mas concentrada em 3 datasets imbalanceados (CREDIT, BANK, SHOPPERS). Mostra que *a robustez do paradigma Transformer não se preserva automaticamente quando se aplica compressão CUR à atenção inter-instâncias sem estratificação por classe*. Achado contraintuitivo importante.

Interpretação preliminar

A migração Tier 1 $\rightarrow$ Tier 2 **reordena** a hierarquia entre paradigmas: em datasets sintéticos pequenos com fronteiras geométricas, kernels dominam ($+0,10$ vs. Transformers); em datasets reais grandes, Transformers atingem o patamar do gradient boosting, enquanto kernels (LSSVM-Std e Nyström-SVM) perdem $\approx 0,13$ em F1.

A vantagem do Transformer é diretamente proporcional à complexidade de features e ao ruído estrutural dos dados — não à escolha de função de ativação da atenção. Isto sugere que **o ganho real do paradigma vem do mecanismo de aprendizado de representações, não da estrutura esparsa da atenção feature-level**.

Pendências para confirmação

- **Nyström-SVM** mantém o padrão "esparsidade sem custo": Δ vs. LSSVM-Std é de $-0,002$ no Tier 2 (irrelevante), confirmando o achado central da Seção 3 também em dados reais.
- **DualFISTA** ainda não rodado em Tier 2 — se replicar o empate Tier 1 com LSSVM-Std ($\Delta \leq 0,001$), confirma a generalização do método dual em $N_{\text{treino}} = 5000$.
- **SAINT** ainda não rodado — hipótese: *não* colapsará em datasets imbalanceados (como o FT-CUR), pois usa atenção inter-instâncias densa. Se confirmado, isola a causa do colapso do FT-CUR à seleção colnorm de landmarks. Um rerun focal em CREDIT/BANK com *early stopping* por `val_loss` ou `val_f1_macro` também é prioritário para separar efeito de arquitetura de efeito do critério de checkpoint.
- **ADMM-Nesterov** (paper-base) e **ADMM-ElasticNet** (variante) ainda em tuning.

10.5 XGBoost vs. FT-Transformers em datasets reais

XGBoost lidera em 5 dos 6 datasets, com vantagem expressiva em ADULT ($+0,031$ sobre FT-Softmax), TELCO ($+0,007$) e HIGGS50K ($+0,021$). Em CREDIT, FT-Entmax

marginalmente supera (+0,005). A média agregada coloca XGBoost a +0,011 sobre o melhor FT-Transformer.

As 4 variantes esparsas de FT-Transformer (Softmax, TopK, Entmax, Sparsemax) ficam todas dentro de 0,005 entre si — esparsidade de atenção inter-features não traz vantagem mensurável em datasets reais desta escala. Achado consistente com o Tier 1 sintético, onde sparsemax foi 0,774 vs. softmax 0,740 (diferença +0,034 apenas em ablação de ruído).

11 Sumário e Próximos Passos

Tabela 20: Síntese dos experimentos realizados.

Experimento	Configuração	Runs	Resultado principal
Tier 1	18 modelos, 9 datasets, 30 seeds	4860	DualFISTA 0,842 / Nyström 0,834 / XGBoost 0,776
Ablação A (escala)	18 modelos, 3 sintéticos, $N=2000$, 30s	1620	Nyström +0,14; FT-CUR/SAINT data-hungry
Ablação B (ruído)	18 modelos, 3 sintéticos, +3 feat. ruído, 30s	1620	XGBoost +0,30 em TWC; FT-CUR/SAINT robustos
Ablação C (MK5)	18 modelos, 3 sintéticos, 30 seeds	1620	Nyström 0,845 > XGBoost 0,829 > FT-CUR 0,809
Total		9720	
Tier 2 parcial (Seção 10)	6/18 modelos, 6 datasets, $N=5000$, 30s	1080	XGBoost lidera (0,735); FT-CUR colapsa em datasets imbalanceados
Tier 2 (em andamento)	restante: 12 modelos	2160	LSSVMs, ADMM family, Nyström, SAINT — conclusão ~01/06/2026

Conclusões preliminares:

1. **DualFISTA** é o resultado mais significativo em baixa esparsidade: F1 quase idêntico ao LSSVM-Std completo ($\Delta = 0,0006$) com 20% de esparsidade.
2. **Nyström-SVM** (após auditoria matemática) é o melhor entre os modelos com alta esparsidade: 0,834 no Tier 1 com 69% de esparsidade, a 0,008 do LSSVM-Std. Combina compressão de memória real ($O(nm)$ vs. $O(n^2)$) com F1 competitivo.
3. A **compressão Nyströmformer no FT-CUR é validada pelo SAINT**: os dois modelos atingem F1 idêntico em todos os 4 experimentos ($\Delta \leq 0,013$), mas o FT-CUR opera com 79% de compressão inter-instâncias. Comprimir não custou F1 — a aproximação é fiel.
4. **Robustez a ruído**: FT-CUR e SAINT mantêm desempenho na ablação de features irrelevantes ($\Delta \approx -0,07$); LSSVMs/Nyström/ DualFISTA caem $-0,24$ a $-0,43$. A atenção é estruturalmente mais robusta que o kernel RBF a features ruidosas.
5. **XGBoost como referência externa**: o baseline geral tabular fica em 0,776 no Tier 1, abaixo do top 5 dos LSSVMs e do DualFISTA/Nyström. Em ablações com features extras (5D retunado: 0,894), XGBoost se beneficia mais que kernel/atenção. Resultado coerente com a literatura de *tabular learning*: kernel domina em geometria pura; gradient boosting em datasets feature-rich; atenção é robusta a ruído.

6. **Tier 2 (parcial) revela limitação do FT-CUR em dados imbalanceados:** nos seis datasets reais com $N_{\text{treino}} = 5000$, XGBoost lidera (0,735), seguido dos quatro FT-Transformer baselines empatados (0,720–0,724). O **FT-CUR cai para** 0,646 — $-0,079$ vs. FT-Softmax — com colapso especificamente em CREDIT (22% positivos), BANK (11%) e SHOPPERS (15%). Hipótese verificável: seleção colnorm não-estratificada sub-representa a classe minoritária nos landmarks (Seção 10.3).

Próximas etapas:

1. **Tier 2 $N_{\text{treino}} = 5000$ — 12 modelos restantes:** execução local em andamento dos 7 LSSVMs baselines, paper-base LSSVM-ADMM, variantes (ADMM-EN), Nyström-SVM, DualFISTA e SAINT. Conclusão esperada $\sim 01/06/2026$.
2. **Tier 2 *full-data*:** benchmarks com N completo em Colab T4 GPU, restrito a modelos escaláveis (XGBoost, Nyström-SVM, 4 FT baselines, FT-CUR). Os demais (LSSVMs com K denso e SAINT com atenção $n \times n$) excedem capacidade de memória para $N \gg 10k$.
3. **Análise estatística formal:** teste de Friedman + Nemenyi / diagrama de diferença crítica sobre todos os datasets consolidados (Tier 1 + 3 ablações + Tier 2).
4. **Análise de complexidade temporal:** medição empírica do speedup do Nyström-SVM vs. LSSVM-Std em função de n , usando os dados de tempo coletados nas execuções Tier 2.
5. **Benchmark de eficiência computacional — DualFISTA vs. família ADMM (paper-base e variantes):** observação preliminar do Tier 2 sugere que o tuning do ADMM-Nesterov requer $\sim 5\text{--}9\text{h}$ por dataset (frequentemente atingindo `max_iter = 5000` sem convergência, `converged = False`), enquanto DualFISTA tuna em $\sim 30\text{--}60$ min por dataset (**ordem de magnitude mais rápido**). Hipótese a verificar: o ADMM-ElasticNet ($\ell_1 + \ell_2$) deve convergir mais rápido que o ADMM- ℓ_1 puro, devido à **fortemente convexa** introduzida pela penalidade ℓ_2 (Tikhonov), que melhora o condicionamento do subproblema primal a cada iteração. Estudo formal proposto:
 - Coletar dados de tempo por iteração e número de iterações até convergência (já gravados em `train_time_s`) para todos os 4 métodos com ℓ_1 : ADMM-Nesterov, ADMM-ElasticNet, FISTA-Nesterov, DualFISTA;
 - Plotar curva de convergência (loss vs. iteração) e wall-clock time vs. qualidade de solução;
 - Reportar como uma das **contribuições centrais** da dissertação: o DualFISTA não apenas atinge esparsidade comparável ao paper-base (Marinho et al.), mas o faz com eficiência computacional 1–2 ordens de magnitude superior.

A Infraestrutura e Reprodutibilidade

- **Código:** repositório `sparse-lssvm-transformers-study/`
- **Ambiente:** Python 3.12, PyTorch, scikit-learn, Optuna; virtualenv em `.venv/`

- **Resultados:** arquivos JSON em `results/`: `tier1_results.json` (baselines), `tier1_custom_models.json` (propostos), `synthetic_scaling_n2000.json`, `synthetic_5features_tuned.json`, `synthetic_mk5.json`
- **Tuning:** `results/tuning/best_params*.json`
- **Scripts:** `scripts/run_*.py` são resumíveis (checkpoint por chave `model/dataset/seed`)
- **Figuras:** geradas por `scripts/generate_report_figs.py`