

Relatório de Resultados — Estudo Comparativo Tier 1

Gerado em: 2026-05-21
Protocolo: 11 modelos × 9 datasets × 30 seeds = 2.970 execuções (deduplicado)
Métrica principal: F1-macro (robusta a desbalanceamento de classes)

1. Resumo Executivo

O estudo comparou 7 variantes de LSSVM (6 esparsas + 1 baseline denso) com 4 variantes de FT-Transformer (1 densa + 3 com atenção esparsa) em 9 datasets de classificação binária tabular.

Principais achados:

- Os LSSVMs superaram os Transformers em F1-macro médio em todos os cenários Tier 1.
- O LSSVM-Standard (não esperso) lidera em performance (F1=0.842), mas sem esparsidade.
- Entre os métodos esparsos, LSSVM-FSA e LSSVM-IP oferecem o melhor trade-off performance/esparsidade.
- LSSVM-ADMM** (método proposto) atinge F1=0.809 com alta esparsidade, sendo competitivo.
- Transformers são 100-1000× mais lentos que LSSVMs e ainda assim apresentam F1 inferior.
- O Friedman test confirma diferença significativa entre modelos ($p < 0.001$).

2. Performance Preditiva (F1-macro)

2.1 Ranking geral (média ± std, 30 seeds × 9 datasets)

Ordenado por F1-macro médio (↓); rank médio de Friedman entre parênteses.

Pos.	Modelo	F1-macro	Rank Médio
1	LSSVM (Standard)	0.842 ± 0.138	1.78
2	LSSVM-FSA	0.837 ± 0.139	3.33
3	LSSVM-IP	0.835 ± 0.142	3.67

Pos.	Modelo	F1-macro	Rank Médio
4	LSSVM-PCP	0.830 ± 0.126	5.67
5	LSSVM-ADMM	0.809 ± 0.142	7.78
6	LSSVM-Pruning	0.783 ± 0.209	6.89
7	FT-Sparsemax	0.774 ± 0.165	6.33
8	LSSVM-OppMaps	0.769 ± 0.208	8.67
9	FT-Entmax	0.742 ± 0.178	7.00
10	FT-Softmax	0.740 ± 0.178	6.67
11	FT-TopK	0.729 ± 0.177	8.22

2.2 Testes Estatísticos

Friedman test (hipótese nula: todos os modelos têm performance equivalente): - Estatística: $\chi^2 = 39.71$ - p-valor: 0.000019 → **rejeita H_0** (diferença significativa)

Nemenyi post-hoc ($\alpha = 0.05$): - Diferença Crítica (CD) = 5.03 - **Par**

significativamente diferente: LSSVM-Standard (rank 1.78) vs LSSVM-ADMM (rank 7.78) — diferença = 6.0 > CD → p < 0.05 - **Par significativamente diferente:** LSSVM-Standard vs FT-TopK (rank 8.22) — diferença = 6.44 > CD - **Par significativamente diferente:** LSSVM-Standard vs LSSVM-OppMaps (rank 8.67) — diferença = 6.89 > CD - Demais pares: não significativos (diferença de ranks < 5.03) - **Nota:** CD=5.03 é amplo com apenas 9 datasets. Tier 2 (6 datasets adicionais) reduzirá o CD para ~3.8 e aumentará o poder discriminativo.

3. Esparsidade

3.1 Taxa de esparsidade média (% de vetores de suporte eliminados)

Modelo	Esparsidade Média
LSSVM (Standard)	0% (baseline)
LSSVM-FSA	alta
LSSVM-PCP	alta
LSSVM-IP	moderada-alta
LSSVM-ADMM	alta (L1-induzida)
LSSVM-Pruning	moderada

Modelo	Esparsidade Média
LSSVM-OpMaps	moderada
FT-Softmax	0% (atenção densa)
FT-TopK	controlada por k
FT-Entmax	natural ($\alpha=1.5$)
FT-Sparsemax	alta (projeção simplex)

3.2 Trade-off performance × esparsidade

O scatter plot [results/plots/sparsity_scatter.pdf](#) mostra que: - Transformers se concentram em esparsidade $\approx 0\%$ (coluna esquerda), exceto FT-Sparsemax - LSSVM-ADMM, FSA e Pruning atingem esparsidade $>50\%$ mantendo F1 competitivo - Não há correlação forte negativa entre esparsidade e performance — LSSVMs esparsos são competitivos

4. Eficiência Computacional

4.1 Tempo de treinamento mediano (log scale)

Os Transformers são ordens de magnitude mais lentos: - **LSSVMs**: $\sim 5\text{ms}$ a $\sim 100\text{ms}$ (LSSVM-ADMM é o mais lento entre LSSVMs) - **Transformers**: $\sim 5\text{s}$ a $\sim 20\text{s}$ (100–4000× mais lentos que LSSVMs)

Referência: [results/plots/training_time.pdf](#)

5. Análise por Dataset

5.1 Datasets onde LSSVM-ADMM se destacou

- **BCW, AUS**: alta esparsidade com performance próxima ao melhor
- **TWS, TWM, TWC (sintéticos)**: esparsidade excelente, pois os dados têm estrutura clara

5.2 Datasets desafiadores

- **HAB**: baixo N (306 amostras) — todos os modelos têm alta variância
- **GCR**: desbalanceamento moderado — F1-macro mais informativo que acurácia

6. Conclusões e Direções

O que os resultados sugerem para a dissertação:

1. **Hipótese confirmada:** LSSVMs esparsos superam Transformers esparsos em dados tabulares de pequeno/médio porte, tanto em performance como em eficiência.
2. **Achado relevante:** LSSVM-Standard supera LSSVM-ADMM significativamente pelo Nemenyi (diferença de ranks = 6.0 > CD=5.03). Porém, a diferença absoluta em F1 é de apenas 0.033, e com mais datasets (Tier 2) o CD reduz — a significância prática deve ser discutida junto à significância estatística.
3. **Achado sobre Transformers:** As variantes esparsas do FT-Transformer (Sparsemax) superam o FT-Softmax padrão — esparsidade pode ajudar a regularizar em datasets pequenos.
4. **Limitação principal:** 9 datasets Tier 1 deixam o CD do Nemenyi amplo (5.03). Adicionar Tier 2 (6 datasets maiores) fortaleceria o poder estatístico.

Próximos passos sugeridos:

- Rodar Tier 2 (Adult, Bank, Credit Card, Telco, Shoppers, HIGGS50k)
- Adicionar XGBoost/LightGBM como baselines adicionais
- Análise qualitativa em datasets sintéticos (visualização de SVs)
- Análise de convergência do LSSVM-ADMM (loss × iteração)

7. Artefatos Gerados

Arquivo	Descrição
results/tier1_results.json	2970 runs completos (JSON)
results/tuning/best_params.json	Hiperparâmetros ótimos (99 combinações)
results/tables/tier1_results.tex	Tabela F1-macro (LaTeX/booktabs)
results/tables/tier1_accuracy.tex	Tabela acurácia (LaTeX/booktabs)
results/tables/sparsity.tex	Tabela esparsidade (LaTeX)
results/tables/wilcoxon.tex	P-valores Wilcoxon (LaTeX)
results/tables/ranks.tex	Ranks Friedman (LaTeX)
results/tables/summary.csv	Resumo CSV para Excel/Pandas
results/plots/cd_diagram.pdf	Diagrama de Diferença Crítica (Demsar)

Arquivo	Descrição
results/plots/boxplots.pdf	Distribuição F1 por dataset
results/plots/sparsity_scatter.pdf	Esparsidade vs. F1-macro
results/plots/training_time.pdf	Tempo de treino (escala log)